中图分类号：XXX　　单位代号：10280
密　　级：公开　　学　　号：23722063

上海大学

专业硕士学位论文

SHANGHAI UNIVERSITY PROFESSIONAL MASTER'S DISSERTATION

题目	基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者　邱模聪
学科专业　机械
导　　师　袁建军
完成日期　二〇二六年五月

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学

本论文经答辩委员会全体委员审查，确认符合上海大学专业硕士学位论文质量要求。

答辩委员会签名:

主　　席:

委　　员:

导　　师:

答辩日期:　　年　　月　　日

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学学位论文原创性声明

本人郑重声明: 所呈交的学位论文是本人在导师指导下，独立进行研究工作所取得的成果。除了文中特别加以标注和致谢的内容外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他研究者对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名:

日期:　　年　　月　　日

上海大学学位论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定，即: 学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

(保密的论文在解密后应遵守此规定)

学位论文作者签名:　　导师签名:

日期:　　年　　月　　日　　日期:　　年　　月　　日

上海大学工学专业硕士学位论文

基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者: 邱模聪
导　　师: 袁建军
学科专业: 机械

机电工程与自动化学院
上海大学
2026 年 5 月

A Dissertation Submitted to Shanghai University for the
Degree of Professional Master in Engineering

Learning-Based Point Cloud Geometric Feature Detection and Robotic Grasp Planning

Candidate: Mocong Qiu
Supervisor: Jianjun Yuan
Major: Mechanics

School of Mechatronic Engineering and Automation
Shanghai University
December, 2026

摘　要

针对点云几何特征检测精度不足及机器人抓取规划灵活性受限的问题，本文提出一种融合神经网络特征学习与基于模型抓取规划的框架。首先，提出神经边缘角点检测网络（NECDNet）。该网络通过分析多尺度邻域内的位置和法向分布构建特征矩阵，利用层次化神经网络实现面、边、角点的同步分类；同时构建了包含 1000 个模型的 ABC-Corner 数据集。其次，本文提出一种考虑边、角接触的六自由度双指抓取规划算法。该算法利用 NECDNet 提取特征区域，设计特征化接触检测器搜索对偶接触点，并引入软接触模型评估稳定性，有效解决了非规则物体的抓取难题，增强抓取规划多样性。实验表明，NECDNet 的角点检测 F1 分数达 0.815，优于现有方法；抓取算法在分布复杂度指标（STD、Range、MAD）均优于 GPD，GraspIt 等基于模型的抓取规划方法，抓取配置灵活性显著提升。机器人实验验证了包括角-角、角-边等六种接触组合的有效性与鲁棒性，展示了抓取规划的有效性及抓取成功率上的提升。

关键词：点云处理；几何特征检测；神经网络；机器人；抓取规划；平行手爪

ABSTRACT

This thesis addresses the challenges of insufficient geometric feature detection accuracy in point clouds and limited flexibility in robotic grasp planning by proposing a unified framework that integrates neural network-based feature learning with model-based grasp planning. First, we introduce the Neural Edge and Corner Detection Network (NECDNet), which constructs a feature matrix by analyzing the positional and normal distributions within multi-scale neighborhoods and employs a hierarchical neural network to simultaneously classify faces, edges, and corners. Additionally, we curate the ABC-Corner dataset containing 1,000 annotated models to support training and evaluation. Second, we present a six-degree-of-freedom dual-finger grasp planning algorithm that explicitly accounts for edge and corner contacts. This algorithm leverages NECDNet for feature region extraction, employs feature-specific contact detectors to identify antipodal contact pairs, and integrates a soft contact model for stability assessment, thereby effectively tackling the grasp planning challenges associated with irregular objects and enhancing grasp configuration diversity. Experimental results demonstrate that NECDNet achieves corner detection with an F1 score of 0.815, outperforming existing methods. Furthermore, the proposed grasp algorithm surpasses model-based grasp planning approaches such as GPD and GraspIt across all distribution complexity metrics (STD, Range, MAD), significantly improving grasp configuration flexibility. Real-world robotic experiments validate the robustness and effectiveness of six distinct contact combinations, including corner-corner and corner-edge interactions, demonstrating improved grasp planning efficacy and success rate.

Keywords: Point cloud processing; Geometrical feature detection; Neural network; Robotics; Grasp planning; Parallel gripper.

目　录

摘　要 I

ABSTRACT II

主要符号表 VII

第一章　研究背景与意义 1

1.1　研究背景 1

1.2　国内外研究现状 2

1.2.1　点云几何特征检测研究现状 2

1.2.2　机器人抓取规划研究现状 3

1.3　本文主要研究内容 4

1.4　论文组织结构 5

第二章　基于多尺度特征融合的点云几何特征检测 6

2.1　引言 6

2.2　逐点邻域构建及前处理 7

2.2.1　邻域构建策略 7

2.2.2　点云前处理 8

2.2.3　法向量估计与定向 9

2.3　多尺度局部特征提取与计算 10

2.3.1　多尺度特征矩阵构建 11

2.3.2　局部特征描述符设计 12

2.3.3　局部特征描述符数值可视化分析 15

2.4　NECDNet 网络架构设计 16

2.4.1　多尺度特征融合 16

2.4.2　逐级分类器 18

2.4.3　损失函数 19

2.5　本章小结 20

第三章 点云几何特征检测实验及分析 21
3.1 引言 21
3.2 ABC-Corner 数据集构建 22
3.2.1 数据集选取 22
3.2.2 数据集标注流程 23
3.3 实验环境与参数配置 25
3.3.1 软硬件环境与开发框架 26
3.3.2 数据预处理与划分方案 26
3.3.3 训练超参数配置 27
3.3.4 类别不平衡问题处理 28
3.3.5 法向量估计方法的选择与对比 29
3.3.6 评价指标设计 29
3.4 对比实验结果及分析 30
3.4.1 边缘与角点联合检测结果分析 31
3.4.2 纯边缘检测结果分析 35
3.4.3 法向量估计精度对检测的影响 36
3.5 消融实验分析 38
3.5.1 特征维度的影响 38
3.5.2 多尺度参数的选择 39
3.5.3 训练策略的探讨 39
3.6 本章小结 41
第四章 考虑边缘与角点接触的机器人抓取规划 42
4.1 引言 42
4.2 类别感知的接触点采样 43
4.2.1 几何特征检测 43
4.2.2 基于类别的体素采样 45
4.2.3 凸性检测 45
4.3 基于几何特征的接触对检测 47
4.3.1 特征化接触检测器设计 47
4.3.2 对偶接触点配对策略 50

4.3.3 初步抓取配置生成 51
4.4 抓取构型增强及碰撞检测 52
4.4.1 抓取构型增强策略 52
4.4.2 碰撞检测策略 53
4.5 基于软接触模型的稳定性评估 55
4.5.1 接触区域的离散化建模 55
4.5.2 力学平衡与稳定性判据 56
4.6 本章小结 57
第五章 机器人抓取规划实验结果及分析 58
5.1 引言 58
5.2 实验环境及参数配置 58
5.2.1 实验平台搭建 58
5.2.2 评估对象集选取 60
5.2.3 实验参数分析及配置 62
5.3 对比实验及分析 65
5.3.1 对比实验设置 65
5.3.2 抓取配置多样性分析 66
5.3.3 抓取成功率分析 66
5.4 算法耗时 68
5.5 总结 69
第六章 总结与展望 70
6.1 全文总结 70
6.2 创新点 71
6.3 研究不足与展望 71
插图索引 73
表格索引 75
参考文献 76
攻读专业硕士学位期间取得的研究成果 81

致　谢 82

附录 A　经典函数公式 83

附录 B　用于定量比较的指标公式 84

主要符号表

$\mathcal{P}^{\mathrm{c}}$	非结构化点云
n	点云中点的数量
$\mathbf{p}_i^{\mathrm{c}}$	查询点（点云中第 i 个点的三维坐标）
$\mathcal{Q}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的邻域
k	查询点邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 中点的数量
$\mathbf{x}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 在某一尺度下的局部特征向量
$\mathbf{X}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的多尺度特征矩阵
m	多尺度邻域的数量

第一章　研究背景与意义

本章节主要介绍本文的研究背景与意义，综述点云几何特征检测和机器人抓取规划的国内外研究现状，指出现有研究存在的问题，并阐述本文的主要研究内容和章节安排。

1.1　研究背景

随着计算机视觉和机器人技术的飞速发展，三维（3D）点云数据的处理与分析已成为学术界和工业界的研究热点。点云数据能够精确地表达物体表面的几何结构，获取物体内在的交互信息，因此在逆向工程、三维重建、物体识别、场景分割以及机器人自主操作等任务中发挥着至关重要的作用。

在这些任务中，物体的几何特征（如边缘和角点）承载了最关键的结构信息。边缘和角点定义了物体的边界和轮廓，是理解物体形状的基础。在分割和重建任务中，这些特征作为区域的分割边界[?]；在识别任务中，它们作为关键线或关键点[?]；在机器人抓取或焊接等应用中，它们提供了必要的轮廓信息[1]。准确提取这些几何特征，能够显著降低任务的复杂度并提高处理精度。

然而，从点云中自动检测几何特征仍面临巨大挑战。首先，由于现实世界物体的物理平滑特性以及扫描设备的精度限制，获取的三维扫描点云往往缺乏绝对锐利的特征，导致边缘和角点的定义存在固有的模糊性。其次，区分边缘和角点的特征值往往非常敏感，难以通过简单的阈值进行界定。此外，不同特征的样本密度极不平衡，角点样本的数量远少于边缘和面点，这使得高精度的角点检测尤为困难。

与此同时，机器人抓取规划作为实现机器人自主操作的核心环节，其目标是生成稳定且灵活的抓取配置。目前的抓取规划方法，无论是基于模型的解析方法还是基于深度学习的数据驱动方法，通常都优先考虑面接触（Face Contact）。这类方法倾向于将手爪指腹与物体表面法线对齐，以确保抓取的稳定性[2?]。虽然这种策略在处理规则物体时表现优异，但在面对多面体、非对称物体或具有复杂尖锐几何特征的物体时，往往因为受限于平行的平面接触区域而显得灵活性不足。为了获得稳定的面接触，规划器往往会刻意避开边缘和角点区域，这在很大程度上限制了机器人的

操作能力。

事实上，在引入软指（Soft Finger）接触模型后，手爪指腹的变形能力使得边缘和角点也能形成等效的面接触，从而提供足够的摩擦力和抗扭矩能力[?]。这意味着，如果能够有效利用边缘和角点作为潜在的接触区域，将极大地扩展机器人抓取的候选空间，提高抓取规划的灵活性和适应性。因此，本文致力于研究点云几何特征的精确检测方法，并在此基础上探索考虑边缘和角点接触的机器人抓取规划算法，以解决当前特征检测精度不足和抓取规划灵活性受限的问题。

1.2 国内外研究现状

1.2.1 点云几何特征检测研究现状

点云几何特征检测方法主要分为传统解析方法和基于数据驱动的方法。

1） 传统解析方法

传统解析方法主要通过分析局部邻域的统计信息来计算特征描述符，并结合人工设定的阈值进行特征提取。主成分分析（PCA）是最常用的方法之一，Gumhold 等人[3] 通过计算邻域协方差矩阵的特征值，当最小特征值超过阈值时判定为特征点。基于此，Xia 等人[?] 和 Bazazian 等人[4] 分别利用单尺度和多尺度的特征值比率作为局部特征描述符。此外，基于曲率估计的方法[5?] 和基于法向量变化的方法[6] 也被广泛应用。

为了提高检测的鲁棒性，一些研究引入了更复杂的几何分析。Daniels 等人[?] 利用移动最小二乘法（MLS）进行表面重建，通过局部近似来增强特征检测。Guo 等人[?] 提出了基于图的方法，结合全局上下文信息来提升特征提取效果。Zhang 等人[?] 提出的 VAM 方法利用一致性投票机制估计法向量，有效保留了重建过程中的锐利特征。Mérigot 等人[?] 则利用局部 Voronoi 单元内的法向量分布来提取锐利边缘。Zhao 等人[?] 提出了多任务神经网络架构，用于识别锐利特征附近的点并预测位移向量。

在角点检测方面，Ahmed 等人[1] 采用了两步提取法，首先提取边缘点，然后基于边缘点重新计算特征以识别角点。Schmidt 等人[?] 提出利用 RANSAC 提取直线或平面，通过它们的交点来检测角点。

总体而言，传统解析方法计算效率高，但其性能高度依赖于参数和阈值的精细调节。在面对尺度变化大或特征模糊的复杂场景时，难以实现鲁棒的检测。特别是

高精度的角点检测通常需要复杂的两步流程，效率较低且难以调参。

2） 基于数据驱动的方法

近年来，基于深度学习的数据驱动方法逐渐成为主流，这类方法通常将特征检测视为点云分类问题，即区分平滑点和锐利特征点。PIE-Net[?] 采用基于 PointNet++[?] 的双流网络分别提取边缘和角点，但其效率较低且要求输入点数固定。EDC-Net[?] 利用胶囊网络将点分类为非边缘或锐利边缘。PCPNet[?] 和 MSL-Net[?] 分别以点块和点云为输入，利用多层感知机（MLP）进行分类。PCEDNet[7] 和 BoundED[8] 通过神经网络学习多尺度局部特征描述符，在边缘检测方面取得了显著成果。

除了分类方法，部分研究将其建模为回归问题。DEFs[?] 和 EC-Net[?] 通过学习点坐标残差并估计到边缘的距离来实现精确的边缘点识别。NerVE[?] 使用体素化点云以结构化格式检测锐利特征。JSENet[?] 则利用双流全卷积网络同时执行边缘检测和语义分割。

然而，现有基于学习的方法大多集中于边缘特征的提取，针对角点检测的研究相对较少。由于角点特征与边缘特征具有相似性，且数据量更为稀疏，直接应用现有边缘检测网络往往导致角点识别精度低、误判率高的问题。即便是专门针对角点检测的方法（如 PIE-Net），也常因特征区分度不足而出现较多误分类。

1.2.2 机器人抓取规划研究现状

机器人抓取规划方法主要分为基于模型的方法和基于学习的方法。

1） 基于模型的抓取规划

基于模型的方法依赖于物体的几何模型和物理规则来生成抓取配置，并通过解析计算评估其稳定性。这类方法主要分为图元拟合（Primitive Fitting）和表面分割（Surface Segmentation）两类策略。

图元拟合方法[??] 将物体近似为基本几何体（如圆柱、球体、方块）以简化抓取合成。Chen 等人[?] 利用词嵌入量化已知模型与真实物体之间的语义相似度，通过模型匹配实现抓取。表面分割方法[??] 则通过识别有意义的表面区域来指导抓取生成。Harada 等人[?] 根据接触柔软度对三角网格进行聚类，实现了针对软指的抓取规划。Wan 等人[?] 提出了叠加分割法，根据表面法线将每个三角形分割为具有受控重叠和厚度的不同面片。

这些传统的基于模型的方法通常强调面接触的重要性[2]，并刻意避免在边缘和角点附近进行接触[?]。这种权衡虽然提高了稳定性，但降低了抓取的多样性和灵活性。

2） 基于学习的抓取规划

基于学习的方法利用神经网络和数据驱动技术来增强抓取的灵活性和适应性[? ?]。Dex-Net 4.0[?] 探索了一种混合方法，利用几何和力学模型生成合成训练数据集。L2G[?] 采用由多任务优化目标引导的可微采样过程，联合求解接触点采样、抓取回归和分类。然而，这些基于学习的方法通常依赖于抓取数据集，而这些数据集往往也是基于传统的面接触规则生成的[?]，因此生成的抓取策略依然倾向于面接触。

3） 抓取质量评价标准

评估抓取候选可行性和质量的标准多种多样。最常用的是抓取稳定性，通常通过力封闭（Force Closure）或形封闭（Form Closure）条件进行评估。解析方法通过评估旋量空间覆盖率、抗扭矩能力或最小力需求来确定抓取可靠性[? ?]。GraspIt![?] 是一个广泛使用的仿真平台，支持力封闭计算和抓取姿态优化。相比之下，数据驱动方法通常训练模型直接从视觉或几何输入预测抓取质量分数[?]。此外，一些混合方法结合了解析指标和数据驱动模型以增强泛化能力[? ?]。

然而，现有的评价标准主要关注稳定性、可抓取性[?]或功能性（Affordance），很少关注抓取配置的分布特性。抓取配置的分布反映了机器人手爪接近和抓取物体的位姿范围，是衡量抓取灵活性的重要指标。

1.3 本文主要研究内容

针对上述问题，本文的主要研究内容包括以下三个方面：

1. **基于多尺度局部特征的点云边缘与角点检测网络（NECDNet）：**提出了一种能够同时提取点云中面、边缘和角点特征的神经网络框架。该方法通过分析多尺度邻域内的位置和法向量分布，构建包含曲率、投影距离、法向角差等六维特征的多尺度特征矩阵。设计了基于多层感知机（MLP）的层次化网络结构，融合多尺度特征并实现高精度的三分类。该方法不仅在边缘检测上达到了竞争水平，更显著提升了角点检测的精度。

2. **ABC-Corner 点云几何特征数据集构建：**针对现有数据集（如 ABC 数据集）

缺乏角点标注的问题，本文构建了包含 1000 个物体模型的 ABC-Corner 数据集。通过结合算法辅助与人工精细修正的方法，提供了高质量的边缘和角点标签，解决了数据驱动方法在角点检测任务中训练数据匮乏的问题，为相关研究提供了基准。

3. **考虑边缘和角点接触的六自由度抓取规划算法：**提出了一种基于模型的解析式抓取规划方法。该方法利用提取的几何特征，针对面、边缘和角点分别设计了圆柱形、扇形和锥形接触检测器，以搜索潜在的对指抓取点对。引入软接触模型对边缘和角点接触的稳定性进行评估，从而生成包含多种接触类型（如角-角、角-边、边-面等）的抓取配置。此外，本文还引入了抓取分布统计指标来量化抓取灵活性，实验证明该方法显著提高了抓取规划的灵活性和对复杂几何物体的适应性。

1.4 论文组织结构

本文共分为六章，各章节安排如下：

第一章：绪论。介绍了课题的研究背景与意义，综述了点云几何特征检测和机器人抓取规划的国内外研究现状，指出了现有研究存在的问题，并阐述了本文的主要研究内容和章节安排。

第二章：基于多尺度特征融合的点云几何特征检测网络 NECDNet。详细介绍了 NECDNet 的网络架构、多尺度特征计算方法以及 ABC-Corner 数据集的构建过程。

第三章：点云几何特征检测实验结果及分析。对 NECDNet 在 ABC-Corner 数据集上的检测性能进行了全面的定量与定性对比实验，分析了法向量估计精度的影响，并通过消融实验验证了网络各模块设计的合理性。

第四章：考虑边缘与角点接触的机器人抓取规划。阐述了基于几何特征的类别感知接触点采样、特征化接触检测器设计、对偶接触点配对策略以及基于软接触模型的稳定性评估方法。

第五章：机器人抓取规划实验结果及分析。在仿真环境和真实物理平台上对抓取规划算法进行了全面验证，通过抓取分布统计指标定量分析了方法的灵活性优势，并统计了在 9 个测试物体上的抓取成功率。

第六章：总结与展望。总结了本文的主要研究成果与创新点，分析了存在的不足，并对未来的研究方向进行了展望。

第二章　基于多尺度特征融合的点云几何特征检测

2.1　引言

三维点云几何特征检测（如边缘和角点的提取）是三维视觉领域的关键环节，在模型重建、物体识别及机器人抓取规划中具有不可替代的作用[9]。传统的分析方法主要依赖于局部几何描述符（如曲率、法向量偏差等）并结合人工设置的阈值。然而，由于点云数据存在噪声、密度不均以及边缘及角点定义模糊等问题，传统方法往往难以兼顾检测精度与鲁棒性[3,5-6]。

为了解决边缘与角点特征在微小尺度下难以区分的问题，本章提出了一种名为NECDNet（Neural Edge and Corner Detection Network）的深度学习架构。该方法通过融合统计特征描述符与轻量级神经网络，利用多尺度邻域分析来捕捉点云局部的空间分布和法向量变化特征，从而实现对面点（Face）、边缘点（Edge）和角点（Corner）的高精度同步分类。

图 2.1展示了所提 NECDNet 的工作流程，NECDNet 由两个主要部分组成：多尺度局部特征矩阵计算和基于神经网络的分类器。流程的输入是一个非结构化点云，输出的是一个三类点云，包含面点、边缘点和角点。在多尺度特征计算阶段，我们针对每个查询点构建了包含四个不同尺度邻域的特征矩阵，每个尺度下计算六种解析特征：曲率、投影距离、均值中心距离、法向角差、法向分布和投影法向模。最终形成一个 4×6 的多尺度特征矩阵，作为神经网络的输入。在分类器阶段，我们基于多层感知机（MLP）设计了一个层次化网络结构，通过逐层融合多尺度特征，学习从特征矩阵到几何类别的映射关系。输出三类几何特征的概率得分，从而实现面、边缘和角点的同步检测。

图中左上为输入的点云数据，每次选择一个查询点（红色）及其邻域（绿色）。其中不同的 k 值表示不同尺度的邻域大小（黄色点的数量）。通过计算各尺度下的六维特征，形成多尺度特征矩阵并输入神经网络进行分类。最终输出查询点所属的几何类别（面、边缘或角点）。通过循环查询各个点，完成整个点云的几何特征检测任务，最后输出检测结果（左下）。

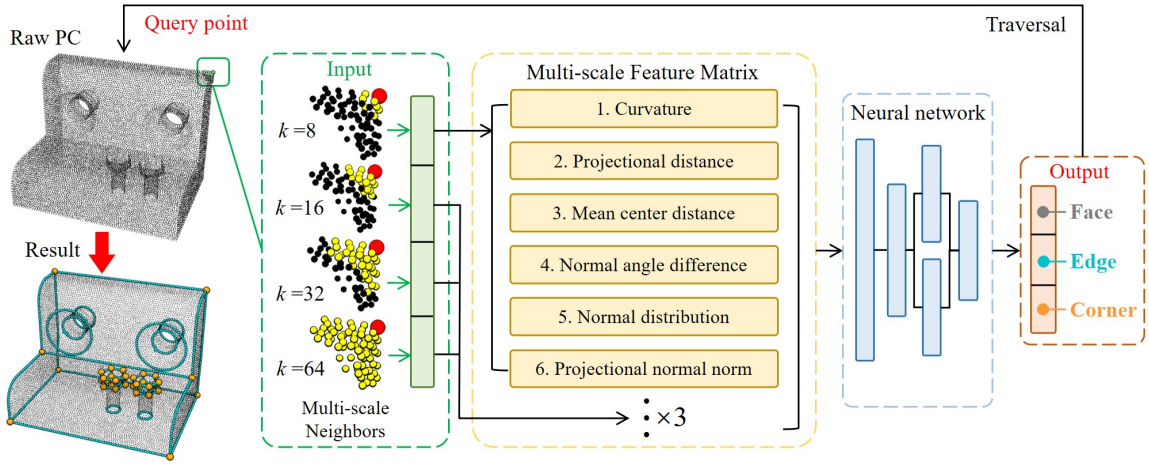


图 2.1　NECDNet 网络架构及工作流程示意图。

Figure 2.1　NECDNet network architecture and workflow diagram.

2.2　逐点邻域构建及前处理

非结构化的三维点云只包含点的空间坐标信息，缺乏拓扑连接关系，因此需要通过邻域构建方法为每个点建立局部几何关系。邻域构建是点云特征提取的基础步骤，它决定了后续几何特征计算的准确性和稳定性。本节首先介绍基于 k 近邻（k-Nearest Neighbors, k-NN）的邻域构建方法，该方法能够自适应地处理点云的非均匀分布特性，并通过 KD-树索引结构实现高效的邻域检索。随后，针对构建的邻域进行归一化预处理，消除点云的绝对位置、平移和尺度差异对特征计算的影响。此外，本节还介绍了基于主成分分析（PCA）的法向量估计方法，为后续的方向特征计算奠定基础。

2.2.1　邻域构建策略

为了有效描述点云中每个查询点的局部几何特性，需要首先确定其邻域范围。本文采用基于距离度量的 k 近邻（k-Nearest Neighbors, k-NN）方法为每个查询点构建邻域[10]。k-NN 是一种基于距离度量的邻域选择方法，通过计算查询点与其他点之间的欧氏距离，选取距离最近的 k 个点作为邻域。与固定半径（radius-based）邻域相比，k-NN 对点云非均匀采样与稀疏区域更加稳健：在稠密区不会过采样、在稀疏区不会因样本不足而破坏特征稳定性。对于非结构化的点云，其只包含点的三维坐标信息，k-NN 方法能够有效适应点云的稀疏性和不均匀分布特性。

为提升检索效率，给定一个非结构化点云 $\mathcal{P}^c$，其定义如公式 (2.1) 所示。我们在三维坐标空间上构建 KD-树（K-Dimensional Tree）索引[11]。KD-树通过在各坐标轴

上递归划分点集，使每个节点对应一个超矩形子空间，从而形成近似平衡的二叉树。查询时，先依据查询点坐标自顶向下定位至叶节点，再在回溯过程中检查可能包含更近邻点的分支，并维护容量为 k 的候选集合以持续更新最近邻。相比于暴力检索的 $O(n)$ 复杂度，KD-树可将单次最近邻查询的平均复杂度降至 $O(\log n)$，显著提升大规模点云处理的效率。

$$\mathcal{P}^{\mathrm{c}} = \{\mathbf{p}_i^{\mathrm{c}} \mid i = 1, \ldots, n\} \tag{2.1}$$

基于上述索引结构，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，我们通过 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}}$，其定义如公式 (2.2) 所示。通过调节 k 的大小即可改变邻域的空间尺度：较小的 k 更敏感于细粒度几何细节（如尖锐小角、细薄边），较大的 k 则能稳健表征更大范围的局部结构。邻域构建完成后，即可在此基础上进行几何特征的计算与提取。

$$\mathcal{Q}_i^{\mathrm{c}} = \{\mathbf{p}_{i,j}^{\mathrm{c}} \mid j = 1, \ldots, k\} \tag{2.2}$$

2.2.2 点云前处理

为了消除点云绝对坐标、平移以及尺度差异对特征计算的影响，在提取特征前，本文首先对邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 进行归一化处理。该过程基于主成分分析（Principal Component Analysis, PCA）思想，计算邻域点的协方差矩阵 $\mathbf{K}_i = \mathrm{cov}(\mathcal{Q}_i^{\mathrm{c}})$，并对其进行奇异值分解（Singular Value Decomposition, SVD），如公式 (2.3) 所示[12]。

$$\mathbf{K}_i = \mathbf{U}_i \mathbf{\Sigma}_i \mathbf{V}_i^T \tag{2.3}$$

其中，$\mathbf{U}_i$ 和 $\mathbf{V}_i$ 分别为左奇异向量矩阵和右奇异向量矩阵，$\mathbf{\Sigma}_i$ 为对角奇异值矩阵。通过该分解，我们能够获得邻域点在主方向上的分布特性。具体而言，通过对角矩阵 $\mathbf{\Sigma}_i$ 提取奇异向量 $\boldsymbol{\sigma}_i = (\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3})$，其中的奇异值计为降序排列。右奇异向量矩阵 $\mathbf{V}_i$ 的列向量对应于邻域点在三个主方向上的投影轴。不同的奇异值反映了邻域点在各主方向上的扩展程度。奇异值较小的方向点云分布较为集中，反之则较为分散。

通过上述分解结果，可以对邻域点进行去中心化与尺度归一化处理。具体而言，

首先计算邻域点的质心 $\bar{\mathbf{p}}_{i,j}^{c}$，如公式 (2.4) 所示。其中 $|\mathcal{Q}_i^c|$ 表示邻域点的数量。

$$\bar{\mathbf{p}}_{i,j}^{c} = \frac{1}{|\mathcal{Q}_i^c|} \sum_{j=1}^{k} \mathbf{p}_{i,j}^{c} \tag{2.4}$$

随后，将所有邻域点坐标减去质心实现去中心化，并利用奇异值 $\sigma_{i,1}$ 和 $\sigma_{i,2}$ 对去中心化后的邻域点进行尺度缩放，确保各个方向上的分布具有统一的量纲，如公式 (2.5) 所示。最终，得到归一化后的邻域 $\hat{\mathcal{Q}}_i^c$，为后续特征计算提供了标准化的输入。归一化邻域后的查询点坐标记为 $\hat{\mathbf{p}}_i^c$，邻域中的点坐标记为 $\hat{\mathbf{p}}_{i,j}^c$。

$$\hat{\mathcal{Q}}_i^c = \left\{ \frac{2}{\sqrt{\sigma_{i,1}} + \sqrt{\sigma_{i,2}}} \left(\mathbf{p}_{i,j}^{c} - \bar{\mathbf{p}}_{i,j}^{c} \right) \mid \mathbf{p}_{i,j}^{c} \in \mathcal{Q}_i^c \right\} \tag{2.5}$$

2.2.3 法向量估计与定向

法向量是描述点云局部表面方位的重要几何属性，也是计算后续方向特征的基础。本文采用基于局部平面拟合的方法估计查询点的法向量。从公式 (2.3) 的奇异值分解结果中可知，奇异值 $\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3}$ 对应的右奇异向量（即矩阵 $\mathbf{V}_i$ 的列向量）构成了邻域内点集分布的正交主轴。由于奇异值按降序排列，最小奇异值 $\sigma_{i,3}$ 对应的奇异向量 $\mathbf{v}_{i,3}$ 指向了邻域内点集分布方差最小的方向。在几何意义上，该方向与局部最小二乘拟合平面的法向重合。因此，查询点的法向量 $\mathbf{n}_i^c$ 可根据归一化后的右奇异向量 $\mathbf{v}_{i,3}$ 得出。

然而，仅通过 PCA 获得的法向量存在 180° 的方向模糊性（即法向量可能指向物体内侧或外侧）。为了确保在计算后续法向量夹角差异等特征时的数值一致性，必须对法向量进行定向处理。在处理具有闭合表面的物体时，通常利用视点方向或邻域一致性进行约束。本文采用最小生成树（Minimum Spanning Tree, MST）算法在点云图中传播法向量方向，以实现全局的方向一致化[13]。具体而言，将点云视为图结构，以点间距离为边权构建图，从初始点开始，通过遍历图确保相邻点的法向量满足内积大于零的约束，实现对点云中各点法向量的方向一致化。最终得到的法向量 $\mathbf{n}_i^c$ 既具有准确的方向信息，又消除了模糊性，为后续特征计算提供了可靠的基础，整体点云的法向量估计结果如图 2.2所示。

基于 PCA 的法向量估计方法具有计算效率高、实现简单的优点，能够在大规模点云数据中快速获得局部表面方向信息。然而查询点位于边缘或角点位置时，其近邻区域内点的分布较为不规则，导致法向量估计结果不稳定，使法向量估计精度下

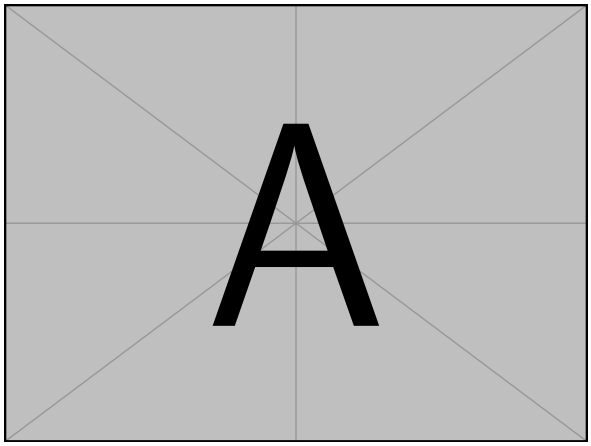


图 2.2　基于 PCA 的点云法向量估计结果示意图。

Figure 2.2　Point cloud normal estimation result diagram based on PCA.

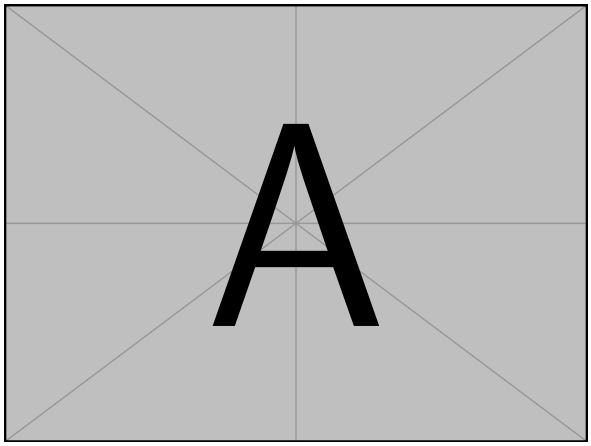


图 2.3　基于 CAD 网格模型的点云法向量估计结果示意图。

Figure 2.3　Point cloud normal estimation result diagram based on CAD mesh model.

降。当点云数据存在其对应的 CAD 网格结构时，可以通过网格面片的法向量直接获取查询点的法向量，从而避免上述问题，真实的法相朝向如图 2.3所示。在后续实验章节 三 中，本文将训练两个模型：一个使用基于 PCA 的法向量估计结果作为输入特征，另一个使用 MeshLab 基于原始 CAD 网格模型进行点云法向量估计[14]。通过对比分析两个模型的检测性能，验证法向量估计精度对边缘与角点检测结果的显著影响。

2.3　多尺度局部特征提取与计算

在完成邻域构建和前处理后，本节将重点介绍如何在多尺度邻域框架下提取和计算局部几何特征。多尺度表示的是针对每个查询点，选择不同数量的邻域点以构

建多层次的局部几何描述。由于点云捕获时的视角、距离及分辨率等因素影响，单一尺度往往难以全面反映局部几何结构的信息。通过分析不同尺度下的点云分布特征，可以更全面地捕捉局部几何结构，从而提升边缘和角点的区分能力[7]。

适用的尺度取决于多个因素：物体大小、形状复杂度、点云密度、观察尺度等。为了使训练得到的模型能泛化处理未知物体的情况，本文为输入点云中的每个查询点在多尺度邻域内计算多个特征，并在章节 3.5中进行了消融实验确保各个尺度选择的合理性。本节首先介绍多尺度特征矩阵的构建策略，随后详细阐述六种局部几何特征描述符的设计与计算方法，最后通过数值可视化分析验证所选特征的有效性。

2.3.1 多尺度特征矩阵构建

为兼顾不同尺度的几何信息，本文针对多个 k 值为同一查询点构建多组邻域，形成多尺度邻域表示。具体而言，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，通过前一节介绍的 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}} = \{\mathbf{p}_{i,j}^{\mathrm{c}} \mid j = 1, \ldots, k\}$。通过调节 k 的大小即可改变邻域的空间尺度：较小的 k 更敏感于细粒度几何细节（如尖锐小角、细薄边），较大的 k 则能稳健表征更大范围的局部结构。

对由给定 k 值确定的局部区域 $\mathcal{Q}_i^{\mathrm{c}}$ 计算六个解析特征，得到 6 维特征向量 $\mathbf{x}_i^{\mathrm{c}}$。当为同一查询点在多个 k 值下重复上述过程，即可获得对应的 $\mathbf{x}_{i,k}^{\mathrm{c}}$。将这些特征按尺度汇集，构成用于后续网络学习的多尺度特征矩阵，如公式 (2.6) 所示：

$$\mathbf{X}_i^{\mathrm{c}} = \begin{bmatrix} \mathbf{x}_{i,k_1}^{\mathrm{c}} \\ \mathbf{x}_{i,k_2}^{\mathrm{c}} \\ \vdots \\ \mathbf{x}_{i,k_m}^{\mathrm{c}} \end{bmatrix} \tag{2.6}$$

其中，$k_1, k_2, \ldots, k_m$ 表示所选择的不同邻域尺度，m 为尺度数量。多尺度特征矩阵中的尺度数 m 和尺度大小 k 直接影响神经网络的学习结果。具体来说，k 影响结果对点云不同稀疏度的适用性，而 m 影响网络学习数据的维度。选择合适的尺度尺寸和数量可以优化检测精度。因此，在第 3.5 节中，本文对邻近尺度选择进行了消融实验以确定参数，并最终选择了 k 的四个值：8、16、32 和 64 进行特征计算。这种多尺度策略能够在保证计算效率的同时，充分捕捉从局部细节到全局结构的几何信息。

2.3.2 局部特征描述符设计

在构建多尺度邻域的基础上，本文进一步设计了一套包含六个维度的局部几何特征描述符，旨在精确捕捉查询点及其邻域在不同空间尺度下的结构属性。这六种特征可归纳为基于位置的几何特征（Position-based Features）与基于法向量方向的特征（Normal-based Features）两大类。基于位置的特征主要通过分析邻域点的空间分布规律来描述局部形状，而基于法向量的特征则通过分析表面方向的连续性与一致性，提供关于几何边缘与尖锐角点的关键判别信息。这种多维特征的结合，增强了模型在面对复杂、模糊边界时的区分能力。消融实验中对特征计算中涉及的所有描述符进行了评估，说明了该选择的有效性。

1） 曲率（κ_i）

首先计算基于位置的几何特征，表征邻域内点的几何分布特性。曲率 κ_i 是几何物体偏离平面程度的度量。在本文中，查询点邻域的曲率可以根据上述得到的奇异值进行计算，用于表征局部表面的平坦程度。具体而言，曲率定义为最大奇异值与三维奇异值之和的比值，如公式 (2.7) 所示。

$$\kappa_i = \frac{\sigma_{i,3}}{\sigma_{i,1} + \sigma_{i,2} + \sigma_{i,3}} \tag{2.7}$$

当查询点位于平坦表面时，$\sigma_{i,3}$ 较小，曲率值接近于零；而当查询点位于尖锐边缘或角点时，$\sigma_{i,3}$ 较大，曲率值相应增大。因此，曲率特征有助于区分面点与边缘、角点。

2） 投影距离均值（$\bar{d}_i$）

投影距离均值 $\bar{d}_i$ 用于刻画查询点邻域内点相对于该点法向平面的空间分布，其大小反映了局部几何结构的突变程度。具体地，对于任一查询点 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，结合其法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可定义通过该点的投影平面。邻域内所有点 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$ 到该投影平面的距离均值即为 $\bar{d}_i$，计算公式如 (2.8) 所示。

$$\bar{d}_i = \frac{1}{|\hat{\mathcal{Q}}_i^{\mathrm{c}}|} \sum_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \left| (\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} - \hat{\mathbf{p}}_i^{\mathrm{c}}) \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.8}$$

图 2.4展示了该距离度量的几何意义。其反映了邻域点在查询点法向方向上的分布特性：当邻域点主要分布在查询点法向平面附近时，投影距离较小，表明局部几

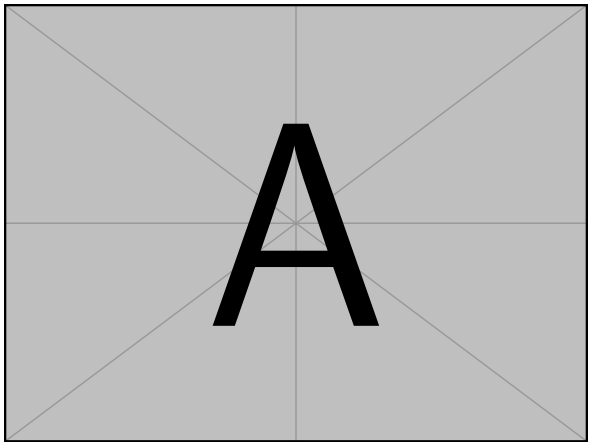


图 2.4　投影距离均值的几何意义示意图。

Figure 2.4　Geometric significance diagram of mean projection distance.

何结构较为平滑；而当邻域点在法向方向上分布较为分散时，投影距离增大，通常对应于边缘或角点区域。

3）　中心偏离比（r_i ）

中心偏离比 r_i 是量化查询点在其局部邻域内的相对空间位置的度量，其能够衡量查询点相对于其邻域质心的偏移程度。具体而言，首先计算邻域点的质心，由于此时的邻域 $\hat{\mathcal{Q}}_i^{\mathrm{c}}$ 已经进行了去中心化及归一化处理，因此邻域质心即为原点。之后计算查询点到质心的距离 $\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|$ 与邻域内各点到质心距离 $\|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|$ 的最小值之比，得到中心距离均值比 r_i，计算公式如 (2.9) 所示，由于该特征为比值，当分母较小时产生的结果不受此前归一化邻域的影响。故针对特征 r_i，本文选用 Sigmoid 函数对其进行标准化处理，以减小数值分布的变化范围。

$$r_i = \mathrm{Sigmoid}\left(\frac{\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|}{\min_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|}\right) \tag{2.9}$$

其中 Sigmoid 表示 Sigmoid 函数，$\|\cdot\|$ 表示欧氏距离，min 运算符用于获取邻域点中距离质心最近的点的距离，式中省略了减去质心零向量的表示。中心偏离比 r_i 反映了查询点在邻域内的相对位置关系：当查询点位于邻域质心附近时，r_i 值较小，表明该点可能位于平坦区域；而当查询点远离邻域质心时，r_i 值增大，通常对应于边缘或角点区域。因此，中心偏离比有助于区分不同几何特征。

4） 法向量角度差（$\mu_{\theta,i}$）

以此特征描述符开始，后续的三个描述符是基于法向量方向的特征，旨在捕捉表面方向的突变信息。法向角度差 $\mu_{\theta,i}$ 衡量查询点法向量与其邻域内各点法向量之间夹角的平均值，反映了局部表面方向的一致性。具体而言，首先根据章节2.2.3中的方法估计邻域内每个点的单位法向量 $\mathbf{n}_{i,j}^{c}$，组合为 $\mathcal{N}_i^{c}$。随后，计算查询点法向量 $\mathbf{n}_i^{c}$ 与邻域内各点法向量之间的夹角 $\theta_{i,j}$ ，计算公式如 (2.10)。最后并求各个夹角的平均值，求解公式如 (2.11) 所示。

$$\theta_{i,j} = \arccos\left(\mathbf{n}_i^{c} \cdot \mathbf{n}_{i,j}^{c}\right) \tag{2.10}$$

$$\mu_{\theta,i} = \frac{1}{|\mathcal{N}_i^{c}|} \sum_{j=1}^{|\mathcal{N}_i^{c}|} \theta_{i,j} \tag{2.11}$$

其中，arccos 表示反余弦函数。法向角度差 $\mu_{\theta,i}$ 反映了邻域内法向量的方向变化程度：当邻域内法向量与查询点法向量高度一致时，$\mu_{\theta,i}$ 值较小，表明局部表面较为平滑；而当邻域内法向量与查询点法向量差异较大时，$\mu_{\theta,i}$ 值增大，通常对应于边缘或角点区域。

此外，除了用法向量夹角来表示方向变化外，还可以直接使用法向量的数值之差来表示方向变化。具体而言，计算查询点法向量与邻域内各点法向量的差值，并求其平均值，得到法向量数值差 $\bar{\Delta\mathbf{n}}_i$，计算公式如 (2.12) 所示。相较与法向量角度差 $\mu_{\theta,i}$，法向量数值差 $\bar{\Delta\mathbf{n}}_i$ 直接采用原始法向量数据进行统计计算，后续消融实验中会讨论两者的效果差异。

$$\bar{\Delta\mathbf{n}}_i = \frac{1}{|\mathcal{N}_i^{c}|} \sum_{\mathbf{n}_{i,j}^{c} \in \mathcal{N}_i^{c}} (\mathbf{n}_i^{c} - \mathbf{n}_{i,j}^{c}) \tag{2.12}$$

5） 法向量分布方差（$\sigma_{\theta,i}^2$ ）

法向量分布方差 $\sigma_{\theta,i}^2$ 用于量化邻域内法向量夹角的变化剧烈程度，反映了局部表面方向的稳定性。具体而言，基于前述计算的法向角度差 $\mu_{\theta,i}$，计算邻域内各点法

向量与查询点法向量夹角的方差，求解公式如 (2.13) 所示。

$$\sigma_{\theta,i}^2 = \frac{1}{|\mathcal{N}_i^c|} \sum_{j=1}^{|\mathcal{N}_i^c|} (\theta_{i,j} - \mu_{\theta,i})^2 \tag{2.13}$$

法向量分布方差 $\sigma_{\theta,i}^2$ 反映了邻域内法向量变化的剧烈程度：当邻域内法向量夹角较为集中时，$\sigma_{\theta,i}^2$ 值较小，表明局部表面方向较为稳定；而当邻域内法向量夹角分布较为分散时，$\sigma_{\theta,i}^2$ 值增大，通常对应于边缘或角点区域，而角点区域的分散程度更为显著。

6） 法线投影距离均值（$\bar{\mathbf{proj}}_i$ ）

法线投影距离均值 $\bar{\text{proj}}_i$ 用于量化邻域点法向量在查询点法向上的投影强度，反映了表面法向的对齐程度。具体而言，计算邻域内每个点法向量 $\mathbf{n}_{i,j}^c$ 在查询点法向 $\mathbf{n}_i^c$ 上的投影长度，并求其平均值，计算公式如 (2.14) 所示。

$$\bar{\text{proj}}_i = \frac{1}{|\mathcal{N}_i^c|} \sum_{\mathbf{n}_{i,j}^c \in \mathcal{N}_i^c} \left| \mathbf{n}_{i,j}^c \cdot \mathbf{n}_i^c \right| \tag{2.14}$$

由于各点的法向量均为单位向量，法线投影距离均值 $\bar{\text{proj}}_i$ 可以反映邻域内法向量与查询点法向量的对齐程度：$\bar{\text{proj}}_i$ 值较大，表明局部表面方向较为统一；而当邻域内法向量与查询点法向量差异较大时，$\bar{\text{proj}}_i$ 值减小，通常对应于边缘或角点区域。

2.3.3 局部特征描述符数值可视化分析

通过上述计算的局部特征描述符，本文最终选择了其中六个组成特征描述向量，并用于后续的特征融合和分类任务。最后得到的特征向量如公式 (2.15) 所示。六个特征均为标量，组成的特征向量维度为 6，包含了点云的位置分布特性和法向量变化信息，能够有效表征点云局部的几何结构属性。

$$\mathbf{x}_i^c = \left(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma_{\theta,i}^2, \bar{\text{proj}}_i \right) \tag{2.15}$$

图 2.5 展示了多尺度几何特征在点云三类特征（面、边缘、角点）中的分布表现，直观体现了所选六维特征向量对于区分不同几何类别的有效性。其中图 (a) 对单个物体点云的六个特征进行了空间分布可视化。每个子图分别显示了特征描述符 κ_i（曲率）、$\bar{d}_i$（投影距离均值）、r_i（中心偏离比）、$\mu_{\theta,i}$（法向量角度差）、$\sigma_{\theta,i}^2$（法向量分布方差）、$\bar{\text{proj}}_i$（法向投影距离均值）在点云空间上的数值分布情况。颜色表示数值

大小，采用从蓝色（低值）到红色（高值）的渐变色带。根据上一小节对各特征的定义，可以观察到：除了特征 $\bar{\text{proj}}_i$ 外，其他五个特征在面、边缘和角点区域均表现出从低到高的数值变化趋势（蓝色到红色）。而特征 $\bar{\text{proj}}_i$ 则呈现出相反的趋势，在面区域数值较高（红色），而在边缘和角点区域数值降低（橙黄色）。各个特征在不同的几何结构上有着明显的区别。

图 (b) 部分给出了在我们构建的数据集 ABC-Corner 中 1000 个点云样本的六个特征在三类标签下的数值分布，数据集的描述及构建过程请见章节 (3.2)。纵轴为点云 ID，横轴为特征值，颜色标记类别：蓝色为面、黄色为边缘、红色为角点。统计结果显示，在面、边缘、角点三类之间，所有特征分布具有明显的界限。以曲率和法向分布为例，角点（红色）主要集中在中高值段，面点则聚集于低值，边缘点分布于中间区域。其他如投影距离、均值中心距离等特征也展现出对类别的良好区分能力。

虽然可以观察到直接使用这些特征描述符就能进行一定程度上的几何特征区分。然而，直接使用这些特征进行检测类似于分析方法，需要参数调整并且可能无法保证稳健的结果。为了解决这个问题，本文利用神经网络从计算的特征矩阵中学习。这种方法使能够结合分析方法和基于学习的检测技术的优势，实现精准的自分类。

2.4 NECDNet 网络架构设计

NECDNet 网络架构针对点云数据中特征点的精细分类任务（包括面点、边缘点和角点），设计了以多层感知机（Multi-Layer Perceptron, MLP）为核心、多尺度特征深度融合与分阶段判别相结合的高效结构[15]。整体网络流程如图 2.6 所示，主要包括两大模块：首先，多尺度特征融合模块从多个邻域尺度提取并逐级整合各类局部几何信息，实现输入信息的丰富表达；其次，逐级分类模块采用分层分类思路，将点的最终类别归属过程划分为由简到繁的两个层次，提升了分类准确率和模型的泛化能力。结合全连接层、Leaky ReLU 激活及 Dropout 策略，有效增强了网络的判别能力并抑制了过拟合风险[16-17]。下文将分别对多尺度特征融合与逐级分类策略进行详细阐述。

2.4.1 多尺度特征融合

NECDNet 的输入部分针对每个查询点构建了多尺度邻域下的几何属性特征矩阵。具体地，针对每个点，分别在 $k = 8, 16, 32, 64$ 四种不同邻域尺度内提取点云的

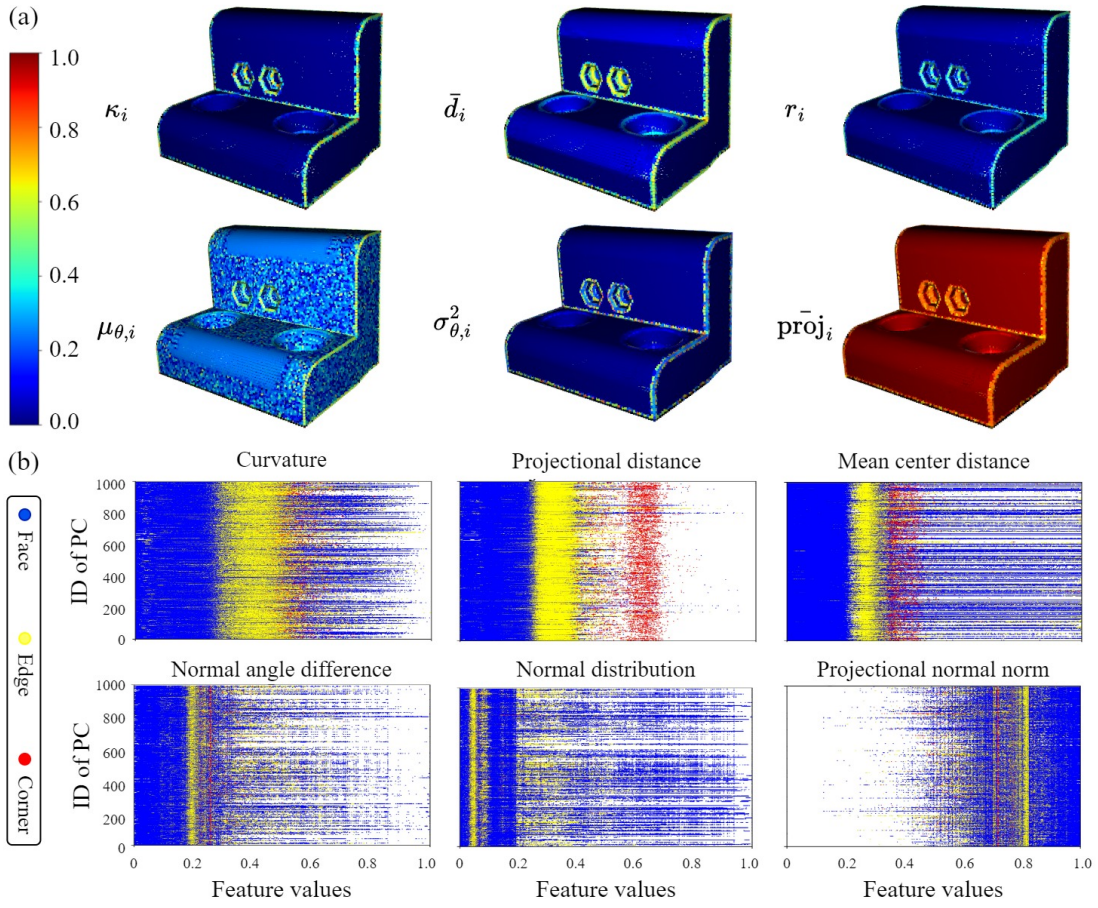


图 2.5　六个局部特征描述符在不同几何类别下的数值分布情况。

Figure 2.5　Distribution of six local feature descriptors across different geometric categories.

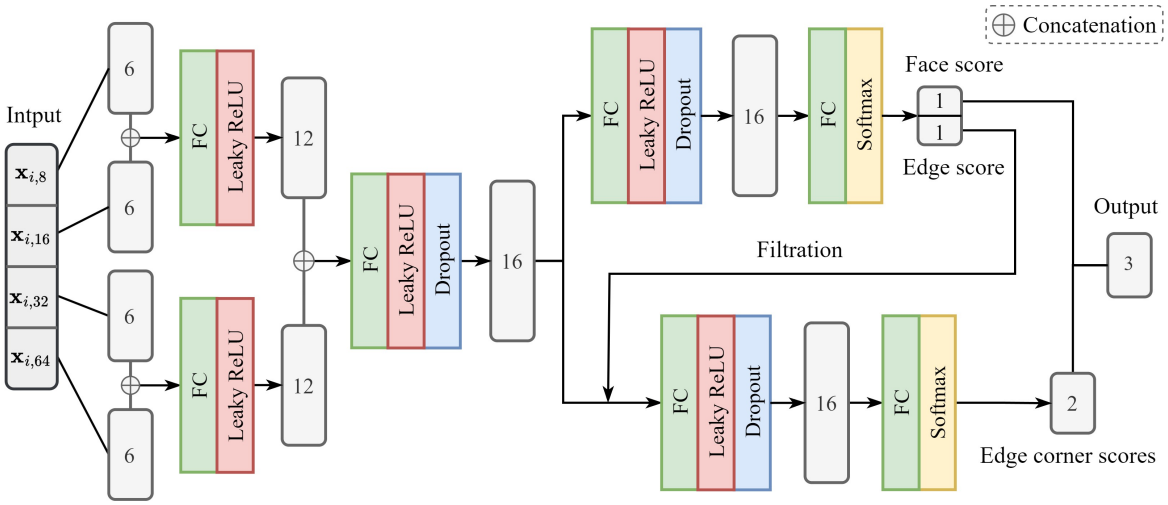


图 2.6　NECDNet 网络架构示意图。

Figure 2.6　NECDNet network architecture diagram.

几何特征，每个尺度获得一个 6 维特征向量 $\mathbf{x}_{i,k} \in \mathbb{R}^6$，所有尺度拼接形成 4×6 的特征矩阵。

这一多尺度特征首先经过特征提取单元处理。对于第 j 个尺度 ($j \in \{1,2,3,4\}$) 的输入特征 $\mathbf{x}_{i,j}$，通过全连接层（FC）、Leaky ReLU 激活函数进行非线性映射。该过程可表示为：

$$\mathbf{h}_i^{(1)} = \sigma_{\text{LReLU}}(\mathbf{W}_i^{(1)}\mathbf{x}_{i,j} + \mathbf{b}_i^{(1)}) \tag{2.16}$$

其中，$\mathbf{W}_i^{(1)}$ 和 $\mathbf{b}_i^{(1)}$ 为权重矩阵和偏置项，σ_{LReLU} 表示 Leaky ReLU 激活函数，其定义为 $f(x) = \max(x, \alpha x)$，α 为负半轴斜率（通常取 0.01）[16]。

随后，参考图 2.6 中的结构，模型将相邻两个尺度的特征进行两两拼接（Concatenate）。例如，将 $k = 8$ 和 $k = 16$ 对应的特征 $\mathbf{h}_1^{(1)}$ 和 $\mathbf{h}_2^{(1)}$ 拼接得到 $\mathbf{z}_{12} = [\mathbf{h}_1^{(1)}, \mathbf{h}_2^{(1)}]$。融合后的特征再次通过类似的非线性变换，公式如 (2.17) 所示。相较于上一步，这里引入了 Dropout 层以防止过拟合现象的发生[17]。

$$\mathbf{h}_{12}^{(2)} = \text{Dropout}\left(\sigma_{\text{LReLU}}(\mathbf{W}_{12}^{(2)}\mathbf{z}_{12} + \mathbf{b}_{12}^{(2)})\right) \tag{2.17}$$

同理可得 $\mathbf{h}_{34}^{(2)}$。接着，将这两组特征进一步拼接为 24 维大向量 $\mathbf{z}_{\text{final}}$，并通过进一步的 FC 层非线性降维，得到 16 维的综合多尺度特征输出 $\mathbf{F}_{\text{out}}$。

整个多尺度特征融合过程不仅实现了不同邻域尺度下信息的交互、互补和融合，还通过层级式的非线性变换消除了简单拼接可能造成的信息冗余，使网络能够自主学习到最具区分力的综合表达，为后续分类模块奠定坚实基础。

2.4.2 逐级分类器

多尺度特征融合单元输出的 16 维向量 $\mathbf{F}_{\text{out}}$ 随后交由逐级分类器进行细粒度类别判别。该模块采用两级分层判别架构。

1） 第一级分类（面点判别）

首先，$\mathbf{F}_{\text{out}}$ 经过类似公式 (2.17) 的变换降维至 8 维，得到中间特征 $\mathbf{v}_{\text{mid}}$。随后，通过 FC 层输出面点与非面点的逻辑值（Logits）$\mathbf{l}_1 \in \mathbb{R}^2$。最终的初级分类概率分布 $\mathbf{p}_1$ 由 Softmax 函数计算得出[18]：

$$\mathbf{p}_1 = \text{Softmax}(\mathbf{l}_1) = \frac{e^{\mathbf{l}_{1,j}}}{\sum_{k=1}^{2} e^{\mathbf{l}_{1,k}}}, \quad j \in \{1,2\} \tag{2.18}$$

若判定为面点，则直接据此输出结果；若为非面点，则将中间特征 $\mathbf{v}_{\text{mid}}$ 送入下一级分类子模块。

2） 第二级分类（边缘点与角点判别）

在第二级分类器中，传入的 8 维特征 $\mathbf{v}_{\text{mid}}$ 再次经历 FC、Leaky ReLU 和 Dropout 处理，降维为 4 维特征 $\mathbf{v}_{\text{sub}}$，最后映射为边缘点和角点的二分类逻辑值 $\mathbf{l}_2$。同样利用 Softmax 得到概率分布 $\mathbf{p}_2$，类似公式 (2.18) 所示。最终，对于每个输入点，网络结合两级输出确定“面-边缘-角”三类别的归属。

这种分级判别方法，有效简化了单次多分类的复杂度，提升了点云中特征类别区分的精度和鲁棒性。值得一提的是，每层分类器均结合 Leaky ReLU 增强非线性表达，Dropout 有效应对过拟合风险，整体保证了 NECDNet 在结构复杂、类别分布不均等点云场景下的自适应能力。

2.4.3 损失函数

点云中几何特征的分布存在不平衡现象，面点数量远多于边缘点和角点，特别是角点[19]。为了应对类别不平衡问题，本文在训练过程中采用 Focal Loss 作为优化指标[20]。Focal Loss 旨在解决训练中前景与背景类别极度不平衡的单阶段物体检测场景（例如 1：1000）。其在交叉熵损失（Cross Entropy, CE）的基础上引入了调节因子，降低了易分类样本的权重，从而使模型更加关注难分类样本。

交叉熵损失是分类任务中常用的损失函数，其可以度量模型预测概率分布与真实标签分布之间的差异。交叉熵越小，说明两者越相似；越大，说明差异越大。交叉熵损失的定义如公式 (2.19) 所示[21]。其中，p_t 表示模型对真实类别的预测概率。然而交叉熵损失在类别不平衡的情况下，容易被大量的易分类样本主导，导致模型对少数类别的学习效果不佳。

$$\mathrm{CE}(p_t) = -\log(p_t) \tag{2.19}$$

为了解决类别极度不均衡的问题，可以在交叉熵损失的基础上引入类别权重 α，得到加权交叉熵损失（Weighted Cross Entropy, WCE）。其在计算时对不同类别赋予不同的权重，增强对少数类别的关注，定义如公式 (2.20) 所示。其中，α_t 为类别 t 的

权重，通常根据类别频率进行设置。

$$\mathrm{WCE}_{\alpha}(p_t) = -\alpha_t \log(p_t) \tag{2.20}$$

Focal Loss 正是在加权交叉熵损失的基础上进行改进的。Focal Loss 在加权交叉熵损失的基础上引入了调节因子 $(1-p_t)^{\gamma}$，其中 γ 为调节参数，用于控制易分类样本的权重衰减程度。Focal Loss 的定义如公式 (2.21) 所示[20]。相较于加权交叉熵损失，Focal Loss 通过调节因子有效降低了易分类样本的影响力，使模型更加关注难分类样本，从而提升在类别不平衡情况下的分类性能。

$$\mathrm{FL}(p_t) = -\alpha_t (1-p_t)^{\gamma} \log(p_t) \tag{2.21}$$

2.5 本章小结

本章主要对 NECDNet 网络的设计与实现进行了详细阐述。首先，介绍了多尺度几何特征的提取方法及其在点云三类几何特征中的分布表现，验证了所选特征描述符的有效性。随后，详细描述了 NECDNet 的网络架构设计，包括多尺度特征融合模块和逐级分类器模块，强调了其在处理点云几何特征检测任务中的优势。接着，介绍了网络训练中的损失函数和评估指标等设置。最后，详细介绍了 ABC-Corner 数据集的构建过程，包括数据集选取、标注流程及统计特性，为后续实验提供了坚实的数据基础。整体而言，本章为 NECDNet 的实现奠定了理论与实践基础，为后续章节的实验评估做好准备。

第三章　点云几何特征检测实验及分析

3.1　引言

Todo list

这里需要补充实验数据 28

本章旨在通过系统性的实验验证本文所提出的 NECDNet 在三维点云边缘与角点检测任务中的有效性与鲁棒性。实验主要基于本文构建的 ABC-Corner 数据集展开。首先，本章将详细阐述 ABC-Corner 数据集的构建过程、实验的硬件环境、参数配置以及针对数据不平衡问题所采用的评价指标与训练策略。随后，将 NECDNet 与当前主流的传统几何分析方法及深度学习方法进行多维度的定性与定量对比，并重点分析法向量估计精度对检测结果的显著影响。此外，为了验证网络结构设计的合理性，本章还对特征维度、多尺度参数选择及数据增强策略进行了详尽的消融实验分析。最后，本章对实验结果进行了总结与讨论。

3.2 ABC-Corner 数据集构建

网络训练和评估离不开高质量的标注数据集。针对点云几何特征检测任务，本文构建了一个专门的数据集：ABC-Corner 数据集。该数据集基于 ABC 数据集[22] 中的 CAD 模型，经过精细的标注和处理，包含丰富的面点、边缘点和角点样本，能够有效支持深度学习模型的训练与评估。下文将详细介绍数据集的选取标准、标注流程及统计特性。

3.2.1 数据集选取

针对点云数据的深度学习任务，目前已有多个公开数据集可供使用，图 3.1展示了 ShapeNet[23]、ScanNet[24]、RGB-D Object Dataset[25] 数据集中的部分内容。这些数据集的原始数据一般为扫描得到的非结构化点云，或者 RGB-D 估计得到的点云，适用于多种点云处理任务，如分类、分割和重建等。然而，在本文的几何特征检测任务中，要求数据集具备高质量的几何特征标注，特别是边缘和角点的精确位置标注。通过扫描或重建得到的点云数据往往存在噪声和不完整性，且难以得到精确的几何特征标注，故本文选择基于 CAD 模型的数据集进行构建。

在 CAD 模型数据集中，ABC 数据集因其丰富的几何多样性和高精度的模型表

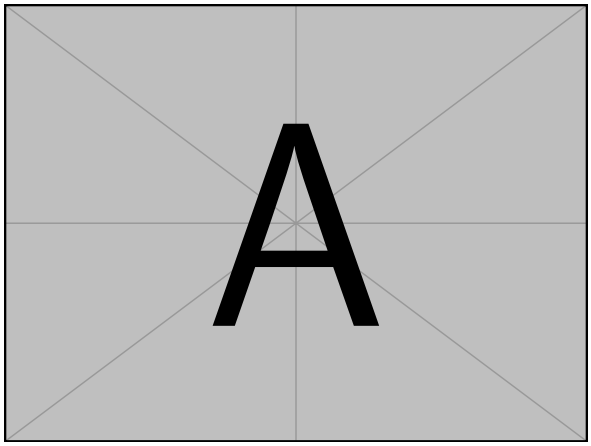


图 3.1　常用点云数据集对比示意图。

Figure 3.1　Comparison of commonly used point cloud datasets.

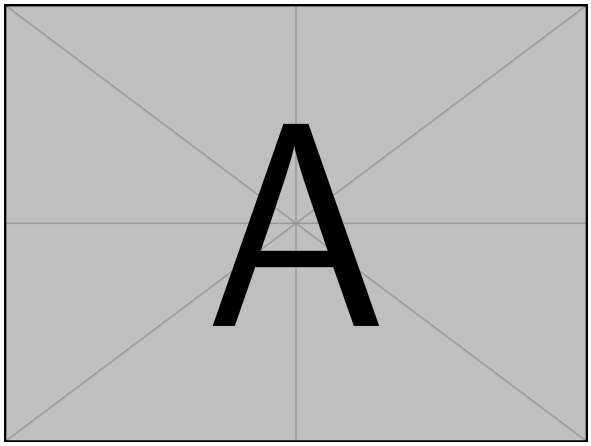


图 3.2　ABC 数据集中的部分 CAD 模型示例。

Figure 3.2　Examples of CAD models from the ABC dataset.

示而被广泛应用于几何处理和计算机图形学领域[22]。如图 3.2，ABC 数据集包含了大量由真实工程设计生成的 CAD 模型，涵盖了各种复杂的几何形状和结构，适合用于点云几何特征检测任务。并且，CAD 模型本身具有明确的几何定义，便于从中提取精确的边缘和角点信息，满足本文对数据集标注质量的高要求。因此，本文选择 ABC 数据集作为构建 ABC-Corner 数据集的基础。

3.2.2　数据集标注流程

ABC 数据集中包含了大量的 CAD 模型，原始数据为模型的几何表示（如 B-Rep）。ABC 数据集在构建过程中基于模型的原始数据，生成了网格化表示和几何真值（法向量、曲率、补丁分割、尖锐特征等）。本文的数据集 ABC-Corner 主要使用原始数据集中的 OBJ 模型文件及其对应的几何真值文件，结合自定义的标注流程，生成包

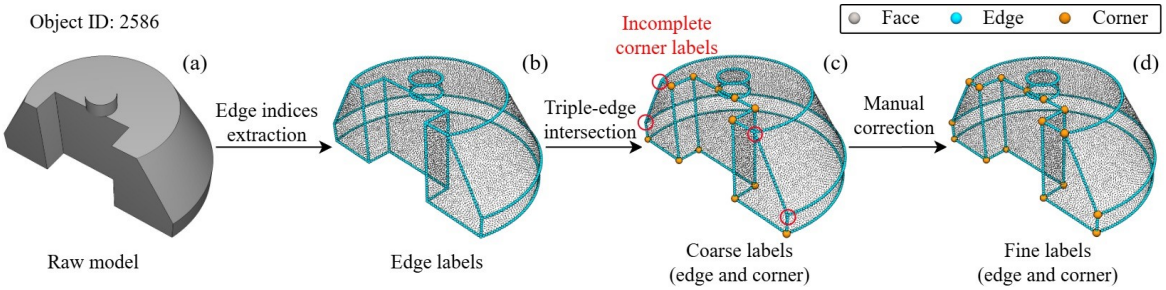


图 3.3　ABC-Corner 数据集标注流程示意图。

Figure 3.3　Annotation pipeline for the ABC-Corner dataset.

含面点、边缘点和角点标签的点云数据集。如图 3.3所示，本文数据集标注流程主要包括以下几个步骤：边缘提取、粗角点检测和人工精修。

ABC 数据集的模型文件中包含均匀采样得到的点云数据（顶点），以及每个顶点的法向量和曲率信息。几何真值文件中包含了模型的曲面补丁划分和边缘曲线信息。其中的边缘曲线信息是将模型所有边缘进行参数化表示，包含边缘上各顶点的索引信息，以及曲线的样式。基于该信息可以实现边缘点的自动标注。

ABC 数据集中虽然包含了边缘信息，但并未直接提供角点的标注。为了提取角点，本文设计了一种基于几何规则的粗角点检测方法。具体而言，根据边缘曲线信息，识别出边缘的交叉点作为角点候选集，即某个索引在所有曲线中出现三次或三次以上，则将其视为角点。在实际检测中发现对于样条曲线，交点的提取由于索引定义的问题，按照上述规则会将所有构成点均视为角点，导致误检较多。因此，在角点粗提取中会排除样条曲线，仅针对直线和圆弧进行交点检测。通过该方法，能够初步获得角点的候选集。

观察图 3.3 中的标注结果，可以发现自动提取的边缘点和角点存在一定的误差和遗漏。且粗角点检测中未考虑样条曲线。为此，本文引入了人工精修环节，对自动标注的结果进行校正和补充。具体而言，使用点云处理软件 CloudCompare 对点云进行展示，人工检查每个模型的边缘和角点标注，修正错误标注并补充遗漏的特征点。通过该流程，最终生成了高质量的点云几何特征标注数据集 ABC-Corner。

ABC-Corner 数据集在 ABC 数据集的基础上增加了对于模型尖锐角点的准确标注，极大地提升了数据集在点云几何特征检测任务中的适用性。该数据集包含了多样化的几何形状和复杂结构，能够有效支持深度学习模型的训练与评估。在平衡人工标注难度及本文训练数据量要求后，最终的 ABC-Corner 包含了 ABC 数据集 chunk00 子集中的 1000 个模型，模型的选择主要针对几何特征较为突出的模型进行筛选。每

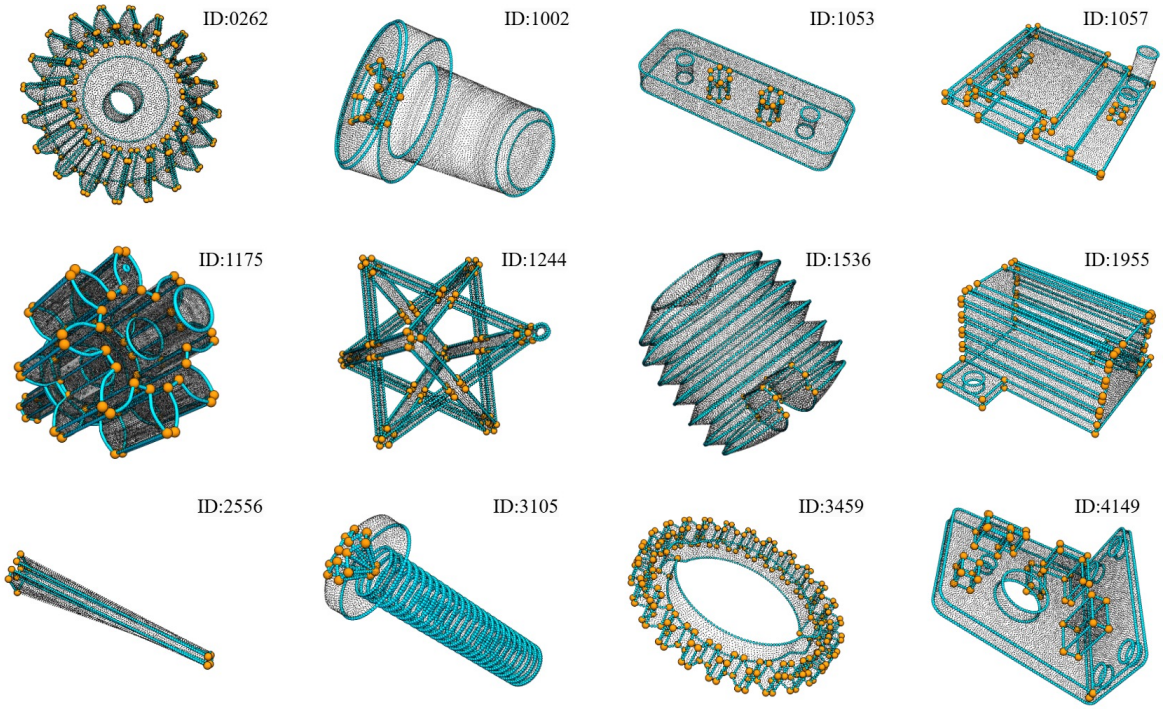


图 3.4　ABC-Corner 数据集中的部分样本及其标注结果。

Figure 3.4　Samples from the ABC-Corner dataset and their annotation results.

个模型均经过上述标注流程处理，生成了包含面点、边缘点和角点标签的点云数据。图 3.4 展示了 ABC-Corner 数据集中的部分样本及其标注结果。

3.3　实验环境与参数配置

进行实验验证前，首先需要明确实验的软硬件环境、数据处理方法、模型训练超参数以及评价指标设计，以确保实验结果的可复现性、科学性和可对比性。本文的实验主要基于自建的 ABC-Corner 数据集进行，涉及两个关键实验任务：点云几何特征的多分类检测，即面、边缘与角点的联合检测；面与边缘的二分类检测。设置这两个任务的主要原因在于，部分现有的对比方法仅具备边缘特征检测的能力，为了全面评估本文方法的有效性，除了多分类检测外，本文也在 ABC 数据集上针对单独的边缘提取任务与这些方法进行了对比。本节将详细阐述实验的完整流程，包括数据预处理策略、训练环境与超参数配置、法向量估计方法的比较，以及多维度评价指标体系的设计。

3.3.1 软硬件环境与开发框架

为了确保实验的可复现性，本文明确记录了实验的所有环境信息。计算硬件采用一台配备 NVIDIA RTX 3090 GPU（显存 24 GB）的高性能工作站，CPU 为 Intel Core i7-10700K，内存 256 GB。软件环境为 Ubuntu 22.04 LTS 操作系统。算法实现基于 PyTorch 2.10 深度学习框架，使用 Python 3.10 编程语言和 CUDA 13.0 计算平台以充分发挥 GPU 的计算能力。为了便于代码的开发、调试和版本管理，采用 PyCharm 作为集成开发环境，并使用 Git 进行版本控制。此外，采用 scikit-learn 库用于计算各种评价指标，numpy 和 scipy 库用于数值计算和科学计算[26-29]。

3.3.2 数据预处理与划分方案

ABC-Corner 数据集中包含 1000 个点云及其对应的几何特征标签，其中各个点云的点数不同。根据章节 2.4中描述的 NECDNet 网络架构可知，网络的输入为逐点的多尺度特征矩阵。因此，在数据预处理阶段，首先需要从数据集原始点云中计算各个点的多尺度特征矩阵。根据章节 2.3中描述的方法进行特征矩阵的计算，值得注意的是数据归一化在计算过程中进行了实现，输入的点云无需进行点数或尺寸的归一化。在特征计算过程中采用了并行计算的方式，以加速处理过程，进程数为 16。得到逐点特征矩阵后，后续的数据则以点为单位进行处理，ABC-Corner 的数据点总数达到了千万级别。

本文采用分层 k 折交叉验证（Stratified k-Fold Cross-Validation）的方法进行数据集划分。本实验选取 $k = 5$，即采用 5 折分层交叉验证，此时训练集数据占比为 60%，验证集占比为 20%，测试集占比为 20%，能够在保证训练数据充足的同时，提供足够的验证和测试数据用于模型评估。交叉验证方法具体而言，首先将整个数据集按照标签类别比例进行分层，随机划分为 5 个互不重叠的子集。在每一轮实验中，轮流选取其中 1 个子集作为测试集，1 个子集作为验证集，其余 3 个子集作为训练集。通过这种方式，共进行 5 次独立的训练与评估过程，确保每个子集都曾作为测试集被评估过。最终的实验结果取这 5 次实验的平均值，以减小随机划分带来的偶然误差，从而更准确地反映模型的泛化能力。

此外，在各折数据划分时，本文采用了随机分层划分的方式，确保每个子集中各类别的分布比例与整个数据集保持一致。这种分层划分方法能够有效避免由于随

机划分导致的模型训练偏差，即将某些类别过多地分配到训练集或测试集中，从而导致模型在某些类别上的性能评估不准确。通过分层划分，能够确保模型在训练和评估过程中都能接触到各个类别的样本，从而更全面地评估模型的性能。

3.3.3 训练超参数配置

网络模型的训练还需要进行超参数配置，本文的设置主要目的是在计算效率与模型性能之间取得最优平衡。部分参数在进行多次训练后的模型评估进行选择，确保最终模型的稳定性和性能。各项参数的具体配置如下。

1） 批量大小与数据加载

为了充分利用 GPU 显存并提高训练效率，批次大小（Batch Size）设定为 20,000。数据加载器（DataLoader）的并行工作线程数配置为 16，以实现高效的多线程数据读取和预处理，减少 GPU 的空闲时间。为了避免因随机数据顺序导致的模型不稳定，采用了随机 Seed 固定的方法，实现数据加载的可重复性，确保实验的可复现性。

2） 训练轮次与早停策略

训练过程的轮次（Epoch）设置为 64，为了防止过拟合现象的发生，实现了早停机制：在验证集上的 F1 分数连续 10 个 Epoch 不再改善时，训练自动停止。这种策略能够在保证模型性能的同时，避免不必要的计算浪费。

3） 优化器与学习率策略

模型优化采用 Adam 优化器，该优化器结合了动量法和自适应学习率的优点，特别适合处理稀疏梯度和高维优化问题[30]。本文中 Adam 优化器的超参数设置为：一阶矩估计系数 $\beta_1 = 0.9$，二阶矩估计系数 $\beta_2 = 0.999$，数值稳定性参数 $\epsilon = 10^{-8}$。

模型的学习率设置采用余弦退火（Cosine Annealing）学习率衰减策略，其数学表达式如式 3.1所示。其中 $\eta_{\max} = 0.001$ 为最大学习率，$\eta_{\min} = 1e^{-5}$ 为最小学习率，t 为当前 epoch，$T = 64$ 为训练总 epoch 数。这种策略能够确保网络在训练初期快速收敛，在训练后期通过较小的学习率进行精细调优，提高最终模型的性能和稳定性[31]。

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\left(1 + \cos\left(\pi \frac{t}{T}\right)\right) \tag{3.1}$$

3.3.4 类别不平衡问题处理

这里需要补充实验数据

点云中三类几何特征的分布严重不平衡，具体统计如表 3.1所示。面点占总数的约 85%，边缘点占 12%，而角点仅占 3%。这种极度不平衡的类别分布会导致网络在训练过程中被大量简单样本（面点）主导，导致对少数类（特别是角点）的学习不充分。例如，模型可能会倾向于将所有点预测为面点，以获得较高的整体准确率，但这显然无法满足实际应用中对边缘和角点的检测需求。因此，针对这一问题，本文采用了 Focal Loss 辅以针对性的数据上采样（Oversampling）策略来共同缓解类别不平衡带来的影响。

表 3.1 ABC-Corner 数据集中各类几何特征的分布统计。

Table 3.1 Distribution statistics of geometric features in the ABC-Corner dataset.

几何特征类别	点数量	占比 (%)	样本数/模型
面点（Face）	852,000,000	85.2%	852,000
边缘点（Edge）	120,000,000	12.0%	120,000
角点（Corner）	28,000,000	2.8%	28,000
总计	1,000,000,000	100%	1,000,000

在损失函数的设计上，本文采用了 Focal Loss[20] 作为主要的训练损失函数，如第 2.4.3 章所述。Focal Loss 通过引入动态加权因子 $(1-p_t)^{\gamma}$，能够自适应地降低易分类样本（面点）的权重，同时增加难分类样本（边缘点与角点）的权重。本文中聚焦参数 γ 设为 2.5，类别权重均衡因子 α 对三类设置为 $[0.2, 0.3, 0.5]$，即对角点赋予最高的权重。

此外，为了进一步增强训练数据的多样性和模型的鲁棒性，本文对少数类样本进行了上采样处理。通常的数据平衡策略是将所有类别的样本数量上采样至一致，但在本文的任务中，角点的数量级远小于面点和边缘点（仅占边缘点的约 1/4）。在进行面点与边缘点的二分类任务时，通过 Focal Loss 的权重调整已能较好地改善类别不平衡问题。然而，角点样本的极度稀缺仍是制约多分类性能的瓶颈。

因此，本文的策略是仅对角点进行上采样，将其数量补充至与边缘点一致，从而将三类的数量比例调整为，面: 边缘: 角点 = 100:14:14。这种策略旨在重点解决角点学习不足的问题，避免了对面点和边缘点进行不必要的过度采样，还降低了由于

过度上采样导致的过拟合风险。为了验证该策略的有效性——即探究是仅对角点上采样更好，还是对边缘点和角点同时上采样至与面点一致更好——本文在后续的消融实验（章节 3.5）中进行了详细的对比分析与指标评估。

3.3.5 法向量估计方法的选择与对比

法向量是 NECDNet 计算特征的重要输入之一，其精度直接影响检测结果。第 2.2.3节已详细论述了本文所涉及的两种法向量估计方法：基于 PCA 的点云法向量估计与基于 CAD 网格模型的法向量估计。基于 PCA 的方法适用于非结构化点云，而基于 CAD 网格模型的方法能够提供精确的几何真值。

为了验证法向量估计精度对检测网络性能的影响，本文设计了对比实验，分别训练了两个版本的 NECDNet 模型：一个使用基于 PCA 方法估计的法向量作为输入特征（记为 NECDNet），以模拟原始数据为点云；另一个使用从 CAD 网格模型提取的精确法向量作为输入（记为 NECDNet†），作为原始数据为网格模型时的对照组。后续实验对两者在 ABC-Corner 数据集上的检测性能进行定量评估和对比分析，以验证法向量精度对边缘与角点检测结果的显著影响。

3.3.6 评价指标设计

为了全面评估 NECDNet 在点云几何特征检测任务中的性能，本文采用了多种评价指标，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）、交并比（Intersection over Union, IoU）和马修斯相关系数（The Matthews Correlation Coefficient, MCC）[19,32-33]。这些指标能够从不同角度反映模型的分类效果，特别是在处理类别不平衡问题时，精确率和召回率尤为重要。评价指标主要通过混淆矩阵（Confusion Matrix）进行计算，混淆矩阵记录了模型在各类别上的预测结果与真实标签的对比情况。混淆矩阵的行表示真实类别，列表示预测类别，其中对角线上的值表示正确分类的数量，非对角线上的值表示分类错误的数量。基于混淆矩阵，可以计算出各项评价指标，从而全面评估模型的性能[34]，各项指标的具体计算公式请见附录B。

本文中分类任务为三分类，类别分别为：`f`（面点）、`e`（边缘点）、`c`（角点）。可以构建对应的混淆矩阵，如表 3.2所示。表中，TP（True Positive）表示正确预测为正类的数量，TN（True Negative）表示正确预测为负类的数量，FP（False Positive）

表示错误预测为正类的数量，FN（False Negative）表示错误预测为负类的数量。

表 3.2 三分类任务的混淆矩阵示例。

Table 3.2 Example of confusion matrix for three-class classification task.

	预测类别			
真实类别	f	e	c	总计
f	$TP_{\mathtt{f}}$	$FP_{\mathtt{e}}$	$FP_{\mathtt{c}}$	$P_{\mathtt{f}}$
e	$FN_{\mathtt{f}}$	$TP_{\mathtt{e}}$	$FP_{\mathtt{c}}$	$P_{\mathtt{e}}$
c	$FN_{\mathtt{f}}$	$FN_{\mathtt{e}}$	$TP_{\mathtt{c}}$	$P_{\mathtt{c}}$
总计	$N_{\mathtt{f}}$	$N_{\mathtt{e}}$	$N_{\mathtt{c}}$	N

上述评价指标的标准公式是基于二分类任务进行设计的。对于多分类任务，需要在指标的计算或者混淆矩阵的构建上进行调整。例如 Erbani et al.[35] 提出基于传输的混淆矩阵构建方法，建立在最优传输理论和最大熵原理之上，针对多标签或软标签分类复杂任务提出了一种新的混淆矩阵构建方法。此外，在指标计算上可以采用宏平均（Macro-Averaging）和微平均（Micro-Averaging）两种方式[19,32]。宏平均是对每个类别分别计算指标，然后取平均值，适用于类别分布不均衡的情况；而微平均则是将所有类别的预测结果合并后计算指标，更适用于类别分布均衡的情况。

由于本文的分类任务较为简单，且为了与目前的其余最新方法（state-of-the-art, SOTA）进行对比，本文中主要采用一般的混淆矩阵构建方法加宏平均的方式计算各项评价指标。具体而言，设 C 为类别总数，M_c 为类别 c 的评价指标值，则宏平均的计算公式如 (3.2) 所示。本文中 $C=3$，分别对应面、边缘、角点三类。

$$M_{\text{macro}} = \frac{1}{C}\sum_{c=1}^{C} M_c \tag{3.2}$$

3.4 对比实验结果及分析

为了全面评估 NECDNet 的性能，本节将其与现有的 SOTA 方法进行了对比。对比实验涵盖两个层面：一是针对边缘与角点联合检测的三分类任务，对比方法包括基于协方差分析的 CA 方法[4]、两阶段检测法 TECD[1] 以及深度学习方法 PIE-Net[36]；二是针对纯边缘检测的二分类任务，对比方法包括 PCEDNet[7] 和 BoundED[8]。

3.4.1 边缘与角点联合检测结果分析

在边缘与角点的联合检测任务中，表 3.3 展示了各方法在 ABC-Corner 数据集上的定量评估结果。为了确保结果的统计可靠性，所有方法的报告数据均为 5 折交叉验证的平均值。其中 PIE-Net 的作者仅开源了其网络模型部分，并未提供完整的数据处理过程，难以进行复现，因此本文直接引用其论文中的数据进行大致对比。对于 CA 和 TECD 方法，本文在 ABC-Corner 数据集上进行了重新实现和评估，以确保对比的公平性和准确性。对于 NECDNet，本文分别评估了使用基于 PCA 的法向量输入（NECDNet）和使用从 CAD 网格模型提取的精确法向量输入（NECDNet†）两种版本，以验证法向量精度对检测性能的影响。

表 3.3 ABC-Corner 数据集上各边缘与角点检测方法的宏平均（Macro-averaging）指标评分。

Method	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
CA [4]	0.415	0.616	0.420	0.616	0.346	0.276
TECD [1]	0.472	0.642	0.513	0.642	0.438	0.526
PIE-NET [36]	0.615	0.814	0.686	0.935	0.577	0.718
NECDNet (Ours)	0.646	0.857	0.715	0.983	0.616	0.833
NECDNet† (Ours)	**0.765**	**0.933**	**0.815**	**0.995**	**0.743**	**0.943**

PIE-Net 的数据基于其作者提供的评估结果整理得出。
† 表示使用从 Mesh 模型估计的法向量。

表 3.3 的总体评估结果显示，NECDNet 在各项核心指标上均显著优于现有方法。具体而言，NECDNet 的宏平均 F1 分数达到 0.715，相较于 PIE-Net 提升了约 4.2%；在使用网格法向量（NECDNet†）时，F1 分数更是提升至 0.815，展现了卓越的特征提取能力。在反映分类一致性的 MCC 指标上，NECDNet† 达到 0.943，远超 PIE-Net (0.718) 和 TECD (0.526)，证明了模型在处理极度不平衡样本时的鲁棒性。

为了进一步揭示各方法在处理复杂几何结构时的具体表现差异，图 3.5 选取了四个具有代表性的复杂机械零件进行可视化对比，其中绿色、红色和灰色点分别代表边缘、角点和平面点。对应地，表 3.4 和表 3.5 详细列出了这四个对象在各方法下的分类别指标（Precision, Recall, F1, Accuracy, IoU, MCC）。下文将结合上述整体统计结果与具体案例的细节表现，对传统几何方法和深度学习方法分别展开深入剖析。

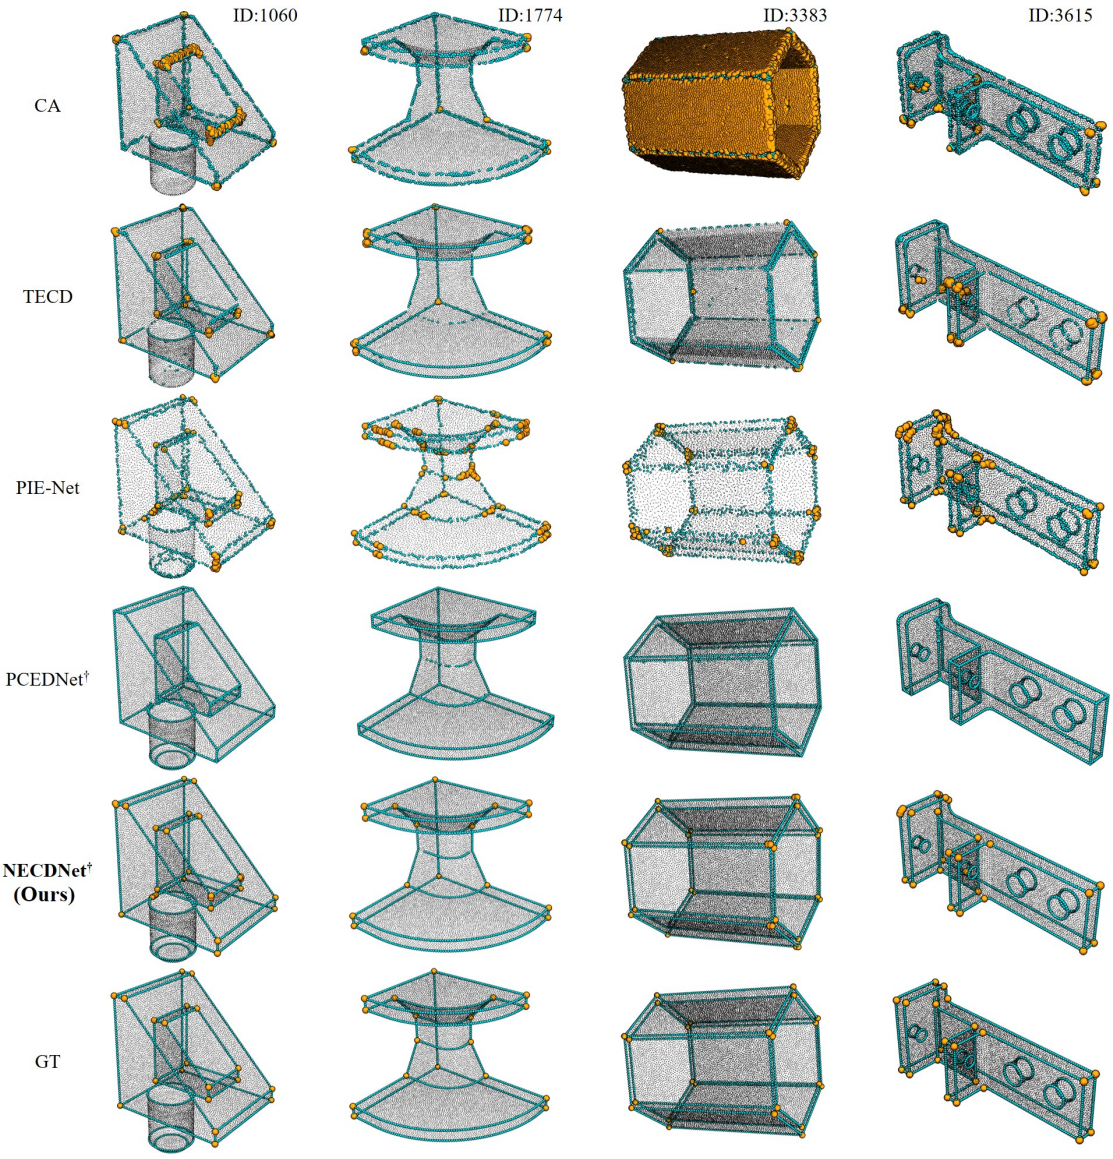


图 3.5 ABC-Corner 数据集上各方法的边缘与角点检测结果可视化对比。本文方法（Ours）取得了最佳的检测效果。CA 和 TECD 缺乏鲁棒性，PIE-Net 检测精度不足，PCEDNet 表现出良好的边缘检测能力但无法检测角点。

1） 与传统几何分析方法的对比

传统的几何分析方法，如 CA（Covariance Analysis）和 TECD（Two-Stage Edge-Corner Detection），主要依赖手工设计的几何特征和基于阈值的判决规则。在本文的对比实验中，针对 ABC-Corner 数据集，CA 方法中边缘检测阈值设置为 0.085，角点检测阈值设置为 0.14。TECD 方法的边缘阈值 λ 设为 1.0，同时保留了其原论文中针对角点检测的其他阈值设置[1]。本文为 CA 和 TECD 方法选择的参数均经过了在 ABC-Corner 数据集上的网格搜索优化，以确保其在该数据集上的最佳性能表现。

CA 方法基于协方差矩阵的特征值进行阈值判定，具有计算简单、速度快的优

表 3.4　图 3.5 中四个点云对象的分类别详细指标评分：Precision, Recall, F1。

Method	Precision(↑)			Recall(↑)			F1(↑)		
	Face	Edge	Corner	Face	Edge	Corner	Face	Edge	Corner
CA[4]	0.975	0.303	0.001	0.582	0.614	0.303	0.729	0.405	0.002
TECD[1]	0.986	0.705	0.062	0.980	0.762	0.158	0.983	0.732	0.089
PIE-NET[36]	0.995	0.673	0.278	0.950	0.898	0.964	0.972	0.770	0.432
NECDNet (Ours)	**0.999**	0.970	0.519	0.998	**0.987**	0.921	**0.999**	0.978	0.664
NECDNet† (Ours)	**0.999**	**0.994**	**0.540**	**1.000**	0.974	**0.987**	**0.999**	**0.984**	**0.698**

表 3.5　图 3.5 中四个点云对象的分类别详细指标评分：Accuracy, IoU, MCC。（续表）

Method	Accuracy(↑)			IoU(↑)			MCC(↑)
	Face	Edge	Corner	Face	Edge	Corner	
CA[4]	0.582	0.614	0.303	0.573	0.254	0.001	0.184
TECD[1]	0.980	0.762	0.158	0.967	0.578	0.046	0.707
PIE-NET[36]	0.950	0.898	0.964	0.946	0.626	0.275	0.759
NECDNet (Ours)	0.998	**0.987**	0.921	0.997	0.957	0.496	0.972
NECDNet† (Ours)	**1.000**	0.974	**0.987**	**0.999**	**0.968**	**0.536**	**0.983**

PIE-Net 的数据基于其作者提供的评估结果整理得出。
† 表示使用从 Mesh 模型估计的法向量。

点，但在实际应用中存在显著局限性。首先，CA 方法采用单一固定阈值进行分类判定，这种设计对阈值的选择极为敏感，而实际物体的几何复杂度差异巨大，薄壳结构和厚重物体的尖锐程度存在数量级的差异，统一的阈值无法有效处理如此多样的场景。如图 3.5 所示的可视化结果，CA 检测出的边缘线条极其不连续且包含大量噪声点（误检），可视化结果对应到表 3.4 中的数据可见：CA 在边缘类别的 F1 分数仅为 0.405，IoU 仅为 0.254。而且由于采用单一尺度的邻域分析，CA 在处理如对象 3383 这样的薄壁结构时，容易同时包含正反两个面的几何信息，导致特征值计算异常。更为重要的是，CA 缺乏专门的角点检测机制，这在表 3.4 数值上体现为其角点检测 Precision 仅为 0.001，F1 分数更是低至 0.002，几乎完全丧失了角点识别能力。其整体 MCC 仅为 0.184，说明预测结果与真实值之间的相关性极低。

TECD 方法试图通过两步策略改进检测效果，即先检测边缘再基于边缘定位角点。相较于 CA，TECD 在边缘检测上取得了一定进步，表 3.4 显示其具体案例的边缘 F1 提升至 0.732。然而，其级联设计的缺陷在角点检测中暴露无遗：角点检测完全依赖于第一步边缘提取的质量，早期错误会被后续步骤放大。从表 3.4 可以看出，

尽管 TECD 的边缘召回率尚可，但其角点 Recall 仅为 0.158，F1 分数仅为 0.089，这表明绝大多数角点被漏检。此外，TECD 的整体分类一致性 MCC 为 0.707，虽然优于 CA，但仍远低于 NECDNet 的 0.972。这种性能差距主要源于 TECD 对多个手工阈值的敏感性，难以通过单一参数设置适应图 3.5 中多样化的几何特征。

相比之下，NECDNet 在各个维度上均展现出压倒性优势。在这些典型复杂对象的测试中，NECDNet 在保持极高面部识别精度（Precision $>$ 0.99）的同时，将边缘 F1 分数提升至 0.978，角点 F1 分数提升至 0.664（Mesh 法向版本更达到 0.698）。特别是在 MCC 指标上，NECDNet 达到了 0.972，比 TECD 高出 37.5%。这得益于端到端的特征学习机制，使其能够自适应地处理不同尺度的几何结构，有效克服了传统方法参数敏感和级联误差积累的问题。

2） 与现有深度学习方法的对比

在深度学习方法中，PIE-Net（Point-wise Implicit Embedding Network）是目前最有代表性的工作。然而，从图 3.5 的可视化对比中可以观察到，PIE-Net 虽然能够检测出大致的轮廓，但在角点区域的识别上存在明显的模糊，且在平滑曲面上容易产生误检点。基于 PIE-Net 作者提供的评估数据，本文结合 ABC-Corner 数据集上的实验结果，对其各项指标进行了重新计算与整合。

结合表 3.4 和表 3.5 针对这四个典型复杂对象的定量评估，NECDNet 相比 PIE-Net 展现出了显著的性能提升。具体而言，PIE-Net 在角点检测任务上的 Precision 仅为 0.278，虽然 Recall 高达 0.964，但这极低的精确率说明其高召回率是建立在大量误检（过分割）的基础上的。这直接导致其角点 F1 分数仅为 0.432，意味着其检测的可信度较低。作为对比，NECDNet 在保持高召回率（0.921）的同时，将角点 Precision 提升至 0.519（提升 86.6%），使得 F1 分数达到 0.664（提升 53.7%）；若使用 Mesh 法向量，F1 更达到 0.698。在边缘检测方面，NECDNet 的边缘 F1 (0.978) 也显著优于 PIE-Net 的 0.770。此外，在反映整体分类质量的 MCC 指标上，NECDNet 达到 0.972，远超 PIE-Net 的 0.759。

PIE-Net 性能受限的根本原因在于其采用的双分支架构设计。该方法使用两个独立的分支分别处理边缘和角点检测，这种独立设计割裂了边缘与角点作为相互关联几何特征的内在联系，导致网络难以利用边缘信息来辅助角点定位。由于缺乏对边缘与角点特征差异性的联合鉴别机制，PIE-Net 容易产生较多的误检（False Positives），

正如其仅为 0.278 的角点 Precision 所示。相比之下，NECDNet 通过统一的多尺度特征融合架构和分层分类器，能够更有效地捕捉局部几何结构中的细微差异，特别是利用从网格模型估计的精确法向量作为输入时，模型的整体 F1 分数和分类一致性均达到最优水平，展现了极高的鲁棒性。

3.4.2 纯边缘检测结果分析

表 3.6 ABC 数据集上各边缘检测方法的指标评分。

Method	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
PCEDNet-2c†[7]	0.735	0.984	0.822	0.970	0.597	0.808
BoundED-2c[8]	**0.959**	0.857	0.875	0.987	0.778	0.869
NECDNet-2c (Ours)	0.708	0.988	0.825	0.980	0.702	0.827
NECDNet-2c† (Ours)	0.922	**0.992**	**0.956**	**0.996**	**0.915**	**0.954**

PCEDNet 和 BoundED 的数据分别整理自文献[7] 和[8]。
† 表示使用从 Mesh 模型估计的法向量。

为了验证模型在通用边缘检测任务上的有效性，表 3.6 展示了在 ABC 数据集上仅关注边缘二分类任务时的对比结果。由于 PCEDNet 和 BoundED 未开源代码，我们引用了其论文中的数据进行对比。本文的模型在该部分实验中进行了调整，将边缘和角点合并为一个类别进行二分类训练，以适应纯边缘检测的评估需求，记作 NECDNet-2c 和 NECDNet-2c†（分别对应使用基于 PCA 的法向量和使用从 CAD 网格模型提取的精确法向量）。

表 3.6 的结果显示，NECDNet 在边缘检测任务上同样表现出色。使用 Mesh 法向量的 NECDNet-2c† 在 Precision、Recall、F1、Accuracy、IoU 和 MCC 等所有指标上均显著优于 PCEDNet 和 BoundED，尤其是在 F1 分数上达到 0.956，远超 PCEDNet 的 0.822 和 BoundED 的 0.875。这表明 NECDNet 不仅能够准确地提取边缘特征，还能有效地减少误检和漏检，提高了整体的检测质量。而利用基于 PCA 的法向量输入的 NECDNet-2c 也表现出较强的竞争力，尤其是在 Recall 上达到 0.988，说明模型能够尽可能多地检出潜在边缘，虽然 Precision 相对较低（0.708），但整体 F1 分数仍然优于 PCEDNet。

除了定量指标对比，图 3.5 的可视化结果也直观展示了各方法在边缘检测上的表现。PCEDNet（图示第四行）作为一个专门的边缘检测网络，能够清晰、连续地提

取出物体的几何轮廓，展现了良好的边缘提取效果，但其局限性在于仅能输出二值的边缘预测结果，无法区分边缘与角点。此外，PCEDNet 使用的是基于网格模型的法向量。与此相比，本文提出的 NECDNet 在边缘检测的视觉质量上与其相当，均能提取出锐利且干净的边缘线条，同时还能准确识别出角点特征。对于 BoundED，由于其作者未将模型开源，依据其论文中的描述进行复现时，复现的结果与其论文中的结果存在较大差异，故本文舍弃了该方法的可视化对比，仅在定量指标上进行了对比分析。

整体实验表明，NECDNet 在边缘与角点的联合检测任务中表现出色，并且在纯边缘检测任务中同样具有竞争力。特别是使用从 CAD 网格模型提取的精确法向量作为输入时，NECDNet 的性能得到了显著提升，进一步验证了法向量估计精度对检测性能的关键影响。

3.4.3 法向量估计精度对检测的影响

在深入分析实验结果后，本文发现法向量的精度是影响检测性能的关键因素。NECDNet 的核心输入特征——包括法向角差、法向分布及投影法向模长——均直接依赖于法向量的计算。从表 3.3 可以看出，仅通过改变法向量的来源，模型的 F1 分数就从 0.715 提升至 0.815，增幅达 13.9%，这充分体现了法向量对检测性能的决定性影响。

为了量化这一影响，本文详细对比了两种法向量估计方式。基于点云局部表面最小二乘拟合的方法假设邻域点位于一个光滑平面上。然而，在物体的尖锐边缘和角点附近，这一假设被打破：邻域点横跨了两个或多个法向截然不同的平面。此时，拟合算法会产生平滑过渡的” 平均化” 法向，而非真实的表面法向。

为了更深入地理解法向量精度对检测性能的影响，我们进行了详细的数值分析。考虑一个尖锐的角点邻域：邻域点分别来自两个法向为 $\mathbf{n}_1$ 和 $\mathbf{n}_2$ 的平面，两个平面的夹角为 90 度。当使用基于最小二乘拟合的法向估计方法时，得到的平均法向 $\mathbf{n}_{\text{avg}}$ 会被迫介于两个真实法向之间，其与真实法向的夹角为 45 度。这种方向上的偏差虽然看似不大，但会直接影响法向角差、法向分布方差等特征的计算。由于这些特征是分类器的核心输入，45 度的法向偏差会导致角点和边缘点的特征值在特征空间中变得接近，从而显著增加分类的困难。

图 3.6 的对比实验清晰地展示了这种影响。在使用点云估计法向的结果

（图 3.6(c)）中，由于邻域法向的平滑化，原本尖锐的边缘特征和角点特征在特征空间中的表现变得模糊和重叠。这种混淆直接导致网络将部分边缘点误判为角点，或将角点误判为边缘点，从而产生 0.715 的 F1 分数。相反，当使用从 Mesh 模型计算出的法向量时（图 3.6(b)），法向量能够精确反映物体的几何拓扑结构。特别是在尖锐特征处，Mesh 法向能够保留法向的突变特征，而不会出现平滑化造成的方向混淆。这使得网络能够准确捕捉到微小的曲率变化，从而实现近乎完美的分类效果，F1 分数达到 0.815。

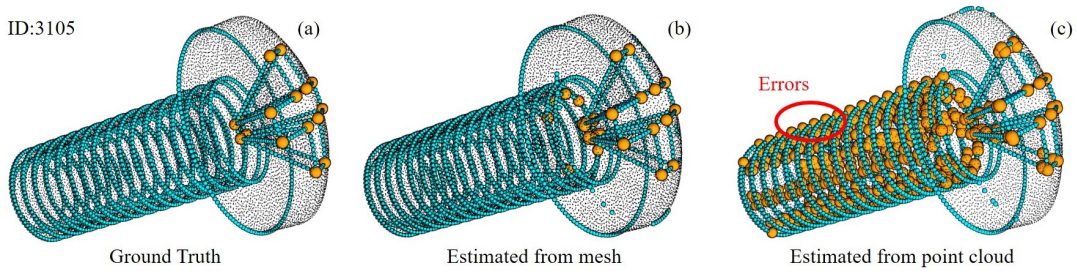


图 3.6 法向量估计精度对检测结果的影响分析：(a) 检测结果真值（Ground Truth）；(b) 使用从 Mesh 估计的法向量得到的检测结果，F1 分数为 0.815；(c) 使用从点云估计的法向量得到的检测结果，F1 分数为 0.715。使用点云估计的法向量会导致更多的边缘点被误分类为角点，在图中表现为红色区域的增加。

上述分析表明，虽然 NECDNet 具有强大的多尺度特征提取能力，但其对输入法向量的精度存在较高的依赖性。在实际应用场景中，往往难以获取完美的网格模型，仅能基于含噪点云进行法向估计，这在一定程度上限制了模型的性能上限。因此，如何在缺乏网格先验的情况下，缩小基于点云与基于网格的检测性能差距，是后续研究值得深入探讨的方向。

未来的工作可以从以下几个维度展开：首先，可以尝试集成更为先进的法向估计算法，特别是基于深度学习的方法（如 PCPNet、NestNet 等），这类方法相较于传统的 PCA 拟合更能有效保留尖锐几何特征，有望为 NECDNet 提供更高质量的输入先验。其次，探索将法向估计模块与特征检测网络进行端到端的联合优化也是一个极具潜力的方向。通过设计可微的法向估计算子，使网络能够根据最终的检测目标自适应地调整法向预测，而非依赖于预计算的固定特征，可能从根本上解决法向平滑带来的特征模糊问题。此外，还可以研究引入更加鲁棒的统计不变量或融合多模态几何信息，以降低模型对单一法向特征的敏感度，从而进一步提升其在真实复杂场景下的泛化能力与稳定性。

3.5 消融实验分析

为了验证 NECDNet 各个模块设计的合理性，本节基于 ABC-Corner 数据集开展了多维度的消融实验。实验设定随机抽取 100 个模型对应的点云数据用于训练，另取 100 个用于测试，控制变量以确保结论的可靠性。主要包括对网络学习的输入特征维度、多尺度参数选择、数据处理策略等方面的参数分析。通过对比不同配置下训练得到的模型定性评价指标，探讨各设计选择对模型性能的具体影响。

3.5.1 特征维度的影响

特征描述子的选择直接决定了网络输入信息的丰富程度与有效性。在构建特征向量时，除了最终选用的 6 个标量特征（$\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i$）外，实验还尝试引入了 3 维 PCA 特征值向量 σ_i 和 3 维法向量差均值向量 $\bar{\Delta\mathbf{n}}_i$。表 3.7 展示了不同特征维度组合的性能差异。各组合从上至下依次代表：仅使用基于位置的特征、仅使用基于法向的特征、使用所有标量特征、使用所有标量特征加上法向差均值向量、使用所有标量特征加上 PCA 特征值向量、使用所有特征。

表 3.7 特征维度选择消融实验结果。

特征组合	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i)$	0.647	0.847	0.654	0.977	0.601	0.790
$(\bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.680	0.922	0.719	0.986	0.656	0.886
$(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	**0.754**	**0.946**	**0.805**	**0.996**	**0.735**	**0.946**
$(\kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.714	0.935	0.758	0.994	0.693	0.929
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.739	0.946	0.793	0.995	0.720	0.934
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.743	0.940	0.797	0.994	0.722	0.929

特征计算的具体方法详见章节 2.3.2 所述。

实验结果显示，当模型仅使用 6 个标量特征时，各项评价指标反而达到了最高值。只使用部分特征时，模型性能明显下降，尤其是当仅使用基于位置的特征时，F1 分数仅为 0.654；而仅使用基于法向的特征时，F1 分数提升至 0.719，但仍不如使用标量特征的组合。而引入向量特征后，性能未升反降。分析其原因，$\hat{\boldsymbol{\sigma}}_i$ 和 $\bar{\Delta\mathbf{n}}_i$ 特征维度与其他标量特征相比显著增加，导致特征空间维度过高，训练数据不足以覆盖整个特征空间，进而引发过拟合问题。此外，这些向量特征在尖锐边缘和角点处的分布较为复杂，可能引入了更多的噪声和不稳定性，反而削弱了模型的判别能力。

因此，尽管引入更多维度的特征理论上可以提供更丰富的信息，但在实际训练过程中，过多的特征维度反而可能导致模型性能的下降。最终，使用所有标量特征的组合在保持信息丰富性的同时，避免了过拟合和噪声引入的问题，从而实现了最佳的检测性能。

3.5.2 多尺度参数的选择

多尺度特征融合是解决点云密度不均和特征尺度变化问题的关键。本节对尺度数量和尺度范围（邻域大小 k）进行了探索，有关尺度的定义请见章节 2.2.1。实验设定 k 的取值范围覆盖 8 到 128，尺度数量从 2 增加至 8。表 3.8 表明，随着尺度数量的增加，模型性能呈现先上升后下降的趋势。

表 3.8 多尺度参数选择消融实验结果。

尺度选择 (k)	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
(8, 16)	0.704	0.913	0.751	0.993	0.680	0.910
(8, 16, 32, 64)	**0.743**	**0.940**	**0.797**	0.994	**0.722**	0.929
(8, 16, 32, 48, 80, 128)	0.723	0.927	0.770	**0.995**	0.702	**0.932**
(8, 16, 24, 32, 48, 64, 96, 128)	0.740	0.935	0.795	0.994	0.718	0.930

尺度的定义对应于 KNN 邻域大小 k。

当选择 4 个尺度（$k = 8, 16, 32, 64$）时，模型取得了最佳的 F1 分数和 IoU。当尺度数量过少（如 2 个）时，网络的感受野受限，难以提取宏观的几何结构信息；而当尺度数量过多（如 6 个或 8 个）时，不仅计算开销显著增加，而且大尺度的邻域（如 $k = 128$）引入了过多的无关背景噪声，平滑了局部的尖锐特征，从而抑制了网络的判别能力。因此，4 个尺度的设置在特征丰富度与噪声控制之间取得了最佳平衡。

3.5.3 训练策略的探讨

针对类别不平衡问题，本节对数据处理和样本标注策略进行了系统的对比研究。其中，数据处理主要涉及对各类样本的重采样操作，旨在平衡不同类别点的数量；而标注策略则关注是否对尖锐特征（边缘、角点）进行平滑处理，即是否将其附近一定范围内的邻域点也视为该特征点。

1） 数据重采样策略

在数据重采样方面，实验对比了两种策略。第一种策略是” 边缘与角点重采样”，即对边缘点和角点进行重采样，使其数量与面点数量保持一致，达到 1:1:1 的比例。第二种策略是” 仅角点重采样”，仅对数量最稀少的角点进行适度重采样。

实验结果如表 3.9 所示。两种策略的性能差异极小，F1 分数分别为 0.795 和 0.797，仅相差 0.2%。然而，第一种 1:1:1 的完全平衡策略会使训练数据集规模显著增长，导致训练时长大幅增加。在效率优先的考量下，最终选择了” 仅重采样角点” 的策略。这种选择充分平衡了检测性能与计算成本，既能缓解类别不平衡问题，又避免了过度的数据冗余。

表 3.9　数据重采样策略的消融实验结果。

策略	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
边缘与角点	0.741	**0.941**	0.795	**0.994**	0.721	0.923
仅角点 (Baseline)	**0.743**	0.940	**0.797**	**0.994**	**0.722**	**0.929**

2） 标注平滑策略

在样本标注方面，本文探索了” 平滑尖锐特征” 策略的可行性，这一策略受到边缘检测方法 PCEDNet 中” 平滑边缘” 方法的启发[7]。具体做法是将尖锐特征（边缘、角点）附近一定范围内的邻域点也标记为该特征参与模型训练，在增加少数类数据的同时降低尖锐特征与平滑特征之间的差异。

实验结果如表 3.10 所示。引入平滑策略后，性能反而出现明显下降，F1 分数从 0.797 降至 0.736。这主要是因为边缘点和角点在几何拓扑上具有本质差异。边缘特征具有连续性，温和平滑有助于强化连通性；而角点属于奇异点，具有极高的局部化特征。当人为地扩展角点标签范围到邻域内时，会使原本属于面点或边缘点的邻域点被强制标记为角点，破坏了样本标签的一致性，导致分类器决策边界模糊。因此，最终方案坚持对尖锐特征进行精确的单点监督，不使用平滑策略。

表 3.10　标注平滑策略的消融实验结果。

策略	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
使用平滑	0.706	0.874	0.736	0.989	0.670	0.868
不使用平滑 (Baseline)	**0.743**	**0.940**	**0.797**	**0.994**	**0.722**	**0.929**

3.6 本章小结

本章系统地评估了 NECDNet 在点云几何特征检测任务中的性能。首先，详细介绍了 ABC-Corner 数据集的构建流程及实验参数配置。对比实验结果表明，NECDNet 在边缘与角点联合检测及纯边缘检测任务中均优于现有的传统方法及深度学习模型，且法向量精度的分析进一步证实了高质量几何先验对尖锐特征检测的重要性。在消融实验中，验证了特征选择与多尺度架构的合理性。特别是针对训练策略的深入探讨，明确了” 仅角点重采样” 在兼顾性能与效率上的优势，并通过对比标注策略，揭示了保持角点拓扑奇异性对于分类决策边界的重要性，否定了平滑标注在角点检测中的适用性。本章工作确立了 NECDNet 的最佳配置，证明了其从复杂点云中提取高质量几何特征的能力，为下游机器人感知任务提供了可靠支持。

第四章　考虑边缘与角点接触的机器人抓取规划

4.1　引言

机器人抓取规划是机器人操作中不可或缺的步骤，其目标是确定机械手与目标物体之间的接触点，以实现稳定且可靠的抓取。抓取规划的方法多种多样，涵盖了从基于模型的方法到基于学习的方法。其中基于模型的方法通常依赖于物体的几何信息，通过分析物体表面的形状特征来选择合适的接触点。基于学习的方法则利用大量的抓取数据，通过训练神经网络等机器学习模型来预测最佳的抓取位置。在已知物体几何模型的情况下，例如工业场景下的零件分拣、码垛任务，基于模型的抓取规划方法因其解释性强、计算效率高和精确性而被广泛应用[37-38]。

在基于模型的抓取规划方法中，传统的规划方法通常侧重于面接触，忽略了边缘和角点等几何特征的潜在优势[39-40]。然而，在实际应用中，边缘和角点接触往往能够提供更高的抓取适应性和灵活性，特别是在处理复杂形状，或物体所处环境不适用面接触时。因此，本文针对物体的几何特征，提出了一种接触点采样与配对方法，结合软接触模型对抓取稳定性进行评估，并引入抓取增强策略以提升整体抓取性能。

基于模型的抓取规划方法，输入的物体模型通常以三角网格的形式表示，最后输出一系列的手爪相对物体的 6 自由度位姿以及对应的手爪宽度、抓取稳定评分等参数。本文的方法采用基于采样点进行抓取规划，如图 4.1，规划流程包含几何特征检测、抓取配置检测及稳定性评估等关键步骤。图中的物体为本文单独进行构建的，命名为箭头（Arrow），目的是展示三种不同几何特征（面、边、角）能实现的六种接触方式（面-面，面-边，面-角，边-边，边-角，角-角），后续的相关方法具体介绍也将以该物体为示例。

本文的抓取规划算法具体而言，首先通过类别感知的体素采样方法，均衡地从物体表面的面、边、角区域采样潜在接触点。其次，本文设计了特征化的接触检测器，分别针对面接触、边接触和角接触进行检测，得到各种查询点对应的潜在接触点对。随后，基于法向量约束和几何位置的筛选规则，实现对偶接触点的配对。之后通过抓取增强策略提升抓取数量并进行手爪与被抓物体的碰撞检测。最后，采用软

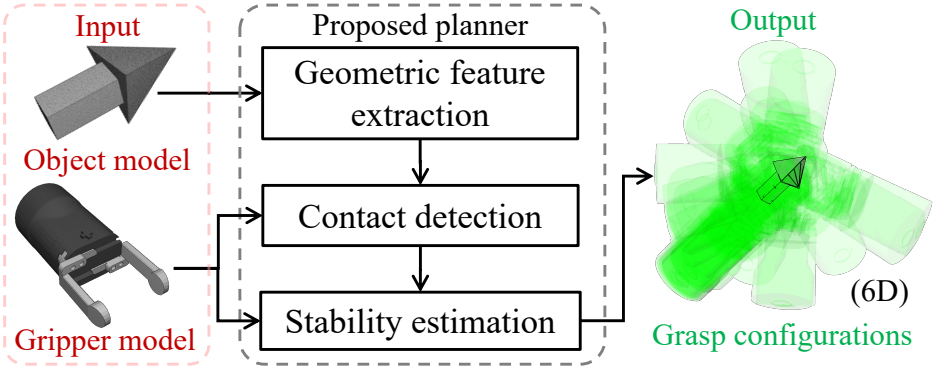


图 4.1　基于几何特征的机器人抓取规划框架

Figure 4.1　Robotic grasp planning framework based on geometric features.

接触模型对生成的抓取配置进行稳定性评估，得到最终的稳定抓取配置。

4.2　类别感知的接触点采样

基于采样点进行抓取规划的方法，首先需要从物体表面获取潜在的接触点。然而，若直接采用全局采样方法，物体的面（Face）、边（Edge）和角（Corner）区域的采样分布将呈现严重的“长尾”特征：即由于面区域占据了绝大部分表面积，接触候选点将主要集中在面上，而极少落在边或角上。这种分布不均将导致抓取规划难以充分利用物体的几何边缘特性，有悖于本文的研究目标。

为此，本文提出了一种类别感知的体素采样方法。该方法首先对物体表面的点云进行几何特征标记，随后在每个类别内独立进行采样。这不仅确保了不同几何区域（面、边、角）能获得数量近似的接触样本，避免了长尾问题，还有效提升了接触样本的多样性。本文将最终的采样点集记为 $\mathcal{S} = \{\mathbf{s}_i\}_{i=1}^{m}$，其中 m 为采样点总数，$\mathbf{s}_i$ 对应的几何特征标签记为 f_i，其取值范围为 $\{\mathtt{f}, \mathtt{e}, \mathtt{c}\}$，分别代表面、边和角。基于类别的采样结果如图 4.2所示，面区域（蓝色）、边区域（橙色）和角区域（红色）均得到了均衡的覆盖。

4.2.1　几何特征检测

进行接触点采样前，首先利用第二章介绍的 NECDNet 算法架构对物体的几何特征进行检测与分类。由于 NECDNet 的输入为点云信息，需先通过均匀采样将物体的三角网格模型转换为点云表示，随后将其输入预训练网络。NECDNet 输出每个点的类别标签 f_i，将点云划分为面、边、角三类。由于基于模型的方法已知物体的真实法

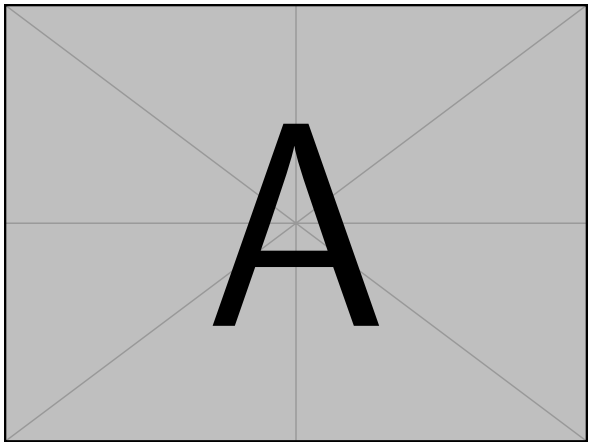


图 4.2　基于类别的体素采样结果

Figure 4.2　Voxel sampling results based on categories.

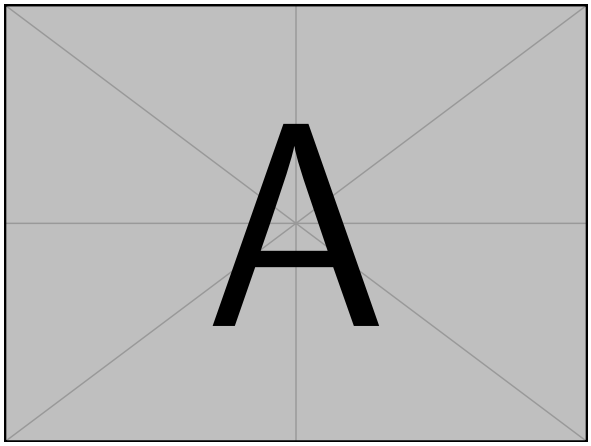


图 4.3　基于 NECDNet 的几何特征检测结果

Figure 4.3　Geometric feature detection results based on NECDNet.

向量，上述网络选用了基于真实法向量训练的模型版本。检测结果如图 4.3所示，不同颜色直观地表示了不同的几何特征类别。

考虑到角点在物体表面通常呈稀疏且孤立的分布，直接使用原始检测点可能造成冗余。为了使结果更适用于抓取规划，本文在 NECDNet 检测后引入 DBSCAN（Density-Based Spatial Clustering of Applications with Noise）聚类算法对角点进行聚类处理[41]。DBSCAN 聚类过程如公式 (4.1) 所示，其中 P 表示待聚类的点集，ϵ 为邻域半径，$MinPts$ 为最小邻域点数。其核心思想是通过考察数据点的邻域密度，将密度较高的数据区域识别为簇，并能有效识别噪声点。算法首先随机选择一个未被访问的数据点，若其 ϵ 邻域内的点数不少于 $MinPts$，则以该点为核心，扩展形成一个新簇；否则，该点被标记为噪声。该过程不断重复，直到所有数据点均被处理，从而

实现对数据点的聚类。

$$\text{DBSCAN}(P, \epsilon, MinPts) \tag{4.1}$$

聚类得到的每个簇对应一个角点区域。为简化表示并便于后续算法处理，首先计算各簇中点的质心，将其作为该区域的代表点。随后，为保持点云数据的一致性，利用原始点云的 KD-树检索距离质心最近的实际点，并将其标记为该区域的角点 c。这样不仅确保后续规划算法使用的仍为原始点云中的有效点，同时使角点的表达更加紧凑，有利于进一步的采样和配对操作。

4.2.2 基于类别的体素采样

在获得带有几何特征标签的点云后，本文采用基于体素的均衡采样方法。具体而言，首先将点云按几何类别划分为三个子集，随后分别对每个子集进行体素化处理：将空间划分为体素网格，并在每个非空体素内随机选择一个点作为采样点 $\mathbf{s}_i$。这种方法确保了采样点在空间上的均匀分布，并强制保证了数量较少的边缘和角点类别也能被充分采样，从而为后续的抓取规划提供均衡的候选集。

在本方法中，体素网格的尺寸是影响采样效果的关键参数。由于抓取规划过程中模型尺寸需与实际物体尺寸保持一致，不能对物体进行归一化处理，因此体素采样参数 v 的定义参考了归一化物体的尺寸。具体而言，物体的实际尺寸通过其包围盒对角线长度进行度量。将实际尺寸与归一化参考尺寸的比值乘以设定的 v，即可获得用于点云采样的体素网格尺度。这种方式能够适应不同物体的尺寸变化，确保采样点数量处于合理区间。体素尺寸 v 可根据需求进行调节：较小的 v 生成更密集的采样点 $\mathcal{S}$，可拓展抓取规划的搜索空间但增加计算负担；较大的 v 则减少采样点，可能遗漏部分关键几何信息。图 4.4 展示了同一物体在不同体素尺寸与采样策略下的对比结果。图中结果表明，相较于全局采样，基于类别的体素采样能够在不同几何区域实现更均匀的分布。

4.2.3 凸性检测

此外，为确保接触点具备物理可行性，本文引入了凸性检测（Convexity Check）机制，以剔除位于凹陷区域的点。具体方法为：对于每个下采样点 $\mathbf{s}_i \in \mathcal{S}$，首先定义其在采样前点云中 k 个最近邻点组成的局部邻域 $\mathcal{Q}_i^{\mathrm{s}}$，并计算邻域点的质心 $\mathbf{c}_i^{\mathrm{s}}$。然后，

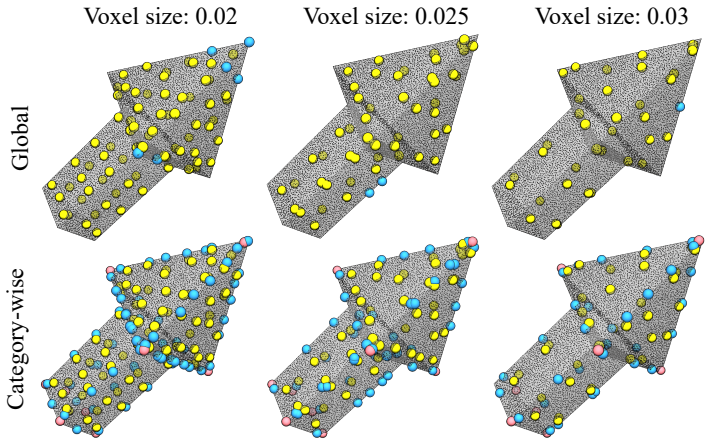


图 4.4　不同体素采样尺寸及采样策略下的采样结果

Figure 4.4　Sampling results under different voxel sizes and sampling strategies.

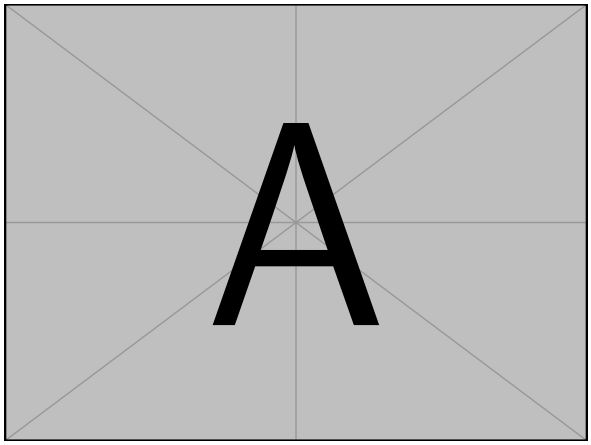


图 4.5　凸性检测中凹凸查询点点对应 θ_i^{s} 对比

Figure 4.5　Comparison of θ_i^{s} for concave and convex query points in convexity check.

构造指向质心的向量 $\mathbf{v}_i^{\mathrm{s}} = \mathbf{c}_i^{\mathrm{s}} - \mathbf{s}_i$。通过计算该点法向量 $\mathbf{n}_i^{\mathrm{s}}$ 与 $\mathbf{v}_i^{\mathrm{s}}$ 之间的夹角 θ_i^{s}，用于判断其几何属性，如公式 (4.2) 所示：

$$\theta_i^{\mathrm{s}} = \arccos\left(\frac{\mathbf{n}_i^{\mathrm{s}} \cdot \mathbf{v}_i^{\mathrm{s}}}{\|\mathbf{n}_i^{\mathrm{s}}\|\|\mathbf{v}_i^{\mathrm{s}}\|}\right) \tag{4.2}$$

如图 4.5 所示，位于凹陷区域的点，其 θ_i^{s} 通常较小，而位于凸起区域的点则具有较大的夹角。选取阈值 θ_{th}，当 $\theta_i^{\mathrm{s}} < \theta_{th}$ 时，将该点判定为凹陷点并从采样集合 $\mathcal{S}$ 中剔除。由于平坦的指腹难以在凹陷位置实现稳定有效的接触，经过凸性筛选后得到的采样点集 $\mathcal{S}$ 既具备几何均衡性，又满足基本的物理接触约束，有效提升了抓取灵活性与成功率。

4.3 基于几何特征的接触对检测

在通过体素均衡采样获得具有类别标签的点集 $\mathcal{S}$ 后，抓取规划的下一阶段任务是搜索能够形成稳定力封闭（Force Closure）的对偶接触点对（Antipodal Contact Pairs）。传统的接触检测方法，如基于射线投射（Ray-shooting）的采样策略，通常假设接触表面为理想平面，这极大地限制了机械手在复杂几何物体表面的抓取灵活性[40]。然而，在实际操作中，物体的边缘和角点往往提供了关键的几何特征，允许手指绕接触点或接触轴进行一定程度的旋转，从而在受限空间内实现有效抓取。

为了突破传统平面假设的局限，本文提出了一种基于几何特征的自适应接触对检测方法。该方法不再单一地依赖法向射线，而是针对面（`f`）、边（`e`）、角（`c`）三种不同的几何特征，分别构建了与之拓扑结构相适应的空间检测器：圆柱体、扇形柱和圆锥体。这一过程本质上是将接触点对的寻找转化为一个带几何约束的空间搜索问题。对于每一个作为查询点的采样点，算法利用其对应的检测器在物体空间中搜索潜在的对偶点。随后，结合法向量共线性约束和几何投影规则，对候选点集进行严格的筛选与配对，以确保生成的抓取配置在物理上满足指腹接触的稳定性要求。

图 4.6 展示了基于几何特征的接触对具体检测流程。首先，从采样集 $\mathcal{S}$ 中选取一个查询点 $\mathbf{s}_i$，根据其特征 f_i 生成对应的检测器 $\mathcal{D}_i$（圆柱、扇形柱、圆锥体）。计算 $\mathcal{D}_i$ 与点集 $\mathcal{S}$ 的空间交集，得到潜在的候选接触点集 $\mathcal{M}_i = \mathcal{S} \cap \mathcal{D}_i$，图 4.6(b) 中红色点。之后对 $\mathcal{M}_i$ 中的每个候选点 $\mathbf{m}_j^s$，根据其特征 f_j 以及与查询点 $\mathbf{s}_i$ 的几何关系，应用相应的配对策略进行筛选，最终得到符合稳定性要求的对偶接触点对 $\mathcal{C}_i$，图 4.6(c) 中黑色线段表示的单个查询点抓取对组合。遍历所有查询点，组合所有单个查询点的结果 $\mathcal{C}_i$ 为最终对偶接触点对规划结果 $\mathcal{P}$。

检测流程中的关键步骤包含：针对不同几何特征设计适配的空间检测器，以捕捉潜在的接触机会；利用几何约束对候选点进行筛选，确保生成的抓取配置满足物理稳定性要求。通过上述方法，本文能够有效地从复杂的物体几何中提取出高质量的抓取配置。下文将详细介绍特征化接触检测器的设计以及对偶接触点的配对策略。

4.3.1 特征化接触检测器设计

为了捕捉不同几何自由度下的潜在接触机会，本文定义了一组参数化的几何约束检测器 $\mathcal{D}$。检测器的几何形态与尺寸严格依赖于查询点的几何特征类别 $f_i \in$

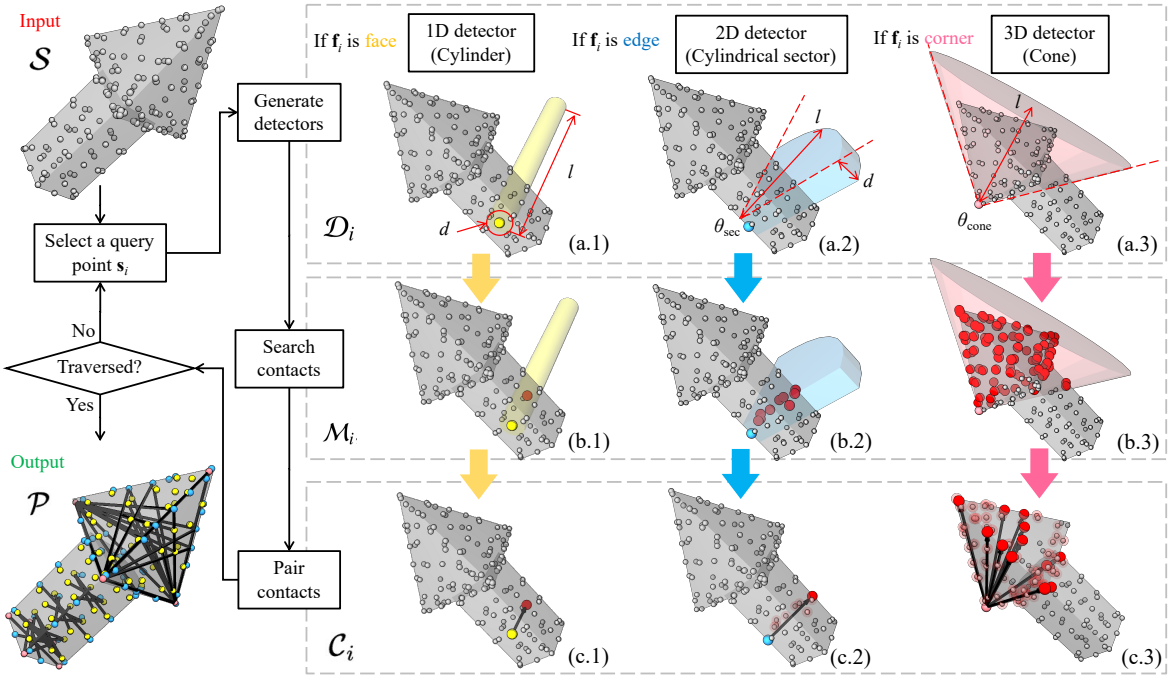


图 4.6　基于几何特征的接触对检测流程

Figure 4.6　Contact pair detection process based on geometric features.

$\{\mathtt{f},\mathtt{e},\mathtt{c}\}$，其构建方向始终沿查询点法向量的负方向 $-\mathbf{n}_i^s$ 延伸，旨在搜索位于物体“对侧”的表面区域。三种检测器的几何定义及示意如图 4.7所示。

1）　面接触检测器

面接触受限于半空间几何约束，要求手指指腹平面尽可能与物体表面平行。因此，面特征点的对偶搜索主要沿法线反方向进行。考虑到机械手并不能总是完美垂直于表面，且指腹具有一定的物理面积，本文将传统的射线模型扩展为圆柱体检测器，如图 4.7(a) 所示。圆柱体的直径 d 对应指腹的有效接触直径（对于平行夹爪，取 d 为指腹最大内切圆直径），代表了允许的横向接触容差。圆柱体的长度 l 决定了搜索的深度范围，为了确保能够覆盖物体的整体几何结构，本文将 l 设定为物体点云包围盒（Bounding Box）的最大对角线长度 d_{bb}。此时，检测器 $\mathcal{D}$ 定义为一个半径为 $d/2$、高为 l 的圆柱空间，凡是落入该区域的点均被视为潜在的对偶面接触点。

2）　边接触检测器

与面接触不同，边接触属于线接触模型。当手指与物体边缘接触时，机械手具备绕边缘轴线旋转的一个自由度。为了适应这种额外的旋转灵活性并捕捉边缘走向，检测器 $\mathcal{D}$ 被设计为扇形柱（Cylindrical Sector），如图 4.7(b) 所示。该检测器在法向截面上呈扇形，半径为 l，厚度为指腹直径 d。扇形的张角 θ_{sec} 决定了允许的旋转搜索范

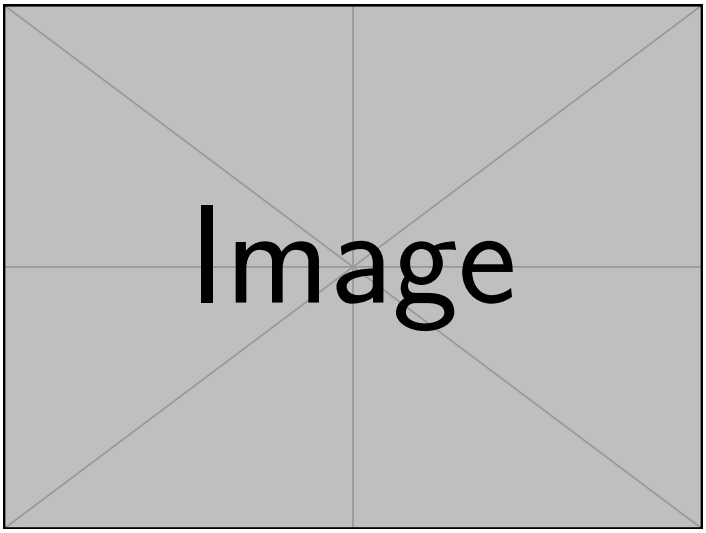


图 4.7 基于几何特征的三种接触检测器：(a) 面接触圆柱体检测器；(b) 边接触扇形柱检测器；(c) 角接触圆锥体检测器

Figure 4.7 Three types of contact detectors based on geometric features: (a) Cylindrical detector for face; (b) Sector detector for edge; (c) Conical detector for corner.

围，考虑到抓取稳定性，防止过大的倾角导致滑脱，本文限制实际使用时 $\theta_{\text{sec}} < 90°$。

在构建扇形柱检测器时，确定扇形的展开方向（即边缘切线方向）是关键步骤。由于原始点云具有较强的离散性，传统差分法推算法向量的鲁棒性较差，难以获得准确的切向信息。针对这一问题，本文采用随机采样一致性（Random Sample Consensus, RANSAC）算法对边缘点进行局部直线拟合，以获取高精度的切向量[42]。

具体而言，以当前查询边缘特征点 $\mathbf{s}_i$ 为中心，在仅包含边缘点的点云（采样前）中检索其半径 r 范围内的邻域点，形成局部点集。在局部点集中，通过 RANSAC 算法迭代执行直线拟合：每次随机选取两点确定一条直线模型，计算其他点到该直线的欧氏距离，并将距离小于一定阈值的点标记为局内点（inliers）。重复上述迭代过程一定次数，最终选取局内点数量最多的直线作为最优拟合结果。该直线的方向向量即作为边缘点 $\mathbf{s}_i$ 局部范围内的切向量。据此，可调整扇形柱检测器的姿态，使其厚度方向与该切向量保持平行，从而保证检测器能够沿着边缘的法平面准确展开，实现对边缘方向的鲁棒感知与拟合。

3） 角接触检测器

角接触近似为点接触模型，理论上允许手指绕接触点在三维空间内进行球面旋转。为了最大化搜索范围，检测器 $\mathcal{D}$ 被设计为圆锥体，如图 4.7(c) 所示。圆锥的高为 l，顶角 θ_{cone} 为可调参数。较大的 θ_{cone} 能够覆盖更广阔的对偶区域，但也可能引

入几何上不稳定或发生干涉的抓取配置。与边检测器类似，θ_{cone} 的取值需在覆盖率与稳定性之间进行权衡。

上述检测器的设计充分考虑了不同几何特征下的接触自由度与机械手的物理限制，其尺寸参数主要包括 d、l、θ_{sec} 和 θ_{cone}。其中，d 和 l 直接关联机械手的指腹尺寸与物体的整体尺度，在手爪与物体确定的情况下无需进行参数调节。而 θ_{sec} 和 θ_{cone} 则反映了接触点的几何灵活性，可以进行调节以适应不同的抓取任务需求。第 **??** 节中的实验将探讨这些参数对抓取规划结果的影响。

4.3.2 对偶接触点配对策略

设计完成上述特征化接触检测器后，即可开展对偶接触点对的检测工作。具体可以分为两个步骤：首先，利用检测器在物体空间中搜索潜在的接触点对；其次，对潜在的接触点对进行对偶筛选，以确保生成的抓取配置在物理上满足稳定性要求。针对潜在接触点对的筛选工作，本文设计了一套基于几何特征的分类配对策略，对不同的接触点组合制定了相应的筛选规则，以确保生成的抓取配置在物理上满足稳定性要求。

如图 4.6 所示，对于 $\mathcal{M}_i$ 中的任意候选点 $\mathbf{m}_j^s$，虽然其空间位置满足检测器的几何约束，但仍需进一步验证其法向量和局部几何特征是否能与 $\mathbf{s}_i$ 构成稳定的力封闭抓取。为此，本文根据接触点对 $(\mathbf{s}_i, \mathbf{m}_j^s)$ 的特征组合，制定了不同的分类配对策略。后续配对特征描述中，点对特征表示为 (f_i-f_j)，其中 f_i 和 f_j 分别为查询点 $\mathbf{s}_i$ 和候选点 $\mathbf{m}_j^s$ 的几何特征类别。根据三种基本特征（面 `f`、边 `e`、角 `c`）的组合，存在六种可能的接触对类型：`f-f`、`f-e`、`f-c`、`e-e`、`e-c`、`c-c`。针对每种类型，本文设计了相应的配对规则，以确保生成的抓取配置在物理上满足稳定性要求。

1） 角-角接触配对（`c-c`）

当两个接触点均为角点时，由于角接触提供了最大的旋转自由度，且角点处的法向量通常具有较大的不确定性，过于严格的法向约束会导致可行解丢失。因此，对于 `c-c` 组合，只要点 $\mathbf{m}_j^s$ 落入圆锥检测器内，本文即认为该配对在几何上是可行的。

2） 角-边/面接触配对（`c-e`, `c-f`）

在此类组合中，一个接触点为角点（$\mathbf{s}_i$），另一个为边或面点（$\mathbf{m}_j^s$）。由于边和面对手指的姿态有较强的几何约束，且指腹尺寸有限，我们需要确保角点 $\mathbf{s}_i$ 能够稳

定地落在对侧手指的有效接触区域内。为此，本文引入了指标 d_{proj}。该指标计算从 $\mathbf{s}_i$ 出发的射线在对侧点 $\mathbf{m}_j^s$ 的约束平面（对于面）或约束直线（对于边）上的投影偏离程度。具体计算如公式 (4.3) 所示：

$$d_{\text{proj}} = \begin{cases} \|\mathbf{d}_j^{\text{s}} - (\mathbf{d}_j^{\text{s}} \cdot \mathbf{n}_j^{\text{s}})\mathbf{n}_j^{\text{s}}\| & \text{若} f_j^{\text{s}} = \texttt{f} \\ \|\mathbf{d}_j^{\text{s}} \cdot \mathbf{t}_j^{\text{s}}\| & \text{若} f_j^{\text{s}} = \texttt{e} \end{cases} \tag{4.3}$$

其中，$\mathbf{d}_j^{\text{s}} = \mathbf{m}_j^{\text{s}} - \mathbf{s}_i$ 为接触连线向量，$\mathbf{n}_j^{\text{s}}$ 为面点的单位法向量，$\mathbf{t}_j^{\text{s}}$ 为边点的单位切向量。若 $d_{\text{proj}} < d$（指腹直径），说明角点处于对侧指腹的有效覆盖范围内，判定该配对有效。

3） 面/边-面/边接触配对（`f-f`, `e-f`, `e-e`）

当接触对中不包含角点时，两个接触点均具有相对准确的法向量估计，且受到较强的几何约束。为了保证抓取的对指性质（Antipodal property），两点的法向量应近似相反，以抵消抓取力。定义法向夹角 θ_j^{s} 如公式 (4.4)：

$$\theta_j^{\text{s}} = \arccos\left(\frac{\mathbf{n}_i^{\text{s}} \cdot \mathbf{n}_j^{\text{s}}}{\|\mathbf{n}_i^{\text{s}}\|\|\mathbf{n}_j^{\text{s}}\|}\right) \tag{4.4}$$

设定阈值 θ_{th}，若 $\theta_j^{\text{s}} > \theta_{\text{th}}$，则认为两点法向足够对立，配对有效。$\theta_{\text{th}}$ 直接影响生成抓取的数量与质量：阈值越大，约束越严格，生成的配置越少但对指度越高。第 **??** 节展示了不同 θ_{th} 下的实验对比结果。

4.3.3 初步抓取配置生成

在完成接触点对的筛选与配对后，最后一步是根据确认有效的接触对 $(\mathbf{s}_i, \mathbf{m}_j^s)$ 计算机械手的 6D 抓取位姿。一个完整的抓取配置通常由抓取中心位置 $\mathbf{j}_i$ 和抓取方向（即接触向量 $\mathbf{v}_i$）决定。

抓取中心 $\mathbf{j}_i$ 定义为两个接触点的几何中心，代表了机械手闭合时的理想中心位置，如公式 (4.5) 所示：

$$\mathbf{j}_i = \frac{\mathbf{m}_j^{\text{s}} + \mathbf{s}_i}{2} \tag{4.5}$$

对于接触向量 $\mathbf{v}_i$，它决定了机械手接近物体的方向。由于面特征（`f`）对法向有严格的平行约束，即机械手必须沿着面法线的反方向接近以确保指腹贴合。而边和

角特征允许一定的旋转自由度，手爪指腹可以绕接触点进行旋转以适应边缘或角点的几何特性。因此，针对不同的接触对类型，本文设计了不同的接触向量计算策略。

若接触对中包含面接触点（$f_j^{\mathrm{s}} = \mathtt{f}$），则优先采用面点的法向量 $\mathbf{n}_j^{\mathrm{s}}$ 作为接触方向，以确保指腹与平面贴合。若接触对仅由边或角点组成（$f_j^{\mathrm{s}} \in \{\mathtt{e}, \mathtt{c}\}$），则缺乏明确的表面法向约束，此时采用两接触点的连线方向作为接触向量，以最大化抓取力的传递效率。计算方式归纳为公式 (4.6)：

$$\mathbf{v}_i = \begin{cases} \mathbf{n}_j^{\mathrm{s}} & \text{若} f_j^{\mathrm{s}} = \mathtt{f} \\ \mathbf{m}_j^{\mathrm{s}} - \mathbf{s}_i & \text{若} f_j^{\mathrm{s}} \in \{\mathtt{e}, \mathtt{c}\} \end{cases} \tag{4.6}$$

通过上述策略，本文能够从复杂的几何特征中高效地提取出满足物理约束的高质量抓取配置，为后续的运动规划奠定基础。

4.4 抓取构型增强及碰撞检测

在得到初步的抓取配置后，下一阶段的任务是对这些配置进行增强和筛选，以确保其在实际操作中的可行性与稳定性。具体而言，在上文得出的包含抓取中心和接触向量的抓取构型上进行旋转增强，以增加规划出的抓取数量，防止在运动规划阶段因环境避障或运动学奇异点而导致无解的情况。同时，由于初步抓取配置的生成过程并未显式考虑机械手与物体之间的空间干涉，因此需要引入碰撞检测机制，以剔除那些在几何上不可行的抓取构型，提升整体规划的成功率。该步骤在抓取规划流程中起到了关键的过滤作用，确保后续的稳定性评估和运动规划仅针对物理上可行的抓取配置进行，从而提升整体效率与成功率。

4.4.1 抓取构型增强策略

经过稳定性筛选的接触对仅确定了机械手的空间接触位置 $\mathbf{j}_i$ 和轴向接触矢量 $\mathbf{v}_i$。为了构建完整的 6D 抓取构型，需进一步确定机械手绕接触轴（即夹爪坐标系 x 轴）的旋转角度 β，以定义机械手的姿态。不同的 β 角对应机械手在接触点周围的不同旋转位置，能够显著增加抓取配置的数量。

如图 4.8(a) 所示，机械手坐标系原点定位于抓取中心 $\mathbf{j}_i$，其 x 轴与接触向量 $\mathbf{v}_i$ 重合。此时，机械手仍保留一个绕 $\mathbf{v}_i$ 旋转的自由度。通过在 $[0, 2\pi)$ 范围内对旋转角 β 进行离散化采样，可基于单一几何接触对生成一系列具备不同末端姿态的抓取构型，

如图 4.8(b) 所示。该策略显著扩充了候选抓取集，赋予了机器人在运动规划阶段应对环境避障及运动学奇异点时更大的解空间。

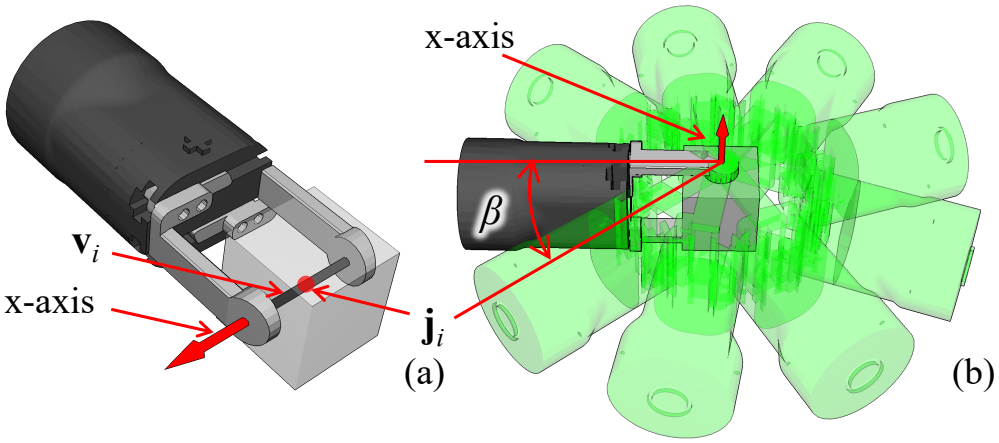


图 4.8 抓取构型增强示意图

Figure 4.8 Schematic of grasp configuration augmentation.

值得注意的是，尽管不同的 β 角对应不同的机械手末端位姿，其本质上基于同一组几何接触特征。因此，在后续章节（详见第 **??** 节）对抓取分布多样性进行评估时，为避免统计数据的冗余与偏差，评估指标将主要聚焦于接触向量 $\mathbf{v}_i$ 的空间分布（表征 3D 旋转多样性）以及抓取中心的位置分布（表征 3D 空间覆盖率），而非单纯统计增强后的配置总数。同理，在结果的可视化呈现中，为保持图像的清晰度，对于每个接触对仅随机选取一个 β 角生成代表性构型进行渲染，省略了密集的旋转增强结果。

4.4.2 碰撞检测策略

完成抓取构型增强后，每个候选抓取构型均对应一个确定的夹爪 6D 位姿，由上文中的抓取中心 $\mathbf{j}_i$ 和接触向量 $\mathbf{v}_i$ 以及旋转角 β 共同定义。由于抓取对规划及增强过程并未显式考虑夹爪实体几何与目标物体的空间干涉，部分抓取构型可能会与物体发生几何干涉，无法作为合理的抓取规划结果。因此需要执行碰撞检测以剔除几何上不可行的候选构型，降低后续稳定性求解的计算负担并提升整体规划成功率。

碰撞检测的目标是在给定两组刚体几何模型及其空间位姿的情况下，判断二者是否发生几何干涉（interference）。对任意一对几何体 $\mathcal{A}$ 与 $\mathcal{B}$，碰撞检测通常可表述为：若存在至少一对点 $(\mathbf{x} \in \mathcal{A}, \mathbf{y} \in \mathcal{B})$ 使得两者在空间中相交或产生穿透，则判定为碰撞；反之则为无碰撞。本文在几何层面采用三角网格对场景物体进行建模，目标物

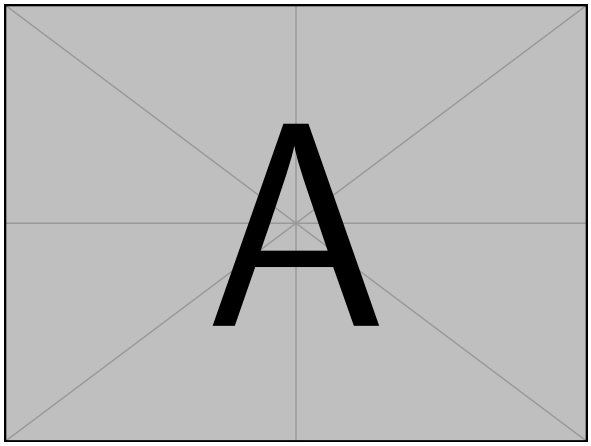


图 4.9　碰撞检测结果对比：红色表示发生碰撞的构型，绿色表示无碰撞的构型

Figure 4.9　Comparison of collision detection results: red indicate colliding configurations, green indicate non-colliding configurations.

体直接使用精细 CAD 网格以准确表征表面细节与局部凹凸结构。对于夹爪模型，为兼顾检测精度与批量筛选效率，本文将夹爪掌部、指体与指尖等刚体部件用多个有向包围盒（Oriented Bounding Box, OBB）进行组合近似。该组合式 OBB 表示能够在保留姿态相关外形特征的同时显著降低碰撞测试复杂度，适合对大量增强构型进行快速判定。

在碰撞求解器层面，本文采用 Open Dynamics Engine (ODE) 提供的碰撞检测机制，并将参与检测的几何体分别表示为 ODE 的碰撞几何对象：夹爪端执行器由若干 OBB 碰撞体组合构成，目标物体则由其 CAD 三角网格构建为 TriMesh 碰撞体[]。在给定候选构型的 6D 位姿后，首先对夹爪各 OBB 碰撞体施加相应的刚体变换，使其与当前抓取姿态一致；随后调用 ODE 的碰撞查询在夹爪与目标物体之间生成接触信息（contact manifold）。若碰撞查询返回的接触点集合非空，则说明夹爪碰撞体与目标物体 TriMesh 在该构型下发生几何接触或穿透，该候选构型被判定为不可行并从候选集中剔除；反之，若无接触点生成，则认为该构型在几何上无干涉并被保留，用于后续的稳定性评估与规划求解。

通过上述基于 ODE 的碰撞检测策略，本文能够在抓取构型增强产生的大规模候选集合中高效滤除与目标物体发生几何干涉的构型，确保后续计算仅针对空间上可执行的抓取配置进行，从而提升整体抓取规划流程的效率与鲁棒性，部分检测结果如图 4.9 所示。

4.5 基于软接触模型的稳定性评估

在初步获取潜在接触点对后，需对其进行物理层面的力学稳定性评估。实际应用中，机械手末端通常配备柔性指腹（Soft Finger Pad），其在接触物体时发生的弹性形变能够有效拟合目标表面的边、角等不规则几何特征。这种形变不仅显著增加了有效接触面积，还能通过接触面间的微观互锁提供额外的摩擦力矩，从而大幅提升抓取的鲁棒性。然而，柔性材料与复杂几何特征（特别是锐边与尖角）之间的接触力学呈现出高度的非线性，对其进行精确的有限元建模将带来巨大的计算开销，难以满足抓取规划的实时性要求。

为此，本文提出一种基于离散化近似的软接触模型。该模型在保留指腹物理厚度与压缩特性的基础上，将复杂的连续软接触简化为一组分布式的硬点接触集合，进而利用经典的力封闭（Force Closure）理论进行高效的稳定性判别。

4.5.1 接触区域的离散化建模

指腹的变形能力在模型中被量化为沿法向的有效压缩深度。如图 4.10所示，对于任意给定的接触对 $(\mathbf{s}_i, \mathbf{m}_j^s)$，以其接触向量 $\mathbf{v}_i$ 为轴向、接触点位置为中心，构建指腹的几何包围体（图中绿色圆柱所示）。设 t_{pad} 为指腹的物理厚度，引入无量纲参数 $\eta \in [0, 1]$ 作为有效压缩系数，用于表征指腹在特定抓取力作用下的最大形变率。在此模型下，凡是落入指腹投影区域内且与指腹表面的距离小于有效变形阈值 $d_{\text{eff}} = \eta t_{\text{pad}}$ 的物体表面点，均被判定为有效接触点。

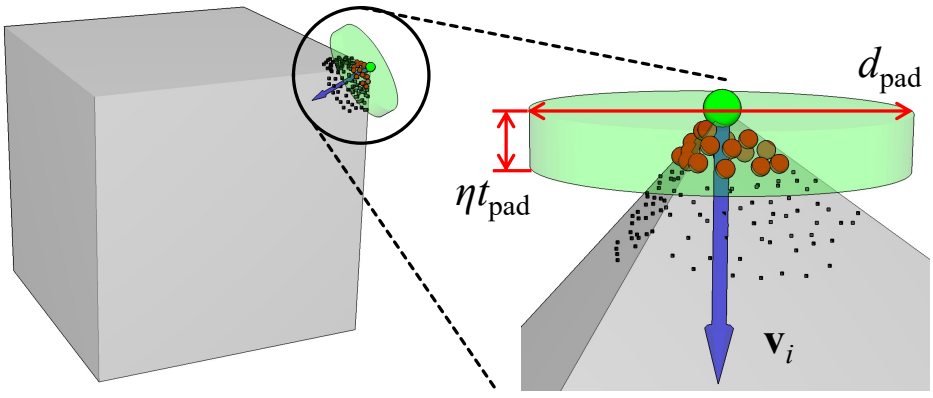


图 4.10　基于软接触变形的接触点集获取示意图

Figure 4.10　Obtaining contact points for stability estimation considering soft contact.

由于依赖于许多耦合因素，准确建模参数 η 数值较为困难。在物理场景中，柔

性指腹材料的特性、施加的握力、物体材料以及接触区域的几何形状都会影响有效压缩，其中许多效应是非线性的。为此，本文选择采用实际实验进行参数标定。通过实验标定（以配备 3 mm 橡胶指腹的 DH-ROBOTICS PGC 夹爪为例，施加 100 N 抓取力），对于角接触与边接触，η 的经验值分别取约为 0.7 与 0.4。

基于上述定义，原本的单一接触点被扩展为一个离散的接触点簇 $\mathbf{C}_i = \{\mathbf{x}_{i,1}, \mathbf{x}_{i,2}, \ldots, \mathbf{x}_{i,|\mathbf{C}_i|}\}$（如图中红色点集所示）。对于簇中任意一点 $\mathbf{x}_{i,j}$，其局部接触法向量近似统一为指腹的进近方向 $\mathbf{n}_{\text{fp}}$。尽管物体表面的局部法向可能存在微小扰动，但在指腹包裹变形的假设下，该近似能够有效反映接触力的主传递方向。

4.5.2 力学平衡与稳定性判据

抓取稳定性的评估核心在于验证接触力空间中是否存在满足物理约束的可行解，以平衡重力及潜在的外力扰动。假设接触面摩擦系数 μ 均匀分布，对于点簇 $\mathbf{C}_i$ 中的任意离散点 $\mathbf{x}_{i,j}$，其接触力 $\mathbf{f}_{i,j}$ 需满足库仑摩擦定律（Coulomb Friction Law）约束：

$$\begin{cases} \mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}} \leq 0 & \text{(单向压力约束)} \\ \|\mathbf{f}_{i,j} - (\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}})\mathbf{n}_{\text{fp}}\| \leq \mu |\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}}| & \text{(摩擦锥约束)} \end{cases} \tag{4.7}$$

上述约束保证了接触作用力仅表现为压力，且切向分量受限于最大静摩擦力。

系统的力矩平衡方程定义为：

$$\sum_{i=1}^{2} \sum_{j=1}^{|\mathbf{C}_i|} \begin{bmatrix} \mathbf{f}_{i,j} \\ \mathbf{r}_{i,j} \times \mathbf{f}_{i,j} \end{bmatrix} + \mathbf{w}_{\text{g}} + \mathbf{w}_{\text{ext}} = \mathbf{0} \tag{4.8}$$

其中，$\mathbf{r}_{i,j}$ 表示接触点 $\mathbf{x}_{i,j}$ 相对于物体质心的位置矢量；$\mathbf{w}_{\text{g}} \in \mathbb{R}^6$ 为重力旋量（Wrench），包含重力及其产生的力矩；$\mathbf{w}_{\text{ext}} \in \mathbb{R}^6$ 代表外部扰动旋量（本研究中设为零向量，但模型保留其通用性）。

若线性规划求解器能在约束范围内找到一组可行力解 $\{\mathbf{f}_{i,j}\}$，则判定该抓取配置具备力封闭稳定性。需特别指出，与经典软指模型将接触简化为单点并附加显式扭转摩擦约束不同[43]，本文采用的分布式多点接触模型通过积分离散点集产生的力矩（即 $\sum \mathbf{r}_{i,j} \times \mathbf{f}_{i,j}$ 项），能够隐式且更真实地捕捉软指腹抵抗旋转扭矩的物理特性，避免了对扭转摩擦系数的显式约束。

4.6 本章小结

本章针对机器人操作中复杂几何物体的抓取难题，特别是传统方法在处理非平面特征时的局限性，提出了一种融合面、边、角多维几何特征的系统化抓取规划方法。

针对物体表面几何特征分布不均导致的采样“长尾”问题，提出了类别感知的体素均衡采样策略。通过结合 NECDNet 深度学习特征推理与 DBSCAN 聚类算法，实现了对面、边、角区域的独立体素化采样，确保了稀疏特征（如角点）在候选集中的有效覆盖，为多样化抓取奠定了数据基础。

其次，依据不同几何特征的自由度约束特性，设计了特征化的空间接触检测器（圆柱体、扇形柱及圆锥体），并制定了相应的对偶接触点配对策略。通过引入基于投影距离与法向夹角的筛选机制，有效解决了混合特征下的接触点配对问题，从几何层面保证了候选抓取的合理性。

为了准确评估柔性指腹在边缘与角点处的接触稳定性，本文建立了基于离散化近似的软接触力学模型。该模型通过将连续的非线性软接触简化为分布式硬点接触簇，实现了基于力封闭理论的高效稳定性判别。此外，结合抓取构型增强策略，通过沿接触轴的旋转采样，进一步扩充了机器人的可行解空间。

综上所述，本章所提出的方法有效突破了传统平面接触假设的束缚，显著提升了抓取规划算法对物体复杂几何外形的适应性，为后续章节的实验验证与实际应用提供了坚实的理论与算法支撑。

第五章　机器人抓取规划实验结果及分析

5.1　引言

本章旨在通过系统性的实验研究，全面评估本文提出的考虑边缘与角点接触特征的机器人抓取规划方法的性能。为了验证算法在处理复杂几何形状物体时的有效性、鲁棒性及计算效率，本章构建了包含仿真分析与物理样机验证在内的多层次测评体系。首先，详细介绍了实验系统的软硬件环境搭建方案，以及涵盖多种典型几何特征的测试对象集选取依据。随后，通过参数敏感性分析确定了算法的最优配置，并以此为基础，将本文方法与多种主流抓取规划算法进行了对比实验。实验重点从抓取构型的空间分布多样性与真实物理环境下的抓取成功率两个核心维度展开，深入分析了引入边缘与角点接触对提升抓取性能的具体贡献。最后，本章还统计了算法的运行耗时，以验证其在实际工程部署中的实时性与可行性。

5.2　实验环境及参数配置

进行实验验证前，需要搭建一个能够支持算法测试的完整实验环境，并合理配置关键参数以确保实验结果的有效性与可比性。首先需要搭建物理实验平台和软件仿真平台，支持后续的对比实验。此外，根据后续抓取实验的需求，本文还对算法中的关键参数进行了系统性的分析与调优，确保参数配置的合理性。最后，针对实验中的物体模型，本文构建并从多个数据集中选取了具有代表性的测试对象，以全面评估算法在不同几何特征上的表现。

5.2.1　实验平台搭建

实验平台主要由物理实验平台和软件软件平台两部分组成，分别用于验证算法在真实环境中的抓取性能以及在仿真环境中的抓取构型分布特性。其中软件平台的可视化部分搭建基于物理实验平台的配置，以确保两者之间的一致性和可比性。图 5.1 展示了软硬件平台的整体架构与组成部分。

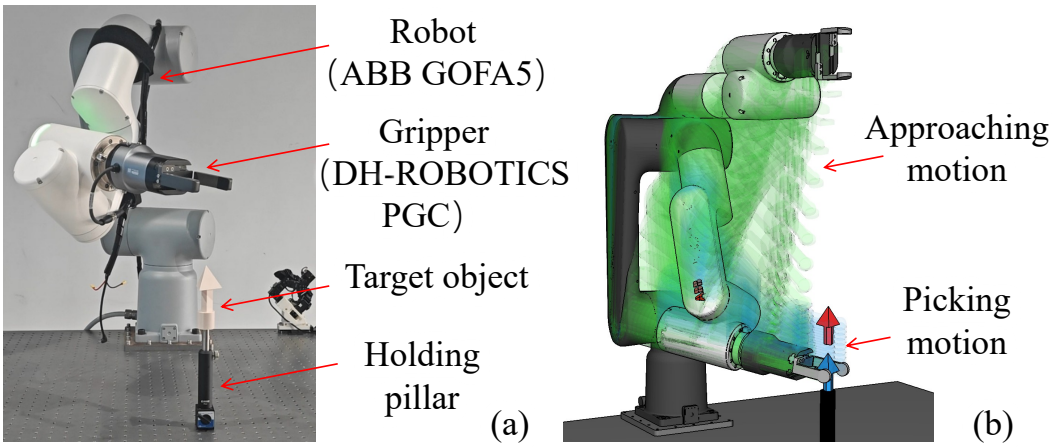


图 5.1 实验平台架构示意图。左侧为物理实验平台，包含 ABB GOFA-5 六轴协作机械臂与 DH-ROBOTICS PGC 系列平行电动夹爪；右侧为软件仿真平台，基于 World Robot System (WRS) 进行开发与测试。

1） 物理实验平台

针对物理实验平台的搭建，为了在真实世界中验证所生成的抓取候选的有效性，本文搭建了一套完整的机器人智能抓取系统实验平台。如图 5.1 所示，物理实验平台下位执行机构采用具备高精度力控与轨迹跟随能力的 ABB GOFA-5 六轴协作机械臂。系统末端执行器配备 DH-ROBOTICS 研发的 PGC 系列平行电动夹爪。该夹爪具备可多段调节的力控特性与灵活的行程适配能力。由于涉及多种不同尺寸的测试物体，通过手动预调整，该夹爪支持在 0-76 mm 与 30-106 mm 的双域张开宽度范围内切换，有效适配了多尺度的操控需求。被抓物体放置于一个固定的工作台上，工作台与机械臂基座之间的相对位置通过精确测量并在软件中进行标定，以确保仿真与物理实验环境的一致性。

此外，考虑到本方法所提出的边缘与角点抓取对指腹变形特征的高敏感性，实物夹爪选用了带一定厚度的圆形柔性橡胶指腹。其设计直径为 28 mm，厚度为 3 mm，表面材质的摩擦系数通过预先测定约为 0.25。该构型能够为线接触与点接触提供足够的法向压缩空间，从而在此类局部曲率极大的特征上形成具备一定面积的类平面接触区域，有效支持了章节 4.5 中设计的基于软接触模型的稳定性评估算法。

2） 软件平台

在软件模拟与规划层面，本实验基于 World Robot System (WRS) 机器人操作系统进行开发与测试。WRS 是一个集成了物理仿真、运动规划及可视化功能的综合机器人软件平台[]。如图 5.1 右侧所示，本研究利用 WRS 提供的精确碰撞检测引擎与

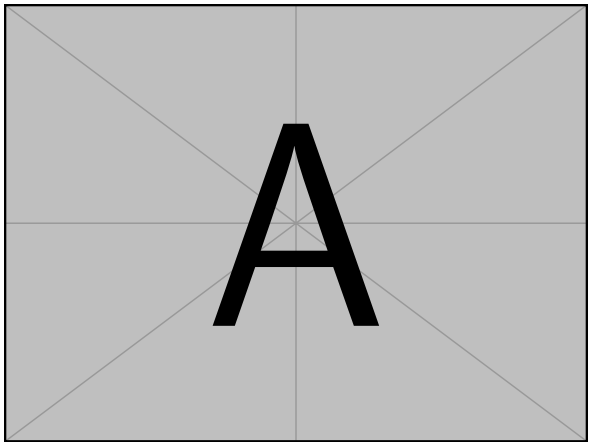


图 5.2　评估对象集的三维模型示例。

Figure 5.2　The mesh models of the evaluation object set.

运动学解算器，对抓取规划算法生成的候选抓取位姿进行验证，并生成无碰撞的机械臂运动轨迹。后续所有仿真实验与算法性能评估均在该软件框架下统一进行，以确保对比测试环境的一致性。

5.2.2　评估对象集选取

抓取实验的评估对象集选取是验证算法性能的关键环节。为了全面评估本文方法在处理不同几何特征物体上的表现，以及实现与其余算法的有效对比，本文从多个公开数据集中选取了具有代表性的物体模型，并结合人工构造的模型，以及日常生活中的常见物体，构建了一个包含十种不同几何特征的测试对象集。该对象集涵盖了从规则几何体到复杂曲面，从平面到锐边的多样化形状特征，能够充分考察算法在不同接触类型上的适应性与性能表现。选择的物体模型如图 5.2 所示，各物体的来源及选取依据如下：

1. **正四面体 (Tetrahedron)**：标准几何体，表面之间不包含任何平行的面对平面，是验证算法能否在无平行面场景中基于边、角特征稳定工作的重要参考基准。
2. **巧克力盒 (Amicelli)**：来源于 KIT 数据集 (ID: 10)，一种典型的正六棱柱包装盒，主要用于考察规划器在扫描模型上基于棱边获取多样性配置的能力。
3. **海豹模型 (Seal)**：来源于 KIT 数据集 (ID: 132)，整体无任何锐利直边，呈现出完全连续的平滑曲面结构，用以检测模型对于自由曲界面的适应性。
4. **乐高积木 (LEGO brick)**：选自 YCB 数据集 (ID: 073-b)，是长方体与多个圆柱凸起的组合，用于测算应对局部复杂凹凸拓扑特征的规划表现。

5. **多齿链轮 (Sprocket)**：取自 ABC 数据集 (ID: 1090)，表面具备极其复杂且细密的几何分布，包含大量的倒角、凹槽与轮缘，挑战算法对于多尺度几何细节的鲁棒性。
6. **牛奶纸盒 (Milk box)**：典型日化包装物品，中部呈现平行面，顶部受折叠封口影响为倾斜表面及不同角度角的合集，评估算法在典型包装几何体上的表现。
7. **杯面 (Cup noodle)**：圆台形日用品，侧面为特定角度的斜圆锥面，同时顶部具带有凸起的薄壁边缘结构，对传统仅依赖面面接触的方法构成挑战。
8. **电机支架 (Motor bracket)**：典型车间用工业部件，具有各类镂孔结构机壁、折弯薄板及不规则表面组合，反映算法在制造零件上的性能。
9. **直齿轮 (Gear)**：典型机械传动零件，包含阵列排列的齿状结构特征，从而向模型导入巨量的边缘及角点区域，挑战算法处理非平行接触类型的能力。
10. **箭头 (Arrow)**：手工构建的由正四面体和正五棱柱结合而成的异形物体。该设计用于展示所有 6 种两指接触种类（角-角、角-边、边-边、角-面、边-面、面-面）的特定目标情况。

上述物体中，自主构建及选自公开数据集的模型均有精准的网格模型，因此利用 3D 打印技术制作了实物。而实际物体则直接从市场上购买，经过精确测量后进行建模与标定，以确保仿真与物理实验环境的一致性。最终各物体的物理重量及体积相关测量信息详细统计于表 5.1 中。这些物体在质量分布与尺度空间上体现了多维度的差异，具备作为测试标准集的多样性特征要求。

表 5.1 实验测试验证对象集的物理特征信息及体积测量

物理属性	四面体	巧克力盒	海豹模型	乐高积木	多齿链轮
重量 (g)	59.27	52.68	29.63	49.72	33.58
体积 (cm^3)	155.16	505.06	226.29	627.66	404.21
物理属性	**牛奶纸盒**	**杯面**	**电机支架**	**直齿轮**	**箭头**
重量 (g)	213.91	106.50	152.71	19.90	69.81
体积 (cm^3)	3124.80	5134.24	569.90	226.98	258.56

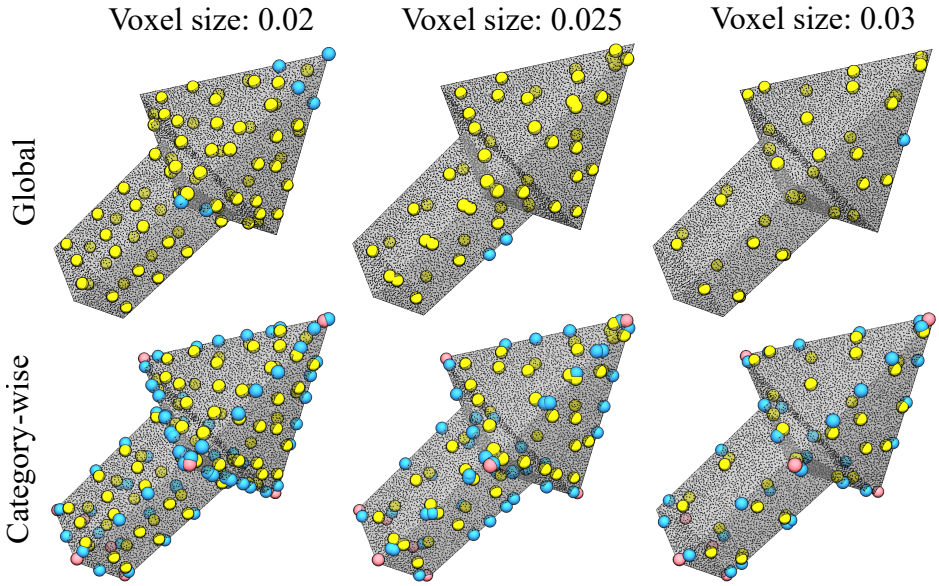


图 5.3　体素尺寸 v 对采样结果的影响分析。

Figure 5.3　The influence of voxel size v on the sampling results.

5.2.3　实验参数分析及配置

确定实验平台及评估对象集后，还需对算法中的关键参数进行分析与配置，以确保实验结果的有效性与可比性。如第四章所述，本文的抓取规划算法涉及到部分需要进行人工调节的参数，这些参数的取值直接影响到特征提取的质量、接触点检测的数量以及最终抓取构型的生成。参数具体包括体素尺寸 v（章节 4.2.2）、接触检测器尺寸参数 $d, \theta_{\text{sec}}, \theta_{\text{cone}}$（章节 4.3.1）、接触对验证阈值 θ_{th}（章节 4.3.2）以及抓取增强旋转角 β（章节 4.4.1）。在正式进行对比实验前，本文对这些关键参数进行了系统性的敏感性分析与调优，以确定最优的参数配置。

1）　体素尺寸 v

体素尺寸 v 决定了点云采样的密度，直接影响可用于抓取规划的候选点数量。如图 5.3 所示，本文对比了 v 在 0.02, 0.025 及 0.03 时的采样效果。观察发现，随着 v 的增加，采样密度降低，导致点云稀疏且候选点减少。反之，较小的 v 值能产生更密集的表示，提供更多的潜在接触位置，但计算成本也随之增加。经过实验分析，选择 $v = 0.025$ 作为后续实验的默认参数，以在采样密度与计算效率之间取得平衡。此时采样点数约为 100 个，与其余类似方法的采样点数相差较小，利于后续对比实验的开展。

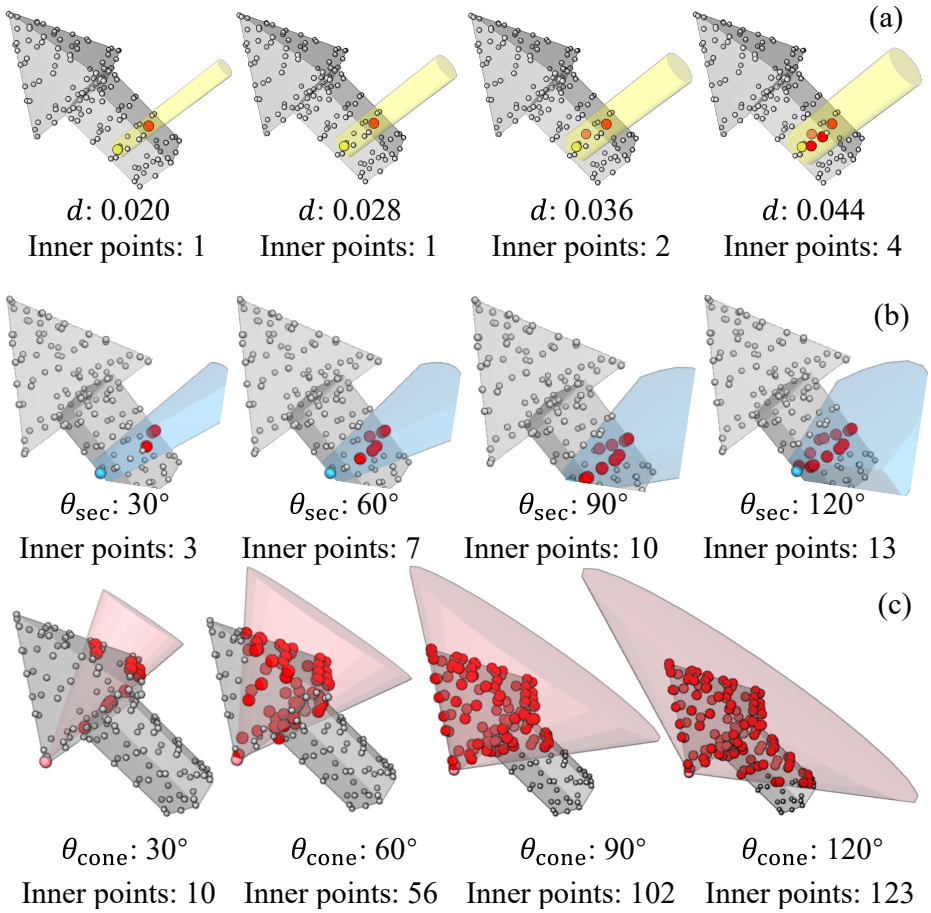


图 5.4 接触检测器尺寸参数 d、θ_{sec} 和 θ_{cone} 对潜在对跖接触点数量的影响分析。

Figure 5.4 The influence of contact detector size parameters d, θ_{sec}, and θ_{cone} on the number of potential antipodal contact points.

2） 接触检测器尺寸 $d, \theta_{\text{sec}}, \theta_{\text{cone}}$

接触检测器的尺寸参数决定了潜在对跖接触点的搜索区域。其中可调参数 d 用于确定圆柱检测器（用于面接触）的直径大小，θ_{sec} 定义了扇形检测器（用于边接触）的张角范围，而 θ_{cone} 则控制了圆锥检测器（用于角接触）的顶角大小。本文在一定范围内对这些参数进行了调节，以分析它们对潜在对跖接触点数量的影响，结果如图 5.4 所示。各参数的调整对潜在对跖接触点数量的影响如下所示：

- **参数 d**：如图 5.4(a) 所示，将 d 从 0.020 增加到 0.044 会扩大圆柱的搜索区域，导致检测到的内部点数量增加（从 1 增加到 4）。
- **参数 θ_{sec}**：如图 5.4(b) 所示，将 θ_{sec} 从 30° 放宽到 120° 会显著扩大边缘周围的覆盖面积，导致检测到的内部点数量从 3 上升到 13。
- **参数 θ_{cone}**：如图 5.4(c) 所示，将 θ_{cone} 从 30° 增加到 120° 会大幅增加搜索区域，导致内部点数量急剧增加（从 10 增加到 123）。

总体而言，较大的检测器尺寸能够覆盖更广的搜索区域，从而增加潜在对跖接触点的数量，但过大的尺寸可能会引入无效接触点，降低抓取质量。通过对比，本文选择了 $d = 0.028$、$\theta_{\text{sec}} = 90°$ 和 $\theta_{\text{cone}} = 90°$ 作为后续实验的默认参数配置，以在捕获足够的边缘与角点特征的同时，控制潜在接触点的数量，确保后续抓取规划的效率与质量。

3） 接触对验证阈值 θ_{th}

阈值 θ_{th} 作为接触对对齐质量的过滤器，用于强制执行对跖约束。图 5.5 展示了将 θ_{th} 从 150° 变化到 180° 的影响。为了取消抓取增强对该部分评估的影响，图中只对接触对进行可视化与统计，而非最终的抓取配置。观察发现，θ_{th} 与有效对的数量成反比。当 θ_{th} 较低（150°）时，约束较宽松，允许不太完美的对跖接触对，从而产生较多数量的有效接触对（82 对）。随着 θ_{th} 向 180° 增加，标准变得更严格，要求表面法线几乎完全共线。因此，经过验证的接触对数量减少（在 180° 时降至 40 对），这虽然保证了更高的抓取稳定性，但也减少了可用抓取候选的总数。本文选择 $\theta_{\text{th}} = 170°$ 作为后续实验的默认参数，以在抓取稳定性与候选数量之间取得平衡。

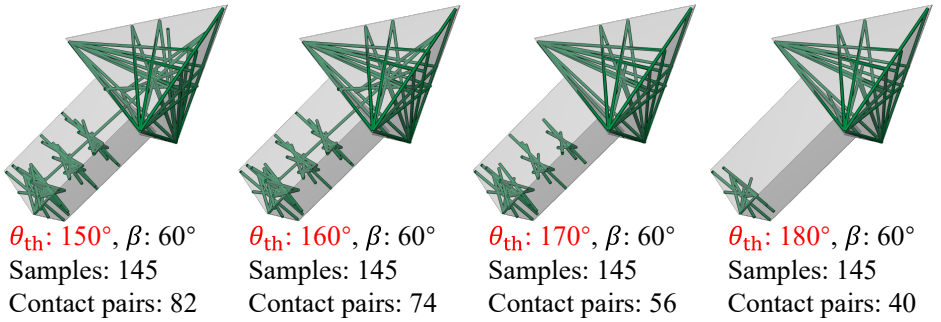


图 5.5 接触对验证阈值 θ_{th} 对生成对数量的影响分析。

Figure 5.5 The influence of antipodal pairing threshold θ_{th} on the number of generated pairs.

4） 抓取增强旋转角 β

参数 β 定义了沿接触向量旋转夹爪的角度步长，用于针对单个接触对生成多个抓取方向。图 5.6 展示了在固定 θ_{th} 的情况下，将 β 从 30° 变化到 180° 的影响。由于 β 是在配对后应用的，因此有效接触对的数量保持不变（56 对）。然而，生成的抓取总数对 β 高度敏感。较小的 β（例如 30°）意味着更精细的采样分辨率，能生成覆盖 360° 范围的密集抓取构型集合（595 个抓取）。随着 β 增加到 180°，采样变得粗糙，显著将总抓取数量减少至 106 个。因此，较小的 β 通过为机器人提供更多的方向选

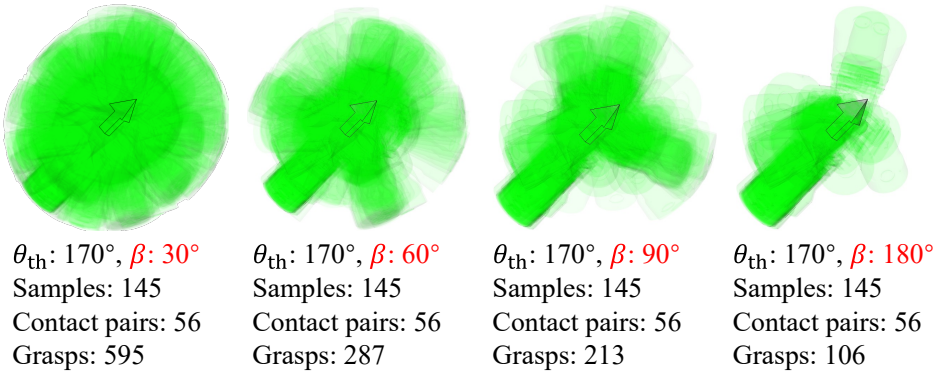


图 5.6　抓取增强旋转角 β 对生成抓取数量的影响分析。

Figure 5.6　The influence of grasp enhancement rotation angle β on the number of generated grasps.

项，增强了抓取的多样性和灵巧性。本文选择 $\beta = 30°$ 作为后续实验的默认参数，增加后续机械臂规划成功率。

5.3　对比实验及分析

针对本文提出的基于边缘与角点特征的抓取规划方法，本文设计了系统性的对比实验，以验证其在抓取构型多样性和实际抓取成功率方面的性能提升。对比实验主要从两个核心维度展开：首先在软件环境中分析不同算法生成的抓取构型在空间分布上的多样性；其次在物理实验平台上评估这些算法在真实环境中的抓取成功率。通过与多种主流抓取规划算法进行对比，本文旨在深入分析引入边缘与角点接触特征对提升抓取性能的具体贡献，并验证其实际应用的可行性。

5.3.1　对比实验设置

为了验证本文方法的性能，我们选择了三种具有代表性的基准算法进行对比：

1. **GraspIt!**[2]：经典的机器人抓取规划工具，基于模拟退火算法在物体表面搜索接触点，主要依赖刚体接触模型。
2. **WRS**[40]：基于几何分析的规划算法，侧重于提取平行平面特征来计算抓取，适合规则几何体。
3. **GPD**[39]：基于深度学习的抓取检测算法，通过神经网络评估局部点云内的抓取质量，不严重依赖完整模型，对不规则物体有较好适应性。

对比实验主要从两个维度进行：**抓取配置多样性分析**（仿真环境）与**抓取成功率分析**（真机环境）。为了保证公平性，各算法的实验设置保持统一：输入相同的物

体模型与位姿，且在统计分析前将各算法生成的候选抓取数量统一采样至 20 个，以消除数量差异带来的统计偏差（鉴于 GraspIt! 通常输出 20 个结果）。

5.3.2 抓取配置多样性分析

1） 评估指标

传统的抓取评价往往关注力封闭或形状封闭，而忽略了抓取构型在空间中的分布。一个分布广泛、均匀的抓取集合意味着机器人拥有更灵活的接近方向，能更好地适应非结构化环境中的避障与运动学约束。为此，本文引入三个统计学指标来量化抓取构型（以接触向量 $\mathbf{v}_i$ 表征）的分布特性：

1. **标准差 (STD)**：反映抓取方向相对于中心均值的离散程度。STD 越大，表示抓取分布越发散，不易陷入局部最优。
2. **极差 (Range, R)**：记录抓取分布边界之间的最大跨度，体现了算法所覆盖的工作空间广度。
3. **平均绝对偏差 (MAD)**：描述样本点相对于平均值的绝对偏差均值，具有较好的抗干扰性。

2） 结果分析与可视化

表 5.2 展示了不同算法在代表性物体（四面体、巧克力盒、海豹模型）上的统计结果。数据表明，本文方法（Ours）在所有三个指标（STD, R, MAD）上均取得了最高值。这直观论证了融合特征边沿及角点接触的机制有效拓宽了抓取解的空间分布。

图 5.7(a) 可视化了各算法生成的抓取位姿。对于无平行面的正四面体（图 a.1），WRS 无法通过平行面约束找到解（0 解），GraspIt! 和 GPD 仅生成了少量聚集性解，而本文方法利用棱边和角点覆盖了大部分空间。对于六棱柱巧克力盒（图 a.2），WRS 和 GraspIt! 的解主要集中在平行的六个面上，而本文方法填充了棱角过渡区域的空白。即便对于平滑的曲面物体海豹模型（图 a.3），本文方法依然保持了更均匀的分布。图 5.7(b) 进一步通过接触向量在三维空间中的散点投影图证实了这一点，红色点集（本文方法）展示了最广泛和均匀的覆盖范围。

5.3.3 抓取成功率分析

随后，我们在物理平台上对所有 9 种待测物体进行了实际抓取测试。实验流程为：针对每种物体，各算法均输出 Top-20 抓取位姿，机器人依次执行抓取、提升、移

表 5.2　不同抓取规划方法在三种代表性外形物体上的分布统计指标比较

测试物体	评估方法	标准差 STD (↑)	极差 R (↑)	平均绝偏 MAD (↑)
四面体 (Tetrahedron)	GraspIt!	0.2516	0.8676	0.1998
	GPD	0.2878	0.9375	0.2389
	WRS	/	/	/
	本文方法	**0.2995**	**0.9498**	**0.2450**
巧克力盒 (Amicelli)	GraspIt!	0.1669	0.6687	0.1177
	GPD	0.2742	0.9454	0.2162
	WRS	0.2639	0.9365	0.2002
	本文方法	**0.2835**	**0.9922**	**0.2193**
海豹模型 (Seal)	GraspIt!	0.2718	0.9063	0.2154
	GPD	0.2667	0.8409	0.2284
	WRS	0.2427	0.8690	0.2014
	本文方法	**0.2857**	**0.9154**	**0.2429**

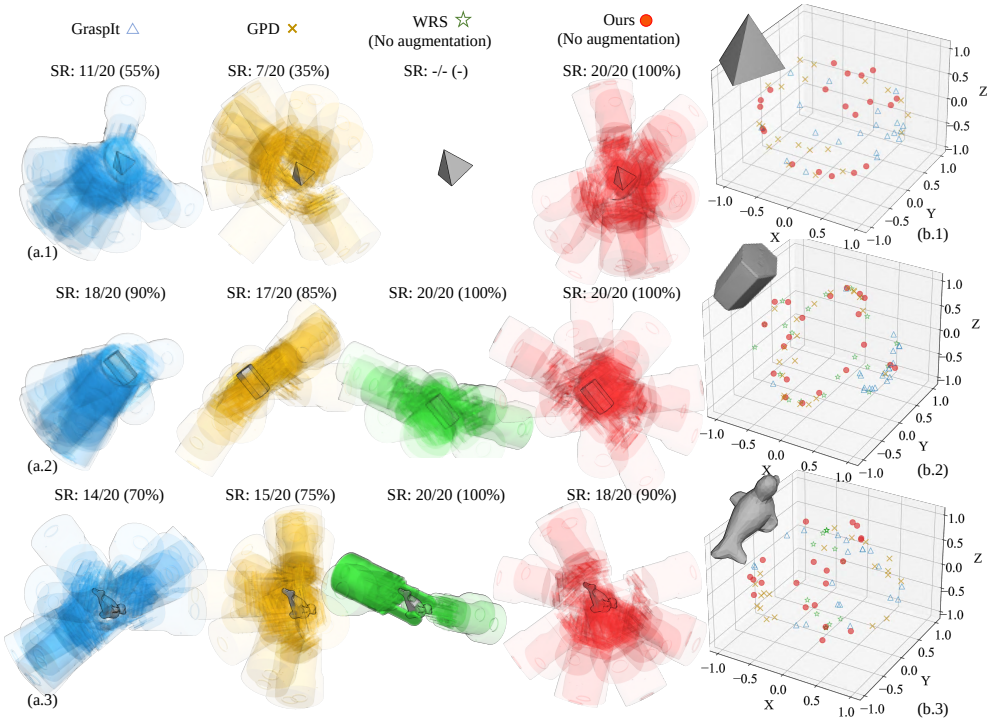


图 5.7　(a) 各算法生成的抓取可视化结果对比（a.1 四面体, a.2 巧克力盒, a.3 海豹模型）。蓝色：GraspIt!，黄色：GPD，绿色：WRS，红色：本文方法。(b) 抓取分布的三维散点图，展示了本文方法在方向覆盖上的优势。

表 5.3　物理实验抓取成功率统计结果（成功次数/总次数）

算法	四面体	巧克力盒	海豹	积木	链轮	牛奶盒	杯面	支架	直齿轮	平均率
GraspIt!	16/20	20/20	16/20	13/20	11/20	20/20	17/20	17/20	10/20	77.8%
GPD	7/20	15/20	17/20	19/20	11/20	20/20	14/20	13/20	11/20	70.6%
WRS	0/20	20/20	18/20	20/20	20/20	20/20	0/20	20/20	20/20	76.7%
Ours	**20/20**	**20/20**	**19/20**	**20/20**	**20/20**	**20/20**	**18/20**	**19/20**	**20/20**	**97.8%**

动、放置任务。抓取过程中不发生滑落、掉落或严重偏移即视为成功。

统计结果如表 5.3 所示。本文方法实现了 **97.8%** 的平均成功率，显著优于 GraspIt! (77.8%)、GPD (70.6%) 和 WRS (76.7%)。

- **WRS** 在规则物体（如巧克力盒、积木、电机支架）上表现满分，但在曲面或锐利边缘物体（四面体、速食杯面）上因找不到平行面而完全失效（0%）。
- **GPD** 虽然适用性广，但在处理尖锐几何特征（如多齿链轮、四面体）时，由于缺乏对物理接触转动的精确建模，容易发生打滑，成功率较低（35%-55%）。
- **GraspIt!** 在复杂接触（直齿轮）判断上表现保守，容易遗漏可行解。
- **本文方法**得益于软指腹变形模型与针对性的边角接触规划，在所有测试对象上均保持了极高的成功率，尤其在处理薄壁（速食杯面）、复杂齿状结构（链轮、直齿轮）时优势明显。

5.4　算法耗时

除了抓取质量，规划效率也是衡量算法实用性的关键指标。本节统计了算法在 Intel Core Ultra 9 处理器处理所有测试对象时的平均计算耗时。

如表 5.4 所示，单次规划全流程的平均耗时约为 **3.585 s**。其中：

- **特征提取阶段**耗时最长（约 3.016 s），因涉及全场点云的法线估计、曲率计算及特征分类。
- **接触检测阶段**耗时极短（约 0.089 s），得益于高效的几何探测器设计。
- **稳定性分析阶段**耗时约 0.481 s，主要用于力封闭验证。

各物体的计算时间波动较小，表明算法对不同几何复杂度的物体具有稳定的时间性能。3 秒左右的规划时间对于静态抓取或离线数据库构建任务是完全可接受的，且具有进一步优化的潜力。

表 5.4　各物体规划阶段平均耗时统计 (单位: 秒)

阶段	四面体	巧克力	海豹	积木	链轮	牛奶盒	杯面	支架	直齿轮	箭头	平均
特征提取	1.766	2.109	4.105	6.844	1.845	1.631	3.697	4.131	2.542	2.322	3.016
接触检测	0.078	0.032	0.082	0.051	0.071	0.129	0.141	0.059	0.038	0.075	0.089
稳定分析	0.626	0.591	0.724	0.092	0.601	0.523	0.301	0.091	0.475	0.461	0.481
总耗时	2.469	2.732	4.911	6.987	2.517	2.284	4.139	4.281	3.054	2.859	**3.585**

5.5　总结

本章通过系统性的仿真与物理实验，验证了考虑边缘与角点接触的抓取规划方法的优越性。实验结果表明：1. 在**抓取多样性**方面，本方法通过解除对平面接触的强依赖，显著提升了抓取构型在空间中的覆盖范围，增强了机器人对复杂环境的适应能力。2. 在**抓取成功率**方面，得益于软指腹形变模型对复杂几何特征（如锐边、尖角）的有效利用，本方法在包含各类异形物体的测试集上实现了 97.8% 的高成功率，解决了传统方法在非平行表面抓取上的痛点。3. 在**计算效率**方面，算法保持了秒级的响应速度，具备实际部署的工程价值。综上所述，本文方法不仅在理论上拓展了抓取接触的类型，更在实际应用中展现了强大的鲁棒性与通用性。

第六章　总结与展望

6.1　全文总结

本文针对三维点云几何特征检测精度不足及机器人抓取规划灵活性受限两大核心问题，提出了一套融合神经网络特征学习与基于模型抓取规划的完整研究框架，主要研究成果总结如下。

（1）基于多尺度局部特征的点云几何特征检测网络 NECDNet

本文提出了一种名为 NECDNet（Neural Edge and Corner Detection Network）的深度学习架构，能够同时完成面、边缘和角点三类几何特征的高精度同步分类。该方法的核心创新在于：针对每个查询点，在 $k \in \{8, 16, 32, 64\}$ 四个空间尺度下构建包含曲率（κ_i）、投影距离均值（$\bar{d}_i$）、中心偏离比（r_i）、法向角度差（$\mu_{\theta,i}$）、法向量分布方差（$\sigma^2_{\theta,i}$）和法线投影距离均值（$\bar{\text{proj}}_i$）六种解析特征的 4×6 多尺度特征矩阵，综合融合了位置分布特性与法向量变化信息。在网络结构上，设计了基于多层感知机（MLP）的层次化架构，通过两级分类器分别完成面点初判与边缘/角点细分，并结合 Focal Loss 策略有效缓解了类别不平衡问题。

在 ABC-Corner 数据集上的对比实验表明，NECDNet 在宏平均 F1 分数（0.815）、精确率（0.765）、召回率（0.933）及 MCC（0.943）等全部关键指标上均显著优于现有方法（CA、TECD、PIE-Net），在角点检测上的优势尤为突出。在纯边缘检测任务上，使用网格法向量的 NECDNet-2c† 取得了 F1 分数 0.956，同样领先于 PCEDNet（0.822）和 BoundED（0.875）。

（2）ABC-Corner 点云几何特征数据集构建

针对现有数据集（如 ABC 数据集）缺乏角点标注的问题，本文从 ABC 数据集的 chunk00 子集中筛选出 1000 个几何特征突出的 CAD 模型，设计了” 算法辅助粗提取 + 人工精细修正” 的两阶段标注流程，构建了 ABC-Corner 数据集。该数据集不仅为 NECDNet 的训练和评估提供了高质量的面、边缘、角点三类标签，也填补了点云几何特征检测领域在角点标注数据方面的空白，为相关研究提供了重要的基准资源。

（3）考虑边缘与角点接触的六自由度机器人抓取规划算法

本文提出了一种基于模型的解析式抓取规划方法，首次系统性地将边缘和角点

接触纳入抓取规划框架。该方法的核心包括： 类别感知的体素均衡采样策略，有效解决了面、边、角区域采样” 长尾” 分布问题； 特征化的接触检测器（面 → 圆柱体、边 → 扇形柱、角 → 圆锥体），突破了传统射线投射方法仅适用于面接触的局限；分类配对策略，针对六种接触组合（`f-f`、`f-e`、`f-c`、`e-e`、`e-c`、`c-c`）设计了不同的法向约束和投影距离筛选规则； 基于离散化近似的软接触力学模型，通过分布式硬点接触簇隐式捕捉软指腹的抗扭特性。

在仿真和物理实验中，本文方法在抓取分布多样性（STD、R、MAD 均最高）和真实抓取成功率（97.8%）两个维度上均优于 GraspIt!（77.8%）、GPD（70.6%）和 WRS（76.7%）三种基线方法。特别地，在四面体等高挑战性物体上，本文方法实现了 100% 的抓取成功率，而 WRS 在此类缺乏平行面的物体上成功率为 0%，有力地证明了边缘与角点接触建模对提升抓取规划灵活性的重要性。

6.2 创新点

本文的主要创新点归纳如下：

创新点一：提出了融合多尺度位置特征与法向量特征的点云几何特征检测方法 NECDNet。通过构建包含六种解析特征的 4×6 多尺度特征矩阵，并设计两级层次化分类器，实现了面、边缘、角点的高精度同步检测，尤其显著提升了角点检测的精度，填补了现有方法在该方向的不足。

创新点二：构建了首个包含角点精确标注的 ABC-Corner 点云几何特征数据集。通过算法辅助与人工精修相结合的标注方法，为 1000 个 CAD 模型提供了高质量的三类几何特征标签，解决了数据驱动方法训练数据匮乏的瓶颈问题。

创新点三：提出了一种利用软接触特性实现边缘与角点稳定抓取的机器人抓取规划框架。通过设计特征化空间接触检测器、软接触稳定性模型及抓取分布量化指标，系统性地突破了传统抓取规划器局限于面接触的约束，显著提升了机器人在多样化、复杂几何物体上的抓取灵活性与成功率。

6.3 研究不足与展望

尽管本文取得了一定的研究成果，但仍存在以下不足之处，有待在未来工作中进一步改进：

（1）法向量估计精度对 NECDNet 性能的制约。本文实验表明，使用从网格模型精确估计的法向量可将 NECDNet 的宏平均 F1 分数提升约 10 个百分点（从 0.715 到 0.815）。然而，在实际点云扫描场景中，基于局部最小二乘拟合的法向量估计在边缘和角点附近存在” 平滑化” 偏差，导致性能有所下降。未来可研究更鲁棒的法向量估计算法（如基于深度学习的法向量预测），以减小对精确法向量的依赖。

（2）抓取规划对完整物体模型的依赖。本文提出的抓取规划方法目前属于离线规划框架，需要已知物体完整的 CAD 模型作为输入。在实际非结构化场景中，物体往往存在遮挡或未知情况，直接限制了方法的在线应用能力。未来可结合三维重建或点云补全技术，探索在残缺点云或未知物体上的应用方案。

（3）对多指灵巧手的扩展性不足。现有方法主要针对平行双指夹爪设计，虽然可以在一定程度上扩展至多指夹爪的对指抓取模式，但对于需要复杂手内操作的多指灵巧手尚未适用。未来可将边缘、角点接触的几何建模思想推广至多指手的协同规划中，进一步提升机器人操作的灵活性。

（4）任务语义与抓取规划的结合。本文的抓取规划主要以几何稳定性为优化目标，未考虑任务语义（Task Semantics）和功能可供性（Affordance）等高层约束。在实际应用中，机器人操作往往需要根据任务意图选择合适的抓取部位（如抓取工具的手柄而非刀刃）。将几何特征检测与任务感知抓取规划相结合，是未来值得深入探索的方向。

插图索引

图 2.1 NECDNet 网络架构及工作流程示意图。 7
图 2.2 基于 PCA 的点云法向量估计结果示意图。 10
图 2.3 基于 CAD 网格模型的点云法向量估计结果示意图。 10
图 2.4 投影距离均值的几何意义示意图。 13
图 2.5 六个局部特征描述符在不同几何类别下的数值分布情况。 17
图 2.6 NECDNet 网络架构示意图。 17
图 3.1 常用点云数据集对比示意图。 23
图 3.2 ABC 数据集中的部分 CAD 模型示例。 23
图 3.3 ABC-Corner 数据集标注流程示意图。 24
图 3.4 ABC-Corner 数据集中的部分样本及其标注结果。 25
图 3.5 ABC-Corner 数据集上各方法的边缘与角点检测结果可视化对比。本文方法（Ours）取得了最佳的检测效果。CA 和 TECD 缺乏鲁棒性，PIE-Net 检测精度不足，PCEDNet 表现出良好的边缘检测能力但无法检测角点。 32
图 3.6 法向量估计精度对检测结果的影响分析：(a) 检测结果真值（Ground Truth）；(b) 使用从 Mesh 估计的法向量得到的检测结果，F1 分数为 0.815；(c) 使用从点云估计的法向量得到的检测结果，F1 分数为 0.715。使用点云估计的法向量会导致更多的边缘点被误分类为角点，在图中表现为红色区域的增加。 37
图 4.1 基于几何特征的机器人抓取规划框架 43
图 4.2 基于类别的体素采样结果 44
图 4.3 基于 NECDNet 的几何特征检测结果 44
图 4.4 不同体素采样尺寸及采样策略下的采样结果 46

图 4.5 凸性检测中凹凸查询点点对应 θ_i^s 对比 46

图 4.6 基于几何特征的接触对检测流程..... 48

图 4.7 基于几何特征的三种接触检测器：(a) 面接触圆柱体检测器；(b) 边接触扇形柱检测器；(c) 角接触圆锥体检测器 49

图 4.8 抓取构型增强示意图 53

图 4.9 碰撞检测结果对比：红色表示发生碰撞的构型，绿色表示无碰撞的构型 54

图 4.10 基于软接触变形的接触点集获取示意图 55

图 5.1 实验平台架构示意图。左侧为物理实验平台，包含 ABB GOFA-5 六轴协作机械臂与 DH-ROBOTICS PGC 系列平行电动夹爪；右侧为软件仿真平台，基于 World Robot System (WRS) 进行开发与测试。 59

图 5.2 评估对象集的三维模型示例。 60

图 5.3 体素尺寸 v 对采样结果的影响分析。 62

图 5.4 接触检测器尺寸参数 d、θ_{sec} 和 θ_{cone} 对潜在对跖接触点数量的影响分析。63

图 5.5 接触对验证阈值 θ_{th} 对生成对数量的影响分析。 64

图 5.6 抓取增强旋转角 β 对生成抓取数量的影响分析。 65

图 5.7 (a) 各算法生成的抓取可视化结果对比（a.1 四面体, a.2 巧克力盒, a.3 海豹模型）。蓝色：GraspIt!，黄色：GPD，绿色：WRS，红色：本文方法。(b) 抓取分布的三维散点图，展示了本文方法在方向覆盖上的优势。 67

表格索引

表 3.1 ABC-Corner 数据集中各类几何特征的分布统计。 28

表 3.2 三分类任务的混淆矩阵示例。 30

表 3.3 ABC-Corner 数据集上各边缘与角点检测方法的宏平均（Macro-averaging）指标评分。 31

表 3.4 图 3.5 中四个点云对象的分类别详细指标评分：Precision, Recall, F1。 .. 33

表 3.5 图 3.5 中四个点云对象的分类别详细指标评分：Accuracy, IoU, MCC。（续表） 33

表 3.6 ABC 数据集上各边缘检测方法的指标评分。 35

表 3.7 特征维度选择消融实验结果。 38

表 3.8 多尺度参数选择消融实验结果。 39

表 3.9 数据重采样策略的消融实验结果。 40

表 3.10 标注平滑策略的消融实验结果。 40

表 5.1 实验测试验证对象集的物理特征信息及体积测量 61

表 5.2 不同抓取规划方法在三种代表性外形物体上的分布统计指标比较 67

表 5.3 物理实验抓取成功率统计结果（成功次数/总次数） 68

表 5.4 各物体规划阶段平均耗时统计 (单位: 秒) 69

参考文献

[1] AHMED S M, TAN Y Z, CHEW C M, et al. Edge and corner detection for unorganized 3d point clouds with application to robotic welding[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2018: 7350-7355.

[2] MILLER A T, ALLEN P K. Graspit!: A versatile simulator for grasp analysis[C]// ASME 2000 International Mechanical Engineering Congress and Exposition. American Society of Mechanical Engineers Digital Collection, 2021: 1251-1258.

[3] GUMHOLD S, WANG X. Feature extraction from point clouds[J]. Proceedings of 10th international meshing roundtable, 2001, 2001.

[4] BAZAZIAN D, CASAS J R, Ruiz-Hidalgo J. Fast and robust edge extraction in unorganized point clouds[C]//2015 International Conference on Digital Image Computing: Techniques and Applications (DICTA). 2015: 1-8.

[5] LIN Y, WANG C, CHENG J, et al. Line segment extraction for large scale unorganized point clouds[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 102: 172-183.

[6] DEMARSIN K, VANDERSTRAETEN D, VOLODINE T, et al. Detection of closed sharp edges in point clouds using normal estimation and graph theory[J]. Computer-Aided Design, 2007, 39(4): 276-283.

[7] HIMEUR C E, LEJEMBLE T, PELLEGRINI T, et al. Pcednet : A lightweight neural network for fast and interactive edge detection in 3d point clouds[J]. ACM Transactions on Graphics, 2022, 41(1): 1-21.

[8] BODE L, WEINMANN M, KLEIN R. Bounded: Neural boundary and edge detection in 3d point clouds via local neighborhood statistics[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 205: 334-351.

[9] MIRZAEI K, ARASHPOUR M, ASADI E, et al. 3d point cloud data processing with machine learning for construction and infrastructure applications: A comprehensive review[J]. ADVANCED ENGINEERING INFORMATICS, 2022, 51: 101501.

[10] COVER T, HART P. Nearest neighbor pattern classification[J/OL]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27. DOI: 10.1109/TIT.1967.1053964.

[11] BROWN R A. Review of three algorithms that build k-d trees: arXiv:2506.20687 [M/OL]. arXiv, 2025. DOI: 10.48550/arXiv.2506.20687.

[12] SHLENS J. A tutorial on principal component analysis: arXiv:1404.1100[M/OL]. arXiv, 2014. DOI: 10.48550/arXiv.1404.1100.

[13] HOPPE H, DEROSE T, DUCHAMP T, et al. Surface reconstruction from unorganized points[J/OL]. SIGGRAPH Comput. Graph., 1992, 26(2): 71-78. DOI: 10.1145/142920.134011.

[14] CIGNONI P, CALLIERI M, CORSINI M, et al. MeshLab: an Open-Source Mesh Processing Tool[C/OL]//SCARANO V, CHIARA R D, ERRA U. Eurographics Italian Chapter Conference. The Eurographics Association, 2008. DOI: 10.2312/LocalChapterEvents/ItalChap/ItalianChapConf2008/129-136.

[15] TOLSTIKHIN I O, HOULSBY N, KOLESNIKOV A, et al. Mlp-mixer: An all-mlp architecture for vision[C/OL]//RANZATO M, BEYGELZIMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems: Vol. 34. Curran Associates, Inc., 2021: 24261-24272. https://proceedings.neurips.cc/paper_files/paper/2021/file/cba0a4ee5ccd02fda0fe3f9a3e7b89fe-Paper.pdf.

[16] XU B, WANG N, CHEN T, et al. Empirical evaluation of rectified activations in convolutional network: arXiv:1505.00853[M/OL]. arXiv, 2015. DOI: 10.48550/arXiv.1505.00853.

[17] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(56): 1929-1958.

[18] BISHOP C M. Pattern recognition and machine learning[M]. New York: Springer, 2006.

[19] JAPKOWICZ N, STEPHEN S. The class imbalance problem: A systematic study[J]. Intell. Data Anal., 2002, 6(5): 429-449.

[20] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[J/OL]. IEEE transactions on pattern analysis and machine intelligence, 2020, 42(2): 318-327. DOI: 10.1109/TPAMI.2018.2858826.

[21] MAO A, MOHRI M, ZHONG Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//ICML'23: Vol. 202 Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA: JMLR.org, 2023: 23803-23828.

[22] KOCH S, MATVEEV A, JIANG Z, et al. Abc: A big cad model dataset for geometric deep learning[C/OL]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 9593-9603. DOI: 10.1109/CVPR.2019.00983.

[23] CHANG A X, FUNKHOUSER T, GUIBAS L, et al. Shapenet: An information-rich 3d model repository: arXiv:1512.03012[M/OL]. arXiv, 2015. DOI: 10.48550/arXiv.1512.03012.

[24] DAI A, CHANG A X, SAVVA M, et al. Scannet: Richly-annotated 3d reconstructions of indoor scenes[C]//Proc. Computer Vision and Pattern Recognition (CVPR), IEEE. 2017.

[25] LAI K, BO L, REN X, et al. A large-scale hierarchical multi-view rgb-d object dataset [C/OL]//2011 IEEE International Conference on Robotics and Automation. 2011: 1817-1824. DOI: 10.1109/ICRA.2011.5980382.

[26] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in python[J]. Journal of Machine Learning Research, 2011, 12(85): 2825-2830.

[27] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library[A]. 2019.

[28] HARRIS C R, MILLMAN K J, van der Walt S J, et al. Array programming with numpy[J]. Nature, 2020, 585(7825): 357-362.

[29] VIRTANEN P, GOMMERS R, OLIPHANT T E, et al. Scipy 1.0: Fundamental algorithms for scientific computing in python[J]. Nature Methods, 2020, 17(3): 261-272.

[30] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. CoRR, 2014.

[31] LOSHCHILOV I, HUTTER F. Sgdr: Stochastic gradient descent with warm restarts: arXiv:1608.03983[M]. arXiv, 2017.

[32] KRSTINIĆ D, BRAOVIĆ M, ŠERIĆ L, et al. Multi-label classifier performance evaluation with confusion matrix[J/OL]. Computer Science & Information Technology (CS & IT), 2020, 10(8): 1. DOI: 10.5121/csit.2020.100801.

[33] CHICCO D, JURMAN G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J/OL]. BMC Genomics, 2020, 21: 6. DOI: 10.1186/s12864-019-6413-7.

[34] DÜNTSCH I, GEDIGA G. Confusion matrices and rough set data analysis[J/OL]. Journal of Physics: Conference Series, 2019, 1229(1): 012055. DOI: 10.1088/1742-6596/1229/1/012055.

[35] ERBANI J, PORTIER P É, Egyed-Zsigmond E, et al. Confusion matrices: A unified theory[J/OL]. IEEE Access, 2024, 12: 181372-181419. DOI: 10.1109/ACCESS.2024.3507199.

[36] WANG X, XU Y, XU K, et al. Pie-net: Parametric inference of point cloud edges [C]//NIPS '20: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020: 20167-20178.

[37] LI R, QIAO H. A survey of methods and strategies for high-precision robotic grasping and assembly tasks—some new trends[J/OL]. IEEE/ASME Transactions on Mechatronics, 2019, 24(6): 2718-2732. DOI: 10.1109/TMECH.2019.2945135.

[38] NEWBURY R, GU M, CHUMBLEY L, et al. Deep learning approaches to grasp synthesis: A review[J/OL]. Trans. Rob., 2023, 39(5): 3994-4015. DOI: 10.1109/TRO.2023.3280597.

[39] TEN PAS A, GUALTIERI M, SAENKO K, et al. Grasp pose detection in point clouds [J/OL]. The International Journal of Robotics Research, 2017, 36(13-14): 1455-1473. DOI: 10.1177/0278364917735594.

[40] WAN W, HARADA K, KANEHIRO F. Planning grasps with suction cups and parallel grippers using superimposed segmentation of object meshes[J]. IEEE Transactions on Robotics, 2021, 37(1): 166-184.

[41] ESTER M, KRIEGEL H P, SANDER J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//KDD'96: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. Portland, Oregon: AAAI Press, 1996: 226-231.

[42] FISCHLER M A, BOLLES R C. Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography[J/OL]. Commun. ACM, 1981, 24(6): 381-395. DOI: 10.1145/358669.358692.

[43] MURRAY R M, SASTRY S S, ZEXIANG L. A mathematical introduction to robotic manipulation[M]. 1st ed. USA: CRC Press, Inc., 1994.

攻读专业硕士学位期间取得的研究成果

一、专著

[1] 张三. XXXXXXXXXXXXXXXXX [M]. 南京: XXXXXXXX 出版社, 2022.

二、论文

[1] ZHANG San. XXXXXXXXXXXXXXXXXXXXX[J]. Bulletin of the Geological Survey of Japan, 2021, 57(5/6): 169-176.

[2] XXX, SATIO M, BUSH G, et al. XXXXXXXXXXXXXXXXXXXXXX XX[J]. Journal of the American Chemical Society, 2022, 2(3):20-26.

三、专利

[1] 张三. XXXXXXXXXXXXXXXXX: 202210050175. 8 [P]. 2022-10-14.

四、项目

1. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），主持，XXXX.XX.XX—XXXX.XX.XX。

2. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），参与，第二，XXXX.XX.XX—XXXX.XX.XX。

致　谢

衷心感谢导师 xxx 教授对本人的精心指导.

作者署名

完成地点

2023 年 12 月 18 日

附录 A　经典函数公式

论文中用到的经典函数公式.

(Sigmoid Function) Sigmoid 函数定义为

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}.$$

(ReLU Function) ReLU 函数定义为

$$\text{ReLU}(x) = \max(0, x).$$

(Leaky ReLU Function) Leaky ReLU 函数定义为

$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases}$$

其中 α 是一个较小的常数，通常取值为 0.01。

附录 B　用于定量比较的指标公式

章节 (3.3.6) 中提到的用于定量比较的指标公式如下。

(Precision) 精确率（Precision）定义为

$$\text{Precision} = \frac{TP}{TP + FP}$$

其中 TP 表示真正例（True Positive）的数量，FP 表示假正例（False Positive）的数量。

(Recall) 召回率（Recall）定义为

$$\text{Recall} = \frac{TP}{TP + FN}$$

其中 TP 表示真正例（True Positive）的数量，FN 表示假负例（False Negative）的数量。

(F1 Score) F1 分数定义为

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

用于综合评估模型的精确率和召回率。

(Matthews Correlation Coefficient) 马修斯相关系数（The Matthews Correlation Coefficient, MCC）定义为

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

其中 TP、TN、FP 和 FN 分别表示真正例、真反例、假正例和假反例的数量。

(Intersection over Union) 交并比（Intersection over Union, IoU）定义为

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

用于衡量预测结果与真实标签之间的重叠程度。

(Accuracy) 准确率（Accuracy）定义为

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

用于衡量模型预测的整体正确性。