中图分类号：XXX　　单位代号：10280
密　　级：公开　　学　　号：23722063

上海大学

专业硕士学位论文

SHANGHAI UNIVERSITY PROFESSIONAL MASTER'S DISSERTATION

题目	基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者　邱模聪
学科专业　机械
导　　师　袁建军
完成日期　二〇二六年五月

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学

本论文经答辩委员会全体委员审查，确认符合上海大学专业硕士学位论文质量要求。

答辩委员会签名:

主　　席:

委　　员:

导　　师:

答辩日期:　　年　　月　　日

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学学位论文原创性声明

本人郑重声明: 所呈交的学位论文是本人在导师指导下, 独立进行研究工作所取得的成果。除了文中特别加以标注和致谢的内容外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他研究者对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名:

日期:　　年　　月　　日

上海大学学位论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定, 即: 学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

(保密的论文在解密后应遵守此规定)

学位论文作者签名:　　导师签名:

日期:　　年　　月　　日　　日期:　　年　　月　　日

上海大学工学专业硕士学位论文

基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者: 邱模聪
导　　师: 袁建军
学科专业: 机械

机电工程与自动化学院
上海大学
2026 年 5 月

A Dissertation Submitted to Shanghai University for the
Degree of Professional Master in Engineering

Learning-Based Point Cloud Geometric Feature Detection and Robotic Grasp Planning

Candidate: Mocong Qiu
Supervisor: Jianjun Yuan
Major: Mechanics

School of Mechatronic Engineering and Automation
Shanghai University
December, 2026

摘 要

针对点云几何特征检测精度不足及机器人抓取规划灵活性受限的问题，本文提出一种融合神经网络特征学习与基于模型抓取规划的框架。首先，提出神经边缘角点检测网络（NECDNet）。该网络通过分析多尺度邻域内的位置和法向分布构建特征矩阵，利用层次化神经网络实现面、边、角点的同步分类；同时构建了包含 1000 个模型的 ABC-Corner 数据集。其次，本文提出一种考虑边、角接触的六自由度双指抓取规划算法。该算法利用 NECDNet 提取特征区域，设计特征化接触检测器搜索对偶接触点，并引入软接触模型评估稳定性，有效解决了非规则物体的抓取难题，增强抓取规划多样性。实验表明，NECDNet 的角点检测 F1 分数达 0.815，优于现有方法；抓取算法在分布复杂度指标（STD、Range、MAD）均优于 GPD，GraspIt 等基于模型的抓取规划方法，抓取配置灵活性显著提升。机器人实验验证了包括角-角、角-边等六种接触组合的有效性与鲁棒性，展示了抓取规划的有效性及抓取成功率上的提升。

关键词：点云处理；几何特征检测；神经网络；机器人；抓取规划；平行手爪

ABSTRACT

This thesis addresses the challenges of insufficient geometric feature detection accuracy in point clouds and limited flexibility in robotic grasp planning by proposing a unified framework that integrates neural network-based feature learning with model-based grasp planning. First, we introduce the Neural Edge and Corner Detection Network (NECDNet), which constructs a feature matrix by analyzing the positional and normal distributions within multi-scale neighborhoods and employs a hierarchical neural network to simultaneously classify faces, edges, and corners. Additionally, we curate the ABC-Corner dataset containing 1,000 annotated models to support training and evaluation. Second, we present a six-degree-of-freedom dual-finger grasp planning algorithm that explicitly accounts for edge and corner contacts. This algorithm leverages NECDNet for feature region extraction, employs feature-specific contact detectors to identify antipodal contact pairs, and integrates a soft contact model for stability assessment, thereby effectively tackling the grasp planning challenges associated with irregular objects and enhancing grasp configuration diversity. Experimental results demonstrate that NECDNet achieves corner detection with an F1 score of 0.815, outperforming existing methods. Furthermore, the proposed grasp algorithm surpasses model-based grasp planning approaches such as GPD and GraspIt across all distribution complexity metrics (STD, Range, MAD), significantly improving grasp configuration flexibility. Real-world robotic experiments validate the robustness and effectiveness of six distinct contact combinations, including corner-corner and corner-edge interactions, demonstrating improved grasp planning efficacy and success rate.

Keywords: Point cloud processing; Geometrical feature detection; Neural network; Robotics; Grasp planning; Parallel gripper.

目　录

主要符号表

$\mathcal{P}^{\mathrm{c}}$	非结构化点云
n	点云中点的数量
$\mathbf{p}_i^{\mathrm{c}}$	查询点（点云中第 i 个点的三维坐标）
$\mathcal{Q}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的邻域
k	查询点邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 中点的数量
$\mathbf{x}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 在某一尺度下的局部特征向量
$\mathbf{X}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的多尺度特征矩阵
m	多尺度邻域的数量

第一章　研究背景与意义

本章节主要介绍本文的研究背景与意义，综述点云几何特征检测和机器人抓取规划的国内外研究现状，指出现有研究存在的问题，并阐述本文的主要研究内容和章节安排。

1.1　研究背景

随着计算机视觉和机器人技术的飞速发展，三维（3D）点云数据的处理与分析已成为学术界和工业界的研究热点。点云数据能够精确地表达物体表面的几何结构，获取物体内在的交互信息，因此在逆向工程、三维重建、物体识别、场景分割以及机器人自主操作等任务中发挥着至关重要的作用。

在这些任务中，物体的几何特征（如边缘和角点）承载了最关键的结构信息。边缘和角点定义了物体的边界和轮廓，是理解物体形状的基础。在分割和重建任务中，这些特征作为区域的分割边界[?]；在识别任务中，它们作为关键线或关键点[?]；在机器人抓取或焊接等应用中，它们提供了必要的轮廓信息[?]。准确提取这些几何特征，能够显著降低任务的复杂度并提高处理精度。

然而，从点云中自动检测几何特征仍面临巨大挑战。首先，由于现实世界物体的物理平滑特性以及扫描设备的精度限制，获取的三维扫描点云往往缺乏绝对锐利的特征，导致边缘和角点的定义存在固有的模糊性。其次，区分边缘和角点的特征值往往非常敏感，难以通过简单的阈值进行界定。此外，不同特征的样本密度极不平衡，角点样本的数量远少于边缘和面点，这使得高精度的角点检测尤为困难。

与此同时，机器人抓取规划作为实现机器人自主操作的核心环节，其目标是生成稳定且灵活的抓取配置。目前的抓取规划方法，无论是基于模型的解析方法还是基于深度学习的数据驱动方法，通常都优先考虑面接触（Face Contact）。这类方法倾向于将手爪指腹与物体表面法线对齐，以确保抓取的稳定性[??]。虽然这种策略在处理规则物体时表现优异，但在面对多面体、非对称物体或具有复杂尖锐几何特征的物体时，往往因为受限于平行的平面接触区域而显得灵活性不足。为了获得稳定的面接触，规划器往往会刻意避开边缘和角点区域，这在很大程度上限制了机器人的

操作能力。

事实上，在引入软指（Soft Finger）接触模型后，手爪指腹的变形能力使得边缘和角点也能形成等效的面接触，从而提供足够的摩擦力和抗扭矩能力[?]。这意味着，如果能够有效利用边缘和角点作为潜在的接触区域，将极大地扩展机器人抓取的候选空间，提高抓取规划的灵活性和适应性。因此，本文致力于研究点云几何特征的精确检测方法，并在此基础上探索考虑边缘和角点接触的机器人抓取规划算法，以解决当前特征检测精度不足和抓取规划灵活性受限的问题。

1.2 国内外研究现状

1.2.1 点云几何特征检测研究现状

点云几何特征检测方法主要分为传统解析方法和基于数据驱动的方法。

1） 传统解析方法

传统解析方法主要通过分析局部邻域的统计信息来计算特征描述符，并结合人工设定的阈值进行特征提取。主成分分析（PCA）是最常用的方法之一，Gumhold 等人[?]通过计算邻域协方差矩阵的特征值，当最小特征值超过阈值时判定为特征点。基于此，Xia 等人[?]和 Bazazian 等人[?]分别利用单尺度和多尺度的特征值比率作为局部特征描述符。此外，基于曲率估计的方法[??]和基于法向量变化的方法[?]也被广泛应用。

为了提高检测的鲁棒性，一些研究引入了更复杂的几何分析。Daniels 等人[?]利用移动最小二乘法（MLS）进行表面重建，通过局部近似来增强特征检测。Guo 等人[?]提出了基于图的方法，结合全局上下文信息来提升特征提取效果。Zhang 等人[?]提出的 VAM 方法利用一致性投票机制估计法向量，有效保留了重建过程中的锐利特征。Mérigot 等人[?]则利用局部 Voronoi 单元内的法向量分布来提取锐利边缘。Zhao 等人[?]提出了多任务神经网络架构，用于识别锐利特征附近的点并预测位移向量。

在角点检测方面，Ahmed 等人[?]采用了两步提取法，首先提取边缘点，然后基于边缘点重新计算特征以识别角点。Schmidt 等人[?]提出利用 RANSAC 提取直线或平面，通过它们的交点来检测角点。

总体而言，传统解析方法计算效率高，但其性能高度依赖于参数和阈值的精细调节。在面对尺度变化大或特征模糊的复杂场景时，难以实现鲁棒的检测。特别是

高精度的角点检测通常需要复杂的两步流程，效率较低且难以调参。

2） 基于数据驱动的方法

近年来，基于深度学习的数据驱动方法逐渐成为主流，这类方法通常将特征检测视为点云分类问题，即区分平滑点和锐利特征点。PIE-Net[?] 采用基于 PointNet++[?] 的双流网络分别提取边缘和角点，但其效率较低且要求输入点数固定。EDC-Net[?] 利用胶囊网络将点分类为非边缘或锐利边缘。PCPNet[?] 和 MSL-Net[?] 分别以点块和点云为输入，利用多层感知机（MLP）进行分类。PCEDNet[?] 和 BoundED[?] 通过神经网络学习多尺度局部特征描述符，在边缘检测方面取得了显著成果。

除了分类方法，部分研究将其建模为回归问题。DEFs[?] 和 EC-Net[?] 通过学习点坐标残差并估计到边缘的距离来实现精确的边缘点识别。NerVE[?] 使用体素化点云以结构化格式检测锐利特征。JSENet[?] 则利用双流全卷积网络同时执行边缘检测和语义分割。

然而，现有基于学习的方法大多集中于边缘特征的提取，针对角点检测的研究相对较少。由于角点特征与边缘特征具有相似性，且数据量更为稀疏，直接应用现有边缘检测网络往往导致角点识别精度低、误判率高的问题。即便是专门针对角点检测的方法（如 PIE-Net），也常因特征区分度不足而出现较多误分类。

1.2.2 机器人抓取规划研究现状

机器人抓取规划方法主要分为基于模型的方法和基于学习的方法。

1） 基于模型的抓取规划

基于模型的方法依赖于物体的几何模型和物理规则来生成抓取配置，并通过解析计算评估其稳定性。这类方法主要分为图元拟合（Primitive Fitting）和表面分割（Surface Segmentation）两类策略。

图元拟合方法[??] 将物体近似为基本几何体（如圆柱、球体、方块）以简化抓取合成。Chen 等人[?] 利用词嵌入量化已知模型与真实物体之间的语义相似度，通过模型匹配实现抓取。表面分割方法[??] 则通过识别有意义的表面区域来指导抓取生成。Harada 等人[?] 根据接触柔软度对三角网格进行聚类，实现了针对软指的抓取规划。Wan 等人[?] 提出了叠加分割法，根据表面法线将每个三角形分割为具有受控重叠和厚度的不同面片。

这些传统的基于模型的方法通常强调面接触的重要性[?]，并刻意避免在边缘和角点附近进行接触[?]。这种权衡虽然提高了稳定性，但降低了抓取的多样性和灵活性。

2） 基于学习的抓取规划

基于学习的方法利用神经网络和数据驱动技术来增强抓取的灵活性和适应性[? ?]。Dex-Net 4.0[?] 探索了一种混合方法，利用几何和力学模型生成合成训练数据集。L2G[?] 采用由多任务优化目标引导的可微采样过程，联合求解接触点采样、抓取回归和分类。然而，这些基于学习的方法通常依赖于抓取数据集，而这些数据集往往也是基于传统的面接触规则生成的[?]，因此生成的抓取策略依然倾向于面接触。

3） 抓取质量评价标准

评估抓取候选可行性和质量的标准多种多样。最常用的是抓取稳定性，通常通过力封闭（Force Closure）或形封闭（Form Closure）条件进行评估。解析方法通过评估旋量空间覆盖率、抗扭矩能力或最小力需求来确定抓取可靠性[? ?]。GraspIt![?] 是一个广泛使用的仿真平台，支持力封闭计算和抓取姿态优化。相比之下，数据驱动方法通常训练模型直接从视觉或几何输入预测抓取质量分数[?]。此外，一些混合方法结合了解析指标和数据驱动模型以增强泛化能力[? ?]。

然而，现有的评价标准主要关注稳定性、可抓取性[?] 或功能性（Affordance），很少关注抓取配置的分布特性。抓取配置的分布反映了机器人手爪接近和抓取物体的位姿范围，是衡量抓取灵活性的重要指标。

1.3 本文主要研究内容

针对上述问题，本文的主要研究内容包括以下三个方面：

1. **基于多尺度局部特征的点云边缘与角点检测网络（NECDNet）**：提出了一种能够同时提取点云中面、边缘和角点特征的神经网络框架。该方法通过分析多尺度邻域内的位置和法向量分布，构建包含曲率、投影距离、法向角差等六维特征的多尺度特征矩阵。设计了基于多层感知机（MLP）的层次化网络结构，融合多尺度特征并实现高精度的三分类。该方法不仅在边缘检测上达到了竞争水平，更显著提升了角点检测的精度。

2. **ABC-Corner 点云几何特征数据集构建**：针对现有数据集（如 ABC 数据集）

缺乏角点标注的问题，本文构建了包含 1000 个物体模型的 ABC-Corner 数据集。通过结合算法辅助与人工精细修正的方法，提供了高质量的边缘和角点标签，解决了数据驱动方法在角点检测任务中训练数据匮乏的问题，为相关研究提供了基准。

3. **考虑边缘和角点接触的六自由度抓取规划算法**：提出了一种基于模型的解析式抓取规划方法。该方法利用提取的几何特征，针对面、边缘和角点分别设计了圆柱形、扇形和锥形接触检测器，以搜索潜在的对指抓取点对。引入软接触模型对边缘和角点接触的稳定性进行评估，从而生成包含多种接触类型（如角-角、角-边、边-面等）的抓取配置。此外，本文还引入了抓取分布统计指标来量化抓取灵活性，实验证明该方法显著提高了抓取规划的灵活性和对复杂几何物体的适应性。

1.4 论文组织结构

本文共分为六章，各章节安排如下：

第一章：绪论。介绍了课题的研究背景与意义，综述了点云几何特征检测和机器人抓取规划的国内外研究现状，指出了现有研究存在的问题，并阐述了本文的主要研究内容和章节安排。

第二章：点云几何特征检测网络 NECDNet。详细介绍了 NECDNet 的网络架构、多尺度特征计算方法以及 ABC-Corner 数据集的构建过程。

第三章：考虑边缘和角点接触的抓取规划算法。阐述了基于几何特征的接触点采样、接触检测器设计、对指点对搜索以及基于软接触模型的稳定性评估方法。

第四章：实验与分析。对提出的特征检测网络和抓取规划算法进行了全面的实验验证，并与现有主流方法进行了对比分析。

第五章：总结与展望。总结了本文的主要研究成果，分析了存在的不足，并对未来的研究方向进行了展望。

第二章　基于多尺度特征融合的点云几何特征检测

2.1　引言

三维点云几何特征检测（如边缘和角点的提取）是三维视觉领域的关键环节，在模型重建、物体识别及机器人抓取规划中具有不可替代的作用。传统的分析方法主要依赖于局部几何描述符（如曲率、法向量偏差等）并结合人工设置的阈值。然而，由于点云数据存在噪声、密度不均以及边缘及角点定义模糊等问题，传统方法往往难以兼顾检测精度与鲁棒性[]。

为了解决边缘与角点特征在微小尺度下难以区分的问题，本章提出了一种名为NECDNet（Neural Edge and Corner Detection Network）的深度学习架构。该方法通过融合统计特征描述符与轻量级神经网络，利用多尺度邻域分析来捕捉点云局部的空间分布和法向量变化特征，从而实现对面点（Face）、边缘点（Edge）和角点（Corner）的高精度同步分类。

图 **??**展示了所提 NECDNet 的工作流程，NECDNet 由两个主要部分组成：多尺度局部特征矩阵计算和基于神经网络的分类器。流程的输入是一个非结构化点云，输出的是一个三类点云，包含面点、边缘点和角点。在多尺度特征计算阶段，我们针对每个查询点构建了包含四个不同尺度邻域的特征矩阵，每个尺度下计算六种解析特征：曲率、投影距离、均值中心距离、法向角差、法向分布和投影法向模。最终形成一个 4×6 的多尺度特征矩阵，作为神经网络的输入。在分类器阶段，我们基于多层感知机（MLP）设计了一个层次化网络结构，通过逐层融合多尺度特征，学习从特征矩阵到几何类别的映射关系。输出三类几何特征的概率得分，从而实现面、边缘和角点的同步检测。

图中左上为输入的点云数据，每次选择一个查询点（红色）及其邻域（绿色）。其中不同的 k 值表示不同尺度的邻域大小（黄色点的数量）。通过计算各尺度下的六维特征，形成多尺度特征矩阵并输入神经网络进行分类。最终输出查询点所属的几何类别（面、边缘或角点）。通过循环查询各个点，完成整个点云的几何特征检测任务，最后输出检测结果（左下）。

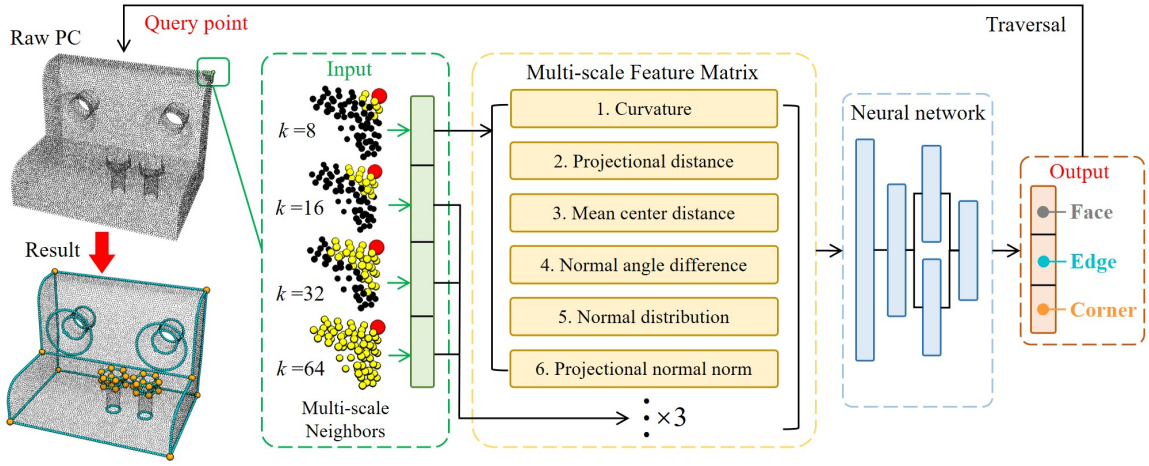


图 2.1 NECDNet 网络架构及工作流程示意图。

Figure 2.1 NECDNet network architecture and workflow diagram.

2.2 多尺度局部特征提取与计算

多尺度表示的是针对每个查询点，选择不同数量的邻域点以构建多层次的局部几何描述。由于点云捕获时的视角、距离及分辨率等因素影响，单一尺度往往难以全面反映局部几何结构的信息。通过分析不同尺度下的点云分布特征，可以更全面地捕捉局部几何结构，从而提升边缘和角点的区分能力[]。适用的尺度取决于多个因素：物体大小、形状复杂度、点云密度、观察尺度等。为了使训练得到的模型能泛化处理未知物体的情况，本文为输入点云中的每个查询点在多尺度邻域内计算多个特征，并在 **??**进行了消融实验确保各个尺度选择的合理性。

2.2.1 多尺度邻域构建

本文采用基于距离度量的 k 近邻（k-Nearest Neighbors, k-NN）为每个查询点构建多尺度邻域，并以此生成多尺度特征输入网络进行学习[]。k-NN 是一种基于距离度量的邻域选择方法，通过计算查询点与其他点之间的欧氏距离，选取距离最近的 k 个点作为邻域。与固定半径（radius-based）邻域相比，k-NN 对点云非均匀采样与稀疏区域更加稳健：在稠密区不会过采样、在稀疏区不会因样本不足而破坏特征稳定性。对于非结构化的点云，其只包含点的三维坐标信息，k-NN 方法能够有效适应点云的稀疏性和不均匀分布特性。

为提升检索效率，给定一个非结构化点云 $\mathcal{P}^{\mathrm{c}} = \{\mathbf{p}_i^{\mathrm{c}} \mid i = 1, \ldots, n\}$，我们在三维坐标空间上构建 KD-树（K-Dimensional Tree）索引[]。KD-树通过在各坐标轴上递

归划分点集，使每个节点对应一个超矩形子空间，从而形成近似平衡的二叉树。查询时，先依据查询点坐标自顶向下定位至叶节点，再在回溯过程中检查可能包含更近邻点的分支，并维护容量为 k 的候选集合以持续更新最近邻。相比于暴力检索的 $O(n)$ 复杂度，KD-树可将单次最近邻查询的平均复杂度降至 $O(\log n)$ ，显著提升大规模点云处理的效率。

基于上述索引结构，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，我们通过 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}} = \{\mathbf{p}_{i,j}^{\mathrm{c}} \mid j = 1, \ldots, k\}$。通过调节 k 的大小即可改变邻域的空间尺度：较小的 k 更敏感于细粒度几何细节（如尖锐小角、细薄边），较大的 k 则能稳健表征更大范围的局部结构。为兼顾不同尺度的几何信息，我们针对多个 k 值为同一查询点构建多组邻域，形成多尺度邻域表示。

具体而言，对由给定 k 值确定的局部区域 $\mathcal{Q}_i^{\mathrm{c}}$ 计算六个解析特征，得到 6 维特征向量 $\mathbf{x}_i^{\mathrm{c}}$。当为同一查询点在多个 k 值下重复上述过程，即可获得对应的 $\mathbf{x}_{i,k}^{\mathrm{c}}$。将这些特征按尺度汇集，构成用于后续网络学习的多尺度特征矩阵，如公式 (**??**) 所示：

$$\mathbf{X}_i^{\mathrm{c}} = \begin{bmatrix} \mathbf{x}_{i,k_1}^{\mathrm{c}} \\ \mathbf{x}_{i,k_2}^{\mathrm{c}} \\ \vdots \\ \mathbf{x}_{i,k_m}^{\mathrm{c}} \end{bmatrix} \tag{2.1}$$

其中，$k_1, k_2, \ldots, k_m$ 表示所选择的不同邻域尺度，m 为尺度数量。多尺度特征矩阵中的尺度数 m 和尺度大小 k 直接影响神经网络的学习结果。具体来说，k 影响结果对点云不同稀疏度的适用性，而 m 影响网络学习数据的维度。选择合适的尺度尺寸和数量可以优化检测精度。因此，在第**??**章中，本文对邻近尺度选择进行了消融实验以确定参数，并选择了 k 的四个值：8、16、32 和 64 进行特征计算。

2.2.2 点云前处理

为了消除点云绝对坐标、平移以及尺度差异对特征计算的影响，在提取特征前，本文首先对邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 进行归一化处理。该过程基于主成分分析（Principal Component Analysis, PCA）思想，计算邻域点的协方差矩阵 $\mathbf{K}_i = \mathrm{cov}(\mathcal{Q}_i^{\mathrm{c}})$，并对其进行奇异值分解（Singular Value Decomposition, SVD），如公式 (**??**) 所示。

$$\mathbf{K}_i = \mathbf{U}_i \mathbf{\Sigma}_i \mathbf{V}_i^T \tag{2.2}$$

其中，$\mathbf{U}_i$ 和 $\mathbf{V}_i$ 分别为左奇异向量矩阵和右奇异向量矩阵，$\mathbf{\Sigma}_i$ 为对角奇异值矩阵。通过该分解，我们能够获得邻域点在主方向上的分布特性。具体而言，通过对角矩阵 $\mathbf{\Sigma}_i$ 提取奇异向量 $\boldsymbol{\sigma}_i = (\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3})$ ，其中的奇异值计为降序排列。右奇异向量矩阵 $\mathbf{V}_i$ 的列向量对应于邻域点在三个主方向上的投影轴。不同的奇异值反映了邻域点在各主方向上的扩展程度。奇异值较小的方向点云分布较为集中，反之则较为分散。通过上述分解结果，可以对邻域点进行去中心化与尺度归一化处理。具体而言，首先计算邻域点的质心 $\bar{\mathbf{p}}_{i,j}^{\mathrm{c}}$ ，如公式 (**??**) 所示。其中 $|\mathcal{Q}_i^{\mathrm{c}}|$ 表示邻域点的数量。

$$\bar{\mathbf{p}}_{i,j}^{\mathrm{c}} = \frac{1}{|\mathcal{Q}_i^{\mathrm{c}}|} \sum_{j=1}^{k} \mathbf{p}_{i,j}^{\mathrm{c}} \tag{2.3}$$

随后，将所有邻域点坐标减去质心实现去中心化，并利用奇异值 $\sigma_{i,1}$ 和 $\sigma_{i,2}$ 对去中心化后的邻域点进行尺度缩放，确保各个方向上的分布具有统一的量纲，如公式 (**??**) 所示。最终，得到归一化后的邻域 $\hat{\mathcal{Q}}_i^{\mathrm{c}}$，为后续特征计算提供了标准化的输入。归一化邻域后的查询点坐标记为 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，邻域中的点坐标记为 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$。

$$\hat{\mathcal{Q}}_i^{\mathrm{c}} = \left\{ \frac{2}{\sqrt{\sigma_{i,1}} + \sqrt{\sigma_{i,2}}} \left(\mathbf{p}_{i,j}^{\mathrm{c}} - \bar{\mathbf{p}}_{i,j}^{\mathrm{c}} \right) \mid \mathbf{p}_{i,j}^{\mathrm{c}} \in \mathcal{Q}_i^{\mathrm{c}} \right\} \tag{2.4}$$

此外，法向量是描述点云局部表面方位的重要几何属性，也是计算后续方向特征的基础。本文采用基于局部平面拟合的方法估计查询点的法向量。从公式 (**??**) 的奇异值分解结果中可知，奇异值 $\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3}$ 对应的右奇异向量（即矩阵 $\mathbf{V}_i$ 的列向量）构成了邻域内点集分布的正交主轴。由于奇异值按降序排列，最小奇异值 $\sigma_{i,3}$ 对应的奇异向量 $\mathbf{v}_{i,3}$ 指向了邻域内点集分布方差最小的方向。在几何意义上，该方向与局部最小二乘拟合平面的法向重合。因此，查询点的法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可直接取为归一化后的右奇异向量 $\mathbf{v}_{i,3}$ 。

然而，仅通过 PCA 获得的法向量存在 180° 的方向模糊性（即法向量可能指向物体内侧或外侧）。为了确保在计算后续法向量夹角差异等特征时的数值一致性，必须对法向量进行定向处理。在处理具有闭合表面的物体时，通常利用视点方向或邻域一致性进行约束。本文采用最小生成树（Minimum Spanning Tree, MST）算法在点云图中传播法向量方向，以实现全局的方向一致化[]。具体而言，将点云视为图结构，以点间距离为边权构建图，从初始点开始，通过遍历图确保相邻点的法向量满足内积大于零的约束，实现对点云中各点法向量的方向一致化。

2.2.3 局部特征描述符设计

在构建多尺度邻域的基础上，本文进一步设计了一套包含六个维度的局部几何特征描述符，旨在精确捕捉查询点及其邻域在不同空间尺度下的结构属性。这六种特征可归纳为基于位置的几何特征（Position-based Features）与基于法向量方向的特征（Normal-based Features）两大类。基于位置的特征主要通过分析邻域点的空间分布规律来描述局部形状，而基于法向量的特征则通过分析表面方向的连续性与一致性，提供关于几何边缘与尖锐角点的关键判别信息。这种多维特征的结合，增强了模型在面对复杂、模糊边界时的区分能力。消融实验中对特征计算中涉及的所有描述符进行了评估，说明了该选择的有效性。

1） 曲率（κ_i）

首先计算基于位置的几何特征，表征邻域内点的几何分布特性。曲率 κ_i 是几何物体偏离平面程度的度量。在本文中，查询点邻域的曲率可以根据上述得到的奇异值进行计算，用于表征局部表面的平坦程度。具体而言，曲率定义为最大奇异值与三维奇异值之和的比值，如公式 (**??**) 所示。

$$\kappa_i = \frac{\sigma_{i,3}}{\sigma_{i,1} + \sigma_{i,2} + \sigma_{i,3}} \tag{2.5}$$

当查询点位于平坦表面时，$\sigma_{i,3}$ 较小，曲率值接近于零；而当查询点位于尖锐边缘或角点时，$\sigma_{i,3}$ 较大，曲率值相应增大。因此，曲率特征有助于区分面点与边缘、角点。

2） 投影距离均值（$\bar{d}_i$）

投影距离均值 $\bar{d}_i$ 用于刻画查询点邻域内点相对于该点法向平面的空间分布，其大小反映了局部几何结构的突变程度。具体地，对于任一查询点 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，结合其法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可定义通过该点的投影平面。邻域内所有点 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$ 到该投影平面的距离均值即为 $\bar{d}_i$，计算公式如 (**??**) 所示。

$$\bar{d}_i = \frac{1}{|\hat{\mathcal{Q}}_i^{\mathrm{c}}|} \sum_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \left| (\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} - \hat{\mathbf{p}}_i^{\mathrm{c}}) \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.6}$$

图 **??**展示了该距离度量的几何意义。其反映了邻域点在查询点法向方向上的分布特性：当邻域点主要分布在查询点法向平面附近时，投影距离较小，表明局部几

何结构较为平滑；而当邻域点在法向方向上分布较为分散时，投影距离增大，通常对应于边缘或角点区域。

3） 中心偏离比（r_i）

中心偏离比 r_i 是量化查询点在其局部邻域内的相对空间位置的度量，其能够衡量查询点相对于其邻域质心的偏移程度。具体而言，首先计算邻域点的质心，由于此时的邻域 $\hat{\mathcal{Q}}_i^{\mathrm{c}}$ 已经进行了去中心化及归一化处理，因此邻域质心即为原点。之后计算查询点到质心的距离 $\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|$ 与邻域内各点到质心距离 $\|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|$ 的最小值之比，得到中心距离均值比 r_i，计算公式如 (**??**) 所示，由于该特征为比值，当分母较小时产生的结果不受此前归一化邻域的影响。故针对特征 r_i，本文选用 Sigmoid 函数对其进行标准化处理，以减小数值分布的变化范围。

$$r_i = \mathrm{Sigmoid}\left(\frac{\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|}{\min_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|}\right) \tag{2.7}$$

其中 Sigmoid 表示 Sigmoid 函数，$\|\cdot\|$ 表示欧氏距离，min 运算符用于获取邻域点中距离质心最近的点的距离，式中省略了减去质心零向量的表示。中心偏离比 r_i 反映了查询点在邻域内的相对位置关系：当查询点位于邻域质心附近时，r_i 值较小，表明该点可能位于平坦区域；而当查询点远离邻域质心时，r_i 值增大，通常对应于边缘或角点区域。因此，中心偏离比有助于区分不同几何特征。

4） 法向量角度差（$\mu_{\theta,i}$）

以此特征描述符开始，后续的三个描述符是基于法向量方向的特征，旨在捕捉表面方向的突变信息。法向角度差 $\mu_{\theta,i}$ 衡量查询点法向量与其邻域内各点法向量之间夹角的平均值，反映了局部表面方向的一致性。具体而言，首先根据章节**??**中的方法估计邻域内每个点的单位法向量 $\mathbf{n}_{i,j}^{\mathrm{c}}$，组合为 $\mathcal{N}_i^{\mathrm{c}}$。随后，计算查询点法向量 $\mathbf{n}_i^{\mathrm{c}}$ 与邻域内各点法向量之间的夹角 $\theta_{i,j}$ ，计算公式如 (**??**)。最后并求各个夹角的平均值，求解公式如 (**??**) 所示。

$$\theta_{i,j} = \arccos\left(\mathbf{n}_i^{\mathrm{c}} \cdot \mathbf{n}_{i,j}^{\mathrm{c}}\right) \tag{2.8}$$

$$\mu_{\theta,i} = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{j=1}^{|\mathcal{N}_i^{\mathrm{c}}|} \theta_{i,j} \tag{2.9}$$

其中，arccos 表示反余弦函数。法向角度差 $\mu_{\theta,i}$ 反映了邻域内法向量的方向变化程度：当邻域内法向量与查询点法向量高度一致时，$\mu_{\theta,i}$ 值较小，表明局部表面较为平滑；而当邻域内法向量与查询点法向量差异较大时，$\mu_{\theta,i}$ 值增大，通常对应于边缘或角点区域。

此外，除了用法向量夹角来表示方向变化外，还可以直接使用法向量的数值之差来表示方向变化。具体而言，计算查询点法向量与邻域内各点法向量的差值，并求其平均值，得到法向量数值差 $\bar{\Delta\mathbf{n}}_i$，计算公式如 (**??**) 所示。相较与法向量角度差 $\mu_{\theta,i}$，法向量数值差 $\bar{\Delta\mathbf{n}}_i$ 直接采用原始法向量数据进行统计计算，后续消融实验中会讨论两者的效果差异。

$$\bar{\Delta\mathbf{n}}_i = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{\mathbf{n}_{i,j}^{\mathrm{c}} \in \mathcal{N}_i^{\mathrm{c}}} (\mathbf{n}_i^{\mathrm{c}} - \mathbf{n}_{i,j}^{\mathrm{c}}) \tag{2.10}$$

5） 法向量分布方差（$\sigma_{\theta,i}^2$）

法向量分布方差 $\sigma_{\theta,i}^2$ 用于量化邻域内法向量夹角的变化剧烈程度，反映了局部表面方向的稳定性。具体而言，基于前述计算的法向角度差 $\mu_{\theta,i}$，计算邻域内各点法向量与查询点法向量夹角的方差，求解公式如 (**??**) 所示。

$$\sigma_{\theta,i}^2 = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{j=1}^{|\mathcal{N}_i^{\mathrm{c}}|} (\theta_{i,j} - \mu_{\theta,i})^2 \tag{2.11}$$

法向量分布方差 $\sigma_{\theta,i}^2$ 反映了邻域内法向量变化的剧烈程度：当邻域内法向量夹角较为集中时，$\sigma_{\theta,i}^2$ 值较小，表明局部表面方向较为稳定；而当邻域内法向量夹角分布较为分散时，$\sigma_{\theta,i}^2$ 值增大，通常对应于边缘或角点区域，而角点区域的分散程度更为显著。

6） 法线投影距离均值（$\bar{\mathbf{proj}}_i$）

法线投影距离均值 $\bar{\mathrm{proj}}_i$ 用于量化邻域点法向量在查询点法向上的投影强度，反映了表面法向的对齐程度。具体而言，计算邻域内每个点法向量 $\mathbf{n}_{i,j}^{\mathrm{c}}$ 在查询点法向 $\mathbf{n}_i^{\mathrm{c}}$ 上的投影长度，并求其平均值，计算公式如 (**??**) 所示。

$$\bar{\mathrm{proj}}_i = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{\mathbf{n}_{i,j}^{\mathrm{c}} \in \mathcal{N}_i^{\mathrm{c}}} \left| \mathbf{n}_{i,j}^{\mathrm{c}} \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.12}$$

由于各点的法向量均为单位向量，法线投影距离均值 $\bar{\mathrm{proj}}_i$ 可以反映邻域内法向

量与查询点法向量的对齐程度：$\bar{\text{proj}}_i$ 值较大，表明局部表面方向较为统一；而当邻域内法向量与查询点法向量差异较大时，$\bar{\text{proj}}_i$ 值减小，通常对应于边缘或角点区域。

2.2.4 局部特征描述符数值可视化分析

通过上述计算的局部特征描述符，本文最终选择了其中六个组成特征描述向量，并用于后续的特征融合和分类任务。最后得到的特征向量如公式 (**??**) 所示。六个特征均为标量，组成的特征向量维度为 6，包含了点云的位置分布特性和法向量变化信息，能够有效表征点云局部的几何结构属性。

$$\mathbf{x}_i^{\text{c}} = \left(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i\right) \tag{2.13}$$

图 **??** 展示了多尺度几何特征在点云三类特征（面、边缘、角点）中的分布表现，直观体现了所选六维特征向量对于区分不同几何类别的有效性。其中图 (a) 对单个物体点云的六个特征进行了空间分布可视化。每个子图分别显示了特征描述符 κ_i（曲率）、$\bar{d}_i$（投影距离均值）、r_i（中心偏离比）、$\mu_{\theta,i}$（法向量角度差）、$\sigma^2_{\theta,i}$（法向量分布方差）、$\bar{\text{proj}}_i$（法向投影距离均值）在点云空间上的数值分布情况。颜色表示数值大小，采用从蓝色（低值）到红色（高值）的渐变色带。根据上一小节对各特征的定义，可以观察到：除了特征 $\bar{\text{proj}}_i$ 外，其他五个特征在面、边缘和角点区域均表现出从低到高的数值变化趋势（蓝色到红色）。而特征 $\bar{\text{proj}}_i$ 则呈现出相反的趋势，在面区域数值较高（红色），而在边缘和角点区域数值降低（橙黄色）。各个特征在不同的几何结构上有着明显的区别。

图 (b) 部分给出了在我们构建的数据集 ABC-Corner 中 1000 个点云样本的六个特征在三类标签下的数值分布，数据集的描述及构建过程请见章节 (**??**)。纵轴为点云 ID，横轴为特征值，颜色标记类别：蓝色为面、黄色为边缘、红色为角点。统计结果显示，在面、边缘、角点三类之间，所有特征分布具有明显的界限。以曲率和法向分布为例，角点（红色）主要集中在中高值段，面点则聚集于低值，边缘点分布于中间区域。其他如投影距离、均值中心距离等特征也展现出对类别的良好区分能力。

虽然可以观察到直接使用这些特征描述符就能进行一定程度上的几何特征区分。然而，直接使用这些特征进行检测类似于分析方法，需要参数调整并且可能无法保证稳健的结果。为了解决这个问题，本文利用神经网络从计算的特征矩阵中学习。这种方法使能够结合分析方法和基于学习的检测技术的优势，实现精准的自分类。

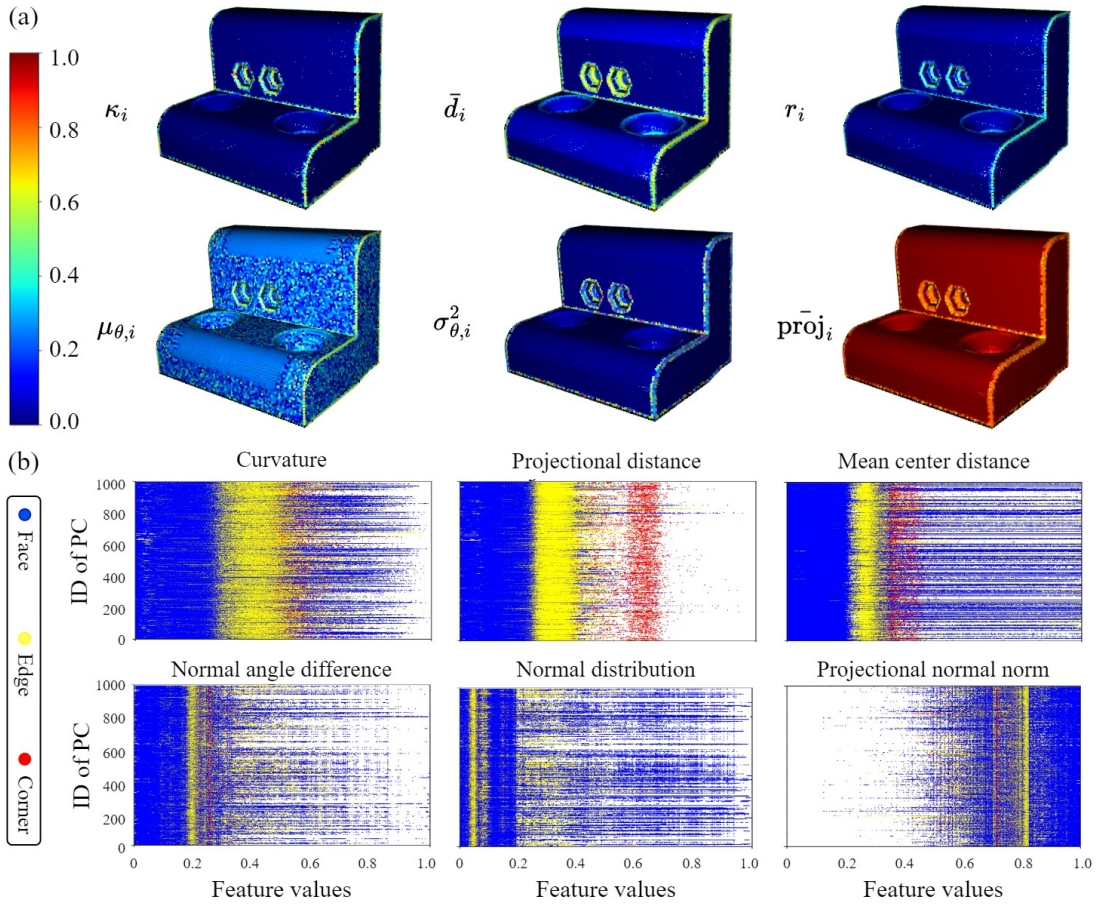


图 2.2 六个局部特征描述符在不同几何类别下的数值分布情况。

Figure 2.2 Distribution of six local feature descriptors across different geometric categories.

2.3 NECDNet 网络架构设计

NECDNet 网络架构针对点云数据中特征点的精细分类任务（包括面点、边缘点和角点），设计了以多层感知机（Multi-Layer Perceptron, MLP）为核心、多尺度特征深度融合与分阶段判别相结合的高效结构[?]。整体网络流程如图 **??** 所示，主要包括两大模块：首先，多尺度特征融合模块从多个邻域尺度提取并逐级整合各类局部几何信息，实现输入信息的丰富表达；其次，逐级分类模块采用分层分类思路，将点的最终类别归属过程划分为由简到繁的两个层次，提升了分类准确率和模型的泛化能力。结合全连接层、Leaky ReLU 激活及 Dropout 策略，有效增强了网络的判别能力并抑制了过拟合风险[??]。下文将分别对多尺度特征融合与逐级分类策略进行详细阐述。

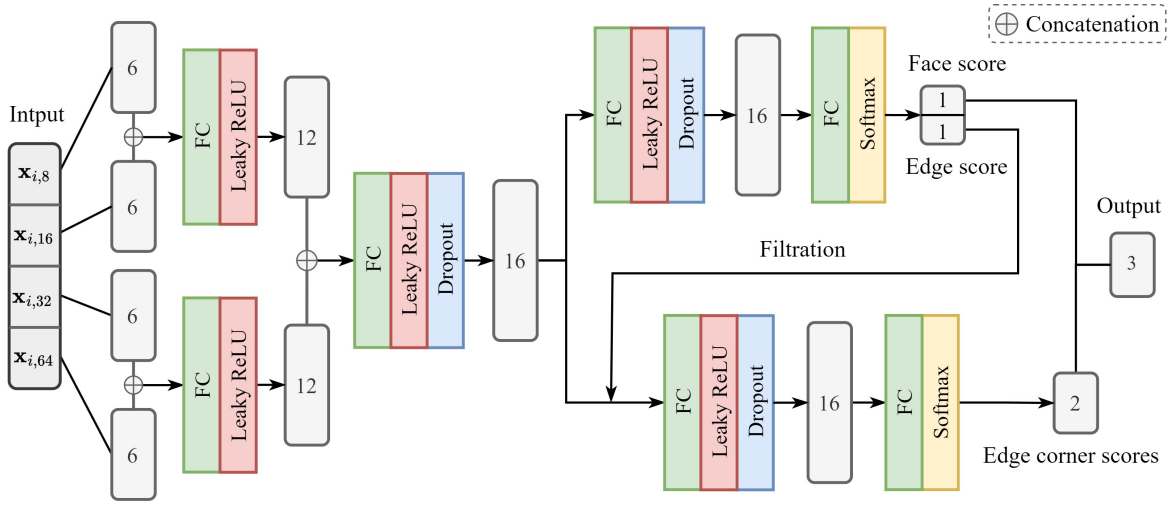


图 2.3 NECDNet 网络架构示意图。

Figure 2.3 NECDNet network architecture diagram.

2.3.1 多尺度特征融合

NECDNet 的输入部分针对每个查询点构建了多尺度邻域下的几何属性特征矩阵。具体地，针对每个点，分别在 $k = 8, 16, 32, 64$ 四种不同邻域尺度内提取点云的几何特征，每个尺度获得一个 6 维特征向量 $\mathbf{x}_{i,k} \in \mathbb{R}^6$，所有尺度拼接形成 4×6 的特征矩阵。

这一多尺度特征首先经过特征提取单元处理。对于第 j 个尺度 ($j \in \{1, 2, 3, 4\}$) 的输入特征 $\mathbf{x}_{i,j}$，通过全连接层（FC）、Leaky ReLU 激活函数进行非线性映射。该过程可表示为：

$$\mathbf{h}_i^{(1)} = \sigma_{\text{LReLU}}(\mathbf{W}_i^{(1)}\mathbf{x}_{i,j} + \mathbf{b}_i^{(1)}) \tag{2.14}$$

其中，$\mathbf{W}_i^{(1)}$ 和 $\mathbf{b}_i^{(1)}$ 为权重矩阵和偏置项，σ_{LReLU} 表示 Leaky ReLU 激活函数，其定义为 $f(x) = \max(x, \alpha x)$，α 为负半轴斜率（通常取 0.01）[?]。

随后，参考图 **??** 中的结构，模型将相邻两个尺度的特征进行两两拼接（Concatenate）。例如，将 $k = 8$ 和 $k = 16$ 对应的特征 $\mathbf{h}_1^{(1)}$ 和 $\mathbf{h}_2^{(1)}$ 拼接得到 $\mathbf{z}_{12} = [\mathbf{h}_1^{(1)}, \mathbf{h}_2^{(1)}]$。融合后的特征再次通过类似的非线性变换，公式如 **(??)** 所示。相较于上一步，这里引入了 Dropout 层以防止过拟合现象的发生[?]。

$$\mathbf{h}_{12}^{(2)} = \text{Dropout}\left(\sigma_{\text{LReLU}}(\mathbf{W}_{12}^{(2)}\mathbf{z}_{12} + \mathbf{b}_{12}^{(2)})\right) \tag{2.15}$$

同理可得 $\mathbf{h}_{34}^{(2)}$。接着，将这两组特征进一步拼接为 24 维大向量 $\mathbf{z}_{\text{final}}$，并通过进一步

的 FC 层非线性降维，得到 16 维的综合多尺度特征输出 $\mathbf{F}_{\text{out}}$。

整个多尺度特征融合过程不仅实现了不同邻域尺度下信息的交互、互补和融合，还通过层级式的非线性变换消除了简单拼接可能造成的信息冗余，使网络能够自主学习到最具区分力的综合表达，为后续分类模块奠定坚实基础。

2.3.2 逐级分类器

多尺度特征融合单元输出的 16 维向量 $\mathbf{F}_{\text{out}}$ 随后交由逐级分类器进行细粒度类别判别。该模块采用两级分层判别架构。

1） 第一级分类（面点判别）

首先，$\mathbf{F}_{\text{out}}$ 经过类似公式 (**??**) 的变换降维至 8 维，得到中间特征 $\mathbf{v}_{\text{mid}}$。随后，通过 FC 层输出面点与非面点的逻辑值（Logits）$\mathbf{l}_1 \in \mathbb{R}^2$。最终的初级分类概率分布 $\mathbf{p}_1$ 由 Softmax 函数计算得出[?]:

$$\mathbf{p}_1 = \text{Softmax}(\mathbf{l}_1) = \frac{e^{\mathbf{l}_{1,j}}}{\sum_{k=1}^{2} e^{\mathbf{l}_{1,k}}}, \quad j \in \{1, 2\} \tag{2.16}$$

若判定为面点，则直接据此输出结果；若为非面点，则将中间特征 $\mathbf{v}_{\text{mid}}$ 送入下一级分类子模块。

2） 第二级分类（边缘点与角点判别）

在第二级分类器中，传入的 8 维特征 $\mathbf{v}_{\text{mid}}$ 再次经历 FC、Leaky ReLU 和 Dropout 处理，降维为 4 维特征 $\mathbf{v}_{\text{sub}}$，最后映射为边缘点和角点的二分类逻辑值 $\mathbf{l}_2$。同样利用 Softmax 得到概率分布 $\mathbf{p}_2$，类似公式 (**??**) 所示。最终，对于每个输入点，网络结合两级输出确定“面-边缘-角”三类别的归属。

这种分级判别方法，有效简化了单次多分类的复杂度，提升了点云中特征类别区分的精度和鲁棒性。值得一提的是，每层分类器均结合 Leaky ReLU 增强非线性表达，Dropout 有效应对过拟合风险，整体保证了 NECDNet 在结构复杂、类别分布不均等点云场景下的自适应能力。

2.3.3 损失函数

点云中几何特征的分布存在不平衡现象，面点数量远多于边缘点和角点，特别是角点[?]。为了应对类别不平衡问题，本文在训练过程中采用 Focal Loss 作为优化

指标[?]。Focal Loss 旨在解决训练中前景与背景类别极度不平衡的单阶段物体检测场景（例如 1：1000）。其在交叉熵损失（Cross Entropy, CE）的基础上引入了调节因子，降低了易分类样本的权重，从而使模型更加关注难分类样本。

交叉熵损失是分类任务中常用的损失函数，其可以度量模型预测概率分布与真实标签分布之间的差异。交叉熵越小，说明两者越相似；越大，说明差异越大。交叉熵损失的定义如公式 (**??**) 所示[?]。其中，p_t 表示模型对真实类别的预测概率。然而交叉熵损失在类别不平衡的情况下，容易被大量的易分类样本主导，导致模型对少数类别的学习效果不佳。

$$\mathrm{CE}(p_t) = -\log(p_t) \tag{2.17}$$

为了解决类别极度不均衡的问题，可以在交叉熵损失的基础上引入类别权重 α，得到加权交叉熵损失（Weighted Cross Entropy, WCE）。其在计算时对不同类别赋予不同的权重，增强对少数类别的关注，定义如公式 (**??**) 所示。其中，α_t 为类别 t 的权重，通常根据类别频率进行设置。

$$\mathrm{WCE}_{\alpha}(p_t) = -\alpha_t \log(p_t) \tag{2.18}$$

Focal Loss 正是在加权交叉熵损失的基础上进行改进的。Focal Loss 在加权交叉熵损失的基础上引入了调节因子 $(1-p_t)^{\gamma}$，其中 γ 为调节参数，用于控制易分类样本的权重衰减程度。Focal Loss 的定义如公式 (**??**) 所示[?]。相较于加权交叉熵损失，Focal Loss 通过调节因子有效降低了易分类样本的影响力，使模型更加关注难分类样本，从而提升在类别不平衡情况下的分类性能。

$$\mathrm{FL}(p_t) = -\alpha_t (1-p_t)^{\gamma} \log(p_t) \tag{2.19}$$

2.3.4 评价指标

为了全面评估 NECDNet 在点云几何特征检测任务中的性能，本文采用了多种评价指标，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）、交并比（Intersection over Union, IoU）和马修斯相关系数（The Matthews Correlation Coefficient, MCC）[? ? ?]。这些指标能够从不同角度反映模型的分类效果，特别是在处理类别不平衡问题时，精确率和召回率尤为重要。这些指标主要通过混

淆矩阵（Confusion Matrix）进行计算，混淆矩阵记录了模型在各类别上的预测结果与真实标签的对比情况。混淆矩阵的行表示真实类别，列表示预测类别，其中对角线上的值表示正确分类的数量，非对角线上的值表示分类错误的数量。基于混淆矩阵，可以计算出各项评价指标，从而全面评估模型的性能[?]，各个指标的具体计算公式请见附录**??**。

本文中分类任务为三分类，类别分别为：f（面点）、e（边缘点）、c（角点）。可以构建对应的混淆矩阵，如表 **??**所示。表中，TP（True Positive）表示正确预测为正类的数量，TN（True Negative）表示正确预测为负类的数量，FP（False Positive）表示错误预测为正类的数量，FN（False Negative）表示错误预测为负类的数量。

表 2.1　三分类任务的混淆矩阵示例。

Table 2.1　Example of confusion matrix for three-class classification task.

	预测类别			
真实类别	f	e	c	总计
f	TP_{f}	FP_{e}	FP_{c}	P_{f}
e	FN_{f}	TP_{e}	FP_{c}	P_{e}
c	FN_{f}	FN_{e}	TP_{c}	P_{c}
总计	N_{f}	N_{e}	N_{c}	N

上述评价指标的标准公式是基于二分类任务进行设计的。对于多分类任务，需要在指标的计算或者混淆矩阵的构建上进行调整。例如**?**] 提出基于传输的混淆矩阵构建方法，建立在最优传输理论和最大熵原理之上，针对多标签或软标签分类复杂任务提出了一种新的混淆矩阵构建方法。其次就是在指标计算上，可以采用宏平均（Macro-Averaging）和微平均（Micro-Averaging）两种方式[? ?]。宏平均是对每个类别分别计算指标，然后取平均值，适用于类别分布不均衡的情况；而微平均则是将所有类别的预测结果合并后计算指标，更适用于类别分布均衡的情况。

由于本文的分类任务较为简单，且为了与目前的其余最新方法（state-of-the-art, SOTA）进行对比，本文中主要采用宏平均的方式计算各项评价指标。具体而言，设 C 为类别总数，M_c 为类别 c 的评价指标值，则宏平均的计算公式如 (**??**) 所示。本文

中 $C=3$，分别对应面、边缘、角点三类。

$$M_{\text{macro}}=\frac{1}{C}\sum_{c=1}^{C}M_c \tag{2.20}$$

2.4 ABC-Corner 数据集构建

网络训练和评估离不开高质量的标注数据集。针对点云几何特征检测任务，本文构建了一个专门的数据集——ABC-Corner 数据集。该数据集基于 ABC 数据集[?]中的 CAD 模型，经过精细的标注和处理，包含丰富的面点、边缘点和角点样本，能够有效支持深度学习模型的训练与评估。下文将详细介绍数据集的选取标准、标注流程及统计特性。

2.4.1 数据集模型选取

针对点云数据的深度学习任务，目前已有多个公开数据集可供使用，如 ModelNet[?]、ShapeNet[?]、ScanNet[?]、ABC[?] 等。然而，这些数据集在几何特征的多样性和标注精度方面存在一定的局限性。例如，ModelNet 和 ShapeNet 主要包含日常物体的点云，几何特征相对简单，且缺乏精细的边缘和角点标注；ScanNet 虽然包含真实场景的点云，但噪声较多，且标注不够细致。相比之下，ABC 数据集基于 CAD 模型，具有丰富的几何特征和高精度的边缘与角点信息，非常适合用于本研究中的几何特征检测任务。因此，本文选择 ABC 数据集作为基础数据源。为了确保数据集的多样性和代表性，我们从 ABC 数据集中筛选出包含丰富几何特征的模型，具体选取标准包括：模型必须包含明显的边缘和角点特征，且模型的复杂度适中，避免过于简单或过于复杂的情况。此外，还考虑了模型的类别多样性，确保涵盖不同类型的几何形状。

2.4.2 初步标注算法

2.4.3 人工排错与精修

2.5 本章小结

第三章　考虑边缘与角点接触的机器人抓取规划

3.1　引言

3.2　基于几何特征的接触点采样与配对

3.2.1　类别感知的体素采样

3.2.2　特征化接触检测器设计

3.2.3　对偶接触点配对策略

3.3　基于软接触模型的稳定性评估

3.4　抓取增强策略

3.5　本章小结

第四章　实验结果与分析

4.1　实验环境及配置

4.2　点云特征检测实验分析

4.2.1　对比实验

4.2.2　消融实验

4.2.3　结果可视化

4.3　抓取规划仿真实验分析

4.3.1　抓取分布多样性评估

4.3.2　典型物体抓取规划结果

4.3.3　参数敏感性分析

4.4　真实机器人抓取实验

4.5　本章小结

第五章　总结与展望

5.1　全文总结

5.2　创新点

5.3　研究不足与展望

插图索引

表格索引

参考文献

[] TOLSTIKHIN I, HOULSBY N, KOLESNIKOV A, et al. Mlp-mixer: An all-mlp architecture for vision[J]. ArXiv, 2021.

[] XU B, WANG N, CHEN T, et al. Empirical evaluation of rectified activations in convolutional network: arXiv:1505.00853[M/OL]. arXiv, 2015[2026-01-18]. DOI: 10.48550/arXiv.1505.00853.

[] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(56):1929-1958.

[] BISHOP C M. Pattern recognition and machine learning[M]. New York: Springer, 2006.

[] JAPKOWICZ N, STEPHEN S. The class imbalance problem: A systematic study[J]. Intell. Data Anal., 2002, 6(5):429-449.

[] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[J/OL]. IEEE transactions on pattern analysis and machine intelligence, 2020, 42(2):318-327. DOI: 10.1109/TPAMI.2018.2858826.

[] MAO A, MOHRI M, ZHONG Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//ICML'23: volume 202 Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA: JMLR.org, 2023: 23803-23828.

[] KRSTINIĆ D, BRAOVIĆ M, ŠERIĆ L, et al. Multi-label classifier performance evaluation with confusion matrix[J/OL]. Computer Science & Information Technology (CS & IT), 2020, 10(8):1[2026-01-17]. DOI: 10.5121/csit.2020.100801.

[] CHICCO D, JURMAN G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J/OL]. BMC Genomics, 2020, 21:6[2026-01-17]. DOI: 10.1186/s12864-019-6413-7.

[] DÜNTSCH I, GEDIGA G. Confusion matrices and rough set data analysis[J/OL]. Journal of Physics: Conference Series, 2019, 1229(1):012055[2026-01-15]. DOI: 10.1088/1742-6596/1229/1/012055.

[] ERBANI J, PORTIER P É, Egyed-Zsigmond E, et al. Confusion matrices: A unified theory[J/OL]. IEEE Access, 2024, 12:181372-181419[2026-01-15]. DOI: 10.1109/ACCESS.2024.3507199.

[] KOCH S, MATVEEV A, JIANG Z, et al. Abc: A big cad model dataset for geometric deep learning[C/OL]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 9593-9603[2024-11-01]. DOI: 10.1109/CVPR.2019.00983.

攻读专业硕士学位期间取得的研究成果

一、专著

[1] 张三. XXXXXXXXXXXXXXXXX [M]. 南京: XXXXXXXX 出版社, 2022.

二、论文

[1] ZHANG San. XXXXXXXXXXXXXXXXXXXXX[J]. Bulletin of the Geological Survey of Japan, 2021, 57(5/6): 169-176.

[2] XXX, SATIO M, BUSH G, et al. XXXXXXXXXXXXXXXXXXXXX XX[J]. Journal of the American Chemical Society, 2022, 2(3):20-26.

三、专利

[1] 张三. XXXXXXXXXXXXXXXXX: 202210050175. 8 [P]. 2022-10-14.

四、项目

1. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），主持，XXXX.XX.XX—XXXX.XX.XX。

2. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），参与，第二，XXXX.XX.XX—XXXX.XX.XX。

致　谢

衷心感谢导师 xxx 教授对本人的精心指导.

作者署名

完成地点

2023 年 12 月 18 日

附录 A　经典函数公式

论文中用到的经典函数公式.

(Sigmoid Function) Sigmoid 函数定义为

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}.$$

(ReLU Function) ReLU 函数定义为

$$\text{ReLU}(x) = \max(0, x).$$

(Leaky ReLU Function) Leaky ReLU 函数定义为

$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases}$$

其中 α 是一个较小的常数，通常取值为 0.01。

附录 B　用于定量比较的指标公式

章节 (**??**) 中提到的用于定量比较的指标公式如下。

(Precision) 精确率（Precision）定义为

$$\text{Precision} = \frac{TP}{TP + FP}$$

其中 TP 表示真正例（True Positive）的数量，FP 表示假正例（False Positive）的数量。

(Recall) 召回率（Recall）定义为

$$\text{Recall} = \frac{TP}{TP + FN}$$

其中 TP 表示真正例（True Positive）的数量，FN 表示假负例（False Negative）的数量。

(F1 Score) F1 分数定义为

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

用于综合评估模型的精确率和召回率。

(Matthews Correlation Coefficient) 马修斯相关系数（The Matthews Correlation Coefficient, MCC）定义为

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

其中 TP、TN、FP 和 FN 分别表示真正例、真反例、假正例和假反例的数量。

(Intersection over Union) 交并比（Intersection over Union, IoU）定义为

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

用于衡量预测结果与真实标签之间的重叠程度。

(Accuracy) 准确率（Accuracy）定义为

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

用于衡量模型预测的整体正确性。