中图分类号：XXX　　单位代号：10280
密　　级：公开　　学　　号：23722063

上海大学

专业硕士学位论文

SHANGHAI UNIVERSITY PROFESSIONAL MASTER'S DISSERTATION

题目	基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者　邱模聪
学科专业　机械
导　　师　袁建军
完成日期　二〇二六年五月

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学

本论文经答辩委员会全体委员审查，确认符合上海大学专业硕士学位论文质量要求。

答辩委员会签名:

主　　席:

委　　员:

导　　师:

答辩日期:　　年　　月　　日

姓　　名：邱模聪　　学号：23722063

论文题目：基于学习的点云几何特征检测及机器人抓取规划方法研究

上海大学学位论文原创性声明

本人郑重声明: 所呈交的学位论文是本人在导师指导下, 独立进行研究工作所取得的成果。除了文中特别加以标注和致谢的内容外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他研究者对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名:

日期:　　年　　月　　日

上海大学学位论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定, 即: 学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

(保密的论文在解密后应遵守此规定)

学位论文作者签名:　　导师签名:

日期:　　年　　月　　日　　日期:　　年　　月　　日

上海大学工学专业硕士学位论文

基于学习的点云几何特征检测及机器人抓取规划方法研究

作　　者: 邱模聪
导　　师: 袁建军
学科专业: 机械

机电工程与自动化学院
上海大学
2026 年 5 月

A Dissertation Submitted to Shanghai University for the
Degree of Professional Master in Engineering

Learning-Based Point Cloud Geometric Feature Detection and Robotic Grasp Planning

Candidate: Mocong Qiu
Supervisor: Jianjun Yuan
Major: Mechanics

School of Mechatronic Engineering and Automation
Shanghai University
December, 2026

摘　要

针对点云几何特征检测精度不足及机器人抓取规划灵活性受限的问题，本文提出一种融合神经网络特征学习与基于模型抓取规划的框架。首先，提出神经边缘角点检测网络（NECDNet）。该网络通过分析多尺度邻域内的位置和法向分布构建特征矩阵，利用层次化神经网络实现面、边、角点的同步分类；同时构建了包含 1000 个模型的 ABC-Corner 数据集。其次，本文提出一种考虑边、角接触的六自由度双指抓取规划算法。该算法利用 NECDNet 提取特征区域，设计特征化接触检测器搜索对偶接触点，并引入软接触模型评估稳定性，有效解决了非规则物体的抓取难题，增强抓取规划多样性。实验表明，NECDNet 的角点检测 F1 分数达 0.815，优于现有方法；抓取算法在分布复杂度指标（STD、Range、MAD）均优于 GPD，GraspIt 等基于模型的抓取规划方法，抓取配置灵活性显著提升。机器人实验验证了包括角-角、角-边等六种接触组合的有效性与鲁棒性，展示了抓取规划的有效性及抓取成功率上的提升。

关键词：点云处理；几何特征检测；神经网络；机器人；抓取规划；平行手爪

ABSTRACT

This thesis addresses the challenges of insufficient geometric feature detection accuracy in point clouds and limited flexibility in robotic grasp planning by proposing a unified framework that integrates neural network-based feature learning with model-based grasp planning. First, we introduce the Neural Edge and Corner Detection Network (NECDNet), which constructs a feature matrix by analyzing the positional and normal distributions within multi-scale neighborhoods and employs a hierarchical neural network to simultaneously classify faces, edges, and corners. Additionally, we curate the ABC-Corner dataset containing 1,000 annotated models to support training and evaluation. Second, we present a six-degree-of-freedom dual-finger grasp planning algorithm that explicitly accounts for edge and corner contacts. This algorithm leverages NECDNet for feature region extraction, employs feature-specific contact detectors to identify antipodal contact pairs, and integrates a soft contact model for stability assessment, thereby effectively tackling the grasp planning challenges associated with irregular objects and enhancing grasp configuration diversity. Experimental results demonstrate that NECDNet achieves corner detection with an F1 score of 0.815, outperforming existing methods. Furthermore, the proposed grasp algorithm surpasses model-based grasp planning approaches such as GPD and GraspIt across all distribution complexity metrics (STD, Range, MAD), significantly improving grasp configuration flexibility. Real-world robotic experiments validate the robustness and effectiveness of six distinct contact combinations, including corner-corner and corner-edge interactions, demonstrating improved grasp planning efficacy and success rate.

Keywords: Point cloud processing; Geometrical feature detection; Neural network; Robotics; Grasp planning; Parallel gripper.

目　录

主要符号表

$\mathcal{P}^{\mathrm{c}}$	非结构化点云
n	点云中点的数量
$\mathbf{p}_i^{\mathrm{c}}$	查询点（点云中第 i 个点的三维坐标）
$\mathcal{Q}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的邻域
k	查询点邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 中点的数量
$\mathbf{x}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 在某一尺度下的局部特征向量
$\mathbf{X}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的多尺度特征矩阵
m	多尺度邻域的数量

第一章　研究背景与意义

本章节主要介绍本文的研究背景与意义，综述点云几何特征检测和机器人抓取规划的国内外研究现状，指出现有研究存在的问题，并阐述本文的主要研究内容和章节安排。

1.1　研究背景

随着计算机视觉和机器人技术的飞速发展，三维（3D）点云数据的处理与分析已成为学术界和工业界的研究热点。点云数据能够精确地表达物体表面的几何结构，获取物体内在的交互信息，因此在逆向工程、三维重建、物体识别、场景分割以及机器人自主操作等任务中发挥着至关重要的作用。

在这些任务中，物体的几何特征（如边缘和角点）承载了最关键的结构信息。边缘和角点定义了物体的边界和轮廓，是理解物体形状的基础。在分割和重建任务中，这些特征作为区域的分割边界[?]；在识别任务中，它们作为关键线或关键点[?]；在机器人抓取或焊接等应用中，它们提供了必要的轮廓信息[?]。准确提取这些几何特征，能够显著降低任务的复杂度并提高处理精度。

然而，从点云中自动检测几何特征仍面临巨大挑战。首先，由于现实世界物体的物理平滑特性以及扫描设备的精度限制，获取的三维扫描点云往往缺乏绝对锐利的特征，导致边缘和角点的定义存在固有的模糊性。其次，区分边缘和角点的特征值往往非常敏感，难以通过简单的阈值进行界定。此外，不同特征的样本密度极不平衡，角点样本的数量远少于边缘和面点，这使得高精度的角点检测尤为困难。

与此同时，机器人抓取规划作为实现机器人自主操作的核心环节，其目标是生成稳定且灵活的抓取配置。目前的抓取规划方法，无论是基于模型的解析方法还是基于深度学习的数据驱动方法，通常都优先考虑面接触（Face Contact）。这类方法倾向于将手爪指腹与物体表面法线对齐，以确保抓取的稳定性[??]。虽然这种策略在处理规则物体时表现优异，但在面对多面体、非对称物体或具有复杂尖锐几何特征的物体时，往往因为受限于平行的平面接触区域而显得灵活性不足。为了获得稳定的面接触，规划器往往会刻意避开边缘和角点区域，这在很大程度上限制了机器人的

操作能力。

事实上，在引入软指（Soft Finger）接触模型后，手爪指腹的变形能力使得边缘和角点也能形成等效的面接触，从而提供足够的摩擦力和抗扭矩能力[?]。这意味着，如果能够有效利用边缘和角点作为潜在的接触区域，将极大地扩展机器人抓取的候选空间，提高抓取规划的灵活性和适应性。因此，本文致力于研究点云几何特征的精确检测方法，并在此基础上探索考虑边缘和角点接触的机器人抓取规划算法，以解决当前特征检测精度不足和抓取规划灵活性受限的问题。

1.2 国内外研究现状

1.2.1 点云几何特征检测研究现状

点云几何特征检测方法主要分为传统解析方法和基于数据驱动的方法。

1） 传统解析方法

传统解析方法主要通过分析局部邻域的统计信息来计算特征描述符，并结合人工设定的阈值进行特征提取。主成分分析（PCA）是最常用的方法之一，Gumhold 等人[?]通过计算邻域协方差矩阵的特征值，当最小特征值超过阈值时判定为特征点。基于此，Xia 等人[?]和 Bazazian 等人[?]分别利用单尺度和多尺度的特征值比率作为局部特征描述符。此外，基于曲率估计的方法[??]和基于法向量变化的方法[?]也被广泛应用。

为了提高检测的鲁棒性，一些研究引入了更复杂的几何分析。Daniels 等人[?]利用移动最小二乘法（MLS）进行表面重建，通过局部近似来增强特征检测。Guo 等人[?]提出了基于图的方法，结合全局上下文信息来提升特征提取效果。Zhang 等人[?]提出的 VAM 方法利用一致性投票机制估计法向量，有效保留了重建过程中的锐利特征。Mérigot 等人[?]则利用局部 Voronoi 单元内的法向量分布来提取锐利边缘。Zhao 等人[?]提出了多任务神经网络架构，用于识别锐利特征附近的点并预测位移向量。

在角点检测方面，Ahmed 等人[?]采用了两步提取法，首先提取边缘点，然后基于边缘点重新计算特征以识别角点。Schmidt 等人[?]提出利用 RANSAC 提取直线或平面，通过它们的交点来检测角点。

总体而言，传统解析方法计算效率高，但其性能高度依赖于参数和阈值的精细调节。在面对尺度变化大或特征模糊的复杂场景时，难以实现鲁棒的检测。特别是

高精度的角点检测通常需要复杂的两步流程，效率较低且难以调参。

2） 基于数据驱动的方法

近年来，基于深度学习的数据驱动方法逐渐成为主流，这类方法通常将特征检测视为点云分类问题，即区分平滑点和锐利特征点。PIE-Net[?] 采用基于 PointNet++[?] 的双流网络分别提取边缘和角点，但其效率较低且要求输入点数固定。EDC-Net[?] 利用胶囊网络将点分类为非边缘或锐利边缘。PCPNet[?] 和 MSL-Net[?] 分别以点块和点云为输入，利用多层感知机（MLP）进行分类。PCEDNet[?] 和 BoundED[?] 通过神经网络学习多尺度局部特征描述符，在边缘检测方面取得了显著成果。

除了分类方法，部分研究将其建模为回归问题。DEFs[?] 和 EC-Net[?] 通过学习点坐标残差并估计到边缘的距离来实现精确的边缘点识别。NerVE[?] 使用体素化点云以结构化格式检测锐利特征。JSENet[?] 则利用双流全卷积网络同时执行边缘检测和语义分割。

然而，现有基于学习的方法大多集中于边缘特征的提取，针对角点检测的研究相对较少。由于角点特征与边缘特征具有相似性，且数据量更为稀疏，直接应用现有边缘检测网络往往导致角点识别精度低、误判率高的问题。即便是专门针对角点检测的方法（如 PIE-Net），也常因特征区分度不足而出现较多误分类。

1.2.2 机器人抓取规划研究现状

机器人抓取规划方法主要分为基于模型的方法和基于学习的方法。

1） 基于模型的抓取规划

基于模型的方法依赖于物体的几何模型和物理规则来生成抓取配置，并通过解析计算评估其稳定性。这类方法主要分为图元拟合（Primitive Fitting）和表面分割（Surface Segmentation）两类策略。

图元拟合方法[??] 将物体近似为基本几何体（如圆柱、球体、方块）以简化抓取合成。Chen 等人[?] 利用词嵌入量化已知模型与真实物体之间的语义相似度，通过模型匹配实现抓取。表面分割方法[??] 则通过识别有意义的表面区域来指导抓取生成。Harada 等人[?] 根据接触柔软度对三角网格进行聚类，实现了针对软指的抓取规划。Wan 等人[?] 提出了叠加分割法，根据表面法线将每个三角形分割为具有受控重叠和厚度的不同面片。

这些传统的基于模型的方法通常强调面接触的重要性[?]，并刻意避免在边缘和角点附近进行接触[?]。这种权衡虽然提高了稳定性，但降低了抓取的多样性和灵活性。

2） 基于学习的抓取规划

基于学习的方法利用神经网络和数据驱动技术来增强抓取的灵活性和适应性[? ?]。Dex-Net 4.0[?] 探索了一种混合方法，利用几何和力学模型生成合成训练数据集。L2G[?] 采用由多任务优化目标引导的可微采样过程，联合求解接触点采样、抓取回归和分类。然而，这些基于学习的方法通常依赖于抓取数据集，而这些数据集往往也是基于传统的面接触规则生成的[?]，因此生成的抓取策略依然倾向于面接触。

3） 抓取质量评价标准

评估抓取候选可行性和质量的标准多种多样。最常用的是抓取稳定性，通常通过力封闭（Force Closure）或形封闭（Form Closure）条件进行评估。解析方法通过评估旋量空间覆盖率、抗扭矩能力或最小力需求来确定抓取可靠性[? ?]。GraspIt![?] 是一个广泛使用的仿真平台，支持力封闭计算和抓取姿态优化。相比之下，数据驱动方法通常训练模型直接从视觉或几何输入预测抓取质量分数[?]。此外，一些混合方法结合了解析指标和数据驱动模型以增强泛化能力[? ?]。

然而，现有的评价标准主要关注稳定性、可抓取性[?] 或功能性（Affordance），很少关注抓取配置的分布特性。抓取配置的分布反映了机器人手爪接近和抓取物体的位姿范围，是衡量抓取灵活性的重要指标。

1.3 本文主要研究内容

针对上述问题，本文的主要研究内容包括以下三个方面：

1. **基于多尺度局部特征的点云边缘与角点检测网络（NECDNet）**：提出了一种能够同时提取点云中面、边缘和角点特征的神经网络框架。该方法通过分析多尺度邻域内的位置和法向量分布，构建包含曲率、投影距离、法向角差等六维特征的多尺度特征矩阵。设计了基于多层感知机（MLP）的层次化网络结构，融合多尺度特征并实现高精度的三分类。该方法不仅在边缘检测上达到了竞争水平，更显著提升了角点检测的精度。

2. **ABC-Corner 点云几何特征数据集构建**：针对现有数据集（如 ABC 数据集）

缺乏角点标注的问题，本文构建了包含 1000 个物体模型的 ABC-Corner 数据集。通过结合算法辅助与人工精细修正的方法，提供了高质量的边缘和角点标签，解决了数据驱动方法在角点检测任务中训练数据匮乏的问题，为相关研究提供了基准。

3. **考虑边缘和角点接触的六自由度抓取规划算法**：提出了一种基于模型的解析式抓取规划方法。该方法利用提取的几何特征，针对面、边缘和角点分别设计了圆柱形、扇形和锥形接触检测器，以搜索潜在的对指抓取点对。引入软接触模型对边缘和角点接触的稳定性进行评估，从而生成包含多种接触类型（如角-角、角-边、边-面等）的抓取配置。此外，本文还引入了抓取分布统计指标来量化抓取灵活性，实验证明该方法显著提高了抓取规划的灵活性和对复杂几何物体的适应性。

1.4 论文组织结构

本文共分为六章，各章节安排如下：

第一章：绪论。介绍了课题的研究背景与意义，综述了点云几何特征检测和机器人抓取规划的国内外研究现状，指出了现有研究存在的问题，并阐述了本文的主要研究内容和章节安排。

第二章：点云几何特征检测网络 NECDNet。详细介绍了 NECDNet 的网络架构、多尺度特征计算方法以及 ABC-Corner 数据集的构建过程。

第三章：考虑边缘和角点接触的抓取规划算法。阐述了基于几何特征的接触点采样、接触检测器设计、对指点对搜索以及基于软接触模型的稳定性评估方法。

第四章：实验与分析。对提出的特征检测网络和抓取规划算法进行了全面的实验验证，并与现有主流方法进行了对比分析。

第五章：总结与展望。总结了本文的主要研究成果，分析了存在的不足，并对未来的研究方向进行了展望。

第二章　基于多尺度特征融合的点云几何特征检测

2.1　引言

三维点云几何特征检测（如边缘和角点的提取）是三维视觉领域的关键环节，在模型重建、物体识别及机器人抓取规划中具有不可替代的作用。传统的分析方法主要依赖于局部几何描述符（如曲率、法向量偏差等）并结合人工设置的阈值。然而，由于点云数据存在噪声、密度不均以及边缘及角点定义模糊等问题，传统方法往往难以兼顾检测精度与鲁棒性[]。

为了解决边缘与角点特征在微小尺度下难以区分的问题，本章提出了一种名为NECDNet（Neural Edge and Corner Detection Network）的深度学习架构。该方法通过融合统计特征描述符与轻量级神经网络，利用多尺度邻域分析来捕捉点云局部的空间分布和法向量变化特征，从而实现对面点（Face）、边缘点（Edge）和角点（Corner）的高精度同步分类。

图 **??**展示了所提 NECDNet 的工作流程，NECDNet 由两个主要部分组成：多尺度局部特征矩阵计算和基于神经网络的分类器。流程的输入是一个非结构化点云，输出的是一个三类点云，包含面点、边缘点和角点。在多尺度特征计算阶段，我们针对每个查询点构建了包含四个不同尺度邻域的特征矩阵，每个尺度下计算六种解析特征：曲率、投影距离、均值中心距离、法向角差、法向分布和投影法向模。最终形成一个 4×6 的多尺度特征矩阵，作为神经网络的输入。在分类器阶段，我们基于多层感知机（MLP）设计了一个层次化网络结构，通过逐层融合多尺度特征，学习从特征矩阵到几何类别的映射关系。输出三类几何特征的概率得分，从而实现面、边缘和角点的同步检测。

图中左上为输入的点云数据，每次选择一个查询点（红色）及其邻域（绿色）。其中不同的 k 值表示不同尺度的邻域大小（黄色点的数量）。通过计算各尺度下的六维特征，形成多尺度特征矩阵并输入神经网络进行分类。最终输出查询点所属的几何类别（面、边缘或角点）。通过循环查询各个点，完成整个点云的几何特征检测任务，最后输出检测结果（左下）。

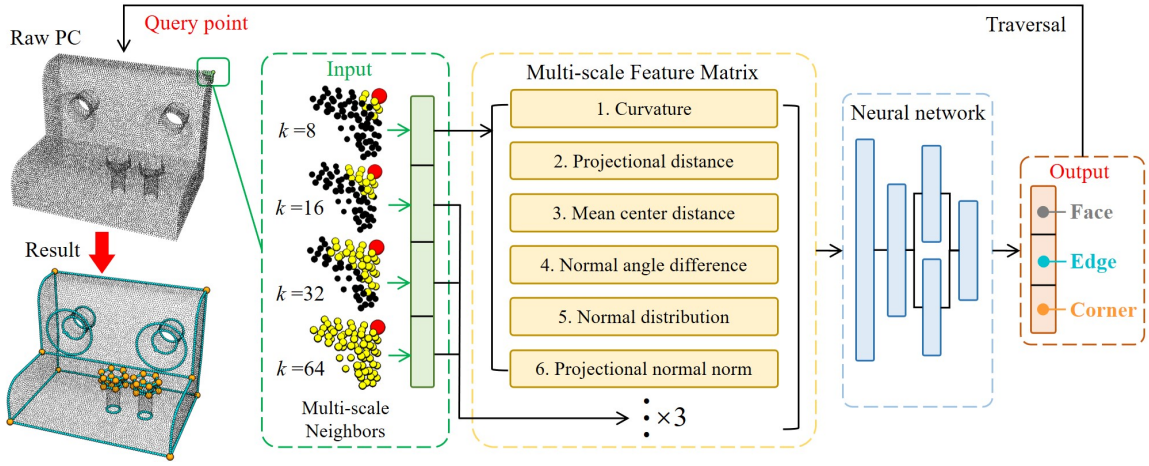


图 2.1 NECDNet 网络架构及工作流程示意图。

Figure 2.1 NECDNet network architecture and workflow diagram.

2.2 多尺度局部特征提取与计算

多尺度表示的是针对每个查询点，选择不同数量的邻域点以构建多层次的局部几何描述。由于点云捕获时的视角、距离及分辨率等因素影响，单一尺度往往难以全面反映局部几何结构的信息。通过分析不同尺度下的点云分布特征，可以更全面地捕捉局部几何结构，从而提升边缘和角点的区分能力[]。适用的尺度取决于多个因素：物体大小、形状复杂度、点云密度、观察尺度等。为了使训练得到的模型能泛化处理未知物体的情况，本文为输入点云中的每个查询点在多尺度邻域内计算多个特征，并在 **??**进行了消融实验确保各个尺度选择的合理性。

2.2.1 多尺度邻域构建

本文采用基于距离度量的 k 近邻（k-Nearest Neighbors, k-NN）为每个查询点构建多尺度邻域，并以此生成多尺度特征输入网络进行学习[]。k-NN 是一种基于距离度量的邻域选择方法，通过计算查询点与其他点之间的欧氏距离，选取距离最近的 k 个点作为邻域。与固定半径（radius-based）邻域相比，k-NN 对点云非均匀采样与稀疏区域更加稳健：在稠密区不会过采样、在稀疏区不会因样本不足而破坏特征稳定性。对于非结构化的点云，其只包含点的三维坐标信息，k-NN 方法能够有效适应点云的稀疏性和不均匀分布特性。

为提升检索效率，给定一个非结构化点云 $\mathcal{P}^{\mathrm{c}} = \{\mathbf{p}_i^{\mathrm{c}} \mid i = 1, \ldots, n\}$，我们在三维坐标空间上构建 KD-树（K-Dimensional Tree）索引[]。KD-树通过在各坐标轴上递

归划分点集，使每个节点对应一个超矩形子空间，从而形成近似平衡的二叉树。查询时，先依据查询点坐标自顶向下定位至叶节点，再在回溯过程中检查可能包含更近邻点的分支，并维护容量为 k 的候选集合以持续更新最近邻。相比于暴力检索的 $O(n)$ 复杂度，KD-树可将单次最近邻查询的平均复杂度降至 $O(\log n)$ ，显著提升大规模点云处理的效率。

基于上述索引结构，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，我们通过 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}} = \{\mathbf{p}_{i,j}^{\mathrm{c}} \mid j = 1, \ldots, k\}$。通过调节 k 的大小即可改变邻域的空间尺度：较小的 k 更敏感于细粒度几何细节（如尖锐小角、细薄边），较大的 k 则能稳健表征更大范围的局部结构。为兼顾不同尺度的几何信息，我们针对多个 k 值为同一查询点构建多组邻域，形成多尺度邻域表示。

具体而言，对由给定 k 值确定的局部区域 $\mathcal{Q}_i^{\mathrm{c}}$ 计算六个解析特征，得到 6 维特征向量 $\mathbf{x}_i^{\mathrm{c}}$。当为同一查询点在多个 k 值下重复上述过程，即可获得对应的 $\mathbf{x}_{i,k}^{\mathrm{c}}$。将这些特征按尺度汇集，构成用于后续网络学习的多尺度特征矩阵，如公式 (**??**) 所示：

$$\mathbf{X}_i^{\mathrm{c}} = \begin{bmatrix} \mathbf{x}_{i,k_1}^{\mathrm{c}} \\ \mathbf{x}_{i,k_2}^{\mathrm{c}} \\ \vdots \\ \mathbf{x}_{i,k_m}^{\mathrm{c}} \end{bmatrix} \tag{2.1}$$

其中，$k_1, k_2, \ldots, k_m$ 表示所选择的不同邻域尺度，m 为尺度数量。多尺度特征矩阵中的尺度数 m 和尺度大小 k 直接影响神经网络的学习结果。具体来说，k 影响结果对点云不同稀疏度的适用性，而 m 影响网络学习数据的维度。选择合适的尺度尺寸和数量可以优化检测精度。因此，在第**??**章中，本文对邻近尺度选择进行了消融实验以确定参数，并选择了 k 的四个值：8、16、32 和 64 进行特征计算。

2.2.2 点云前处理

为了消除点云绝对坐标、平移以及尺度差异对特征计算的影响，在提取特征前，本文首先对邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 进行归一化处理。该过程基于主成分分析（Principal Component Analysis, PCA）思想，计算邻域点的协方差矩阵 $\mathbf{K}_i = \mathrm{cov}(\mathcal{Q}_i^{\mathrm{c}})$，并对其进行奇异值分解（Singular Value Decomposition, SVD），如公式 (**??**) 所示。

$$\mathbf{K}_i = \mathbf{U}_i \mathbf{\Sigma}_i \mathbf{V}_i^T \tag{2.2}$$

其中，$\mathbf{U}_i$ 和 $\mathbf{V}_i$ 分别为左奇异向量矩阵和右奇异向量矩阵，$\mathbf{\Sigma}_i$ 为对角奇异值矩阵。通过该分解，我们能够获得邻域点在主方向上的分布特性。具体而言，通过对角矩阵 $\mathbf{\Sigma}_i$ 提取奇异向量 $\boldsymbol{\sigma}_i = (\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3})$ ，其中的奇异值计为降序排列。右奇异向量矩阵 $\mathbf{V}_i$ 的列向量对应于邻域点在三个主方向上的投影轴。不同的奇异值反映了邻域点在各主方向上的扩展程度。奇异值较小的方向点云分布较为集中，反之则较为分散。通过上述分解结果，可以对邻域点进行去中心化与尺度归一化处理。具体而言，首先计算邻域点的质心 $\bar{\mathbf{p}}_{i,j}^{\mathrm{c}}$ ，如公式 (**??**) 所示。其中 $|\mathcal{Q}_i^{\mathrm{c}}|$ 表示邻域点的数量。

$$\bar{\mathbf{p}}_{i,j}^{\mathrm{c}} = \frac{1}{|\mathcal{Q}_i^{\mathrm{c}}|} \sum_{j=1}^{k} \mathbf{p}_{i,j}^{\mathrm{c}} \tag{2.3}$$

随后，将所有邻域点坐标减去质心实现去中心化，并利用奇异值 $\sigma_{i,1}$ 和 $\sigma_{i,2}$ 对去中心化后的邻域点进行尺度缩放，确保各个方向上的分布具有统一的量纲，如公式 (**??**) 所示。最终，得到归一化后的邻域 $\hat{\mathcal{Q}}_i^{\mathrm{c}}$，为后续特征计算提供了标准化的输入。归一化邻域后的查询点坐标记为 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，邻域中的点坐标记为 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$。

$$\hat{\mathcal{Q}}_i^{\mathrm{c}} = \left\{ \frac{2}{\sqrt{\sigma_{i,1}} + \sqrt{\sigma_{i,2}}} \left(\mathbf{p}_{i,j}^{\mathrm{c}} - \bar{\mathbf{p}}_{i,j}^{\mathrm{c}} \right) \mid \mathbf{p}_{i,j}^{\mathrm{c}} \in \mathcal{Q}_i^{\mathrm{c}} \right\} \tag{2.4}$$

此外，法向量是描述点云局部表面方位的重要几何属性，也是计算后续方向特征的基础。本文采用基于局部平面拟合的方法估计查询点的法向量。从公式 (**??**) 的奇异值分解结果中可知，奇异值 $\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3}$ 对应的右奇异向量（即矩阵 $\mathbf{V}_i$ 的列向量）构成了邻域内点集分布的正交主轴。由于奇异值按降序排列，最小奇异值 $\sigma_{i,3}$ 对应的奇异向量 $\mathbf{v}_{i,3}$ 指向了邻域内点集分布方差最小的方向。在几何意义上，该方向与局部最小二乘拟合平面的法向重合。因此，查询点的法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可直接取为归一化后的右奇异向量 $\mathbf{v}_{i,3}$ 。

然而，仅通过 PCA 获得的法向量存在 180° 的方向模糊性（即法向量可能指向物体内侧或外侧）。为了确保在计算后续法向量夹角差异等特征时的数值一致性，必须对法向量进行定向处理。在处理具有闭合表面的物体时，通常利用视点方向或邻域一致性进行约束。本文采用最小生成树（Minimum Spanning Tree, MST）算法在点云图中传播法向量方向，以实现全局的方向一致化[]。具体而言，将点云视为图结构，以点间距离为边权构建图，从初始点开始，通过遍历图确保相邻点的法向量满足内积大于零的约束，实现对点云中各点法向量的方向一致化。

2.2.3 局部特征描述符设计

在构建多尺度邻域的基础上，本文进一步设计了一套包含六个维度的局部几何特征描述符，旨在精确捕捉查询点及其邻域在不同空间尺度下的结构属性。这六种特征可归纳为基于位置的几何特征（Position-based Features）与基于法向量方向的特征（Normal-based Features）两大类。基于位置的特征主要通过分析邻域点的空间分布规律来描述局部形状，而基于法向量的特征则通过分析表面方向的连续性与一致性，提供关于几何边缘与尖锐角点的关键判别信息。这种多维特征的结合，增强了模型在面对复杂、模糊边界时的区分能力。消融实验中对特征计算中涉及的所有描述符进行了评估，说明了该选择的有效性。

1） 曲率（κ_i）

首先计算基于位置的几何特征，表征邻域内点的几何分布特性。曲率 κ_i 是几何物体偏离平面程度的度量。在本文中，查询点邻域的曲率可以根据上述得到的奇异值进行计算，用于表征局部表面的平坦程度。具体而言，曲率定义为最大奇异值与三维奇异值之和的比值，如公式 (**??**) 所示。

$$\kappa_i = \frac{\sigma_{i,3}}{\sigma_{i,1} + \sigma_{i,2} + \sigma_{i,3}} \tag{2.5}$$

当查询点位于平坦表面时，$\sigma_{i,3}$ 较小，曲率值接近于零；而当查询点位于尖锐边缘或角点时，$\sigma_{i,3}$ 较大，曲率值相应增大。因此，曲率特征有助于区分面点与边缘、角点。

2） 投影距离均值（$\bar{d}_i$）

投影距离均值 $\bar{d}_i$ 用于刻画查询点邻域内点相对于该点法向平面的空间分布，其大小反映了局部几何结构的突变程度。具体地，对于任一查询点 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，结合其法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可定义通过该点的投影平面。邻域内所有点 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$ 到该投影平面的距离均值即为 $\bar{d}_i$，计算公式如 (**??**) 所示。

$$\bar{d}_i = \frac{1}{|\hat{\mathcal{Q}}_i^{\mathrm{c}}|} \sum_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \left| (\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} - \hat{\mathbf{p}}_i^{\mathrm{c}}) \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.6}$$

图 **??**展示了该距离度量的几何意义。其反映了邻域点在查询点法向方向上的分布特性：当邻域点主要分布在查询点法向平面附近时，投影距离较小，表明局部几

何结构较为平滑；而当邻域点在法向方向上分布较为分散时，投影距离增大，通常对应于边缘或角点区域。

3） 中心偏离比（r_i）

中心偏离比 r_i 是量化查询点在其局部邻域内的相对空间位置的度量，其能够衡量查询点相对于其邻域质心的偏移程度。具体而言，首先计算邻域点的质心，由于此时的邻域 $\hat{\mathcal{Q}}_i^{\mathrm{c}}$ 已经进行了去中心化及归一化处理，因此邻域质心即为原点。之后计算查询点到质心的距离 $\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|$ 与邻域内各点到质心距离 $\|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|$ 的最小值之比，得到中心距离均值比 r_i，计算公式如 (**??**) 所示，由于该特征为比值，当分母较小时产生的结果不受此前归一化邻域的影响。故针对特征 r_i，本文选用 Sigmoid 函数对其进行标准化处理，以减小数值分布的变化范围。

$$r_i = \mathrm{Sigmoid}\left(\frac{\|\hat{\mathbf{p}}_i^{\mathrm{c}}\|}{\min_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \|\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}\|}\right) \tag{2.7}$$

其中 Sigmoid 表示 Sigmoid 函数，$\|\cdot\|$ 表示欧氏距离，min 运算符用于获取邻域点中距离质心最近的点的距离，式中省略了减去质心零向量的表示。中心偏离比 r_i 反映了查询点在邻域内的相对位置关系：当查询点位于邻域质心附近时，r_i 值较小，表明该点可能位于平坦区域；而当查询点远离邻域质心时，r_i 值增大，通常对应于边缘或角点区域。因此，中心偏离比有助于区分不同几何特征。

4） 法向量角度差（$\mu_{\theta,i}$）

以此特征描述符开始，后续的三个描述符是基于法向量方向的特征，旨在捕捉表面方向的突变信息。法向角度差 $\mu_{\theta,i}$ 衡量查询点法向量与其邻域内各点法向量之间夹角的平均值，反映了局部表面方向的一致性。具体而言，首先根据章节**??**中的方法估计邻域内每个点的单位法向量 $\mathbf{n}_{i,j}^{\mathrm{c}}$，组合为 $\mathcal{N}_i^{\mathrm{c}}$。随后，计算查询点法向量 $\mathbf{n}_i^{\mathrm{c}}$ 与邻域内各点法向量之间的夹角 $\theta_{i,j}$ ，计算公式如 (**??**)。最后并求各个夹角的平均值，求解公式如 (**??**) 所示。

$$\theta_{i,j} = \arccos\left(\mathbf{n}_i^{\mathrm{c}} \cdot \mathbf{n}_{i,j}^{\mathrm{c}}\right) \tag{2.8}$$

$$\mu_{\theta,i} = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{j=1}^{|\mathcal{N}_i^{\mathrm{c}}|} \theta_{i,j} \tag{2.9}$$

其中，arccos 表示反余弦函数。法向角度差 $\mu_{\theta,i}$ 反映了邻域内法向量的方向变化程度：当邻域内法向量与查询点法向量高度一致时，$\mu_{\theta,i}$ 值较小，表明局部表面较为平滑；而当邻域内法向量与查询点法向量差异较大时，$\mu_{\theta,i}$ 值增大，通常对应于边缘或角点区域。

此外，除了用法向量夹角来表示方向变化外，还可以直接使用法向量的数值之差来表示方向变化。具体而言，计算查询点法向量与邻域内各点法向量的差值，并求其平均值，得到法向量数值差 $\bar{\Delta\mathbf{n}}_i$，计算公式如 (**??**) 所示。相较与法向量角度差 $\mu_{\theta,i}$，法向量数值差 $\bar{\Delta\mathbf{n}}_i$ 直接采用原始法向量数据进行统计计算，后续消融实验中会讨论两者的效果差异。

$$\bar{\Delta\mathbf{n}}_i = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{\mathbf{n}_{i,j}^{\mathrm{c}} \in \mathcal{N}_i^{\mathrm{c}}} (\mathbf{n}_i^{\mathrm{c}} - \mathbf{n}_{i,j}^{\mathrm{c}}) \tag{2.10}$$

5） 法向量分布方差（$\sigma_{\theta,i}^2$ ）

法向量分布方差 $\sigma_{\theta,i}^2$ 用于量化邻域内法向量夹角的变化剧烈程度，反映了局部表面方向的稳定性。具体而言，基于前述计算的法向角度差 $\mu_{\theta,i}$，计算邻域内各点法向量与查询点法向量夹角的方差，求解公式如 (**??**) 所示。

$$\sigma_{\theta,i}^2 = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{j=1}^{|\mathcal{N}_i^{\mathrm{c}}|} (\theta_{i,j} - \mu_{\theta,i})^2 \tag{2.11}$$

法向量分布方差 $\sigma_{\theta,i}^2$ 反映了邻域内法向量变化的剧烈程度：当邻域内法向量夹角较为集中时，$\sigma_{\theta,i}^2$ 值较小，表明局部表面方向较为稳定；而当邻域内法向量夹角分布较为分散时，$\sigma_{\theta,i}^2$ 值增大，通常对应于边缘或角点区域，而角点区域的分散程度更为显著。

6） 法线投影距离均值（$\bar{\mathbf{proj}}_i$ ）

法线投影距离均值 $\bar{\mathrm{proj}}_i$ 用于量化邻域点法向量在查询点法向上的投影强度，反映了表面法向的对齐程度。具体而言，计算邻域内每个点法向量 $\mathbf{n}_{i,j}^{\mathrm{c}}$ 在查询点法向 $\mathbf{n}_i^{\mathrm{c}}$ 上的投影长度，并求其平均值，计算公式如 (**??**) 所示。

$$\bar{\mathrm{proj}}_i = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{\mathbf{n}_{i,j}^{\mathrm{c}} \in \mathcal{N}_i^{\mathrm{c}}} \left| \mathbf{n}_{i,j}^{\mathrm{c}} \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.12}$$

由于各点的法向量均为单位向量，法线投影距离均值 $\bar{\mathrm{proj}}_i$ 可以反映邻域内法向

量与查询点法向量的对齐程度：$\bar{\text{proj}}_i$ 值较大，表明局部表面方向较为统一；而当邻域内法向量与查询点法向量差异较大时，$\bar{\text{proj}}_i$ 值减小，通常对应于边缘或角点区域。

2.2.4 局部特征描述符数值可视化分析

通过上述计算的局部特征描述符，本文最终选择了其中六个组成特征描述向量，并用于后续的特征融合和分类任务。最后得到的特征向量如公式 (**??**) 所示。六个特征均为标量，组成的特征向量维度为 6，包含了点云的位置分布特性和法向量变化信息，能够有效表征点云局部的几何结构属性。

$$\mathbf{x}_i^{\text{c}} = \left(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i\right) \tag{2.13}$$

图 **??** 展示了多尺度几何特征在点云三类特征（面、边缘、角点）中的分布表现，直观体现了所选六维特征向量对于区分不同几何类别的有效性。其中图 (a) 对单个物体点云的六个特征进行了空间分布可视化。每个子图分别显示了特征描述符 κ_i（曲率）、$\bar{d}_i$（投影距离均值）、r_i（中心偏离比）、$\mu_{\theta,i}$（法向量角度差）、$\sigma^2_{\theta,i}$（法向量分布方差）、$\bar{\text{proj}}_i$（法向投影距离均值）在点云空间上的数值分布情况。颜色表示数值大小，采用从蓝色（低值）到红色（高值）的渐变色带。根据上一小节对各特征的定义，可以观察到：除了特征 $\bar{\text{proj}}_i$ 外，其他五个特征在面、边缘和角点区域均表现出从低到高的数值变化趋势（蓝色到红色）。而特征 $\bar{\text{proj}}_i$ 则呈现出相反的趋势，在面区域数值较高（红色），而在边缘和角点区域数值降低（橙黄色）。各个特征在不同的几何结构上有着明显的区别。

图 (b) 部分给出了在我们构建的数据集 ABC-Corner 中 1000 个点云样本的六个特征在三类标签下的数值分布，数据集的描述及构建过程请见章节 (**??**)。纵轴为点云 ID，横轴为特征值，颜色标记类别：蓝色为面、黄色为边缘、红色为角点。统计结果显示，在面、边缘、角点三类之间，所有特征分布具有明显的界限。以曲率和法向分布为例，角点（红色）主要集中在中高值段，面点则聚集于低值，边缘点分布于中间区域。其他如投影距离、均值中心距离等特征也展现出对类别的良好区分能力。

虽然可以观察到直接使用这些特征描述符就能进行一定程度上的几何特征区分。然而，直接使用这些特征进行检测类似于分析方法，需要参数调整并且可能无法保证稳健的结果。为了解决这个问题，本文利用神经网络从计算的特征矩阵中学习。这种方法使能够结合分析方法和基于学习的检测技术的优势，实现精准的自分类。

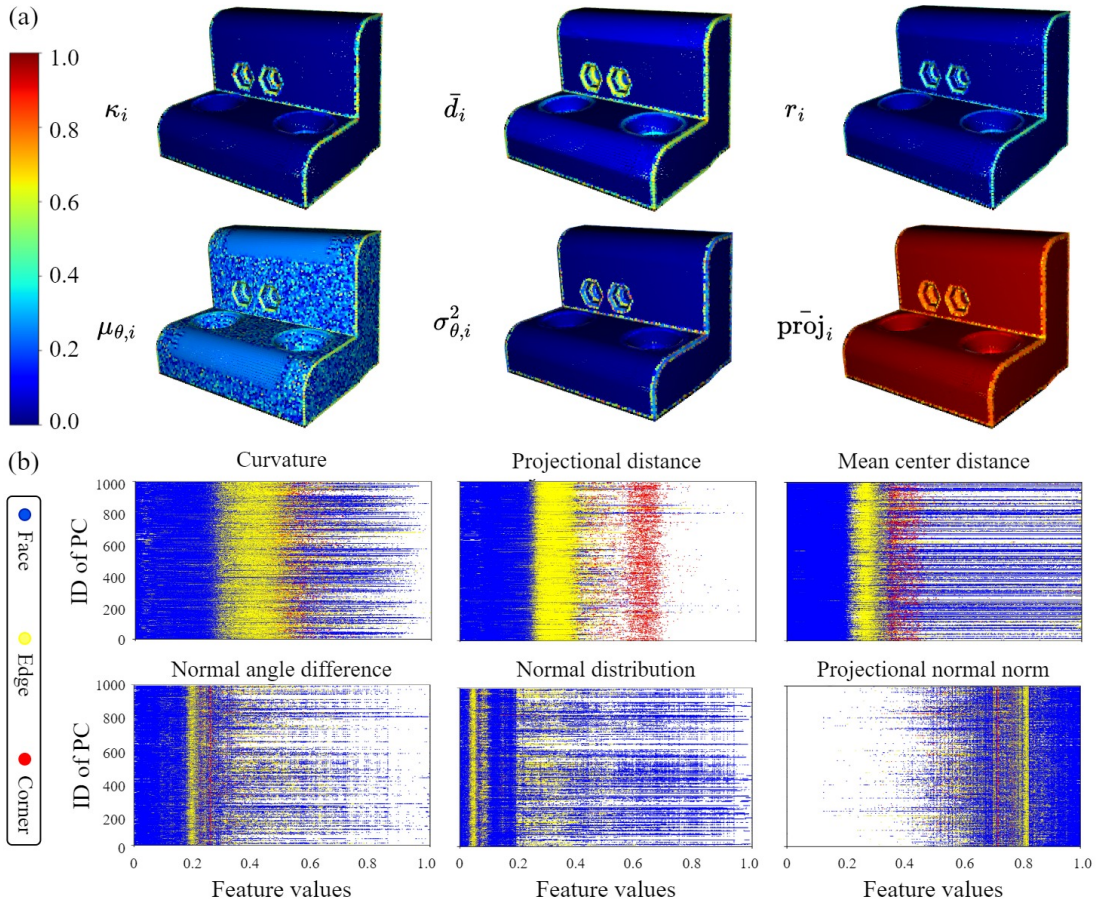


图 2.2 六个局部特征描述符在不同几何类别下的数值分布情况。

Figure 2.2 Distribution of six local feature descriptors across different geometric categories.

2.3 NECDNet 网络架构设计

NECDNet 网络架构针对点云数据中特征点的精细分类任务（包括面点、边缘点和角点），设计了以多层感知机（Multi-Layer Perceptron, MLP）为核心、多尺度特征深度融合与分阶段判别相结合的高效结构[?]。整体网络流程如图 **??** 所示，主要包括两大模块：首先，多尺度特征融合模块从多个邻域尺度提取并逐级整合各类局部几何信息，实现输入信息的丰富表达；其次，逐级分类模块采用分层分类思路，将点的最终类别归属过程划分为由简到繁的两个层次，提升了分类准确率和模型的泛化能力。结合全连接层、Leaky ReLU 激活及 Dropout 策略，有效增强了网络的判别能力并抑制了过拟合风险[??]。下文将分别对多尺度特征融合与逐级分类策略进行详细阐述。

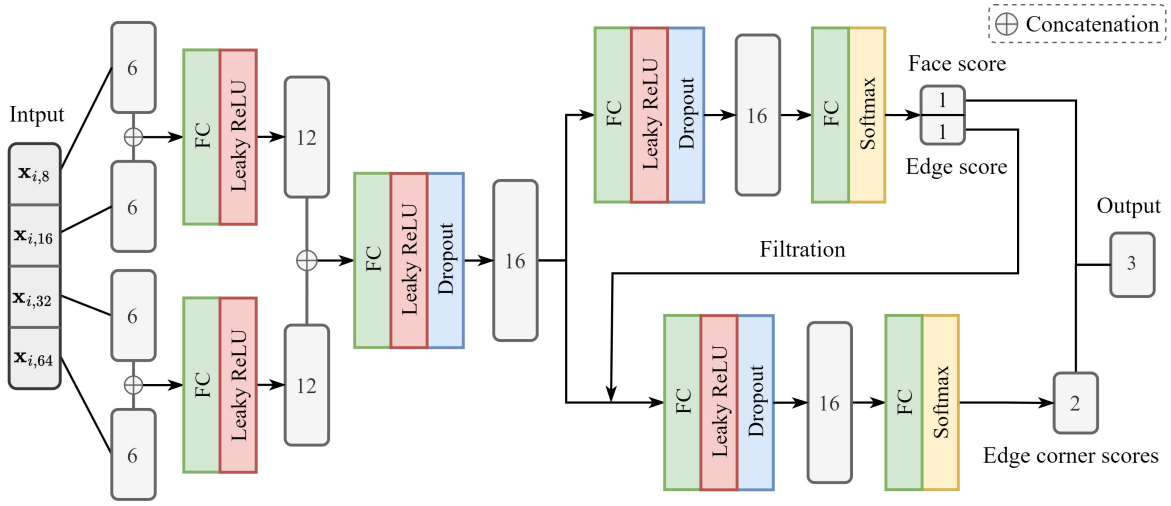


图 2.3 NECDNet 网络架构示意图。

Figure 2.3 NECDNet network architecture diagram.

2.3.1 多尺度特征融合

NECDNet 的输入部分针对每个查询点构建了多尺度邻域下的几何属性特征矩阵。具体地，针对每个点，分别在 $k = 8, 16, 32, 64$ 四种不同邻域尺度内提取点云的几何特征，每个尺度获得一个 6 维特征向量 $\mathbf{x}_{i,k} \in \mathbb{R}^6$，所有尺度拼接形成 4×6 的特征矩阵。

这一多尺度特征首先经过特征提取单元处理。对于第 j 个尺度 ($j \in \{1, 2, 3, 4\}$) 的输入特征 $\mathbf{x}_{i,j}$，通过全连接层（FC）、Leaky ReLU 激活函数进行非线性映射。该过程可表示为：

$$\mathbf{h}_i^{(1)} = \sigma_{\text{LReLU}}(\mathbf{W}_i^{(1)}\mathbf{x}_{i,j} + \mathbf{b}_i^{(1)}) \tag{2.14}$$

其中，$\mathbf{W}_i^{(1)}$ 和 $\mathbf{b}_i^{(1)}$ 为权重矩阵和偏置项，σ_{LReLU} 表示 Leaky ReLU 激活函数，其定义为 $f(x) = \max(x, \alpha x)$，α 为负半轴斜率（通常取 0.01）[?]。

随后，参考图 **??** 中的结构，模型将相邻两个尺度的特征进行两两拼接（Concatenate）。例如，将 $k = 8$ 和 $k = 16$ 对应的特征 $\mathbf{h}_1^{(1)}$ 和 $\mathbf{h}_2^{(1)}$ 拼接得到 $\mathbf{z}_{12} = [\mathbf{h}_1^{(1)}, \mathbf{h}_2^{(1)}]$。融合后的特征再次通过类似的非线性变换，公式如 **(??)** 所示。相较于上一步，这里引入了 Dropout 层以防止过拟合现象的发生[?]。

$$\mathbf{h}_{12}^{(2)} = \text{Dropout}\left(\sigma_{\text{LReLU}}(\mathbf{W}_{12}^{(2)}\mathbf{z}_{12} + \mathbf{b}_{12}^{(2)})\right) \tag{2.15}$$

同理可得 $\mathbf{h}_{34}^{(2)}$。接着，将这两组特征进一步拼接为 24 维大向量 $\mathbf{z}_{\text{final}}$，并通过进一步

的 FC 层非线性降维，得到 16 维的综合多尺度特征输出 $\mathbf{F}_{\text{out}}$。

整个多尺度特征融合过程不仅实现了不同邻域尺度下信息的交互、互补和融合，还通过层级式的非线性变换消除了简单拼接可能造成的信息冗余，使网络能够自主学习到最具区分力的综合表达，为后续分类模块奠定坚实基础。

2.3.2 逐级分类器

多尺度特征融合单元输出的 16 维向量 $\mathbf{F}_{\text{out}}$ 随后交由逐级分类器进行细粒度类别判别。该模块采用两级分层判别架构。

1） 第一级分类（面点判别）

首先，$\mathbf{F}_{\text{out}}$ 经过类似公式 (**??**) 的变换降维至 8 维，得到中间特征 $\mathbf{v}_{\text{mid}}$。随后，通过 FC 层输出面点与非面点的逻辑值（Logits）$\mathbf{l}_1 \in \mathbb{R}^2$。最终的初级分类概率分布 $\mathbf{p}_1$ 由 Softmax 函数计算得出[?]:

$$\mathbf{p}_1 = \text{Softmax}(\mathbf{l}_1) = \frac{e^{\mathbf{l}_{1,j}}}{\sum_{k=1}^{2} e^{\mathbf{l}_{1,k}}}, \quad j \in \{1, 2\} \tag{2.16}$$

若判定为面点，则直接据此输出结果；若为非面点，则将中间特征 $\mathbf{v}_{\text{mid}}$ 送入下一级分类子模块。

2） 第二级分类（边缘点与角点判别）

在第二级分类器中，传入的 8 维特征 $\mathbf{v}_{\text{mid}}$ 再次经历 FC、Leaky ReLU 和 Dropout 处理，降维为 4 维特征 $\mathbf{v}_{\text{sub}}$，最后映射为边缘点和角点的二分类逻辑值 $\mathbf{l}_2$。同样利用 Softmax 得到概率分布 $\mathbf{p}_2$，类似公式 (**??**) 所示。最终，对于每个输入点，网络结合两级输出确定“面-边缘-角”三类别的归属。

这种分级判别方法，有效简化了单次多分类的复杂度，提升了点云中特征类别区分的精度和鲁棒性。值得一提的是，每层分类器均结合 Leaky ReLU 增强非线性表达，Dropout 有效应对过拟合风险，整体保证了 NECDNet 在结构复杂、类别分布不均等点云场景下的自适应能力。

2.3.3 损失函数

点云中几何特征的分布存在不平衡现象，面点数量远多于边缘点和角点，特别是角点[?]。为了应对类别不平衡问题，本文在训练过程中采用 Focal Loss 作为优化

指标[?]。Focal Loss 旨在解决训练中前景与背景类别极度不平衡的单阶段物体检测场景（例如 1：1000）。其在交叉熵损失（Cross Entropy, CE）的基础上引入了调节因子，降低了易分类样本的权重，从而使模型更加关注难分类样本。

交叉熵损失是分类任务中常用的损失函数，其可以度量模型预测概率分布与真实标签分布之间的差异。交叉熵越小，说明两者越相似；越大，说明差异越大。交叉熵损失的定义如公式 (**??**) 所示[?]。其中，p_t 表示模型对真实类别的预测概率。然而交叉熵损失在类别不平衡的情况下，容易被大量的易分类样本主导，导致模型对少数类别的学习效果不佳。

$$\mathrm{CE}(p_t) = -\log(p_t) \tag{2.17}$$

为了解决类别极度不均衡的问题，可以在交叉熵损失的基础上引入类别权重 α，得到加权交叉熵损失（Weighted Cross Entropy, WCE）。其在计算时对不同类别赋予不同的权重，增强对少数类别的关注，定义如公式 (**??**) 所示。其中，α_t 为类别 t 的权重，通常根据类别频率进行设置。

$$\mathrm{WCE}_{\alpha}(p_t) = -\alpha_t \log(p_t) \tag{2.18}$$

Focal Loss 正是在加权交叉熵损失的基础上进行改进的。Focal Loss 在加权交叉熵损失的基础上引入了调节因子 $(1-p_t)^{\gamma}$，其中 γ 为调节参数，用于控制易分类样本的权重衰减程度。Focal Loss 的定义如公式 (**??**) 所示[?]。相较于加权交叉熵损失，Focal Loss 通过调节因子有效降低了易分类样本的影响力，使模型更加关注难分类样本，从而提升在类别不平衡情况下的分类性能。

$$\mathrm{FL}(p_t) = -\alpha_t (1-p_t)^{\gamma} \log(p_t) \tag{2.19}$$

2.3.4 评价指标

为了全面评估 NECDNet 在点云几何特征检测任务中的性能，本文采用了多种评价指标，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）、交并比（Intersection over Union, IoU）和马修斯相关系数（The Matthews Correlation Coefficient, MCC）[???]。这些指标能够从不同角度反映模型的分类效果，特别是在处理类别不平衡问题时，精确率和召回率尤为重要。这些指标主要通过混

淆矩阵（Confusion Matrix）进行计算，混淆矩阵记录了模型在各类别上的预测结果与真实标签的对比情况。混淆矩阵的行表示真实类别，列表示预测类别，其中对角线上的值表示正确分类的数量，非对角线上的值表示分类错误的数量。基于混淆矩阵，可以计算出各项评价指标，从而全面评估模型的性能[?]，各个指标的具体计算公式请见附录**??**。

本文中分类任务为三分类，类别分别为：f（面点）、e（边缘点）、c（角点）。可以构建对应的混淆矩阵，如表 **??**所示。表中，TP（True Positive）表示正确预测为正类的数量，TN（True Negative）表示正确预测为负类的数量，FP（False Positive）表示错误预测为正类的数量，FN（False Negative）表示错误预测为负类的数量。

表 2.1　三分类任务的混淆矩阵示例。

Table 2.1　Example of confusion matrix for three-class classification task.

	预测类别			
真实类别	f	e	c	总计
f	TP_{f}	FP_{e}	FP_{c}	P_{f}
e	FN_{f}	TP_{e}	FP_{c}	P_{e}
c	FN_{f}	FN_{e}	TP_{c}	P_{c}
总计	N_{f}	N_{e}	N_{c}	N

上述评价指标的标准公式是基于二分类任务进行设计的。对于多分类任务，需要在指标的计算或者混淆矩阵的构建上进行调整。例如**?**] 提出基于传输的混淆矩阵构建方法，建立在最优传输理论和最大熵原理之上，针对多标签或软标签分类复杂任务提出了一种新的混淆矩阵构建方法。其次就是在指标计算上，可以采用宏平均（Macro-Averaging）和微平均（Micro-Averaging）两种方式[? ?]。宏平均是对每个类别分别计算指标，然后取平均值，适用于类别分布不均衡的情况；而微平均则是将所有类别的预测结果合并后计算指标，更适用于类别分布均衡的情况。

由于本文的分类任务较为简单，且为了与目前的其余最新方法（state-of-the-art, SOTA）进行对比，本文中主要采用宏平均的方式计算各项评价指标。具体而言，设 C 为类别总数，M_c 为类别 c 的评价指标值，则宏平均的计算公式如 (**??**) 所示。本文

中 $C=3$，分别对应面、边缘、角点三类。

$$M_{\text{macro}}=\frac{1}{C}\sum_{c=1}^{C}M_c \tag{2.20}$$

2.4 ABC-Corner 数据集构建

网络训练和评估离不开高质量的标注数据集。针对点云几何特征检测任务，本文构建了一个专门的数据集——ABC-Corner 数据集。该数据集基于 ABC 数据集[?] 中的 CAD 模型，经过精细的标注和处理，包含丰富的面点、边缘点和角点样本，能够有效支持深度学习模型的训练与评估。下文将详细介绍数据集的选取标准、标注流程及统计特性。

2.4.1 数据集选取

针对点云数据的深度学习任务，目前已有多个公开数据集可供使用，如 ShapeNet[?]、ScanNet[?]、RGB-D Object Dataset[] 等。图 **??**展示了部分常用的点云数据集。这些数据集的原始数据一般为扫描得到的非结构化点云，或者 RGB-D 估计得到的点云，适用于多种点云处理任务，如分类、分割和重建等。然而，在本文的几何特征检测任务中，要求数据集具备高质量的几何特征标注，特别是边缘和角点的精确位置标注。通过扫描或重建得到的点云数据往往存在噪声和不完整性，且难以得到精确的几何特征标注，故本文选择基于 CAD 模型的数据集进行构建。

在 CAD 模型数据集中，ABC 数据集因其丰富的几何多样性和高精度的模型表示而被广泛应用于几何处理和计算机图形学领域[?]。如图 **??**，ABC 数据集包含了大量由真实工程设计生成的 CAD 模型，涵盖了各种复杂的几何形状和结构，适合用于点云几何特征检测任务。并且，CAD 模型本身具有明确的几何定义，便于从中提取精确的边缘和角点信息，满足本文对数据集标注质量的高要求。因此，本文选择 ABC 数据集作为构建 ABC-Corner 数据集的基础。

2.4.2 数据集标注流程

ABC 数据集中包含了大量的 CAD 模型，原始数据为模型的几何表示（如 B-Rep）。ABC 数据集在构建过程中基于模型的原始数据，生成了网格化表示和几何真值（法向量、曲率、补丁分割、尖锐特征等）。本文的数据集 ABC-Corner 主要使用原始数

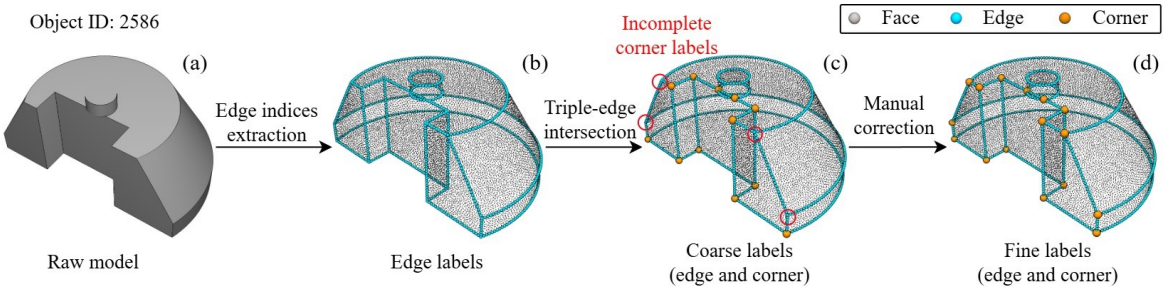


图 2.4 ABC-Corner 数据集标注流程示意图。

Figure 2.4 Annotation pipeline for the ABC-Corner dataset.

据集中的 OBJ 模型文件及其对应的几何真值文件，结合自定义的标注流程，生成包含面点、边缘点和角点标签的点云数据集。如图 **??**所示，本文数据集标注流程主要包括以下几个步骤：边缘提取、粗角点检测和人工精修。

ABC 数据集的模型文件中包含均匀采样得到的点云数据（顶点），以及每个顶点的法向量和曲率信息。几何真值文件中包含了模型的曲面补丁划分和边缘曲线信息。其中的边缘曲线信息是将模型所有边缘进行参数化表示，包含边缘上各顶点的索引信息，以及曲线的样式。基于该信息可以实现边缘点的自动标注。

ABC 中虽然包含了边缘信息，但并未直接提供角点的标注。为了提取角点，本文设计了一种基于几何规则的粗角点检测方法。具体而言，根据边缘曲线信息，识别出边缘的交叉点作为角点候选集，即某个索引在所有曲线中出现三次或三次以上，则将其视为角点。在实际检测中发现对于样条曲线，交点的提取由于索引定义的问题，按照上述规则会将所有构成点均视为角点，导致误检较多。因此，在角点粗提取中会排除样条曲线，仅针对直线和圆弧进行交点检测。通过该方法，能够初步获得角点的候选集。

观察图 **??** 中的标注结果，可以发现自动提取的边缘点和角点存在一定的误差和遗漏。且粗角点检测中未考虑样条曲线。为此，本文引入了人工精修环节，对自动标注的结果进行校正和补充。具体而言，使用可视化工具 CloudCompare 对点云进行展示，人工检查每个模型的边缘和角点标注，修正错误标注并补充遗漏的特征点。通过该流程，最终生成了高质量的点云几何特征标注数据集 ABC-Corner。

ABC-Corner 在 ABC 数据集的基础上增加了对于模型尖锐角点的准确标注，极大地提升了数据集在点云几何特征检测任务中的适用性。该数据集包含了多样化的几何形状和复杂结构，能够有效支持深度学习模型的训练与评估。在平衡人工标注难度及本文训练数据量要求后，最终的 ABC-Corner 包含了 ABC 数据集 chunk00 子

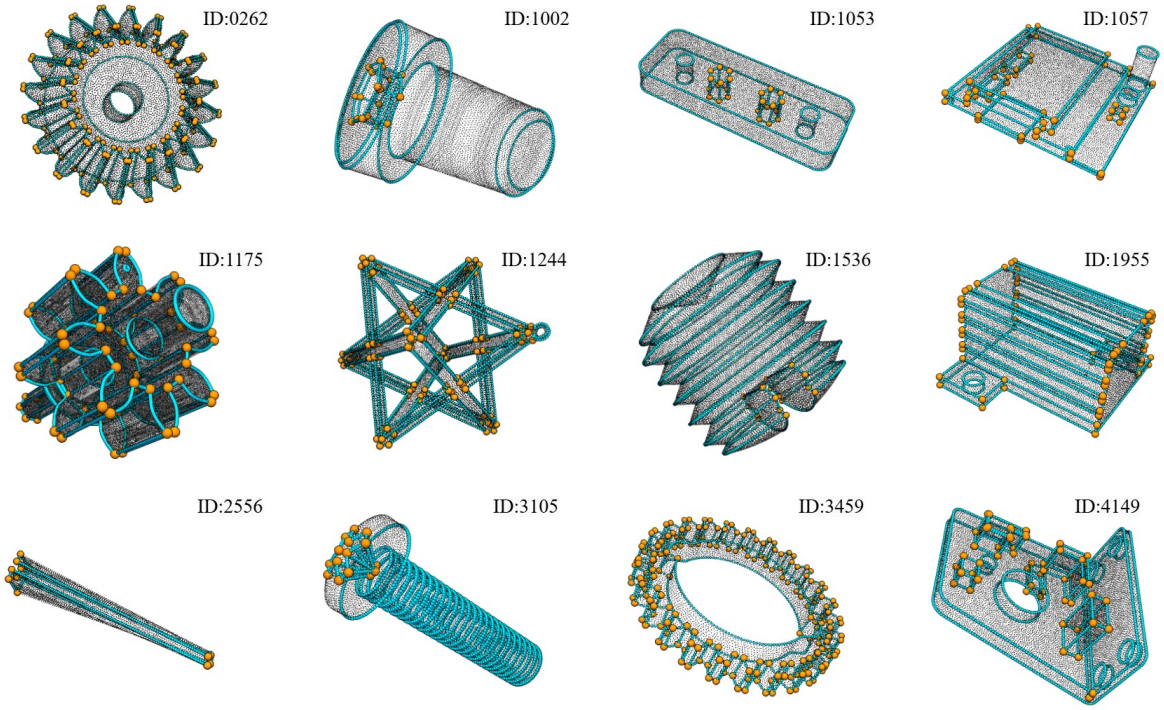


图 2.5 ABC-Corner 数据集中的部分样本及其标注结果。

Figure 2.5 Samples from the ABC-Corner dataset and their annotation results.

集中的 1000 个模型，模型的选择主要针对几何特征较为突出的模型进行筛选。每个模型均经过上述标注流程处理，生成了包含面点、边缘点和角点标签的点云数据。图 **??** 展示了 ABC-Corner 数据集中的部分样本及其标注结果。

2.5 本章小结

本章主要对 NECDNet 网络的设计与实现进行了详细阐述。首先，介绍了多尺度几何特征的提取方法及其在点云三类几何特征中的分布表现，验证了所选特征描述符的有效性。随后，详细描述了 NECDNet 的网络架构设计，包括多尺度特征融合模块和逐级分类器模块，强调了其在处理点云几何特征检测任务中的优势。接着，介绍了网络训练中的损失函数和评估指标等设置。最后，详细介绍了 ABC-Corner 数据集的构建过程，包括数据集选取、标注流程及统计特性，为后续实验提供了坚实的数据基础。整体而言，本章为 NECDNet 的实现奠定了理论与实践基础，为后续章节的实验评估做好准备。

第三章　考虑边缘与角点接触的机器人抓取规划

3.1　引言

机器人抓取规划是机器人操作中不可或缺的步骤，其目标是确定机械手与目标物体之间的接触点，以实现稳定且可靠的抓取。抓取规划的方法多种多样，涵盖了从基于模型的方法到基于学习的方法。其中基于模型的方法通常依赖于物体的几何信息，通过分析物体表面的形状特征来选择合适的接触点。基于学习的方法则利用大量的抓取数据，通过训练神经网络等机器学习模型来预测最佳的抓取位置。在已知物体几何模型的情况下，例如工业场景下的零件分拣、码垛任务，基于模型的抓取规划方法因其解释性强、计算效率高和精确性而被广泛应用。

在基于模型的抓取规划方法中，传统的规划方法通常侧重于面接触，忽略了边缘和角点等几何特征的潜在优势。然而，在实际应用中，边缘和角点接触往往能够提供更高的抓取适应性和灵活性，特别是在处理复杂形状，或物体所处环境不适用面接触时。因此，本文针对物体的几何特征（边缘、角点），提出了一种接触点采样与配对方法，结合软接触模型对抓取稳定性进行评估，并引入抓取增强策略以提升整体抓取性能。

基于模型的抓取规划，输入的物体模型通常以三角网格的形式表示，最后输出一系列的手爪相对物体的 6 自由度位姿以及手爪宽度、抓取稳定评分等参数。本文的方法采用基于采样点进行抓取规划，如图 **??**，规划流程包含接触点采样、接触点检测、接触点配对及稳定性评估等关键步骤。首先，通过类别感知的体素采样方法，均衡地从物体表面的面、边、角区域采样潜在接触点。其次，设计了特征化的接触检测器，分别针对面接触、边接触和角接触进行检测。随后，基于法向量约束和几何位置的筛选规则，实现对偶接触点的配对。最后，采用软接触模型对生成的抓取配置进行稳定性评估，并通过抓取增强策略提升抓取数量。

3.2　类别感知的接触点采样

基于采样点进行抓取规划的方法，首先需要从物体表面获取潜在的接触点。然而，若直接采用全局采样方法，物体的面（Face）、边（Edge）和角（Corner）区域

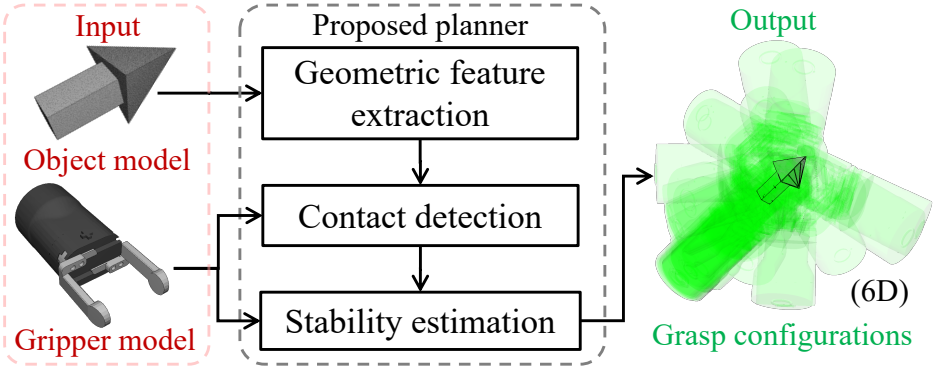


图 3.1 基于几何特征的机器人抓取规划框架

Figure 3.1 Robotic grasp planning framework based on geometric features.

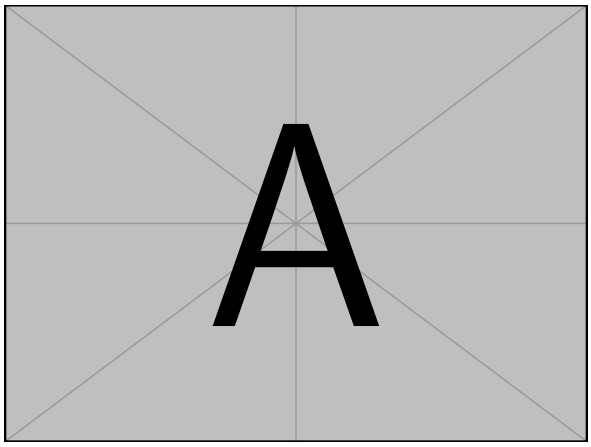


图 3.2 基于类别的体素采样结果

Figure 3.2 Voxel sampling results based on categories.

的采样分布将呈现严重的“长尾”特征：即由于面区域占据了绝大部分表面积，接触候选点将主要集中在面上，而极少落在边或角上。这种分布不均将导致抓取规划难以充分利用物体的几何边缘特性。

为了解决这一问题，本文提出了一种类别感知的体素采样方法。该方法首先对物体表面的点云进行几何特征标记，随后在每个类别内独立进行采样。这不仅确保了不同几何区域（面、边、角）能获得数量近似的接触样本，避免了长尾问题，还有效提升了接触样本的多样性。本文将最终的采样点集记为 $\mathcal{S} = \{\mathbf{s}_i\}_{i=1}^{m}$，其中 m 为采样点总数，$\mathbf{s}_i$ 对应的几何特征标签记为 $\mathbf{f}_i$，其取值范围为 $\{\mathsf{f}, \mathsf{e}, \mathsf{c}\}$，分别代表面、边和角。基于类别的采样结果如图 **??**所示，面区域（蓝色）、边区域（橙色）和角区域（红色）均得到了均衡的覆盖。

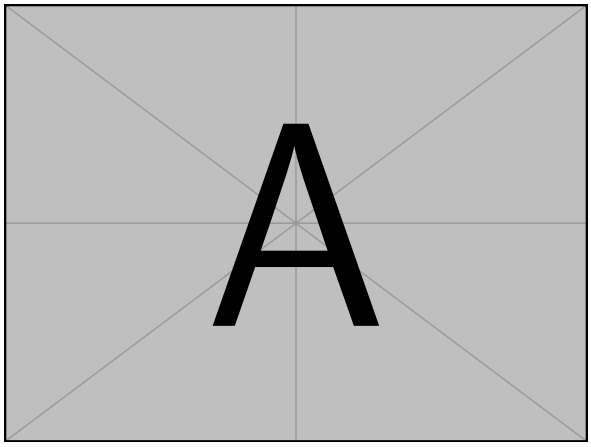


图 3.3　基于 NECDNet 的几何特征检测结果

Figure 3.3　Geometric feature detection results based on NECDNet.

3.2.1　几何特征检测

进行接触点采样前，首先利用第**??**章介绍的 NECDNet 对物体的几何特征进行检测与分类。由于 NECDNet 的输入为点云信息，需先通过均匀采样将物体的三角网格模型转换为点云表示，随后将其输入预训练网络。NECDNet 输出每个点的类别标签 $\mathbf{f}_i$，将点云划分为面、边、角三类。由于基于模型的方法已知物体的真实法向量，上述网络选用了基于真实法向量训练的模型版本。检测结果如图 **??**所示，不同颜色直观地表示了不同的几何特征类别。

考虑到角点在物体表面通常呈稀疏且孤立的分布，直接使用原始检测点可能造成冗余。为了使结果更适用于抓取规划，本文在 NECDNet 检测后引入 DBSCAN 算法对角点进行聚类处理。聚类后的每个簇代表一个角点区域，计算其质心位置作为该区域的代表点，并将类别标签设为角点类别 c。处理后的角点表示更加紧凑，有利于后续的采样与配对。DBSCAN 聚类过程如公式 (**??**) 所示，其中 P 表示待聚类的点集，ϵ 为邻域半径，$MinPts$ 为最小邻域点数。

$$\text{DBSCAN}(P, \epsilon, MinPts) \tag{3.1}$$

3.2.2　基于类别的体素采样

在获得带有几何特征标签的点云后，本文采用基于体素的均衡采样方法。具体而言，首先将点云按几何类别划分为三个子集，随后分别对每个子集进行体素化处

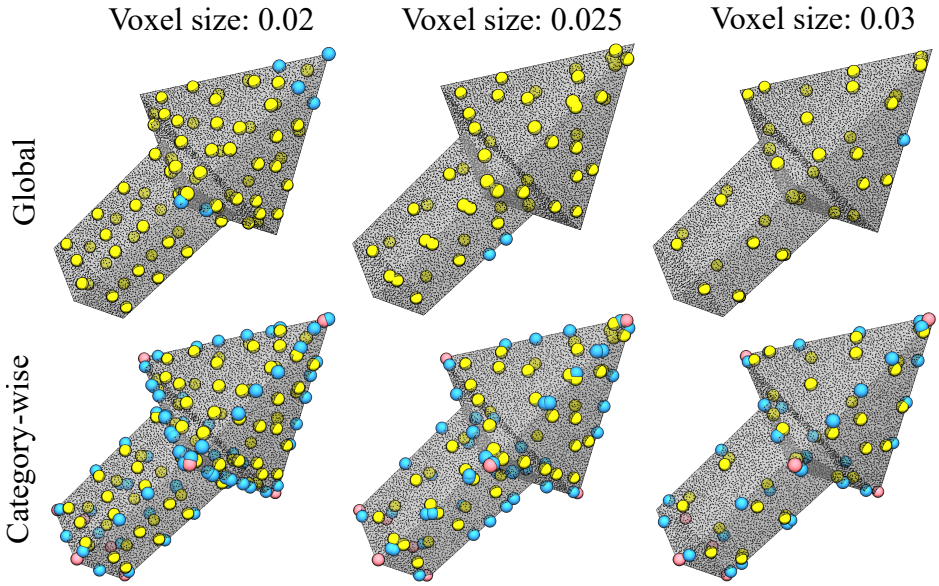


图 3.4　不同体素采样尺寸及采样策略下的采样结果

Figure 3.4　Sampling results under different voxel sizes and sampling strategies.

理：将空间划分为体素网格，并在每个非空体素内随机选择一个点作为采样点 $\mathbf{s}_i$。这种方法确保了采样点在空间上的均匀分布，并强制保证了数量较少的边缘和角点类别也能被充分采样，从而为后续的抓取规划提供均衡的候选集。

在此过程中，体素尺寸 v（针对归一化模型）是影响采样结果的关键参数。v 的大小可以手动微调：较小的 v 会生成更密集的采样点 $\mathcal{S}$，增加抓取规划的搜索空间但降低计算效率；较大的 v 则会减少采样点，可能导致关键几何信息的丢失。图 **??** 展示了同一物体在不同体素尺寸及采样策略下的对比。结果表明，相比于全局采样，基于类别的体素采样在不同几何特征上的分布更为均匀。

此外，为了保证接触的物理有效性，本文还引入了凸性检测（Convexity Check）机制。利用局部表面法向量检查每个采样点 $\mathbf{s}_i$ 的几何凸性，并将位于凹陷区域（Concave regions）的点从集合 $\mathcal{S}$ 中剔除，因为平坦的指腹无法在凹陷处形成有效的接触。经过上述步骤，最终生成的采样点集 $\mathcal{S}$ 既具备几何均衡性，又满足基本的物理接触约束，显著提升了抓取的灵活性。

3.3　基于几何特征的接触对检测

得到物体采样后的接触点则可以进行后续的接触对检测。与采样类似，本文设计了基于几何特征的接触对检测方法，分别针对面接触、边接触和角接触设计了不同的接触检测器，以提高接触检测的准确性和效率。检测器的目的是找到可能与当

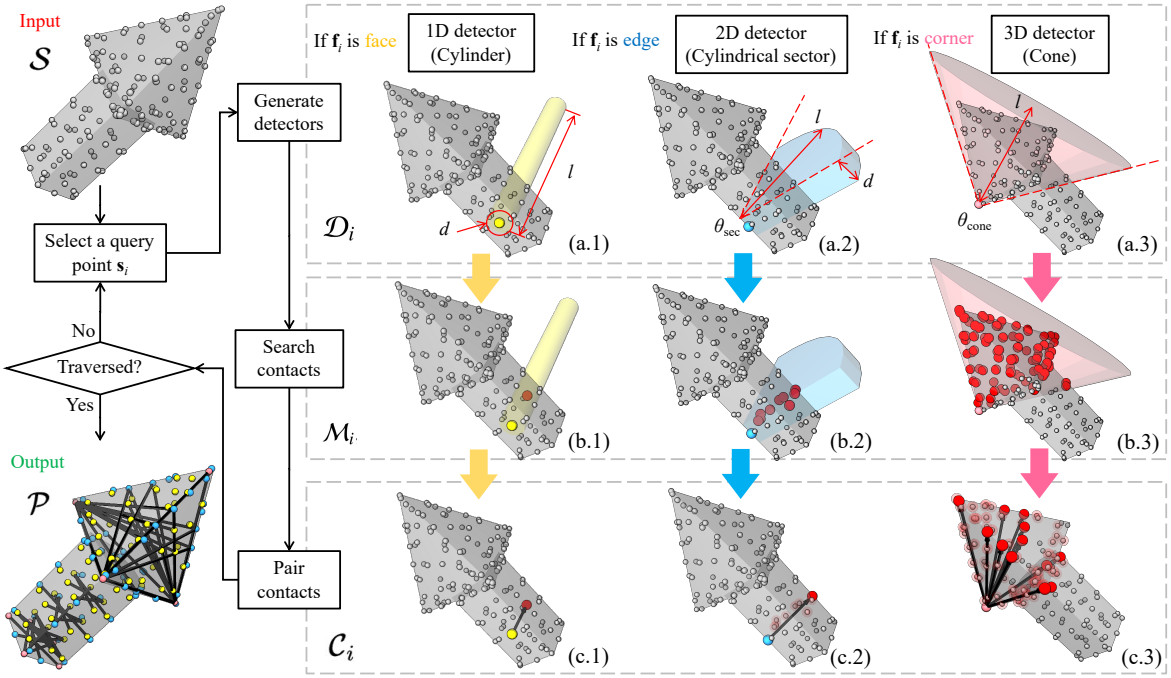


图 3.5 基于几何特征的接触对检测流程

Figure 3.5 Contact pair detection process based on geometric features.

前查询点构成接触点对的点，从而生成潜在的抓取配置。在本文中，三种类别的接触检测器用几何形体进行表示，分别为圆柱体检测器、扇形柱检测器和圆锥体检测器，代表面接触、边接触和角接触。

接触检测器包含的采样点即为当前查询点的潜在接触点对候选点。为了得到最终的抓取配置，本文设计了对偶接触点配对策略，基于法向量约束和几何位置的筛选规则，对检测到的候选点进行筛选与配对。三种接触类别可以构成六种对偶接触类型，分别为面-面、面-边、面-角、边-边、边-角和角-角。在筛选阶段，本文根据不同的对偶接触类型，设计了相应的法向量约束条件，以确保配对的接触点能够形成稳定的抓取配置。

图 **??**展示了本文基于几何特征的接触对检测方法的整体流程。首先，针对每个采样点，根据其几何特征类别选择相应的接触检测器。然后，利用检测器在物体表面进行扫描，找到可能的接触点对候选点。最后，基于法向量约束和几何位置的筛选规则，对候选点进行筛选与配对，生成最终的抓取配置。

3.4 基于几何特征的接触对检测

在通过体素均衡采样获得具有类别标签的点集 $\mathcal{S}$ 后，抓取规划的下一阶段任务是搜索能够形成稳定力封闭（Force Closure）的对偶接触点对（Antipodal Contact Pairs）。传统的接触检测方法，如基于射线投射（Ray-shooting）的采样策略，通常假设接触表面为理想平面，这极大地限制了机械手在复杂几何物体表面的抓取灵活性。然而，在实际操作中，物体的边缘（Edge）和角点（Corner）往往提供了关键的几何特征，允许手指绕接触点或接触轴进行一定程度的旋转，从而在受限空间内实现有效抓取。

为了突破传统平面假设的局限，本文提出了一种基于几何特征的自适应接触对检测方法。该方法不再单一地依赖法向射线，而是针对面（f）、边（e）、角（c）三种不同的几何特征，分别构建了与之拓扑结构相适应的空间检测器：圆柱体、扇形柱和圆锥体。这一过程本质上是将接触点对的寻找转化为一个带几何约束的空间搜索问题。对于每一个作为查询点的采样点，算法利用其对应的检测器在物体空间中搜索潜在的对偶点。随后，结合法向量共线性约束和几何投影规则，对候选点集进行严格的筛选与配对，以确保生成的抓取配置在物理上满足指腹接触的稳定性要求。整体检测流程如图 **??**所示。

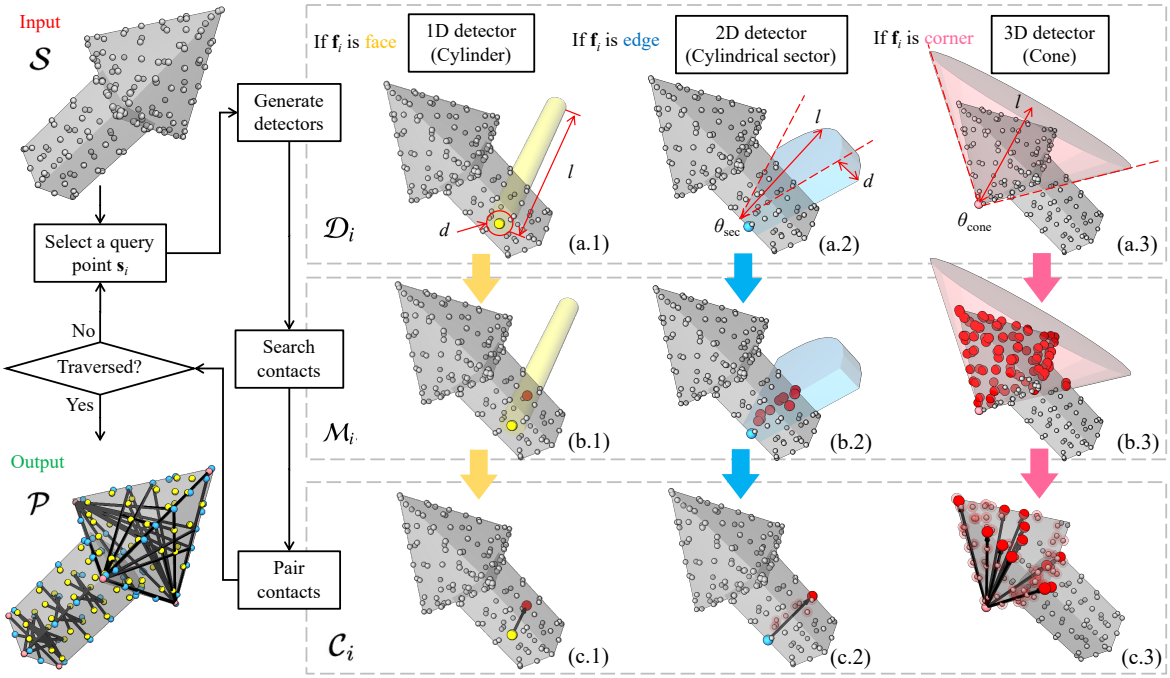


图 3.6　基于几何特征的接触对检测流程

Figure 3.6　Contact pair detection process based on geometric features.

3.4.1 特征化接触检测器设计

为了捕捉不同几何自由度下的潜在接触机会，本文定义了一组参数化的几何约束检测器 $\mathcal{D}$。检测器的几何形态与尺寸严格依赖于查询点的几何特征类别 $\mathbf{f}_i \in \{\mathsf{f}, \mathsf{e}, \mathsf{c}\}$，其构建方向始终沿查询点法向量的负方向 $-\mathbf{n}_i^s$ 延伸，旨在搜索位于物体“对侧”的表面区域。三种检测器的几何定义及示意如图 **??**所示。

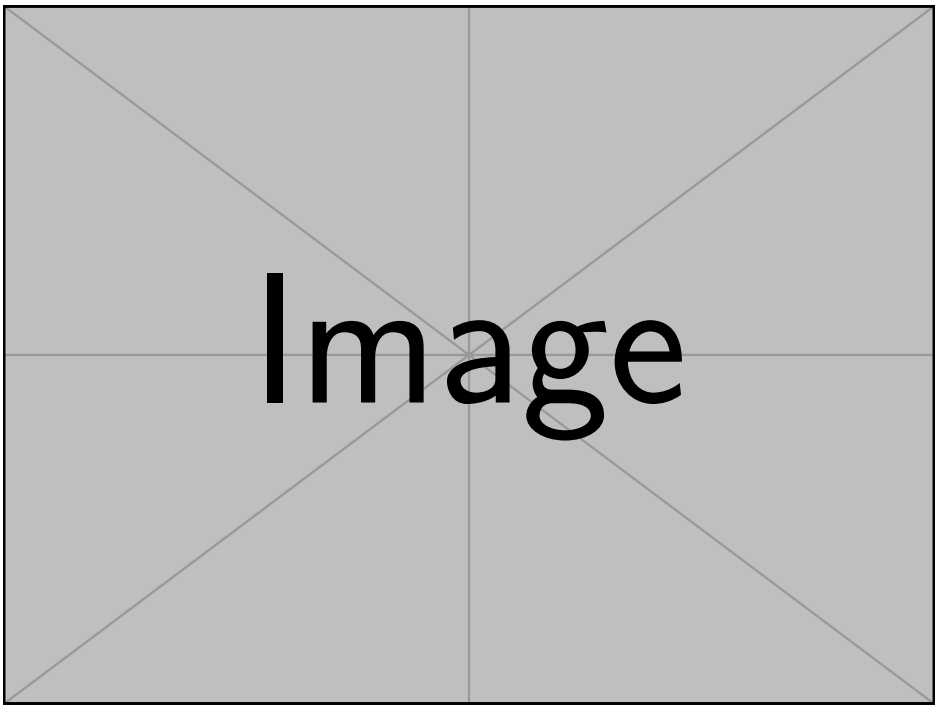


图 3.7　基于几何特征的三种接触检测器：(a) 面接触圆柱体检测器；(b) 边接触扇形柱检测器；(c) 角接触圆锥体检测器

Figure 3.7　Three types of contact detectors based on geometric features: (a) Cylindrical detector for face; (b) Sector detector for edge; (c) Conical detector for corner.

1） 面接触检测器（Face Contact）

面接触受限于半空间几何约束，要求手指指腹平面尽可能与物体表面平行。因此，面特征点的对偶搜索主要沿法线反方向进行。考虑到机械手并不能总是完美垂直于表面，且指腹具有一定的物理面积，我们将传统的射线模型扩展为圆柱体检测器，如图 **??**(a) 所示。圆柱体的直径 d 对应指腹的有效接触直径（对于平行夹爪，通常取 $d = 28$ mm 或指腹最大内切圆直径），代表了允许的横向接触容差。圆柱体的长度 l 决定了搜索的深度范围，为了确保能够覆盖物体的整体几何结构，本文将 l 设定为物体点云包围盒（Bounding Box）的最大对角线长度 d_{bb}。此时，检测器 $\mathcal{D}$ 定义为

一个半径为 $d/2$、高为 l 的圆柱空间，凡是落入该区域的点均被视为潜在的对偶面接触点。

2） 边接触检测器（Edge Contact）

与面接触不同，边接触属于线接触模型。当手指与物体边缘接触时，机械手具备绕边缘轴线旋转的一个自由度。为了适应这种额外的旋转灵活性并捕捉边缘走向，检测器 $\mathcal{D}$ 被设计为扇形柱（Cylindrical Sector），如图 **??**(b) 所示。该检测器在法向截面上呈扇形，半径为 l，厚度为指腹直径 d。扇形的张角 θ_{sec} 决定了允许的旋转搜索范围，考虑到抓取稳定性，防止过大的倾角导致滑脱，通常限制 $\theta_{\text{sec}} < 90°$。

在构建扇形柱检测器时，关键在于确定扇形的展开方向，即边缘的切线方向。由于原始点云数据存在离散性，直接利用差分法计算法向量往往缺乏鲁棒性。为此，本文引入随机采样一致性（RANSAC）算法对边缘点进行局部直线拟合，以获取精确的切向量。

拟合过程具体如下：首先，以当前查询的边特征点 $\mathbf{s}_i$ 为中心，搜索其半径 r 范围内的所有邻域点，构建局部点集 P_{local}。随后，在 P_{local} 中执行迭代拟合：每次随机选取两点定义直线模型，并计算其余点到该直线的欧氏距离，将距离小于设定的阈值 δ 的点标记为局内点（Inliers）。经过 k 次重复迭代后，选取包含局内点数量最多的直线模型作为最优拟合结果。最后，提取该直线的方向向量作为边缘点的切向量 $\mathbf{t}_i$，并据此调整扇形柱的姿态，使其厚度方向与 $\mathbf{t}_i$ 保持垂直，从而确保检测器能够沿着边缘的法平面准确展开。

3） 角接触检测器（Corner Contact）

角接触近似为点接触模型，理论上允许手指绕接触点在三维空间内进行球面旋转。为了最大化搜索范围，检测器 $\mathcal{D}$ 被设计为圆锥体（Cone），如图 **??**(c) 所示。圆锥的高为 l，顶角 θ_{cone} 为可调参数。较大的 θ_{cone} 能够覆盖更广阔的对偶区域，但也可能引入几何上不稳定或发生干涉的抓取配置。与边检测器类似，θ_{cone} 的取值需在覆盖率与稳定性之间进行权衡，具体的参数敏感性分析将在后续实验章节 **??**中详细讨论。

3.4.2 对偶接触点配对策略

接触对检测的具体执行过程如下：首先，从采样集 $\mathcal{S}$ 中选取一个查询点 $\mathbf{s}_i$，根据其特征 $\mathbf{f}_i$ 生成对应的检测器 $\mathcal{D}_i$。计算 $\mathcal{D}_i$ 与点集 $\mathcal{S}$ 的空间交集，得到潜在的候选接触点集 $\mathcal{M}_i = \mathcal{S} \cap \mathcal{D}_i$。

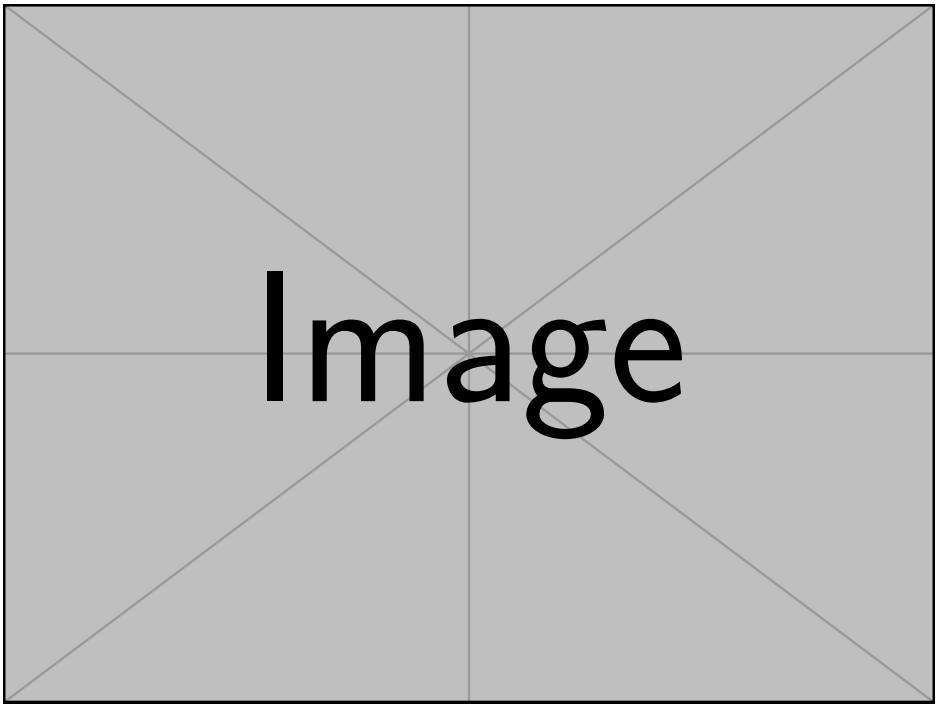


图 3.8　对偶接触点配对策略示意图

Figure 3.8　Schematic of antipodal contact pairing strategy.

对于 $\mathcal{M}_i$ 中的任意候选点 $\mathbf{m}_j^s$，虽然其空间位置满足检测器的几何约束，但仍需进一步验证其法向量和局部几何特征是否能与 $\mathbf{s}_i$ 构成稳定的力封闭抓取。如图 **??**所示，本文根据接触点对 $(\mathbf{s}_i, \mathbf{m}_j^s)$ 的特征组合，制定了以下分类筛选策略：

1）　角-角接触配对（c-c）

当两个接触点均为角点时，由于角接触提供了最大的旋转自由度，且角点处的法向量通常具有较大的不确定性，过于严格的法向约束会导致可行解丢失。因此，对于 c-c 组合，只要点 $\mathbf{m}_j^s$ 落入圆锥检测器内，本文即认为该配对在几何上是可行的。

2）　角-边/面接触配对（c-e, c-f）

在此类组合中，一个接触点为角点（$\mathbf{s}_i$），另一个为边或面点（$\mathbf{m}_j^s$）。由于边和面对手指的姿态有较强的几何约束，且指腹尺寸有限，我们需要确保角点 $\mathbf{s}_i$ 能够稳

定地落在对侧手指的有效接触区域内。为此，本文引入了“投影距离”指标 d_{proj}。该指标计算从 $\mathbf{s}_i$ 出发的射线在对侧点 $\mathbf{m}_j^{\text{s}}$ 的约束平面（对于面）或约束直线（对于边）上的投影偏离程度。具体计算如公式 (**??**) 所示：

$$d_{\text{proj}} = \begin{cases} \|\mathbf{d}_j^{\text{s}} - (\mathbf{d}_j^{\text{s}} \cdot \mathbf{n}_j^{\text{s}})\mathbf{n}_j^{\text{s}}\| & \text{若} \mathbf{f}_j^{\text{s}} = \texttt{f} \\ \|\mathbf{d}_j^{\text{s}} \cdot \mathbf{t}_j^{\text{s}}\| & \text{若} \mathbf{f}_j^{\text{s}} = \texttt{e} \end{cases} \tag{3.2}$$

其中，$\mathbf{d}_j^{\text{s}} = \mathbf{m}_j^{\text{s}} - \mathbf{s}_i$ 为接触连线向量，$\mathbf{n}_j^{\text{s}}$ 为面点的单位法向量，$\mathbf{t}_j^{\text{s}}$ 为边点的单位切向量。若 $d_{\text{proj}} < d$（指腹直径），说明角点处于对侧指腹的有效覆盖范围内，判定该配对有效。

3） 面/边-面/边接触配对（`f-f, e-f, e-e`）

当接触对中不包含角点时，两个接触点均具有相对准确的法向量估计，且受到较强的几何约束。为了保证抓取的对指性质（Antipodal property），两点的法向量应近似相反，以抵消抓取力。定义法向夹角 θ_j^{s} 如公式 (**??**)：

$$\theta_j^{\text{s}} = \arccos\left(\frac{\mathbf{n}_i^{\text{s}} \cdot \mathbf{n}_j^{\text{s}}}{\|\mathbf{n}_i^{\text{s}}\|\|\mathbf{n}_j^{\text{s}}\|}\right) \tag{3.3}$$

设定阈值 θ_{th}，若 $\theta_j^{\text{s}} > \theta_{\text{th}}$，则认为两点法向足够对立，配对有效。$\theta_{\text{th}}$ 直接影响生成抓取的数量与质量：阈值越大，约束越严格，生成的配置越少但对指度越高。实验章节 **??**展示了不同 θ_{th} 下的实验对比结果。

3.4.3 初步抓取配置生成

在完成接触点对的筛选与配对后，最后一步是根据确认有效的接触对 $(\mathbf{s}_i, \mathbf{m}_j^{\text{s}})$ 计算机械手的 6D 抓取位姿。一个完整的抓取配置通常由抓取中心位置 $\mathbf{j}_i$ 和抓取方向（即进近向量 $\mathbf{v}_i$）决定。

抓取中心 $\mathbf{j}_i$ 定义为两个接触点的几何中心，代表了机械手闭合时的理想中心位置，如公式 (**??**) 所示：

$$\mathbf{j}_i = \frac{\mathbf{m}_j^{\text{s}} + \mathbf{s}_i}{2} \tag{3.4}$$

对于进近向量 $\mathbf{v}_i$，它决定了机械手接近物体的方向。由于面特征（`f`）对法向有严格的平行约束（指腹必须平行于面），而边和角特征允许一定的旋转自由度，因此

在确定方向时必须遵循“约束优先”的原则：

- 若接触对中包含面接触点（$\mathbf{f}_j^{\mathrm{s}} = \mathsf{f}$），则优先采用面点的法向量 $\mathbf{n}_j^{\mathrm{s}}$ 作为进近方向，以确保指腹与平面贴合。
- 若接触对仅由边或角点组成（$\mathbf{f}_j^{\mathrm{s}} \in \{\mathsf{e}, \mathsf{c}\}$），则缺乏明确的表面法向约束，此时采用两接触点的连线方向作为进近向量，以最大化抓取力的传递效率。

计算方式归纳为公式 (**??**)：

$$\mathbf{v}_i = \begin{cases} \mathbf{n}_j^{\mathrm{s}} & 若\mathbf{f}_j^{\mathrm{s}} = \mathsf{f} \\ \mathbf{m}_j^{\mathrm{s}} - \mathbf{s}_i & 若\mathbf{f}_j^{\mathrm{s}} \in \{\mathsf{e}, \mathsf{c}\} \end{cases} \tag{3.5}$$

通过上述策略，本文能够从复杂的几何特征中高效地提取出满足物理约束的高质量抓取配置，为后续的运动规划奠定基础。

3.5 基于软接触模型的稳定性评估

在初步获取潜在接触点对后，需对其进行物理层面的力学稳定性评估。实际应用中，机械手末端通常配备柔性指腹（Soft Finger Pad），其在接触物体时发生的弹性形变能够有效拟合目标表面的边、角等不规则几何特征。这种形变不仅显著增加了有效接触面积，还能通过接触面间的微观互锁提供额外的摩擦力矩，从而大幅提升抓取的鲁棒性。然而，柔性材料与复杂几何特征（特别是锐边与尖角）之间的接触力学呈现出高度的非线性，对其进行精确的有限元建模将带来巨大的计算开销，难以满足抓取规划的实时性要求。

鉴于此，本文提出一种基于离散化近似的软接触模型。该模型在保留指腹物理厚度与压缩特性的基础上，将复杂的连续软接触简化为一组分布式的硬点接触集合，进而利用经典的力封闭（Force Closure）理论进行高效的稳定性判别。

3.5.1 接触区域的离散化建模

指腹的变形能力在模型中被量化为沿法向的有效压缩深度。如图 **??**所示，对于任意给定的接触对 $\mathbf{p}_i$，以其接触向量 $\mathbf{v}_i$ 为轴向、接触点位置为中心，构建指腹的几何包围体（图中绿色圆柱所示）。设 t_{pad} 为指腹的物理厚度，引入无量纲参数 $\eta \in [0, 1]$ 作为有效压缩系数，用于表征指腹在特定抓取力作用下的最大形变率。在此模型下，

凡是落入指腹投影区域内且与指腹表面的距离小于有效变形阈值 $d_{\text{eff}} = \eta t_{\text{pad}}$ 的物体表面点，均被判定为有效接触点。

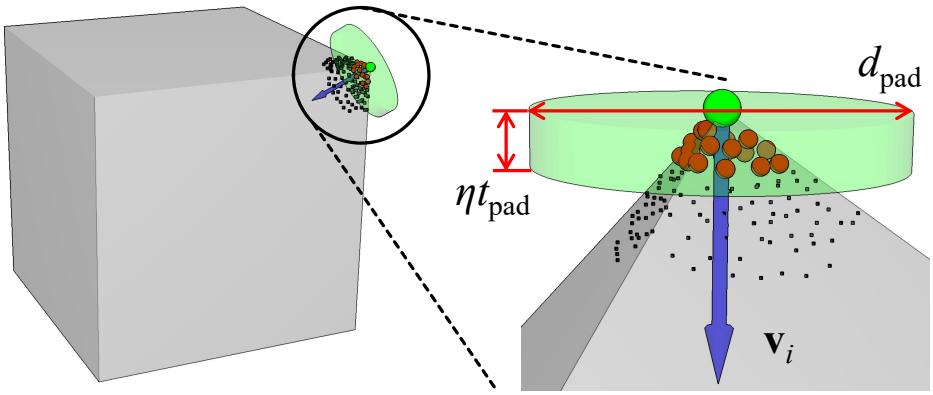


图 3.9 基于软接触变形的接触点集获取示意图

Figure 3.9 Obtaining contact points for stability estimation considering soft contact.

参数 η 的确定涉及材料属性、施加力及接触几何曲率的多物理场耦合。通过实验标定（以配备 3 mm 橡胶指腹的 DH-ROBOTICS PGC 夹爪为例，施加 100 N 抓取力），对于角接触与边接触，η 的经验值分别取约为 0.7 与 0.4。

基于上述定义，原本的单一接触点被扩展为一个离散的接触点簇 $\mathbf{C}_i = \{\mathbf{x}_{i,1}, \mathbf{x}_{i,2}, \ldots, \mathbf{x}_{i,|\mathbf{C}_i|}\}$（如图中红色点集所示）。对于簇中任意一点 $\mathbf{x}_{i,j}$，其局部接触法向量近似统一为指腹的进近方向 $\mathbf{n}_{\text{fp}}$。尽管物体表面的局部法向可能存在微小扰动，但在指腹包裹变形的假设下，该近似能够有效反映接触力的主传递方向。

3.5.2 力学平衡与稳定性判据

抓取稳定性的评估核心在于验证接触力空间中是否存在满足物理约束的可行解，以平衡重力及潜在的外力扰动。假设接触面摩擦系数 μ 均匀分布，对于点簇 $\mathbf{C}_i$ 中的任意离散点 $\mathbf{x}_{i,j}$，其接触力 $\mathbf{f}_{i,j}$ 需满足库仑摩擦定律（Coulomb Friction Law）约束：

$$\begin{cases} \mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}} \leq 0 & \text{(单向压力约束)} \\ \|\mathbf{f}_{i,j} - (\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}})\mathbf{n}_{\text{fp}}\| \leq \mu |\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}}| & \text{(摩擦锥约束)} \end{cases} \tag{3.6}$$

上述约束保证了接触作用力仅表现为压力，且切向分量受限于最大静摩擦力。

系统的力矩平衡方程定义为：

$$\sum_{i=1}^{2}\sum_{j=1}^{|\mathbf{C}_i|}\begin{bmatrix}\mathbf{f}_{i,j}\\ \mathbf{r}_{i,j}\times\mathbf{f}_{i,j}\end{bmatrix}+\mathbf{w}_{\text{g}}+\mathbf{w}_{\text{ext}}=\mathbf{0} \tag{3.7}$$

其中，$\mathbf{r}_{i,j}$ 表示接触点 $\mathbf{x}_{i,j}$ 相对于物体质心的位置矢量；$\mathbf{w}_{\text{g}}\in\mathbb{R}^6$ 为重力旋量（Wrench），包含重力及其产生的力矩；$\mathbf{w}_{\text{ext}}\in\mathbb{R}^6$ 代表外部扰动旋量（本研究中设为零向量，但模型保留其通用性）。

若线性规划（Linear Programming）求解器能在约束范围内找到一组可行力解 $\{\mathbf{f}_{i,j}\}$，则判定该抓取配置具备力封闭稳定性。需特别指出，与经典软指模型（Soft Finger Model）将接触简化为单点并附加显式扭转摩擦约束不同，本文采用的 ** 分布式多点接触模型 ** 通过积分离散点集产生的力矩（即 $\sum\mathbf{r}_{i,j}\times\mathbf{f}_{i,j}$ 项），能够隐式且更真实地捕捉软指腹抵抗旋转扭矩的物理特性，避免了对扭转摩擦系数的人工设定。

3.6 抓取构型增强策略

经过稳定性筛选的接触对仅确定了机械手的空间接触位置 $\mathbf{j}_i$ 和轴向进近矢量 $\mathbf{v}_i$。为了构建完整的 6D 抓取构型（Grasp Configuration），需进一步确定机械手绕进近轴（即夹爪坐标系 x 轴）的旋转角度 β。这一步骤被称为抓取构型增强（Grasp Augmentation）。

如图 **??**(a) 所示，机械手坐标系原点定位于抓取中心 $\mathbf{j}_i$，其 x 轴与接触向量 $\mathbf{v}_i$ 重合。此时，机械手仍保留一个绕 $\mathbf{v}_i$ 旋转的自由度。通过在 $[0,2\pi)$ 范围内对旋转角 β 进行离散化采样，可基于单一几何接触对生成一系列具备不同末端姿态的抓取构型，如图 **??**(b) 所示。该策略显著扩充了候选抓取集（Grasp Candidates），赋予了机器人在运动规划阶段应对环境避障及运动学奇异点时更大的解空间。

值得注意的是，尽管不同的 β 角对应不同的机械手末端位姿，其本质上基于同一组几何接触特征。因此，在后续章节（详见第 **??**节）对抓取分布多样性进行评估时，为避免统计数据的冗余与偏差，评估指标将主要聚焦于接触向量 $\mathbf{v}_i$ 的空间分布（表征 3D 旋转多样性）以及抓取中心的位置分布（表征 3D 空间覆盖率），而非单纯统计增强后的配置总数。同理，在结果的可视化呈现中，为保持图像的清晰度，对于每个接触对仅随机选取一个 β 角生成代表性构型进行渲染，省略了密集的旋转增强

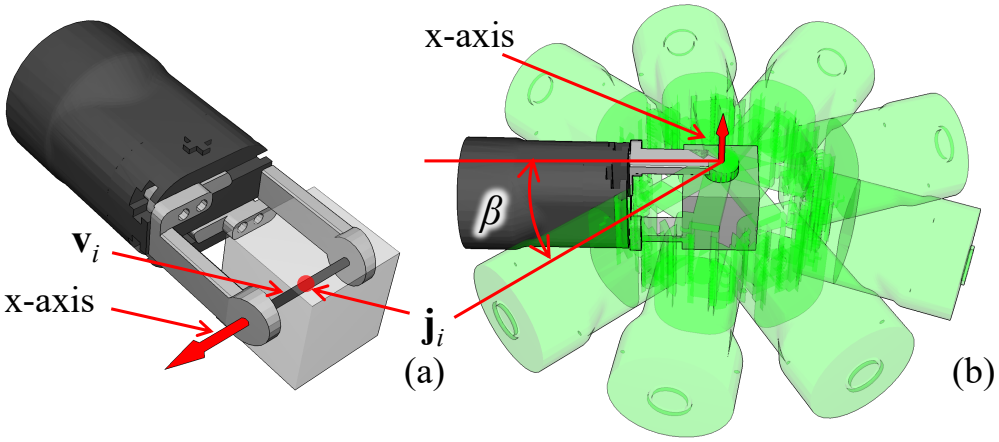


图 3.10 抓取构型增强示意图

Figure 3.10 Schematic of grasp configuration augmentation.

结果。

3.7 本章小结

本章针对机器人操作中复杂几何物体的抓取难题，特别是传统方法在处理非平面特征时的局限性，提出了一种融合面、边、角多维几何特征的系统化抓取规划方法。

针对物体表面几何特征分布不均导致的采样“长尾”问题，提出了类别感知的体素均衡采样策略。通过结合 NECDNet 深度学习特征推理与 DBSCAN 聚类算法，实现了对面、边、角区域的独立体素化采样，确保了稀疏特征（如角点）在候选集中的有效覆盖，为多样化抓取奠定了数据基础。

其次，依据不同几何特征的自由度约束特性，设计了特征化的空间接触检测器（圆柱体、扇形柱及圆锥体），并制定了相应的对偶接触点配对策略。通过引入基于投影距离与法向夹角的筛选机制，有效解决了混合特征下的接触点配对问题，从几何层面保证了候选抓取的合理性。

为了准确评估柔性指腹在边缘与角点处的接触稳定性，本文建立了基于离散化近似的软接触力学模型。该模型通过将连续的非线性软接触简化为分布式硬点接触簇，实现了基于力封闭理论的高效稳定性判别。此外，结合抓取构型增强策略，通过沿进近轴的旋转采样，进一步扩充了机器人的可行解空间。

综上所述，本章所提出的方法有效突破了传统平面接触假设的束缚，显著提升了抓取规划算法对物体复杂几何外形的适应性，为后续章节的实验验证与实际应用

提供了坚实的理论与算法支撑。

第四章　实验结果与分析

4.1　实验环境及配置

4.2　点云特征检测实验分析

4.2.1　对比实验

4.2.2　消融实验

4.2.3　结果可视化

4.3　抓取规划仿真实验分析

4.3.1　抓取分布多样性评估

4.3.2　典型物体抓取规划结果

4.3.3　参数敏感性分析

4.4　真实机器人抓取实验

4.5　本章小结

第五章　总结与展望

5.1　全文总结

5.2　创新点

5.3　研究不足与展望

第六章　点云几何特征检测实验结果及分析

本章旨在通过系统性的实验验证本文所提出的 NECDNet 在三维点云边缘与角点检测任务中的有效性与鲁棒性。实验主要基于本文构建的 ABC-Corner 数据集展开。首先，本章将详细阐述 ABC-Corner 数据集的构建过程、实验的硬件环境、参数配置以及针对数据不平衡问题所采用的评价指标与训练策略。随后，将 NECDNet 与当前主流的传统几何分析方法及深度学习方法进行多维度的定性与定量对比，并重点分析法向量估计精度对检测结果的显著影响。此外，为了验证网络结构设计的合理性，本章还对特征维度、多尺度参数选择及数据增强策略进行了详尽的消融实验分析。最后，本章对实验结果进行了总结与讨论。

6.1　实验环境及配置

6.1.1　软硬件环境与参数设置

为了确保实验结果的可复现性，本节首先明确实验的软硬件环境。本次实验的计算平台采用一台配备 NVIDIA RTX 3090 图形处理单元（显存 256 GB）的高性能工作站，运行环境为 Windows 10 操作系统。算法的开发与实现基于 PyTorch 深度学习框架[?]，集成开发环境为 PyCharm。

在网络模型的训练阶段，超参数的设定对于模型的收敛速度和最终性能至关重要。为了平衡计算效率与显存占用，将批次大小（Batch Size）设定为 20,000，共进行 64 个 Epoch 的迭代训练。为了加速大规模点云数据的读取与预处理，数据加载器的并行工作线程数被配置为 8。模型优化采用 Adam 优化器，该优化器结合了动量法和自适应学习率的优点，能够有效应对稀疏梯度问题。其动量参数分别设定为 $\beta_1 = 0.9$ 和 $\beta_2 = 0.999$，初始学习率设置为 0.001，配合余弦退火策略进行学习率衰减，以确保网络在训练初期的快速收敛以及后期的稳定优化。

针对三维点云数据中普遍存在的几何特征分布不平衡问题，即面点数量远多于边点，而角点最为稀缺，传统的交叉熵损失函数往往会导致模型被大量简单样本主导。为此，本文采用了 Focal Loss[?] 作为损失函数，并将聚焦参数 γ 设为 2.5。该参数能够动态降低易分类样本的权重，使得模型在训练过程中更加关注那些难以分类

的边缘与角点样本，从而有效缓解类别不平衡带来的负面影响。

6.1.2 评价指标设计

为了全面且客观地评估模型的性能，本文选取精确率（Precision）和召回率（Recall）作为主要评价指标，同时辅以准确率（Accuracy）。此外，为了与现有的 SOTA 方法进行公平对比，还计算了马修斯相关系数（MCC）、F1 分数以及交并比（IoU）。

对于纯边缘检测任务，直接采用标准的二分类指标公式。而对于边缘与角点的联合检测任务，这是一个典型的多分类问题，且存在严重的类别不平衡。若直接使用全局准确率，模型倾向于将所有点预测为面点即可获得极高的分数，这显然是不合理的。为此，本文采用宏平均（Macro-averaging）策略来计算 Precision、Recall 和 F1 分数。具体而言，首先基于各类别的真正例（TP）、假正例（FP）、真负例（TN）和假负例（FN）统计量分别计算该类别的指标，然后对所有类别的指标取算术平均。这种计算方式赋予了每个类别同等的权重，确保了稀疏类别（如角点）的检测效果能够被充分反映，避免了评价结果被数量占优的面点所主导。

6.2 对比实验结果及分析

为了全面评估 NECDNet 的性能，本节将其与现有的 SOTA 方法进行了对比。对比实验涵盖两个层面：一是针对边缘与角点联合检测的多分类任务，对比方法包括基于协方差分析的 CA 方法[?]、两阶段检测法 TECD[?] 以及深度学习方法 PIE-Net[?]；二是针对纯边缘检测的二分类任务，对比方法包括 PCEDNet[?] 和 BoundED[?]。

6.2.1 边缘与角点联合检测结果分析

在边缘与角点的联合检测任务中，表 **??** 展示了各方法在 ABC-Corner 数据集上的定量评估结果。数据表明，NECDNet 在 Precision、Recall、F1 分数、Accuracy、IoU 及 MCC 等所有关键指标上均显著优于对比方法。

具体分析各方法的表现，传统几何分析方法 CA 和 TECD 的各项指标相对较低。CA 方法主要依赖单一尺度的几何统计量（如协方差矩阵特征值）进行阈值判定。这种硬阈值策略难以适应不同物体间巨大的几何差异，例如在处理薄壁物体时，单一尺度的邻域分析容易跨越物体的两个表面，导致大量的误检。TECD 方法虽然采用了两步策略，即先检测边缘再基于边缘检测角点，但其角点检测的准确性高度依赖于

第一阶段边缘提取的质量，且存在复杂的阈值参数依赖，导致其泛化能力不足，在复杂拓扑结构下的鲁棒性较差。

相比之下，基于深度学习的 PIE-Net 虽然在性能上优于传统方法，但其 F1 分数仍低于本文方法。PIE-Net 采用了两个独立的网络分支分别处理边缘和角点，缺乏对两者特征相关性的联合建模。这种设计割裂了边缘与角点在几何上的内在联系，导致在某些模糊区域容易产生混淆，且存在较高的假阳性率。本文提出的 NECDNet 通过端到端的特征学习和多尺度特征融合，能够更有效地捕捉局部几何结构。特别是当使用从网格模型（Mesh）估计的精确法向量作为输入时，模型的 F1 分数达到 0.815，MCC 达到 0.943，展现了极高的分类一致性。

表 6.1　ABC-Corner 数据集上各边缘与角点检测方法的宏平均（Macro-averaging）指标评分。

Method	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	I
CA[?]	0.415	0.616	0.420	0.616	0.346	
TECD[?]	0.472	0.642	0.513	0.642	0.438	
PIE-NET[?]	0.615	0.814	0.686	0.935	0.577	
NECDNet (Ours)	0.646	0.857	0.715	0.983	0.616	
NECDNet† (Ours)	**0.765**	**0.933**	**0.815**	**0.995**	**0.743**	

PIE-Net 的数据基于其作者提供的评估结果整理得出。
† 表示使用从 Mesh 模型估计的法向量。

定性分析进一步印证了上述结论。如图 **??** 所示的可视化结果显示，NECDNet 的检测结果与真值（Ground Truth）最为接近，能够清晰地勾勒出物体的骨架结构并准确定位角点。CA 和 TECD 方法的鲁棒性较差，出现了较多的噪点；PIE-Net 虽然检测出了大部分特征，但在角点定位上不够精准。PCEDNet 虽然在边缘检测上表现良好，但由于无法检测角点，在图示中缺失了红色角点标记。为了更细致地探究各方法在不同几何拓扑下的表现，表 **??** 列出了针对图 **??** 中四个典型复杂物体的分类别详细指标。结果显示，NECDNet 在最具挑战性的“角点”类别上取得了压倒性优势，其角点 F1 分数大幅领先于第二名，证明了本文提出的多尺度特征融合模块在捕捉稀疏拓扑特征方面的有效性。

6.2.2　纯边缘检测结果分析

为了验证模型在通用边缘检测任务上的有效性，表 **??** 展示了在 ABC 数据集上仅关注边缘二分类任务时的对比结果。由于 PCEDNet 和 BoundED 未开源代码，我

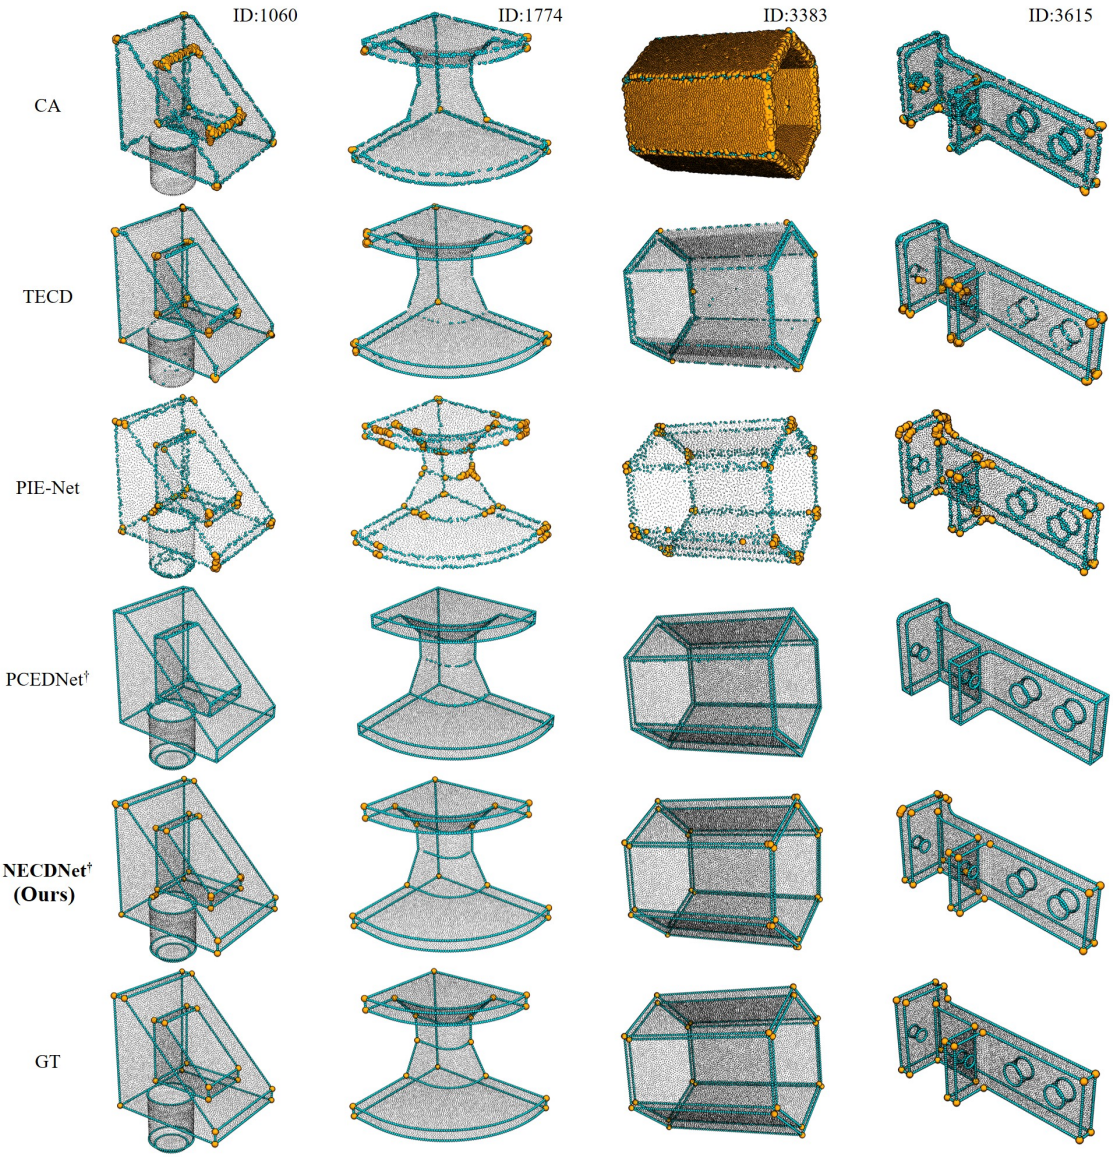


图 6.1 ABC-Corner 数据集上各方法的边缘与角点检测结果可视化对比。本文方法（Ours）取得了最佳的检测效果。CA 和 TECD 缺乏鲁棒性，PIE-Net 检测精度不足，PCEDNet 表现出良好的边缘检测能力但无法检测角点。

们引用了其论文中的数据进行对比。

实验结果表明，NECDNet 在该任务上同样表现出色。在使用 Mesh 法向量的情况下（NECDNet-2c†），其 F1 分数高达 0.956，显著优于 PCEDNet (0.822) 和 BoundED (0.875)。即便是使用基于局部拟合平面的估计法向量（NECDNet-2c），其性能也具备很强的竞争力，尤其是在召回率上表现优异，说明模型能够尽可能多地检出潜在边缘。这表明 NECDNet 不仅是一个优秀的特征点检测器，也是一个鲁棒的边缘提取器，能够适应不同的应用需求。

表 6.2　图 **??** 中四个点云对象的分类别详细指标评分。

Method	Precision(↑)			Recall(↑)			F1(↑)			Accuracy(↑)			IoU	
	Face	Edge	Corner	Face	Edge	Corner	Face	Edge	Corner	Face	Edge	Corner	Face	Ed
CA[?]	0.975	0.303	0.001	0.582	0.614	0.303	0.729	0.405	0.002	0.582	0.614	0.303	0.573	0.2
TECD[?]	0.986	0.705	0.062	0.980	0.762	0.158	0.983	0.732	0.089	0.980	0.762	0.158	0.967	0.5
PIE-NET[?]	0.995	0.673	0.278	0.950	0.898	0.964	0.972	0.770	0.432	0.950	0.898	0.964	0.946	0.6
NECDNet (Ours)	**0.999**	0.970	0.519	0.998	**0.987**	0.921	**0.999**	0.978	0.664	0.998	**0.987**	0.921	0.997	0.9
NECDNet† (Ours)	**0.999**	**0.994**	**0.540**	**1.000**	0.974	**0.987**	**0.999**	**0.984**	**0.698**	**1.000**	0.974	**0.987**	**0.999**	**0.9**

PIE-Net 的数据基于其作者提供的评估结果整理得出。
† 表示使用从 Mesh 模型估计的法向量。

表 6.3　ABC 数据集上各边缘检测方法的指标评分。

Method	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)
PCEDNet-2c†[?]	0.735	0.984	0.822	0.970	0.597
BoundED-2c[?]	**0.959**	0.857	0.875	0.987	0.778
NECDNet-2c (Ours)	0.708	0.988	0.825	0.980	0.702
NECDNet-2c† (Ours)	0.922	**0.992**	**0.956**	**0.996**	**0.915**

PCEDNet 和 BoundED 的数据分别整理自文献[?]和[?]。
† 表示使用从 Mesh 模型估计的法向量。

6.2.3　讨论：法向量估计精度对检测的影响

在深入分析实验结果后，本文发现法向量的精度是影响检测性能的关键因素。NECDNet 的核心输入特征——包括法向角差、法向分布及投影法向模长——均直接依赖于法向量的计算。因此，精确的法向量估计对于提升 NECDNet 的性能至关重要。

为了量化这一影响，本文分别测试了基于点云局部表面最小二乘拟合（Least Squares Fitting）和基于网格模型（Mesh）几何信息两种法向量估计方式。从几何原理上讲，最小二乘拟合假设邻域点位于一个光滑平面上。然而，在物体的尖锐边缘和角点附近，这一假设被打破：邻域点横跨了两个或多个法向截然不同的平面。此时，拟合算法往往会产生平滑过渡的“平均化”误差法向，而非真实的表面法向。

如图 **??** 的对比实验所示，这种方向误差会导致显著的分类混淆。在图 **??**(c) 中，由于法向的平滑，原本尖锐的边缘特征在特征空间中变得模糊，导致网络将部分边缘点误判为角点，或者将角点误判为边缘点。相反，利用 Mesh 计算出的法向量能够精确反映物体的几何拓扑（图 **??**(b)），帮助网络准确捕捉微小的曲率变化，从而实现近乎完美的分类效果。这一发现表明，虽然 NECDNet 具有强大的特征提取能力，但

在实际应用中，高质量的法向信息预处理是发挥其性能上限的必要条件。

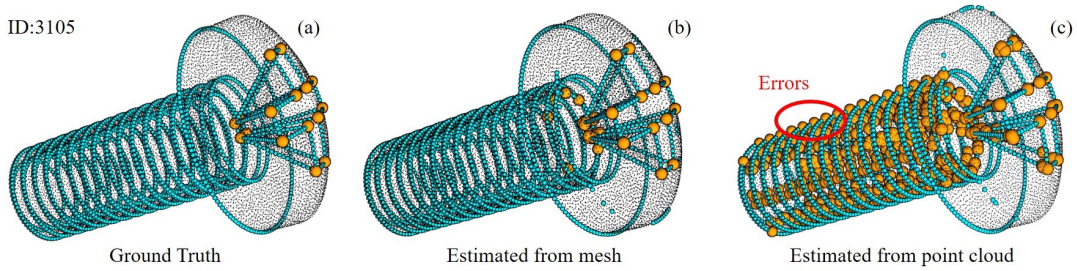


图 6.2 法向量估计精度对检测结果的影响分析：(a) 检测结果真值（Ground Truth）；(b) 使用从 Mesh 估计的法向量得到的检测结果；(c) 使用从点云估计的法向量得到的检测结果。可以看出，使用点云估计的法向量会导致更多的边缘点被误分类为角点。

6.3 消融实验分析

为了验证 NECDNet 各个模块设计的合理性，本节基于 ABC-Corner 数据集开展了多维度的消融实验。实验设定随机抽取 100 个模型用于训练，另外 100 个用于测试，控制变量以确保结论的可靠性。

6.3.1 特征维度的影响

特征描述子的选择直接决定了网络输入信息的丰富程度与有效性。在构建特征向量时，除了最终选用的 6 个标量特征（$\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i$）外，实验还尝试引入了 3 维 PCA 特征值向量 σ_i 和 3 维法向量差均值向量 $\Delta\bar{\mathbf{n}}_i$。表 **??** 中的“特征维度”部分展示了不同组合的性能差异。

实验结果显示，当模型仅使用 6 个标量特征时，各项评价指标反而达到了最高值。引入向量特征后，性能未升反降。分析其原因，σ_i 和 $\Delta\bar{\mathbf{n}}_i$ 虽然包含方向信息，但在无序点云网络中，这种绝对方向信息可能引入了对旋转的敏感性或数据噪声。由于点云网络（如 PointNet++ 结构）通常具有旋转不变性或对局部坐标系的依赖，直接输入全局或不稳定的方向向量可能增加了输入数据的维度和复杂性，导致“维度灾难”效应，反而干扰了网络对核心几何不变量的学习。因此，NECDNet 最终选择更加紧凑且鲁棒的 6 维标量特征组合。

6.3.2 多尺度参数的选择

多尺度特征融合是解决点云密度不均和特征尺度变化问题的关键。本节对尺度数量（Number of scales）和尺度范围（邻域大小 k）进行了探索。实验设定 k 的取值范围覆盖 8 到 128，尺度数量从 2 增加至 8。表 **??** 中的“尺度选择”部分表明，随着尺度数量的增加，模型性能呈现先上升后下降的趋势。

当选择 4 个尺度（$k = 8, 16, 32, 64$）时，模型取得了最佳的 F1 分数和 IoU。当尺度数量过少（如 2 个）时，网络的感受野受限，难以提取宏观的几何结构信息；而当尺度数量过多（如 6 个或 8 个）时，不仅计算开销显著增加，而且大尺度的邻域（如 $k = 128$）引入了过多的无关背景噪声，平滑了局部的尖锐特征，从而抑制了网络的判别能力。因此，4 个尺度的设置在特征丰富度与噪声控制之间取得了最佳平衡。

表 6.4　关于特征维度选择和多尺度参数选择的消融实验结果。

		Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	M
特征维度	$(\hat{\sigma}_i, \kappa_i, \bar{d}_i, r_i)$	0.647	0.847	0.654	0.977	0.601	0
	$(\bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.680	0.922	0.719	0.986	0.656	0
	$(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	**0.754**	**0.946**	**0.805**	**0.996**	**0.735**	**0**
	$(\kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.714	0.935	0.758	0.994	0.693	0
	$(\hat{\sigma}_i, \kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.739	0.946	0.793	0.995	0.720	0
	$(\hat{\sigma}_i, \kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.743	0.940	0.797	0.994	0.722	0
尺度选择	(8, 16)	0.704	0.913	0.751	0.993	0.680	0
	(8, 16, 32, 64)	**0.743**	**0.940**	**0.797**	0.994	**0.722**	0
	(8, 16, 32, 48, 80, 128)	0.723	0.927	0.770	**0.995**	0.702	**0**
	(8, 16, 24, 32, 48, 64, 96, 128)	0.740	0.935	0.795	0.994	0.718	0

特征计算的具体方法和尺度的定义详见前文所述。

6.3.3 训练策略的有效性分析

针对类别不平衡问题，实验首先比较了两种数据重采样策略：一是仅对角点进行重采样，使其数量与边缘点一致；二是同时对角点和边缘点进行重采样，使其数量与面点一致。表 **??** 的结果显示，两种策略在最终的检测精度上差异极小。然而，第二种策略会使训练数据集的规模呈指数级增长，导致训练时长大幅延长且内存开销巨大。基于效率优先的原则，本文最终采用了“仅重采样角点”的策略。

此外，受边缘检测领域中“平滑边缘（Smooth-Edge）”策略（即采样尖锐边缘附

近的点作为平滑边缘点以提升检测鲁棒性）的启发，本实验尝试了类似的“平滑角点（Smooth-Corner）”策略，将角点邻域内的点也标记为角点参与训练。然而，表 **??** 的实验结果表明，引入平滑角点后，模型的各项指标反而出现了下滑。深入分析认为，边缘特征通常具有一定的连续性，因此平滑操作有助于增强边缘的连通性；而角点在几何拓扑上属于“奇点”，具有高度的局部化特征。平滑操作人为地模糊了角点与边缘点之间的特征界限，混淆了分类边界，反而增加了分类器的学习难度。因此，本文在最终方案中摒弃了平滑角点策略，坚持对角点进行精确的单点监督。

表 6.5　关于训练策略的消融实验结果。

		Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
重采样策略	边缘与角点	0.741	**0.941**	0.795	**0.994**	0.721	0.923
	仅角点	**0.743**	0.940	**0.797**	**0.994**	**0.722**	**0.929**
平滑角点策略	使用平滑	0.706	0.874	0.736	0.989	0.670	0.868
	不使用平滑	**0.743**	**0.940**	**0.797**	**0.994**	**0.722**	**0.929**

6.4　本章小结

本章通过一系列严谨的对比实验与消融分析，系统评估了 NECDNet 在点云几何特征检测任务中的性能。实验结果表明，NECDNet 在边缘与角点检测任务上显著优于现有的传统分析方法及其他深度学习模型，展现出更强的特征提取能力和分类精度。通过对法向量精度的深入分析，揭示了高质量几何先验信息对尖锐特征检测的重要性。同时，消融实验验证了本文在特征维度选择、多尺度架构设计及数据平衡策略上的设计合理性，确立了最佳的模型配置。本章的实验结论充分证明了 NECDNet 能够有效地从复杂点云中提取出高质量的几何特征，为机器人抓取规划等下游任务提供了可靠的感知基础。

第七章　机器人抓取规划实验结果及分析

本章旨在通过多维度的实验验证所提出的抓取规划方法的有效性与鲁棒性。实验部分主要分为两个阶段：首先在仿真环境中，通过定量指标对比分析不同规划方法生成的抓取分布特性，以评估规划结果的多样性与灵活性；随后在真实物理环境中搭建实验平台，开展抓取成功率的验证实验，以检验算法在实际应用中的可靠性。最后，本章将综合讨论实验结果，分析方法的局限性并给出总结。

7.1　实验环境及配置

7.1.1　真实环境

为了在物理世界中验证抓取规划的可行性，我们搭建了一套完整的机器人实验平台。实验采用 ABB GOFA-5 协作机械臂作为运动执行机构，该机械臂具备高精度的运动控制能力，能够满足精细抓取任务的需求。末端执行器选用了 DH-ROBOTICS PGC 系列平行电动夹爪。该夹爪具备灵活的行程调节功能，最大行程可达 76 mm。通过更换不同规格的指尖，夹爪可提供 0-76 mm 和 30-106 mm 两种不同的张开宽度范围，以适应不同尺寸的物体。实验中使用的指尖指腹设计为圆形，直径为 28 mm，厚度为 3 mm，表面摩擦系数约为 0.25，以确保接触时的稳定性。

在测试对象的选择上，为了全面评估规划器的泛化能力，我们选取了 9 个具有不同几何特征的物体。这些物体包括来自 KIT、YCB 等开源数据集的标准模型，同时也包含工业场景中常见的机械零件以及日常生活用品。此外，为了测试算法在极端几何特征下的表现，我们还引入了专门设计的人工模型（如四面体）。这些物体的几何特性涵盖了规则曲面、锐利边缘、多面体结构等多种形态，能够充分检验抓取规划器在不同接触条件下的适应性。详细的物体选择理由及参数说明可参见附录 IV。

7.1.2　仿真环境

仿真实验的主要目的是在受控条件下定量分析抓取规划结果的分布特性。为了排除视觉感知误差及环境噪声对规划结果的影响，确保各算法对比的公平性，仿真实验中设定物体的位置和姿态为已知真值。我们选取了三种在机器人抓取领域具有

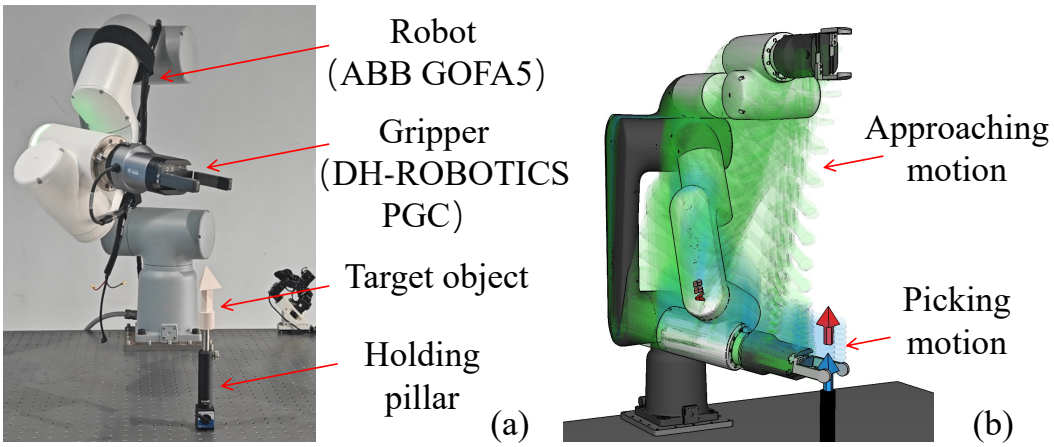


图 7.1 (a) 真实物理实验场景设置；(b) 机器人运动规划路径示意：接近物体（绿色）、执行抓取（蓝色）及移动至目标位（绿色）。

代表性的基准方法进行对比分析：(1) GraspIt!，这是一种经典的基于模型的抓取规划器，通过模拟退火算法搜索最优抓取；(2) GPD (Grasp Pose Detection)，这是一种基于深度学习的规划器，其网络模型基于力封闭 (Force Closure) 策略筛选的数据集进行训练；(3) WRS，这是一种通用的机器人系统规划框架。所有对比实验均在相同的计算平台和环境参数设置下进行，以保证实验结果的可比性。

7.2 抓取分布多样性对比

7.2.1 抓取分布统计指标

在现有的抓取规划研究中，评价标准往往主要关注抓取的力学稳定性 (Stability) 和物体可抓取性 (Graspability)，而较少关注抓取构型 (Configuration) 在空间中的分布情况。然而，抓取构型的分布特性直接决定了机器人在非结构化环境中接近和操作物体的灵活性。一个分布更广泛、更均匀的抓取集合意味着机器人拥有更多的接近方向选择，从而在面对复杂障碍物或关节运动受限时，拥有更大的可行解空间。本文提出的规划器利用对点、线、面接触的综合分析，能够生成更加灵活的抓取结果。

为了量化评估抓取分布的多样性，我们采用抓取构型的 6D 数据（位置与旋转）作为统计分析对象。特别地，为了确保结果的直观性与物理意义，我们重点考察接触向量 $\mathbf{v}_i$ 的分布情况。我们引入了三个关键的统计学指标来描述分布特性：标准差 (Standard Deviation, STD) 用于反映抓取构型相对于中心分布的离散程度；极差 (Range, R) 用于反映抓取覆盖空间的最大跨度；平均绝对偏差 (Mean Absolute Deviation, MAD) 用于反映数据的绝对离散水平。在对比实验中，为了消除候选数量不同

带来的统计偏差，我们统一让每个规划器生成超过 20 个抓取候选，并随机降采样至 20 个进行最终分析。用于定量分析的测试对象包括四面体 (Tetrahedron)、六棱柱巧克力盒 (Amicelli) 和海豹模型 (Seal)。

表 7.1　不同抓取规划方法在三个测试物体上的分布统计指标对比

物体	**方法**	**STD (标准差)**	**R (极差)**	**MAD (平均偏差)**
Tetrahedron	GraspIt!	0.xx	0.xx	0.xx
	GPD	0.xx	0.xx	0.xx
	WRS	N/A	N/A	N/A
	Ours	**0.xx**	**0.xx**	**0.xx**
Amicelli	GraspIt!	0.xx	0.xx	0.xx
	GPD	0.xx	0.xx	0.xx
	WRS	0.xx	0.xx	0.xx
	Ours	**0.xx**	**0.xx**	**0.xx**

7.2.2　抓取分布可视化

表 **??** 展示了各方法在三个统计指标上的定量对比结果。数据表明，本文提出的方法在 STD、R 和 MAD 三个指标上均取得了最高值，且在所有测试物体上保持了一致的优越性。这强有力地证明了我们的规划器能够生成覆盖范围更广、方向更多样的抓取候选，显著提升了抓取的灵活性。

图 **??**(a) 展示了抓取构型的可视化结果，其中不同颜色的夹爪分别代表不同方法的规划结果（GraspIt 为蓝色，GPD 为黄色，WRS 为绿色，本文方法为红色）。观察结果显示，本文方法生成的夹爪位姿在空间中覆盖了更大的区域，展现出更高的构型多样性。这种优势主要得益于本文方法不再局限于传统的面-面接触，而是允许在边缘和角点处建立稳定接触。以四面体（图 **??**(a.1)）为例，WRS 方法由于严格依赖平行面特征，无法在该物体上找到可行的抓取配置；GraspIt 和 GPD 虽然能找到解，但数量较少且分布局限；而本文方法则成功生成了多角度的抓取分布。对于六棱柱（图 **??**(a.2)），其他方法的抓取结果呈现出明显的聚类现象，主要集中在特定的平行面法线方向，而本文方法则利用棱边接触填补了空间空缺。即便是对于表面光滑的海豹模型（图 **??**(a.3)），本文方法依然表现出更好的分布均匀性。

为了更直观地展示分布情况，我们将抓取构型的归一化配对向量映射到 3D 笛

卡尔空间进行散点图可视化，如图 **??**(b) 所示。散点分布清晰地显示，代表本文方法的红色标记在所有测试物体上均展现出最广泛且均匀的空间覆盖，没有出现明显的局部聚集或空白区域，进一步验证了该方法在探索抓取构型空间方面的优势。

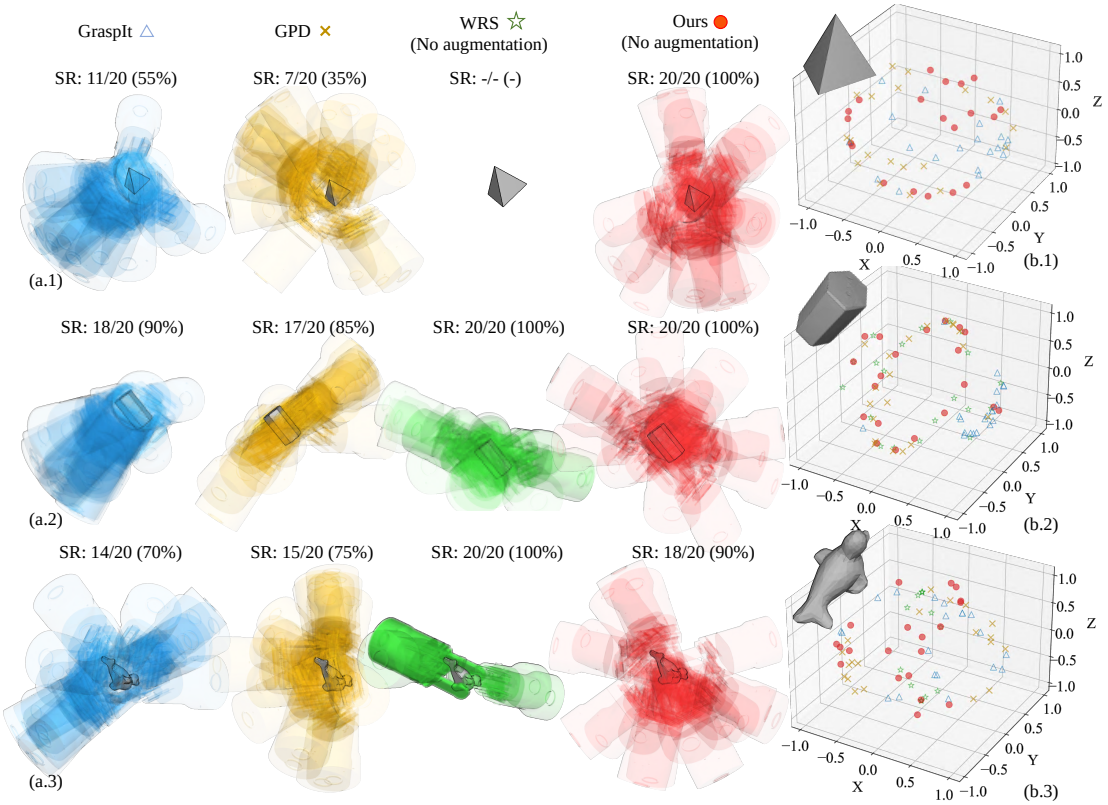


图 7.2　抓取分布可视化对比。(a) 各方法生成的抓取位姿展示（蓝色：GraspIt，黄色：GPD，绿色：WRS，红色：本文方法）；(b) 抓取构型在 3D 空间中的分布散点图。

7.3　抓取成功率对比

7.3.1　实验设置与流程

为了验证规划结果在物理世界中的真实表现，我们在 ABB GOFA-5 机器人平台上进行了系统的抓取成功率测试。为了减少桌面碰撞干扰并增加机器人运动的可达空间，我们将待抓取物体放置于一个支撑柱上。由于本研究的核心在于抓取点规划而非避障路径规划，为了隔离运动规划算法对抓取成功率的干扰，实验采用了基于 RRT-connect 的运动规划算法生成无碰撞路径，控制机器人从预设位置接近物体、执行抓取并将其移动至目标位置。此外，为了排除视觉感知噪声的影响，实验中物体的位置和姿态均为已知。

表 7.2　各抓取规划方法的抓取成功率统计

Method	**四面体**	**巧克力**	**海豹**	**乐高**	**链轮**	**牛奶盒**	**杯面**	**电机座**	**齿轮**	**平均值**
Ours	**100%**	**100%**	**90%**	**100%**	**100%**	**95%**	**95%**	**100%**	**100%**	**97.8%**
WRS[?]	0%	100%	100%	100%	95%	95%	0%	100%	100%	76.7%
GPD[?]	35%	85%	75%	85%	85%	70%	75%	70%	55%	70.6%
Graspit[?]	55%	90%	70%	90%	80%	80%	90%	75%	70%	77.8%

实验流程设计如下：针对每个测试物体，各规划器生成 20 个抓取候选，机器人依次执行这 20 次抓取尝试。由于部分抓取构型可能导致机械臂逆解不可达或发生碰撞，我们在必要时调整物体的初始放置姿态以确保所有候选均可被执行。抓取成功的判定标准为：机器人能够成功将物体从支撑柱上提起，且在移动过程中物体未发生滑落、掉落或显著的姿态偏转。主要的失败模式包括：手指在闭合前意外碰撞物体导致其位移、接触点摩擦力不足导致物体滑落、以及抓取构型不稳定导致物体在提升过程中发生翻转。

7.3.2　结果分析

表 **??** 汇总了各方法在 9 个物体上的抓取成功率。实验结果表明，本文提出的方法展现出了最高的平均成功率，达到了 97.8%，证明了其在实际应用中的强鲁棒性。相比之下，WRS 方法的平均成功率为 76.7%，GPD 和 GraspIt 分别为 70.6% 和 77.8%。

具体分析来看，WRS 方法对于具有平行面特征的物体（如立方体、电机支架）表现优异，但在处理缺乏平行面的物体（如四面体、杯面）时，由于无法生成有效抓取候选，其成功率骤降至 0%，这反映了该方法在几何适应性上的主要局限。GPD 和 GraspIt 虽然能够为所有物体生成抓取候选，但在处理具有锐利边缘或复杂几何特征的物体时表现不佳。例如在四面体抓取实验中，GPD 的成功率仅为 35%，GraspIt 为 55%，主要原因是这些方法难以精确建模边缘接触，导致实际抓取时发生打滑。而本文方法得益于对点、线、面接触的精确建模与分析，在四面体和齿轮等高难度物体上依然保持了 95% 以上的成功率。对于积木、六棱柱等主要依赖面接触的物体，所有方法均表现出了较高的成功率。总体而言，对比实验有力地证明了本文方法在处理多样化物体，尤其是异构几何特征物体时，具有更强的适应性和更高的可靠性。

7.4 本章小结

本章通过严谨的仿真分析与物理实验，对所提出的抓取规划方法进行了全面验证。实验首先通过统计指标与可视化分析，证明了该方法生成的抓取构型在空间分布上比现有主流方法（GraspIt, GPD, WRS）更加均匀且广泛，显著提升了机器人的接近灵活性。随后，在真实物理实验中，该方法实现了 97.8% 的平均抓取成功率，验证了基于点、边、面混合接触模型的实用性和鲁棒性。

尽管该方法表现优异，但仍存在一定的局限性值得后续探讨。首先，该方法目前定位为离线规划框架，且严格依赖完整的物体 3D 模型作为输入，这限制了其在存在遮挡或模型未知的在线场景中的直接应用，未来可结合点云补全技术加以改进。其次，当前规划器主要针对平行夹爪设计，虽然可以扩展应用于部分多指夹爪的对指抓取模式，但对于涉及复杂手内操作的多指灵巧手抓取尚不适用。此外，虽然我们在实验中尽力确保对比的公平性，但由于各基准方法参数调优机制的差异，绝对统一的比较基准难以完全实现，但实验结果已足以揭示各方法在处理特定几何特征时的核心性能差异。

插图索引

表格索引

参考文献

[] TOLSTIKHIN I O, HOULSBY N, KOLESNIKOV A, et al. Mlp-mixer: An all-mlp architecture for vision[C/OL]//RANZATO M, BEYGELZIMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems: volume 34. Curran Associates, Inc., 2021: 24261-24272. https://proceedings.neurips.cc/paper_files/paper/2021/file/cba0a4ee5ccd02fda0fe3f9a3e7b89fe-Paper.pdf.

[] XU B, WANG N, CHEN T, et al. Empirical evaluation of rectified activations in convolutional network: arXiv:1505.00853[M/OL]. arXiv, 2015[2026-01-18]. DOI: 10.48550/arXiv.1505.00853.

[] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(56):1929-1958.

[] BISHOP C M. Pattern recognition and machine learning[M]. New York: Springer, 2006.

[] JAPKOWICZ N, STEPHEN S. The class imbalance problem: A systematic study[J]. Intell. Data Anal., 2002, 6(5):429-449.

[] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[J/OL]. IEEE transactions on pattern analysis and machine intelligence, 2020, 42(2):318-327. DOI: 10.1109/TPAMI.2018.2858826.

[] MAO A, MOHRI M, ZHONG Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//ICML'23: volume 202 Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA: JMLR.org, 2023: 23803-23828.

[] KRSTINIĆ D, BRAOVIĆ M, ŠERIĆ L, et al. Multi-label classifier performance evaluation with confusion matrix[J/OL]. Computer Science & Information Technology (CS & IT), 2020, 10(8):1[2026-01-17]. DOI: 10.5121/csit.2020.100801.

[] CHICCO D, JURMAN G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J/OL]. BMC Genomics, 2020, 21:6[2026-01-17]. DOI: 10.1186/s12864-019-6413-7.

[] DÜNTSCH I, GEDIGA G. Confusion matrices and rough set data analysis[J/OL]. Journal of Physics: Conference Series, 2019, 1229(1):012055[2026-01-15]. DOI: 10.1088/1742-6596/1229/1/012055.

[] ERBANI J, PORTIER P É, Egyed-Zsigmond E, et al. Confusion matrices: A unified theory[J/OL]. IEEE Access, 2024, 12:181372-181419[2026-01-15]. DOI: 10.1109/ACCESS.2024.3507199.

[] KOCH S, MATVEEV A, JIANG Z, et al. Abc: A big cad model dataset for geometric deep learning[C/OL]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 9593-9603[2024-11-01]. DOI: 10.1109/CVPR.2019.00983.

攻读专业硕士学位期间取得的研究成果

一、专著

[1] 张三. XXXXXXXXXXXXXXXXX [M]. 南京: XXXXXXXX 出版社, 2022.

二、论文

[1] ZHANG San. XXXXXXXXXXXXXXXXXXXXX[J]. Bulletin of the Geological Survey of Japan, 2021, 57(5/6): 169-176.

[2] XXX, SATIO M, BUSH G, et al. XXXXXXXXXXXXXXXXXXXXX XX[J]. Journal of the American Chemical Society, 2022, 2(3):20-26.

三、专利

[1] 张三. XXXXXXXXXXXXXXXXX: 202210050175. 8 [P]. 2022-10-14.

四、项目

1. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），主持，XXXX.XX.XX—XXXX.XX.XX。

2. XX 省“十五”制造业信息化工程重大科技攻关项目“基于支持智能化 XXX 设计的创新开发平台”（编号），参与，第二，XXXX.XX.XX—XXXX.XX.XX。

致　谢

衷心感谢导师 xxx 教授对本人的精心指导.

作者署名

完成地点

2023 年 12 月 18 日

附录 A　经典函数公式

论文中用到的经典函数公式.

(Sigmoid Function) Sigmoid 函数定义为

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}.$$

(ReLU Function) ReLU 函数定义为

$$\text{ReLU}(x) = \max(0, x).$$

(Leaky ReLU Function) Leaky ReLU 函数定义为

$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases}$$

其中 α 是一个较小的常数，通常取值为 0.01。

附录 B　用于定量比较的指标公式

章节 (**??**) 中提到的用于定量比较的指标公式如下。

(Precision) 精确率（Precision）定义为

$$\text{Precision} = \frac{TP}{TP + FP}$$

其中 TP 表示真正例（True Positive）的数量，FP 表示假正例（False Positive）的数量。

(Recall) 召回率（Recall）定义为

$$\text{Recall} = \frac{TP}{TP + FN}$$

其中 TP 表示真正例（True Positive）的数量，FN 表示假负例（False Negative）的数量。

(F1 Score) F1 分数定义为

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

用于综合评估模型的精确率和召回率。

(Matthews Correlation Coefficient) 马修斯相关系数（The Matthews Correlation Coefficient, MCC）定义为

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

其中 TP、TN、FP 和 FN 分别表示真正例、真反例、假正例和假反例的数量。

(Intersection over Union) 交并比（Intersection over Union, IoU）定义为

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

用于衡量预测结果与真实标签之间的重叠程度。

(Accuracy) 准确率（Accuracy）定义为

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

用于衡量模型预测的整体正确性。