中图分类号：XXX　　单位代号：10280
密　　级：公开　　学　　号：23722063

上海大学

专业硕士学位论文

SHANGHAI UNIVERSITY PROFESSIONAL MASTER'S DISSERTATION

题目	基于多维特征融合的物体几何特征检测及机器人抓取规划研究

作　　者　邱模聪
学科专业　机械
导　　师　袁建军
完成日期　二〇二六年五月

姓　　名：邱模聪　　学号：23722063

论文题目：基于多维特征融合的物体几何特征检测及机器人抓取规划研究

上海大学

本论文经答辩委员会全体委员审查，确认符合上海大学专业硕士学位论文质量要求。

答辩委员会签名:

主　　席:

委　　员:

导　　师:

答辩日期:　　年　　月　　日

姓　　名：邱模聪　　学号：23722063

论文题目：基于多维特征融合的物体几何特征检测及机器人抓取规划研究

上海大学学位论文原创性声明

本人郑重声明: 所呈交的学位论文是本人在导师指导下，独立进行研究工作所取得的成果。除了文中特别加以标注和致谢的内容外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他研究者对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名:

日期:　　年　　月　　日

上海大学学位论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定，即: 学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

(保密的论文在解密后应遵守此规定)

学位论文作者签名:　　导师签名:

日期:　　年　　月　　日　　日期:　　年　　月　　日

上海大学工学专业硕士学位论文

基于多维特征融合的物体几何特征检测及机器人抓取规划研究

作　　者: 邱模聪

学科专业: 机械

导　　师: 袁建军

机电工程与自动化学院

上海大学

2026 年 5 月

A Dissertation Submitted to Shanghai University for the Degree of Master in Engineering

Research on Multidimensional Feature Fusion-Based Geometric Feature Detection and Robotic Grasp Planning

Candidate: Mocong Qiu
Major: Mechanics
Supervisor: Jianjun Yuan

School of Mechatronic Engineering and Automation
Shanghai University
December, 2026

摘　要

针对物体几何特征检测精度不足与机器人抓取规划灵活性受限的问题，本文提出一套融合神经网络特征学习与基于模型抓取规划的方法框架。首先，提出基于多维特征融合的点云边缘与角点检测网络 NECDNet（Neural Edge and Corner Detection Network）。该网络通过分析点云多尺度邻域内的位置分布与法向分布构建特征矩阵，并利用层次化神经网络实现面点、边缘点与角点的同步分类；同时，构建包含 1000 个模型的 ABC-Corner 数据集用于网络训练。其次，提出一种考虑边缘与角点接触的六自由度双指抓取规划算法。该算法利用 NECDNet 提取特征区域，设计特征化接触检测器搜索对偶接触点，并引入软接触模型进行稳定性评估，有效提升了非规则物体抓取的可行性与抓取构型多样性。实验结果表明，NECDNet 的角点检测 F1 分数达到 0.815，优于现有方法；所提抓取规划算法在分布复杂度指标（STD、Range、MAD）上均优于 Grasp Pose Detection（GPD）、GraspIt 等方法，抓取构型灵活性显著提升。机器人实验进一步验证了角-角、角-边等六类接触组合的有效性与鲁棒性，显示出抓取规划性能与抓取成功率的同步提升。

关键词：点云处理；几何特征检测；神经网络；机器人抓取规划；二指平行手爪

ABSTRACT

To address the limited accuracy of object geometric feature detection and the restricted flexibility of robotic grasp planning, this thesis proposes a framework that combines neural-network feature learning with model-based robotic grasp planning. First, a multi-feature fusion point-cloud edge and corner detection network, NECDNet (Neural Edge and Corner Detection Network), is developed. NECDNet builds feature matrices from positional and normal distributions in multi-scale neighborhoods, and uses a hierarchical neural architecture to jointly classify faces, edges, and corners for geometric feature extraction. In addition, the ABC-Corner dataset with 1,000 models is constructed for network training. Second, a six-degree-of-freedom two-finger grasp planning algorithm considering edge and corner contacts is proposed. Based on feature regions extracted by NECDNet, the algorithm designs feature-aware contact detectors to search for antipodal contact pairs, and introduces a soft-contact model for stability evaluation. This effectively addresses grasping challenges for irregular objects and improves the diversity of grasp planning. Experiments show that NECDNet achieves a corner-detection F1 score of 0.815, outperforming existing methods. The proposed grasp planning algorithm also outperforms model-based methods such as Grasp Pose Detection (GPD) and GraspIt on distribution complexity metrics (STD, Range, and MAD), with a significant gain in grasp configuration flexibility. Robotic experiments further verify the effectiveness and robustness of six contact combinations, including corner-corner and corner-edge contacts, demonstrating improved grasp planning performance and grasp success rate.

Keywords: Point cloud processing; Geometric feature detection; Neural network; Robotic grasp planning; Two-finger parallel gripper

目　录

摘　要 I

ABSTRACT II

主要符号表 VII

第一章　研究背景与意义 1

1.1　研究背景 1

1.2　国内外研究现状 3

1.2.1　物体几何特征检测研究现状 3

1.2.2　机器人抓取规划研究现状 8

1.3　本文主要研究内容 11

1.4　论文组织结构 13

第二章　基于多维特征融合的物体几何特征检测 15

2.1　引言 15

2.2　逐点邻域构建及前处理 16

2.2.1　邻域构建策略 16

2.2.2　点云前处理 17

2.2.3　法向量估计与定向 18

2.3　多尺度局部特征提取与计算 19

2.3.1　多尺度特征矩阵构建 20

2.3.2　局部特征描述符设计 20

2.3.3　局部特征描述符数值可视化分析 24

2.4　NECDNet 网络架构设计 26

2.4.1　多尺度特征融合 26

2.4.2　逐级分类器 27

2.4.3　损失函数 28

2.5　本章小结 29

第三章 几何特征检测对比实验及分析 30
3.1 引言 30
3.2 ABC-Corner 数据集构建 30
3.2.1 数据集选取 30
3.2.2 数据集标注流程 31
3.3 实验环境与参数配置 33
3.3.1 软硬件环境与开发框架 33
3.3.2 数据预处理与划分方案 34
3.3.3 训练超参数配置 34
3.3.4 类别不平衡问题处理 35
3.3.5 法向量估计方法的选择与对比 36
3.3.6 评价指标设计 37
3.4 对比实验结果及分析 38
3.4.1 边缘与角点联合检测结果分析 38
3.4.2 纯边缘检测结果分析 42
3.4.3 法向量估计精度对检测的影响 44
3.5 消融实验分析 45
3.5.1 特征维度 45
3.5.2 多尺度参数 46
3.5.3 训练策略 47
3.6 本章小结 48
第四章 适应复杂几何特征接触的机器人抓取规划 49
4.1 引言 49
4.2 类别感知的接触点采样 50
4.2.1 几何特征检测 50
4.2.2 基于类别的体素采样 51
4.2.3 凸性检测 52
4.3 基于几何特征的接触对检测 52
4.3.1 特征化接触检测器设计 54
4.3.2 对偶接触点配对策略 56

4.3.3 初步抓取构型生成 57
4.4 抓取构型增强及碰撞检测 58
4.4.1 抓取构型增强策略 58
4.4.2 碰撞检测策略 59
4.5 基于软接触模型的稳定性评估 60
4.5.1 接触区域的离散化建模 61
4.5.2 力学平衡与稳定性判据 62
4.6 本章小结 62
第五章 面向复杂接触的机器人抓取规划对比实验 64
5.1 引言 64
5.2 实验环境及参数配置 64
5.2.1 实验平台搭建 64
5.2.2 评估对象集选取 66
5.2.3 实验参数分析及配置 68
5.3 对比实验及分析 71
5.3.1 对比实验设置 71
5.3.2 抓取构型多样性分析 72
5.3.3 抓取成功率分析 73
5.3.4 实物抓取演示 75
5.4 算法耗时 75
5.5 总结 77
第六章 总结与展望 78
6.1 全文总结 78
6.2 创新点 79
6.3 研究不足与展望 80
参考文献 82
攻读专业硕士学位期间取得的研究成果 91
致 谢 92
附录 A 经典函数公式 93

附录 B 用于定量比较的指标公式 94

附录 C NECDNet 额外检测结果 95

附录 D 额外测试物体上的抓取构型分布图 96

主要符号表

$\mathcal{P}^{\mathrm{c}}$	非结构化点云
n	点云中点的数量
$\mathbf{p}_i^{\mathrm{c}}$	查询点（点云中第 i 个点的三维坐标）
$\mathcal{Q}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的邻域点集合
k	查询点邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 中点的数量
$\mathbf{n}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的法向量
κ_i	查询点邻域的曲率特征
$\bar{d}_i$	查询点邻域的投影距离均值特征
r_i	查询点邻域的中心偏离比特征
$\mu_{\theta,i}$	查询点邻域的法向量角度差均值特征
$\sigma_{\theta,i}^2$	查询点邻域的法向量分布方差特征
$\bar{\mathrm{proj}}_i$	查询点邻域的法线投影距离均值特征
$\mathbf{x}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 在某一尺度下的局部特征向量
$\mathbf{X}_i^{\mathrm{c}}$	查询点 $\mathbf{p}_i^{\mathrm{c}}$ 的多尺度特征矩阵
m	多尺度特征矩阵中的尺度数量
$\mathcal{S}$	用于抓取规划的采样点集合
$\mathbf{s}_i$	采样点（集合 $\mathcal{S}$ 中第 i 个点）
f_i	采样点 $\mathbf{s}_i$ 的几何特征类别标签
$\mathtt{f}, \mathtt{e}, \mathtt{c}$	几何特征类别：面点、边缘点、角点
v	体素采样尺寸参数
$\mathcal{D}_i$	基于几何特征的接触检测器
d	接触检测器（或机械手指腹）的直径
l	接触检测器的长度
θ_{sec}	边特征检测器（扇形柱）的张角
θ_{cone}	角特征检测器（圆锥体）的顶角
θ_{th}	对偶接触点法向对齐验证阈值

$\mathbf{j}_i$	机械手抓取中心位置
$\mathbf{v}_i$	机械手接触向量（接近方向）
β	机械手绕接触轴的旋转增强角度
η	软指腹有效压缩系数
$\mathbf{C}_i$	软接触模型下的离散接触点簇

第一章　研究背景与意义

1.1　研究背景

随着智能制造、服务机器人以及自动驾驶技术的飞速发展，具备高精度环境感知与自主交互能力的智能系统正成为学术界与工业界的研究焦点。在这一领域中，三维点云（3D Point Clouds）凭借其对物体几何结构和空间尺度的精确表达能力，已成为连接物理世界与数字世界的重要纽带。作为一种无序、非结构化的数据集合，点云能够直接反映物体的真实拓扑结构，不存在二维图像中的透视形变，因此被广泛应用于逆向工程、三维重建、场景理解以及机器人自主抓取等关键任务中[1]。

在点云数据分析中，物体几何特征（尤其是边缘与角点）的提取不仅是数据简化的过程，更是语义理解的关键。边缘勾勒了物体的轮廓骨架，角点则确立了形体的关键节点。这些特征承载了最丰富的结构语义信息：在三维重建中，它们往往作为曲面拟合的自然边界，决定了重建模型的保真度[2]；在物体识别与配准任务中，它们充当了具有高辨识度的关键描述符，能够显著提升算法在复杂场景下的鲁棒性[3-5]；而在机器人操作领域，准确的轮廓信息更是实现精细化装配与灵巧抓取的前提条件[6]。

尽管物体几何特征具有重要的应用价值，但从非结构化点云中自动且精确地检测这些特征仍面临严峻挑战。首先受限于物理平滑及采样精度，现实物体原本的尖锐几何特征在点云数据中往往表现为一定范围内的圆角过渡区域，使得边缘和角点的界定变得模糊，不利于检测。其次是不同类别的几何特征数据分布的极度不平衡。在一个完整的物体点云中，绝大多数点属于平坦表面，边缘点次之，而角点最为稀疏。传统上，局部几何描述符（如协方差矩阵的特征值[7]、法向量[8]和曲率[9]）通常被用于提取边缘和角点，但这些方法依赖于人工调整的参数和阈值。其优势在于简单且计算效率高，却往往受困于难以调整的阈值、模糊的特征界定以及变化的尺度，难以兼顾检测的灵敏度与特异性。

另一方面，基于学习的方法有潜力解决上述部分缺陷。训练好的模型无需调整参数和阈值[10-11]即可实现检测，表现出优越的适应性和鲁棒性。边缘特征提取已被广泛研究[12-13]，这些方法利用网络学习从局部解析特征到几何特征的映射，在边缘检测方面表现出色。然而，现有的数据驱动方法往往忽略了角点检测，或因缺乏针

对性设计而导致角点检测精度低。角点检测面临着诸如与边缘特征相似、数据可用性有限以及对尺度更敏感等特有问题。这些问题在专门针对角点检测的方法[14]中也依然存在，常表现为较高的误报率和特征点的误分类。

在机器人物理交互层面，机器人抓取规划（Robotic Grasp Planning）是实现自主操作的核心环节，其生成的目标物体抓取构型对于规划操作任务中的机器人运动至关重要[15]。传统的机器人系统往往依赖于耗时费力的人工示教，而近年来广泛研究的自动化抓取规划算法[16]，极大地推动了自主操作技术的发展。

机器人抓取规划的核心目标是生成既满足力学稳定性又具备空间灵活性的抓取候选。早期的研究为解析抓取方法奠定了理论框架基础[17]。研究人员利用图元拟合[18-19]或表面分割[20-21]等技术开发了基于已知模型的规划算法。这些解析方法不仅通过模型匹配支撑了装配、分拣等在线操作任务[22]，也为构建离线数据库以训练端到端的抓取规划器提供了数据基础。

目前的抓取规划算法主要强调面接触的重要性，以确保抓取的鲁棒性。这种倾向同样存在于端到端的学习方法中，因为它们通常在以面接触为核心的数据集[23-24]上进行训练。面接触策略通过将手爪指腹与物体表面法线对齐来实现最大化接触面积，虽然能提供稳定的抓取，但往往以牺牲灵活性为代价。在处理复杂多面体、非对称形状或具有丰富锐角结构的物体时，这种刚性约束常会导致规划失败。尽管部分研究试图通过设计特殊的指尖[25-26]或利用多指手爪[27]来增加接触面积，但面接触优先策略仍限制了抓取策略对广泛物体形状的适应能力。

边缘和角点通常因被认为不稳定而被排除在抓取采样之外。在刚体接触假设下，边缘或角点上的接触退化为点接触，抗扭矩能力有限[28]。然而，在引入软接触（Soft Contact）模型后，指腹的弹性形变可以包裹住尖锐特征，从而有效地模拟面接触。这一范式的转变使得涉及边缘和角点的抓取成为可能，不仅增强了抓取的灵巧性，还将其适用性扩展到了面接触优先规划器无法触及的复杂物体上。

基于上述背景，本文的研究动机源于两个紧密耦合的需求：一是如何从非结构化点云中提取出高保真的几何结构信息，实现对面、边缘及角点的高精度同步检测，解决稀疏角点特征难识别的问题；二是如何利用这些检测到的丰富几何特征，突破面接触的局限，规划出更灵活、更多样、覆盖率更高的机器人抓取构型。本文致力于构建一套完整的从几何感知到抓取规划的技术框架，以解决当前特征检测精度不足和抓取策略灵活性受限的关键问题。

1.2 国内外研究现状

针对基于点云信息的物体几何特征检测和机器人抓取规划两个研究领域，国内外学者已经开展了大量研究工作。本章节将对这两个领域的研究现状进行详细综述，重点分析现有方法的技术路线以及优缺点。

1.2.1 物体几何特征检测研究现状

针对点云数据的物体几何特征检测旨在从无序点云中区分出具有语义信息的结构特征，可以区分为平滑特征（平滑面）和尖锐特征（边缘、边界及角点）两大类。根据技术路线的不同，现有方法主要分为传统的解析方法和基于深度学习的数据驱动方法。

1） 传统解析方法

传统方法包括基于人工设计的几何描述符、基于表面网格重建以及基于图的方法以及来表征局部邻域的统计特性等，实现不同几何特征的区分。其中基于人工设计的几何描述符是最早被广泛研究的技术路线。

Gumhold 等人[7] 提出的基于主成分分析（Principal Component Analysis, PCA）的方法是该领域的经典工作。该方法通过构建点云中每个点及其 k 近邻点的协方差矩阵，计算该矩阵的特征值来描述局部表面的几何变化。如图 1.1 所示，不同几何特征的邻域范围内存在不同的数据分布。具体而言，如果不为零的最小特征值超过了预设的阈值，则认为该点附件的数据变化程度较大，属于边缘或角点特征。

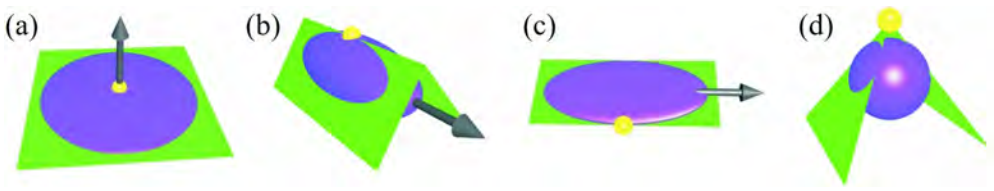


图 1.1 不同几何特征点的邻域形状[7]：(a) 平面点；(b) 折边点；(c) 边界点；(d) 角点
Figure 1.1 Neighborhood shapes of different geometric feature points[7]: (a) Face point; (b) Ridge point; (c) Boundary point; (d) Corner point.

在 PCA 方法的基础上，Xia 等人[29] 进一步引入了基于局部协方差矩阵的特征值比率的边缘检测算法，通过分析特征值之间的相对关系，实现几何特征的检测。Pauly 等人[30] 和 Bazazian 等人[31] 则提出了多尺度分析框架，通过综合不同邻域尺度下的几何响应值来增强特征检测的鲁棒性。多尺度分析能够在一定程度上缓解单一尺度

选择带来的问题，但仍然依赖于人工设定的阈值，且在处理具有复杂几何结构的物体时，特征点的界定仍然模糊不清。

Nguyen 等人[9] 基于曲率进行边缘特征提取并分为三个阶段：先利用曲率估计并配合阈值策略定位可能的边缘点；再通过迭代非极大值抑制对高曲率响应的宽带区域进行压缩与精炼，以获得更准确、稀疏的边缘点集合；最后基于距离阈值判定点与点之间的邻接关系，将相邻点逐步连接形成连续的特征线或边缘，从而实现稳定的线状特征恢复。王丽辉等人[32] 则结合曲率和法线信息进行邻域分析，并通过八叉树结构计算模型数据点密度，利用密度信息辅助边缘点的提取和连接，提升了边缘检测的准确性和连续性。

基于图的方法可以通过结合全局上下文信息进一步增强特征提取。例如，Demarsin 等人[8] 针对曲线的检测开展相关工作。其先基于点云法线信息，通过一阶分割获得候选特征点，并将其组织为图结构以恢复锐特征线；随后构建最小生成树以形成初始线结构，并通过后续的重连接过程将断裂的线段闭合，从而获得闭合特征线。此外，Che 等人[33] 采用了基于一致性投票的方法：首先设计了特征提取策略 NORmal VAriation ANAlysis（Norvana），能够针对点云多视图投影中频繁出现的边缘进行投票提取；随后采用区域生长，将同一平滑曲面上的点聚合得到分割结果。图 1.2 展示了 Norvana 的结构。

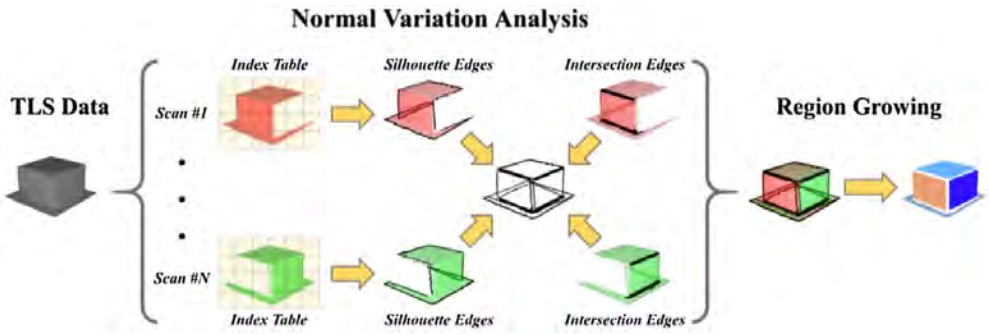


图 1.2　基于一致性投票的边缘检测方法 Norvana[33]

Figure 1.2　Norvana: Normal Variation Analysis-based edge detection method[33].

基于表面重建的方法，如利用移动最小二乘法（Moving Least Squares, MLS）[34]，可以通过利用局部近似来改善尖锐特征的检测。该方法首先在局部邻域内拟合一个高阶多项式曲面，然后分析数据点到拟合曲面的残差分布。特征点通常表现为拟合残差较大的区域，或者拟合曲面曲率极大的位置。这类方法的优势在于能够提供亚

像素级别的特征定位精度，但高阶曲面拟合的计算开销较大，且在特征交汇复杂的角点区域容易产生伪影。Zhang 等人[35] 提出了 VAM，利用成对一致性投票机制进行法向量估计，在尖锐边缘或角点处允许存在多个法向量假设，并通过邻域内的一致性投票来筛选出最能代表几何结构的法向量组合，从而有效地在重建过程中保留尖锐特征。

Lin 等人[36] 则利用多视图投影点云的方法进行边缘检测。如图 1.3 ，其将三维点云进行多视图投影，再基于二维图像的线段检测算法（LSD）进行边缘提取，最后将检测到的线段重新映射回三维空间。并利用半平面线段分割结构（Line-Segment-Half-Planes, LSHP）进行进一步的匹配，得到完整的三维线段特征。该方法通过引入多视图投影的策略，成功地将二维图像处理技术应用于三维点云的边缘检测中。

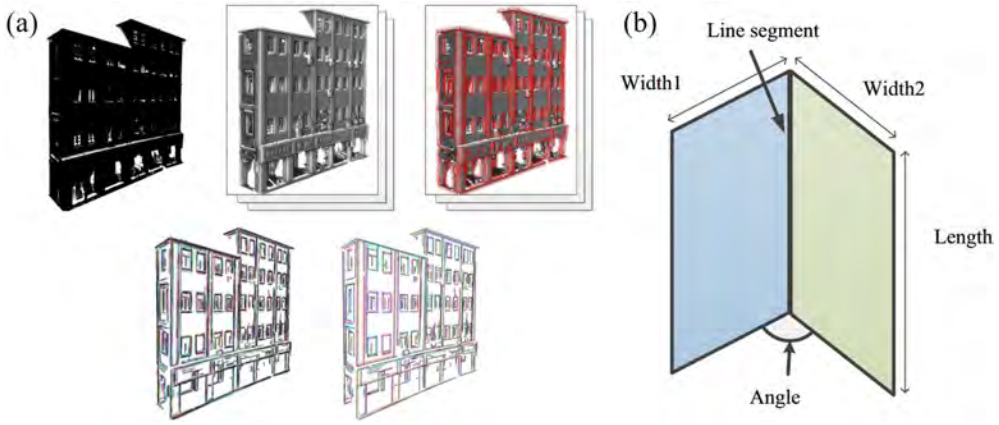


图 1.3　基于多视图投影的三维点云边缘检测流程[36]：(a) 各阶段检测结果；(b) LSHP 结构示意图

Figure 1.3　Multi-view projection-based 3D point cloud edge detection pipeline[36]: (a) The detection results of each stage; (b) Schematic of the LSHP structure.

在角点检测方面，针对仅提取边缘不足以描述完整几何特征的问题，Ahmed 等人[6] 采用了两步提取过程：首先基于邻域的空间分析区分出面点和非面点，然后利用聚类的方法在非面点中识别角点。此外，Schmidt 等人[37] 提出使用随机采样一致性（Random Sample Consensus, RANSAC）算法从点云中提取直线或平面，并在它们的交点处检测角点。这些方法尝试通过几何基元的组合关系来定位角点，但在复杂噪声环境下仍面临挑战。

综上所述，虽然以几何描述符、表面重建及图优化为代表的传统解析方法为点云特征提取奠定了理论基础，并在规则模型的边缘检测中表现出一定有效性，但其局限性亦十分显著。首先，这类方法本质上依赖于人工设计的几何规则与先验假设，

对噪声极其敏感，且高度依赖如邻域尺度、曲率阈值等参数的精细调节，难以在物体形状多变、数据质量参差的现实场景中实现自适应的稳健检测。其次，基于平滑拟合的策略往往导致尖锐特征被过度平滑，造成定位精度损失。最为关键的是，角点检测在此类方法中常被边缘化，多作为边缘提取后的二次处理步骤或依赖于理想化的平面相交假设，这种两阶段策略不仅计算冗余，且在处理复杂拓扑结构的角点时极易因特征模糊而产生误检或漏检。

2） 基于数据驱动的方法

近年来，随着深度学习在三维视觉领域的突破，基于数据驱动的几何特征检测方法逐渐成为主流。这类方法通常将特征提取任务建模为分类或回归问题，将点云中的每个点标记为属于特定的几何类别或找出拟合的几何参数。相较于传统方法，数据驱动模型不再依赖人工设定的复杂阈值，而是通过神经网络自动学习从局部几何结构到特征类别的映射关系，展现出更强的鲁棒性和泛化能力。

点云数据存在无序、稀疏且高维的特点，传统卷积神经网络难以直接应用于点云数据的处理。随着 PointNet[10] 及其改进版本 PointNet++[38] 的提出，直接处理点云数据的深度学习方法得以实现。基于此架构，研究者们设计了多种网络结构来针对边缘和角点的检测进行优化。例如，Wang 等人提出的 PIE-Net[14] 基于 PointNet++ 设计了两个相同的网络分别用于边缘和角点的检测。其实现了点云边缘和角点检测的端到端检测。然而，PIE-Net 的分离提取设计效率较低，需要对角点检测结果进行后处理，且网络对输入点数有严格限制，难以适应大规模点云场景。

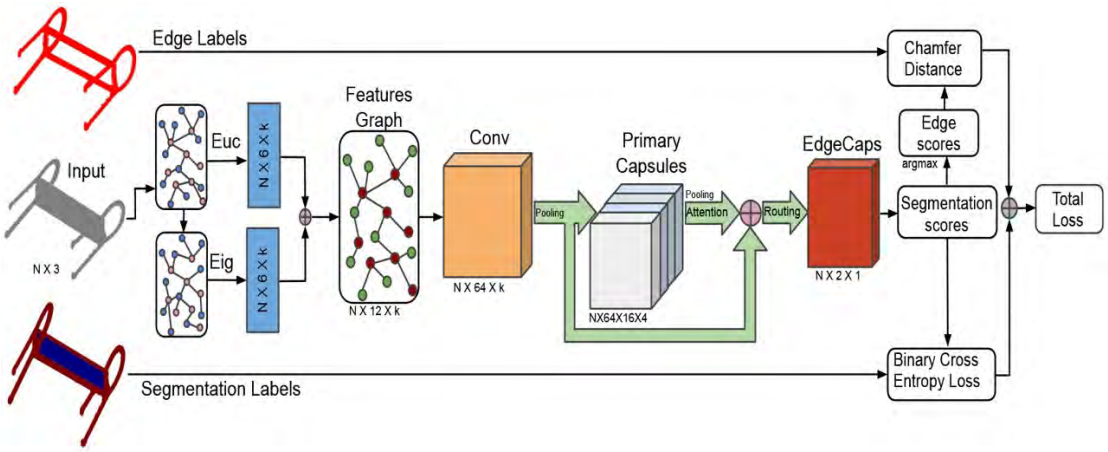


图 1.4 基于胶囊网络的边缘检测方法 EDC-Net[11]

Figure 1.4 EDC-Net: Capsule network-based method for edge detection[11].

针对特征空间层级关系的建模，Bazazian 等人提出的 EDC-Net[11] 引入了胶囊网络（Capsule Network），如图 1.4 所示。该方法首先将局部邻域编码为几何描述符，利用胶囊层独特的动态路由机制来捕捉特征的空间分布结构，从而将点稳健地分类为非边缘或锐利边缘，减少了对人工参数的依赖。此外，针对输入形式的不同，Guerrero 等人的 PCPNet[39] 专注于局部几何属性的估计，它以多尺度的点云局部图块（Patches）作为输入，通过共享权重的 MLP 学习局部形状特征，不仅能估计法向量和曲率，也能用于特征点的分类。Jiao 等人的 MSL-Net[40] 则提出了一种轻量级的多尺度局域网络，通过在不同半径下聚合局部邻域信息增强特征表达，旨在解决大规模点云场景下边缘提取的实时性问题。

为了更有效地利用局部几何信息，Himeur 等人提出的 PCEDNet[12] 和 Bode 等人提出的 BoundED[13] 采用了基于多尺度局部特征描述符的策略。这类方法首先计算点云的多尺度几何属性（如曲率、法向量分布等），然后将这些描述符输入 MLP 进行特征融合与分类。研究表明，通过神经网络学习局部描述符的非线性组合，可以显著提升边缘检测的精度。然而，由于边缘和角点在局部邻域内的几何特征极具相似性，现有方法仍未运用于角点的检测，无法证明其有效性。

除了将被检测任务视为逐点分类问题，部分研究将其重构为回归问题或采用不同的数据表征。Yu 等人提出的 EC-Net[41] 不直接进行二分类，而是学习预测每个点到最近边缘的距离场（Distance Field）。通过回归距离值为零的等值线，EC-Net 能够以亚像素级的精度恢复出锐利的边缘曲线，尤其在处理倒角特征时表现优异。类似的，Matveev 等人的 DEFs[42] 采用了一种隐式场回归的策略。该网络训练模型回归每个查询点到最近边缘曲线的距离以及特征点的坐标残差，随后通过后处理算法重建高精度的连续边缘线。

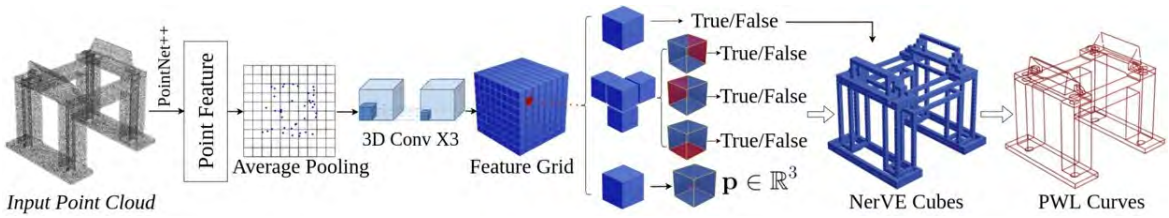


图 1.5　基于体素网格的边缘检测方法 NerVE[43]

Figure 1.5　NerVE: Voxel-based edge detection method[43].

在数据表征方面，Zhu 等人提出的 NerVE[43]（如图 1.5 所示）针对无序点云难

以进行常规卷积的问题，将点云转化为规则的体素（Voxel）网格。该方法利用稀疏三维卷积神经网络提取体素特征，并在体素内进一步进行节点分类，在保持结构化感知的同时实现了对尖锐几何特征的有效检测。Hu 等人的 JSENet[44] 则将任务扩展为三维语义边缘检测，采用双流全卷积架构，一支流负责语义分割，另一支流专注边缘检测，通过特征交互模块融合两者的信息，从而在提取几何边缘的同时赋予其语义类别属性。这种方法的检测结果不仅具有几何准确性，还能提供丰富的语义信息，但其处理效率较低，在大规模点云场景下的适应性有待提升。

总体而言，目前的学习型方法主要集中在边缘特征提取上，且效果显著，但针对角点检测的研究相对匮乏。PCEDNet 和 BoundED 等方法证明了通过神经网络学习局部几何描述符在边缘检测上的有效性。基于此，本文延续并改进这一技术路线：针对角点和边缘难以区分的难点，本文对计算特征描述符进行针对性的设计，提出了能够有效辨识角点的新型几何特征，并采用基于 MLP 的层次化网络结构来学习这些特征，从而实现对面、边缘和角点三类特征的高精度同步检测。

1.2.2 机器人抓取规划研究现状

机器人抓取规划主要可以分为抓取构型（Grasp Configuration）规划和抓取质量评估两个方面。这两部分都包括基于分析和数据驱动的方法。

1） 抓取构型规划

机器人抓取规划方法通常可分为基于模型（Model-based）和基于学习（Learning-based）的方法。基于模型的方法依赖于物体的几何信息和物理规则来生成抓取构型，这类方法进一步可分为两种主要策略：图元拟合（Primitive Fitting）和表面分割（Surface Segmentation）。

图元拟合策略使用基本的几何图元（如圆柱体、球体、方块等）来近似物体，从而简化抓取合成过程[19]。Miller 等人提出了 GraspIt! 仿真器[18,45]，通过将复杂物体分解为一组简单的几何原语来快速生成抓取假设。Chen 等人[22] 利用词嵌入（Word Embeddings）来量化已知模型类别与真实物体之间的语义相似度，从而实现新物体与数据库模型的匹配。虽然图元近似降低了计算复杂度，但它往往丢失了物体的局部细节几何信息，导致生成的抓取难以适应具有丰富几何特征的复杂物体。

表面分割策略则致力于识别有意义的表面区域以指导抓取生成。Harada 等人[20] 针对软指尖手爪，根据接触软度对三角网格进行聚类，规划出适应物体局部曲率的

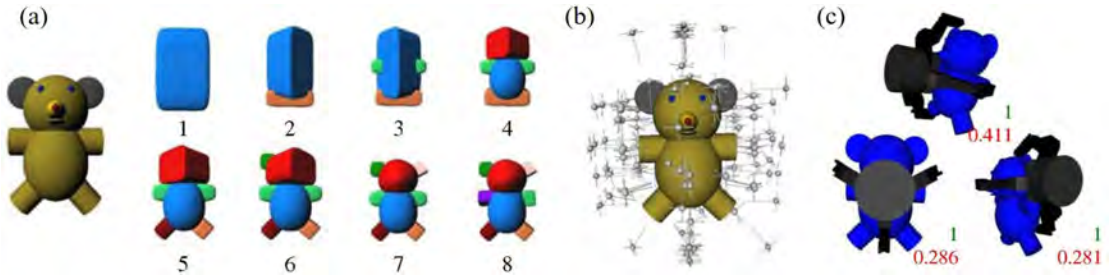


图 1.6 基于图元拟合的抓取规划方法[19]：(a) 图元拟合过程；(b) 抓取构型生成；(c) 抓取质量评估

Figure 1.6 Grasp planning method based on primitive fitting[19]: (a) Primitive fitting process; (b) Grasp configuration generation; (c) Grasp evaluation.

抓取。Wan 等人[21] 引入了叠加分割（Superimposed Segmentation）技术，根据表面法向量将每个三角形分割为具有受控重叠和厚度的多个面片。然而，为了确保力封闭的稳定性，这类方法通常显式地剔除边缘和角点附近的区域，避免在曲率突变处建立接触[21,45]。这种“面接触优先”的策略虽然提高了抓取的保守稳定性，却极大限制了抓取构型在物体表面的分布，导致灵活性不足。

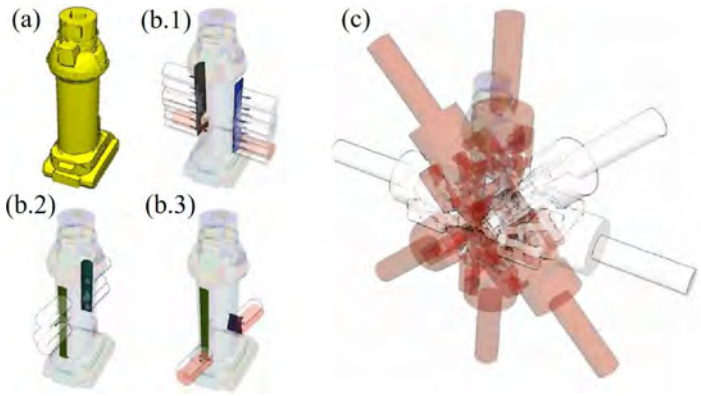


图 1.7 基于表面分割的抓取规划方法[21]：(a) 物体模型；(b.1-3) 表面分割结果；(c) 抓取构型生成

Figure 1.7 Grasp planning method based on surface segmentation[21]: (a) Object model; (b.1-3) Surface segmentation results; (c) Grasp configuration generation.

另一方面，基于学习的方法利用神经网络和数据驱动技术来增强抓取的泛化能力。Mahler 等人提出的 Dex-Net[23,46] 系列构建了大规模的合成抓取数据集，训练卷积神经网络（Convolutional Neural Network, CNN）模型 GQ-CNN 直接从深度图像中预测平面抓取的成功率。Mousavian 等人[47] 则提出了六自由度（six degrees of freedom, 6-DOF）GraspNet，通过基于变分自编码器（VAE）的框架生成多样化的 6 自由度抓取构型。该方法利用抓取评价或精炼网络对候选进行评分并迭代优化，以提高抓取

的稳定性与可执行性；最终结合碰撞检测等几何约束过滤不可行抓取，实现对复杂物体的多样化 6D 抓取构型生成。

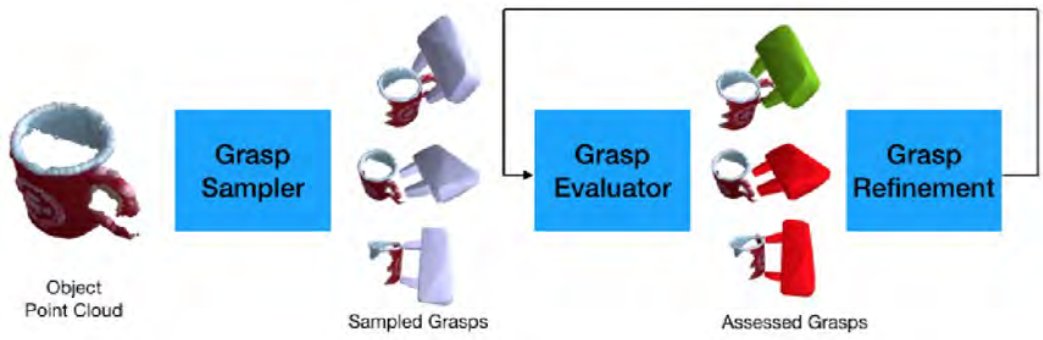


图 1.8　基于变分自编码器的 6-DOF 抓取生成方法[47]

Figure 1.8　6-DOF grasp generation method based on variational autoencoder[47].

尽管这些方法在未见过物体上表现出色，但其训练数据通常是基于传统解析指标（如 GraspIt! 中的能量函数）生成的[48]。因此，数据驱动模型倾向于继承“排斥边缘”的偏见，将边缘和角点视为噪声或不稳定区域，从而难以生成涉及这些尖锐特征的多样化抓取[46,49]。本文提出的方法打破了这一局限，引入软接触模型，将潜在的稳定接触扩展到边缘和角点。通过开发包含边缘和角点接触的抓取规划算法，旨在显著增加抓取分布的覆盖率和灵活性。

2） 抓取质量评估

为了评估抓取候选的可行性和质量，研究者提出了多种抓取评价标准。最常用的解析指标是抓取稳定性，通常通过力封闭（Force Closure）或形封闭（Form Closure）条件进行评估[28]。解析方法通过评估旋量空间覆盖率（Wrench Space Coverage）、抗扭矩能力或最小力需求来确定抓取的可靠性。Ferrari 和 Canny[50] 提出了经典的 ϵ 指标，通过计算抓取矩阵在旋量空间中张成的最大球半径（L_2 范数）或最大多胞体体积（L_1 / L_∞ 范数）来量化抓取抵抗外部扰动的能力。然而，这些解析指标通常假设刚性接触，对于边缘和角点这类理论上接触面积为零的区域，往往给出极低的稳定性评分。

相比之下，数据驱动方法通常训练模型直接从视觉或几何输入预测抓取质量评分。Ten Pas 等人提出的 GPD（Grasp Pose Detection）算法[51] 则直接在三维点云中采样候选抓取，并对物体点云进行投影，利用 CNN 网络评估其抓取质量。Liang 等人则对 GPD 的抓取质量评估网络进行了改进，提出了基于 PointNet++ 的 PointNetGPD[52]，

通过引入多尺度特征融合和注意力机制来提升评估的准确性和鲁棒性，并且无需对点云进行投影。

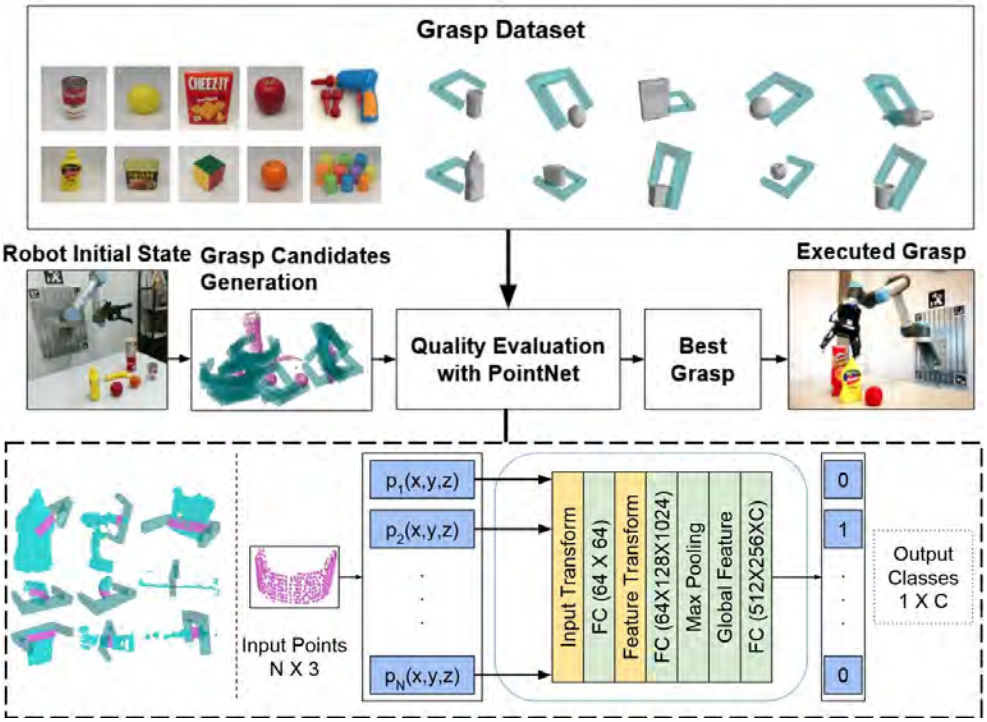


图 1.9　基于深度学习的抓取质量评估方法 PointNetGPD[52]

Figure 1.9　PointNetGPD: Grasp Pose Detection method based on deep learning[52].

近期，Yu 等人[53] 和 Cao 等人[49] 引入了更先进的深度网络架构来捕捉抓取区域的全局上下文信息，进一步提升了评估的准确性。虽然这些学习模型可能缺乏如力封闭等形式化保证，但它们在非结构化和实时环境中表现出了卓越的适应性。此外，一些混合方法结合了解析指标与数据驱动模型，以增强泛化能力和鲁棒性[54]。

值得注意的是，现有的大多数评价指标主要关注单个抓取构型的成功率或稳定性，而缺乏对规划器生成的抓取解集在物体表面空间分布情况的量化评估。针对这一问题，本文引入了一种基于统计熵的指标，用于量化抓取构型的分布均匀性，并作为抓取灵活性的代理指标。该指标能够对不同规划器在抓取灵活性方面进行定量且直观的比较，而不受其选择接触区域优先级的差异影响。

1.3　本文主要研究内容

针对物体几何特征检测中存在的角点识别困难、检测精度不足的问题，以及机器人抓取规划中因过分依赖面接触而导致的抓取灵活性受限问题，本文开展了系统

性的研究工作。本文的核心目标是建立一套从高精度几何感知到灵活多模式抓取规划的完整技术方案。本文的主要研究内容包括以下两个方面：

第一，本文提出了一种基于多尺度局部特征融合的点云边缘与角点检测流程框架（NECDNet）。针对现有方法在角点检测上的缺失，该研究设计了一套包含曲率、投影距离、法向分布等六个维度的解析特征描述符，专门用于捕捉稀疏且模糊的角点信号。通过构建多尺度邻域特征矩阵作为输入，并设计基于多层感知机（Multi Layer Perceptron, MLP）的层次化分类网络，该方法实现了对点云中面、边缘、角点三类特征的高精度端到端识别。如图 1.10 所示，较其余方法，该网络不仅保持了边缘检测的高性能，更显著提升了角点检测的准确率。

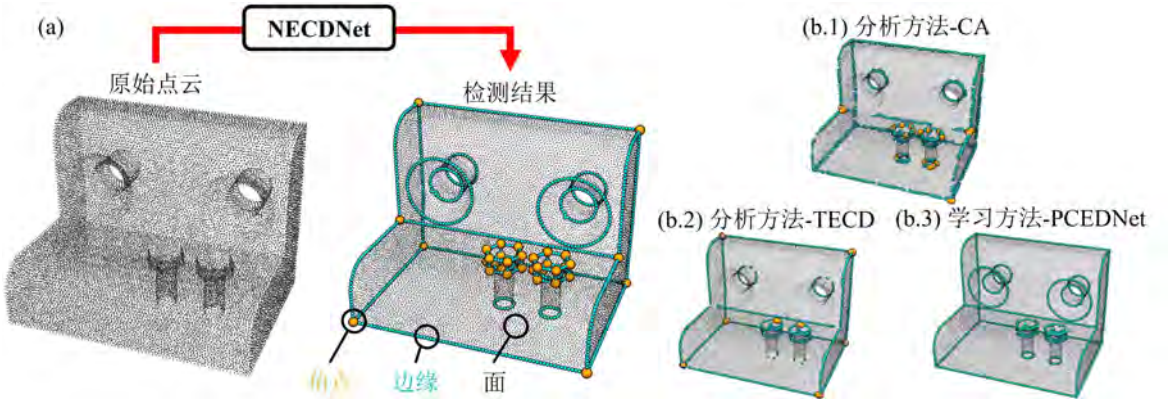


图 1.10 不同几何特征检测方法结果对比：(a) NECDNet；(b.1-3) CA[7], TECD[6], PCEDNet[12]
Figure 1.10 Comparison of geometric feature detection results: (a) NECDNet; (b.1-3) CA[7], TECD[6], PCEDNet[12].

其中，为了解决深度学习方法在几何特征检测领域面临的训练数据匮乏问题，本文构建了 ABC-Corner 基准数据集。该数据集从大规模 CAD 模型库 ABC 数据集中精选了 1000 个具有丰富几何细节的代表性模型。通过结合基于几何规则的自动初筛算法与人工精细交互修正的标注流程，生成了包含面、边缘、角点三类高精度标签的点云数据。该数据集填补了领域内缺乏专门针对角点检测的大规模公开数据集的空白，为后续的数据驱动算法研究提供了可靠的基准。

第二，本文提出了一种考虑边缘和角点接触的六自由度机器人抓取规划算法。该算法突破了传统面接触优先的规划范式，将边缘和角点纳入可行的接触候选区域。算法利用提取的几何特征进行类别感知的均衡采样，并针对面、边、角三种不同特征分别设计了圆柱形、扇形和圆锥形接触检测器，以高效搜索潜在的对指抓取配对。通过引入基于离散化的软指接触模型，实现了对边缘和角点接触稳定性的有效评估。此

外，本文还首次引入了抓取分布统计指标来量化评估抓取规划的灵活性。如图 1.11 展示了该算法生成的抓取构型，实验结果证明，该方法在正四面体、非对称曲面等复杂物体上实现了极高的抓取成功率和空间覆盖率。

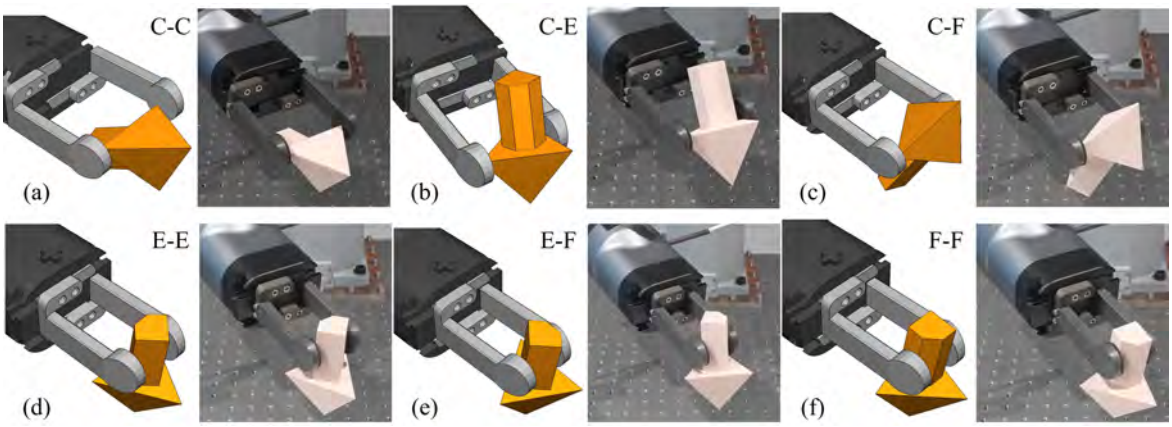


图 1.11 基于物体几何特征的抓取规划结果展示：(a-f) 针对三种几何特征实现的六种抓取构型，依次为：角-角，角-边，角-面，边-边，边-面，面-面
Figure 1.11 Grasp planning results based on object geometric features: (a-f) Six grasp configurations for three geometric features, including C-C, C-E, C-F, E-E, E-F, and F-F.

综上所述，本文的主要创新点可以归纳为以下三个方面：

（1）提出了一种融合显式几何描述符与数据驱动的基于物体点云的几何特征检测网络（NECDNet）。通过引入多尺度显式几何特征描述符，解决了纯数据驱动方法在稀疏角点检测上的特征模糊问题，实现了对面、边缘和角点的高精度同步检测。

（2）构建了包含高精度角点标注的大规模点云几何特征数据集（ABC-Corner）。针对现有数据集缺乏角点标注的问题，建立了一套半自动化的精细标注流程，为几何特征检测领域提供了高质量的数据基准。

（3）提出了一种基于软接触模型并融合边缘与角点接触的抓取规划算法。该算法突破了传统面接触优先假设，针对不同几何特征设计了专门的抓取构型检测策略，并引入抓取分布统计指标以量化评估抓取灵活性，同时采用软接触模型进行抓取稳定性评估，从而显著提升了机器人在复杂物体抓取任务中的灵活性和空间覆盖率。

1.4 论文组织结构

本文共分为六章，各章节的具体内容安排如下：

第一章为绪论，主要阐明点云几何特征检测与机器人抓取规划的研究背景和工

程意义，系统梳理国内外相关研究进展，分析现有方法在角点检测精度与抓取灵活性方面的不足，并据此明确本文的研究目标、技术路线与主要创新点。

第二章围绕点云几何特征检测方法展开，重点介绍 NECDNet 的整体框架与实现过程，包括多尺度 k 近邻邻域构建、六维显式几何描述符设计以及基于多层感知机的层次化分类结构。

第三章在上述方法基础上开展实验评估，首先给出 ABC-Corner 数据集的构建流程，为后续实验提供数据基础。之后通过与主流方法的定性和定量对比验证 NECDNet 在边缘与角点检测任务中的性能优势，并结合消融实验进一步分析特征维度、网络模块及法向量估计精度对结果的影响。

第四章进一步面向机器人抓取规划问题，提出一种考虑边缘与角点接触的六自由度抓取规划方法，系统介绍类别感知采样、面/边/角接触检测器设计、接触对构建与软接触稳定性评估等关键环节，形成从几何特征到抓取构型生成的完整流程。

第五章对所提抓取规划方法进行实验验证，分别从仿真与真实物理实验两个层面评估其性能，并通过抓取分布统计指标、抓取成功率指标与对比方法进行综合分析，验证方法在复杂几何物体上的有效性与实用性。最后分析了算法计算效率。

第六章对全文工作进行总结，归纳本文在物体几何特征检测与机器人抓取规划两方面的主要贡献，客观讨论当前方法的局限，并结合机器人操作场景的发展需求给出后续研究方向与改进思路。

第二章　基于多维特征融合的物体几何特征检测

2.1　引言

物体几何特征检测（如边缘和角点提取）是三维视觉领域的关键环节，在模型重建、物体识别及机器人抓取规划中具有重要作用[1]。传统方法主要依赖局部几何描述符（如曲率、法向量偏差等）并结合人工设置的阈值进行判别。然而，由于点云数据普遍存在噪声干扰、采样密度不均以及边缘与角点定义模糊等问题，此类方法往往难以同时兼顾检测精度与鲁棒性[7-8,36]。

为了解决边缘与角点特征难以区分的问题，本章提出了一种名为NECDNet（Neural Edge and Corner Detection Network）的深度学习架构。该方法通过融合统计特征描述符与轻量级神经网络，利用多尺度邻域分析来捕捉点云局部的空间分布和法向量变化特征，并利用网络进行学习，从而实现对物体点云中面点（Face points）、边缘点（Edge points）和角点（Corner points）的高精度同步分类。

图 2.1 展示了 NECDNet 的工作流程。NECDNet 由两个主要部分组成：多尺度局部特征矩阵计算和基于神经网络的分类器。流程输入为非结构化点云，输出为面点、边缘点和角点的逐点分类结果。在多尺度特征计算阶段，本文针对每个查询点构建包含四个不同尺度邻域的特征矩阵，并在每个尺度下计算六种解析特征：曲率、投影距离均值、中心偏离比、法向角度差、法向分布方差和法向投影距离均值。最终形成 4×6 的多尺度特征矩阵，作为神经网络输入。在分类器阶段，本文基于多层感知机（MLP）设计层次化网络结构，通过逐层融合多尺度特征，学习从特征矩阵到几何类别的映射关系，输出三类几何特征的概率得分，从而实现面、边缘和角点的同步检测。

图中左上为输入点云，每次选择一个查询点及其邻域（绿色）。其中，不同的 k 值对应不同尺度的邻域大小（黄色点数量）。通过计算各尺度下的六维特征，形成多尺度特征矩阵并输入神经网络进行分类，最终输出查询点所属几何类别（面、边缘或角点）。通过循环遍历各查询点，可完成整个点云的物体几何特征检测任务，得到图中左下所示结果。

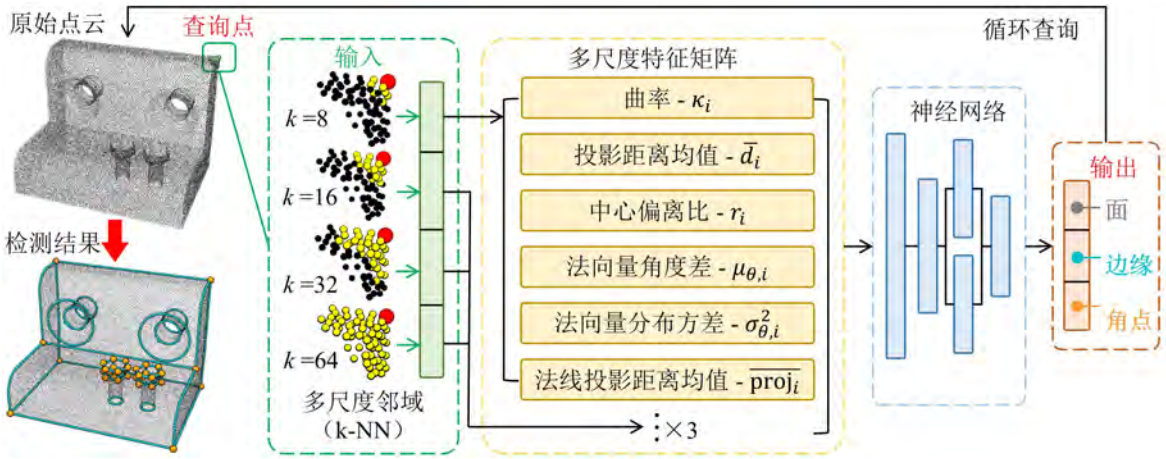


图 2.1　NECDNet 架构及工作流程示意图

Figure 2.1　NECDNet architecture and workflow diagram.

2.2　逐点邻域构建及前处理

非结构化的三维点云只包含点的空间坐标信息，缺乏拓扑连接关系，因此需要通过邻域构建方法为每个点建立局部几何关系。邻域构建是点云特征提取的基础步骤，它决定了后续几何特征计算的准确性和稳定性。本节首先介绍基于 k 近邻（k-Nearest Neighbors, k-NN）的邻域构建方法，该方法能够自适应地处理点云的非均匀分布特性，并通过 KD-树索引结构实现高效的邻域检索。随后，针对构建的邻域进行归一化预处理，消除点云的绝对位置、平移和尺度差异对特征计算的影响。此外，本节还介绍了基于主成分分析（PCA）的法向量估计方法，为后续的方向特征计算奠定基础。

2.2.1　邻域构建策略

为了有效描述点云中每个查询点的局部几何特性，需要首先确定其邻域范围。本文采用基于距离度量的 k-NN 方法为每个查询点构建邻域[55]。k-NN 是一种基于距离度量的邻域选择方法，通过计算查询点与其他点之间的欧氏距离，选取距离最近的 k 个点作为邻域。与固定半径（radius-based）邻域相比，即将距离查询点一定距离内的点作为邻域，k-NN 对点云非均匀采样与稀疏区域更加稳健：在稠密区不会过采样、在稀疏区不会因样本不足而破坏特征稳定性。对于非结构化的点云，其只包含点的三维坐标信息，k-NN 方法能够有效适应点云的稀疏性和不均匀分布特性。

为提升检索效率，给定一个非结构化点云 $\mathcal{P}^c$，其定义如公式 (2.1) 所示。本文在三维坐标空间上构建 KD 树（k-dimensional tree）索引[56]。KD 树通过在各坐标轴上递归划分点集，使每个节点对应一个超矩形子空间，从而形成近似平衡的二叉树。

查询时，先依据查询点坐标自顶向下定位至叶节点，再在回溯过程中检查可能包含更近邻点的分支，并维护容量为 k 的候选集合以持续更新最近邻。相比暴力检索的 $O(n)$ 复杂度，KD 树可将单次最近邻查询的平均复杂度降至 $O(\log n)$，显著提升大规模点云处理效率。

$$\mathcal{P}^{\mathrm{c}} = \{\mathbf{p}_i^{\mathrm{c}} \mid i = 1, \ldots, n\} \tag{2.1}$$

基于上述索引结构，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，通过 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}}$，其定义如公式 (2.2) 所示。通过调节 k 的大小即可改变邻域空间尺度：较小的 k 更敏感于细粒度几何细节，较大的 k 则能稳健表征更大范围的局部结构。邻域构建完成后，即可在此基础上进行几何特征计算与提取。

(2.2)

2.2.2 点云前处理

为了消除点云绝对坐标、平移以及尺度差异对特征计算的影响，在提取特征前，本文首先对邻域 $\mathcal{Q}_i^{\mathrm{c}}$ 进行归一化处理。该过程同样基于 PCA 思想，计算邻域点的协方差矩阵 $\mathbf{K}_i = \mathrm{cov}(\mathcal{Q}_i^{\mathrm{c}})$，并对其进行奇异值分解（Singular Value Decomposition, SVD），如公式 (2.3) 所示[57]。

$$\mathbf{K}_i = \mathbf{U}_i \mathbf{\Sigma}_i \mathbf{V}_i^T \tag{2.3}$$

其中，$\mathbf{U}_i$ 和 $\mathbf{V}_i$ 分别为左奇异向量矩阵和右奇异向量矩阵，$\mathbf{\Sigma}_i$ 为对角奇异值矩阵。通过该分解，能够获得邻域点在主方向上的分布特性。具体而言，通过对角矩阵 $\mathbf{\Sigma}_i$ 提取奇异向量 $\boldsymbol{\sigma}_i = (\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3})$，其中的奇异值计为降序排列。右奇异向量矩阵 $\mathbf{V}_i$ 的列向量对应于邻域点在三个主方向上的投影轴。不同的奇异值反映了邻域点在各主方向上的扩展程度。奇异值较小的方向点云分布较为集中，反之则较为分散。图 2.2 展示了三种几何特征邻域点云的 PCA 分解示意图，其中不同颜色的线段表示对应于不同奇异值的主轴方向及占比。

通过上述分解结果，可以对邻域点进行去中心化与尺度归一化处理。具体而言，

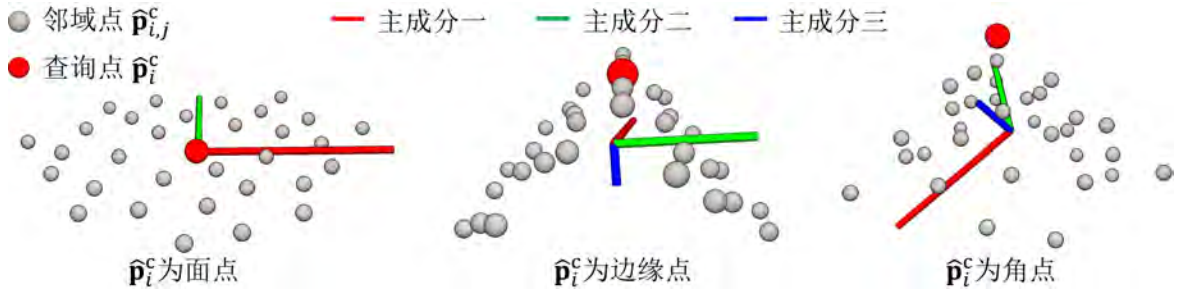


图 2.2　不同几何特征邻域点云的 PCA 分解示意图

Figure 2.2　PCA decomposition of neighbor region with different geometric features.

首先计算邻域点的质心 $\bar{\mathbf{p}}_{i,j}^{c}$，如公式 (2.4) 所示。其中，$|\mathcal{Q}_i^c|$ 表示邻域点数量。

$$\bar{\mathbf{p}}_{i,j}^{c} = \frac{1}{|\mathcal{Q}_i^c|} \sum_{j=1}^{k} \mathbf{p}_{i,j}^{c} \tag{2.4}$$

随后，将所有邻域点坐标减去质心实现去中心化，并利用奇异值 $\sigma_{i,1}$ 和 $\sigma_{i,2}$ 对去中心化后的邻域点进行尺度缩放，确保各个方向上的分布具有统一量纲，如公式 (2.5) 所示。最终，得到归一化后的邻域 $\hat{\mathcal{Q}}_i^c$，为后续特征计算提供标准化输入。归一化邻域后的查询点坐标记为 $\hat{\mathbf{p}}_i^c$，邻域中的点坐标记为 $\hat{\mathbf{p}}_{i,j}^c$。

$$\hat{\mathcal{Q}}_i^c = \left\{ \frac{2}{\sqrt{\sigma_{i,1}} + \sqrt{\sigma_{i,2}}} \left(\mathbf{p}_{i,j}^{c} - \bar{\mathbf{p}}_{i,j}^{c} \right) \mid \mathbf{p}_{i,j}^{c} \in \mathcal{Q}_i^c \right\} \tag{2.5}$$

2.2.3　法向量估计与定向

法向量是描述点云局部表面方位的重要几何属性，也是计算后续方向特征的基础。本文采用基于局部平面拟合的方法估计查询点的法向量。从公式 (2.3) 的奇异值分解结果中可知，奇异值 $\sigma_{i,1}, \sigma_{i,2}, \sigma_{i,3}$ 对应的右奇异向量（即矩阵 $\mathbf{V}_i$ 的列向量）构成了邻域内点集分布的正交主轴。由于奇异值按降序排列，最小奇异值 $\sigma_{i,3}$ 对应的奇异向量 $\mathbf{v}_{i,3}$ 指向了邻域内点集分布方差最小的方向。在几何意义上，该方向与局部最小二乘拟合平面的法向重合。因此，查询点的法向量 $\mathbf{n}_i^c$ 可根据归一化后的右奇异向量 $\mathbf{v}_{i,3}$ 得出。

然而，仅通过 PCA 获得的法向量存在 180° 的方向模糊性（即法向量可能指向物体内侧或外侧）。为了确保在计算后续法向量夹角差异等特征时的数值一致性，必须对法向量进行定向处理。在处理具有闭合表面的物体时，通常利用视点方向或邻域一致性进行约束。本文采用最小生成树（Minimum Spanning Tree, MST）算法在点云图中传播法向量方向，以实现全局的方向一致化[58]。具体而言，将点云视为图结构，

以点间距离为边权构建图，从初始点开始，通过遍历图确保相邻点的法向量满足内积大于零的约束，实现对点云中各点法向量的方向一致化。最终得到的法向量 $\mathbf{n}_i^c$ 既具有准确的方向信息，又消除了模糊性，为后续特征计算提供了可靠的基础。

基于 PCA 的法向量估计方法具有计算效率高、实现简单的优点，能够在大规模点云数据中快速获得局部表面方向信息。然而，当查询点位于边缘或角点等尖锐特征附近时，其邻域点分布通常不规则，容易导致法向量估计不稳定并降低估计精度。当点云对应 CAD 网格可用时，可直接利用网格面片法向量获取查询点法向，从而缓解上述问题。图 2.3 展示了基于 PCA 和基于 CAD 网格模型的法向量估计结果，其中基于 PCA 的方法在靠近尖锐特征的区域会显示出偏斜的法向。在后续实验章节 三 中，本文将训练两个模型：一个使用基于 PCA 的法向量估计结果作为输入特征，另一个使用 MeshLab 基于原始 CAD 网格模型进行法向量估计[59]。通过对比两个模型的检测性能，验证法向量估计精度对边缘与角点检测结果的影响。

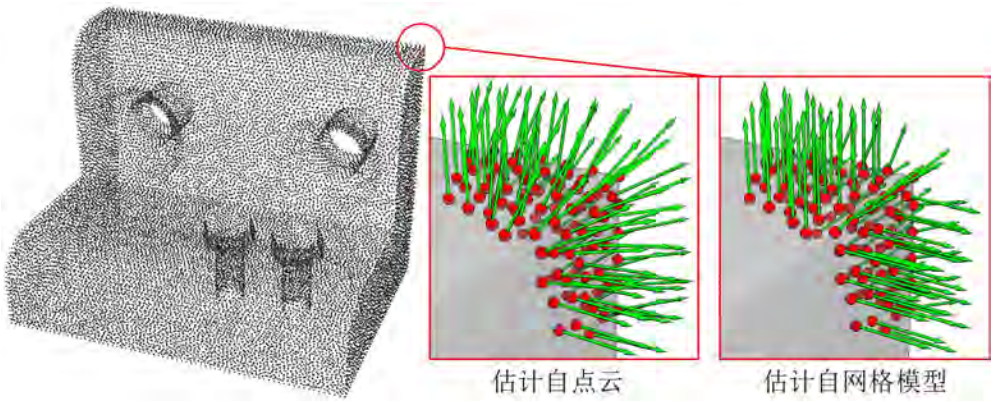


图 2.3　估计自原始点云及网格模型的部分点云法向量示意图

Figure 2.3　Normal vectors estimated from point cloud and mesh model.

2.3　多尺度局部特征提取与计算

在完成邻域构建和前处理后，本节将重点介绍如何在多尺度邻域框架下提取和计算局部几何特征。多尺度表示的是针对每个查询点，选择不同数量的邻域点以构建多层次的局部几何描述。由于点云捕获时的视角、距离及分辨率等因素影响，单一尺度往往难以全面反映局部几何结构的信息。通过分析不同尺度下的点云分布特征，可以更全面地捕捉局部几何结构，从而提升边缘和角点的区分能力[12]。

适用的尺度取决于多个因素：物体大小、形状复杂度、点云密度、观察尺度等。

为了使训练得到的模型能泛化处理未知物体的情况，本文为输入点云中的每个查询点在多尺度邻域内计算多个特征，并在章节 3.5 中进行了消融实验确保各个尺度选择的合理性。本节首先介绍多尺度特征矩阵的构建策略，随后详细阐述六种局部几何特征描述符的设计与计算方法，最后通过数值可视化分析验证所选特征的有效性。

2.3.1 多尺度特征矩阵构建

为兼顾不同尺度的几何信息，本文针对多个 k 值为同一查询点构建多组邻域，形成多尺度邻域表示。具体而言，对每个查询点 $\mathbf{p}_i^{\mathrm{c}}$，通过前一节介绍的 k-NN 方法在点云中搜索其 k 个最近邻点，形成邻域集合 $\mathcal{Q}_i^{\mathrm{c}} = \{\mathbf{p}_{i,j}^{\mathrm{c}} \mid j = 1, \ldots, k\}$。通过调节 k 的大小即可改变邻域的空间尺度：较小的 k 更敏感于细粒度几何细节（如尖锐小角、细薄边），较大的 k 则能稳健表征更大范围的局部结构。

对由给定 k 值确定的局部区域 $\mathcal{Q}_i^{\mathrm{c}}$ 计算六个解析特征，得到 6 维特征向量 $\mathbf{x}_i^{\mathrm{c}}$。当为同一查询点在多个 k 值下重复上述过程，即可获得对应的 $\mathbf{x}_{i,k}^{\mathrm{c}}$。将这些特征按尺度汇集，构成用于后续网络学习的多尺度特征矩阵，如公式 (2.6) 所示：

$$\mathbf{X}_i^{\mathrm{c}} = \begin{bmatrix} \mathbf{x}_{i,k_1}^{\mathrm{c}} \\ \mathbf{x}_{i,k_2}^{\mathrm{c}} \\ \vdots \\ \mathbf{x}_{i,k_m}^{\mathrm{c}} \end{bmatrix} \tag{2.6}$$

其中，$k_1, k_2, \ldots, k_m$ 表示所选择的不同邻域尺度，m 为尺度数量。多尺度特征矩阵中的尺度数 m 和尺度大小 k 直接影响神经网络的学习结果。具体来说，k 影响结果对点云不同稀疏度的适用性，而 m 影响网络学习数据的维度。选择合适的尺度尺寸和数量可以优化检测精度。因此，在章节 3.5 中，本文对邻近尺度选择进行了消融实验以确定参数，并最终选择了 k 的四个值：8、16、32 和 64 进行特征计算。这种多尺度策略能够在保证计算效率的同时，充分捕捉从局部细节到全局结构的几何信息。

2.3.2 局部特征描述符设计

在构建多尺度邻域的基础上，本文进一步设计了一套包含六个维度的局部几何特征描述符，旨在精确捕捉查询点及其邻域在不同空间尺度下的结构属性。这六种特征可归纳为基于位置的几何特征与基于法向量方向的特征两大类。基于位置的特

征主要通过分析邻域点的空间分布规律来描述局部形状，而基于法向量的特征则通过分析表面方向的连续性与一致性，提供关于几何边缘与尖锐角点的关键判别信息。这种多维特征的结合，增强了模型在面对复杂、模糊边界时的区分能力。消融实验中对特征计算中涉及的所有描述符进行了评估，说明了该选择的有效性。

1） 曲率（κ_i）

首先计算基于位置的几何特征，表征邻域内点的几何分布特性。曲率 κ_i 是几何物体偏离平面程度的度量。在本文中，查询点邻域曲率可根据上述奇异值计算，用于表征局部表面的平坦程度。具体而言，曲率定义为最小奇异值与三维奇异值之和的比值，如公式 (2.7) 所示。

$$\kappa_i = \frac{\sigma_{i,3}}{\sigma_{i,1} + \sigma_{i,2} + \sigma_{i,3}} \tag{2.7}$$

当查询点位于平坦表面时，$\sigma_{i,3}$ 较小，曲率值接近于零；而当查询点位于尖锐边缘或角点时，$\sigma_{i,3}$ 较大，曲率值相应增大，如图 2.2 所示。因此，曲率特征有助于区分面点与边缘、角点。

2） 投影距离均值（$\bar{d}_i$）

投影距离均值 $\bar{d}_i$ 用于刻画查询点邻域内点相对于该点法向平面的空间分布，其大小反映了局部几何结构的突变程度。具体地，对于任一查询点 $\hat{\mathbf{p}}_i^{\mathrm{c}}$，结合其法向量 $\mathbf{n}_i^{\mathrm{c}}$ 可定义通过该点的投影平面。邻域内所有点 $\hat{\mathbf{p}}_{i,j}^{\mathrm{c}}$ 到该投影平面的距离均值即为 $\bar{d}_i$，计算公式如 (2.8) 所示。

$$\bar{d}_i = \frac{1}{|\hat{\mathcal{Q}}_i^{\mathrm{c}}|} \sum_{\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} \in \hat{\mathcal{Q}}_i^{\mathrm{c}}} \left| (\hat{\mathbf{p}}_{i,j}^{\mathrm{c}} - \hat{\mathbf{p}}_i^{\mathrm{c}}) \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.8}$$

图 2.4展示了该距离度量的几何意义。其反映了邻域点在查询点法向方向上的分布特性：当邻域点主要分布在查询点法向平面附近时，投影距离较小，表明局部几何结构较为平滑；而当邻域点在法向方向上分布较为分散时，投影距离增大，通常对应于边缘或角点区域。

3） 中心偏离比（r_i）

中心偏离比 r_i 是量化查询点在其局部邻域内的相对空间位置的度量，其能够衡量查询点相对于其邻域质心的偏移程度。具体而言，首先计算邻域点的质心，由于

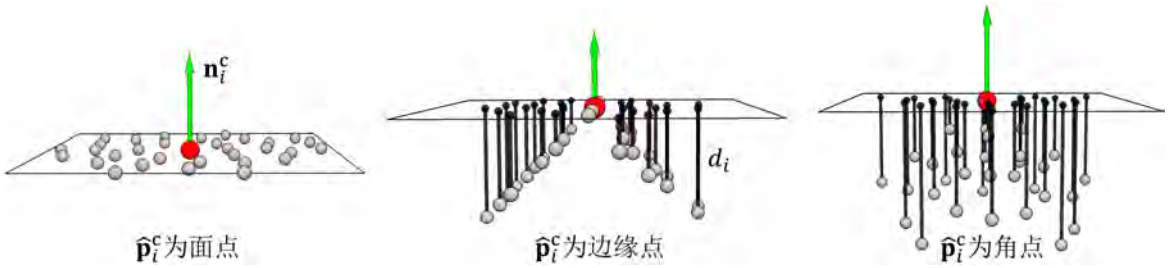


图 2.4　投影距离均值的几何意义示意图

Figure 2.4　Geometric significance diagram of mean projectional distance.

此时的邻域 $\hat{\mathcal{Q}}_i^c$ 已经进行了去中心化及归一化处理，因此邻域质心即为原点。之后计算查询点到质心的距离 $\|\hat{\mathbf{p}}_i^c\|$ 与邻域内各点到质心距离 $\|\hat{\mathbf{p}}_{i,j}^c\|$ 的最小值之比，得到中心距离均值比 r_i，计算公式如 (2.9) 所示，由于该特征为比值，当分母较小时产生的结果不受此前归一化邻域的影响。故针对特征 r_i，本文选用 Sigmoid 函数对其进行标准化处理，以减小数值分布的变化范围。

$$r_i = \text{Sigmoid}\left(\frac{\|\hat{\mathbf{p}}_i^c\|}{\min_{\hat{\mathbf{p}}_{i,j}^c \in \hat{\mathcal{Q}}_i^c} \|\hat{\mathbf{p}}_{i,j}^c\|}\right) \tag{2.9}$$

其中 Sigmoid 表示 Sigmoid 函数，$\|\cdot\|$ 表示欧氏距离，min 运算符用于获取邻域点中距离质心最近的点的距离，式中省略了减去质心零向量的表示。如图 2.5 所示，中心偏离比 r_i 反映了查询点在邻域内的相对位置关系：当查询点位于邻域质心附近时，r_i 的分子 $\|\hat{\mathbf{p}}_i^c\|$ 值较小，表明该点可能位于平坦区域；而当查询点远离邻域质心时，同理通常对应于边缘或角点区域。因此，中心偏离比有助于区分不同几何特征。

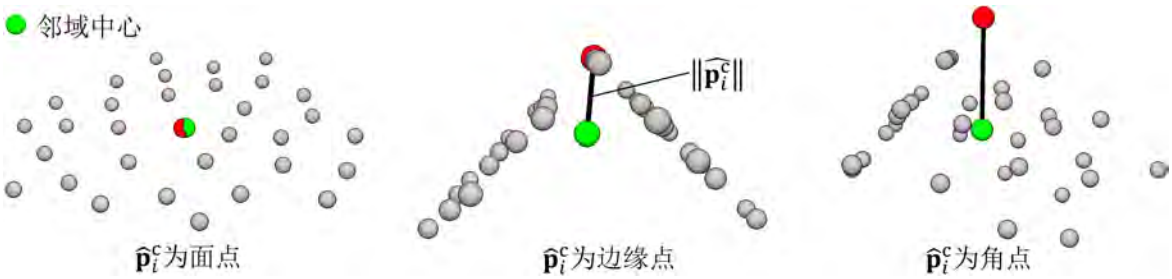


图 2.5　中心偏离比的几何意义示意图

Figure 2.5　Geometric significance of center bias.

4）法向量角度差（$\mu_{\theta,i}$）

以此特征描述符开始，后续的三个描述符是基于法向量方向的特征，旨在捕捉表面方向的突变信息。如图 2.6 所示，在光滑面区域，邻域内法向量的分布较为集中，

且与查询点法向量高度一致；而在边缘区域，邻域内法向量的分布较为分散，与查询点法向量存在较大夹角，角点区域更甚。因此，通过分析邻域内法向量与查询点法向量之间的关系，可以有效区分不同几何特征。

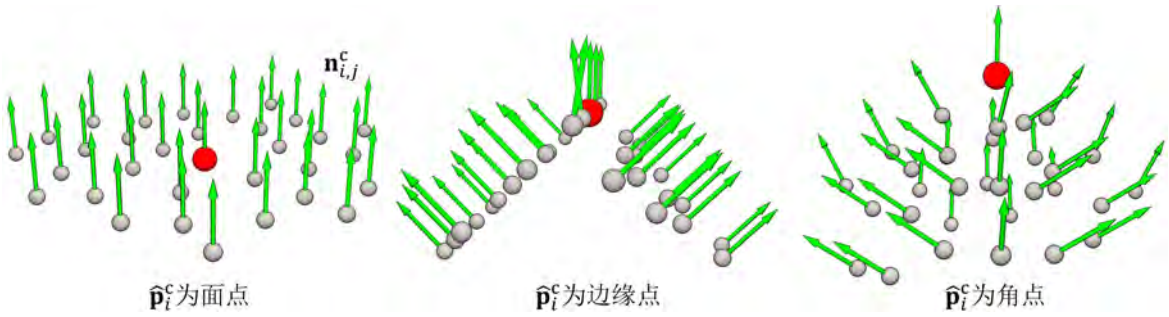


图 2.6　不同几何特征邻域点云的法向量分布示意图

Figure 2.6　Normal vector distribution of neighbor region with different geometric features.

法向角度差 $\mu_{\theta,i}$ 衡量查询点法向量与其邻域内各点法向量之间夹角的平均值，反映了局部表面方向的一致性。具体而言，首先根据章节 2.2.3 中的方法估计邻域内每个点的单位法向量 $\mathbf{n}_{i,j}^{c}$，组合为 $\mathcal{N}_i^c$。随后，计算查询点法向量 $\mathbf{n}_i^c$ 与邻域内各点法向量之间的夹角 $\theta_{i,j}$ ，最后并求各个夹角的平均值，求解公式如 (2.10) 所示。

$$\begin{cases} \theta_{i,j} = \arccos\left(\mathbf{n}_i^c \cdot \mathbf{n}_{i,j}^c\right) \\ \mu_{\theta,i} = \dfrac{1}{|\mathcal{N}_i^c|}\displaystyle\sum_{j=1}^{|\mathcal{N}_i^c|}\theta_{i,j} \end{cases} \tag{2.10}$$

其中，arccos 表示反余弦函数。法向角度差 $\mu_{\theta,i}$ 反映了邻域内法向量的方向变化程度：当邻域内法向量与查询点法向量高度一致时，$\mu_{\theta,i}$ 值较小，表明局部表面较为平滑；而当邻域内法向量与查询点法向量差异较大时，$\mu_{\theta,i}$ 值增大，通常对应于边缘或角点区域。

此外，除了采用法向量夹角刻画方向变化外，也可直接使用法向量的数值差异进行表征。具体而言，计算查询点法向量与邻域内各点法向量的差值并求其均值，得到法向量数值差 $\bar{\Delta\mathbf{n}}_i$，计算公式如 (2.11) 所示。相较于法向量角度差 $\mu_{\theta,i}$，法向量数值差 $\bar{\Delta\mathbf{n}}_i$ 直接基于原始法向量进行统计，后续消融实验将比较两者的效果差异。

$$\bar{\Delta\mathbf{n}}_i = \frac{1}{|\mathcal{N}_i^c|}\sum_{\mathbf{n}_{i,j}^c \in \mathcal{N}_i^c}\left(\mathbf{n}_i^c - \mathbf{n}_{i,j}^c\right) \tag{2.11}$$

5） 法向量分布方差（$\sigma_{\theta,i}^2$）

法向量分布方差 $\sigma_{\theta,i}^2$ 用于量化邻域内法向量夹角的变化剧烈程度，反映了局部表面方向的稳定性。具体而言，基于前述计算的法向角度差 $\mu_{\theta,i}$，计算邻域内各点法向量与查询点法向量夹角的方差，求解公式如 (2.12) 所示。

$$\sigma_{\theta,i}^2 = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{j=1}^{|\mathcal{N}_i^{\mathrm{c}}|} (\theta_{i,j} - \mu_{\theta,i})^2 \tag{2.12}$$

法向量分布方差 $\sigma_{\theta,i}^2$ 反映了邻域内法向量变化的剧烈程度：当邻域内法向量夹角较为集中时，$\sigma_{\theta,i}^2$ 值较小，表明局部表面方向较为稳定；而当邻域内法向量夹角分布较为分散时，$\sigma_{\theta,i}^2$ 值增大，通常对应于边缘或角点区域，而角点区域的分散程度更为显著。

6） 法线投影距离均值（$\bar{\mathbf{proj}}_i$）

法线投影距离均值 $\bar{\mathrm{proj}}_i$ 用于量化邻域点法向量在查询点法向上的投影强度，反映了表面法向的对齐程度。具体而言，计算邻域内每个点法向量 $\mathbf{n}_{i,j}^{\mathrm{c}}$ 在查询点法向 $\mathbf{n}_i^{\mathrm{c}}$ 上的投影长度，并求其平均值，计算公式如 (2.13) 所示。

$$\bar{\mathrm{proj}}_i = \frac{1}{|\mathcal{N}_i^{\mathrm{c}}|} \sum_{\mathbf{n}_{i,j}^{\mathrm{c}} \in \mathcal{N}_i^{\mathrm{c}}} \left| \mathbf{n}_{i,j}^{\mathrm{c}} \cdot \mathbf{n}_i^{\mathrm{c}} \right| \tag{2.13}$$

由于各点的法向量均为单位向量，法线投影距离均值 $\bar{\mathrm{proj}}_i$ 可以反映邻域内法向量与查询点法向量的对齐程度：$\bar{\mathrm{proj}}_i$ 值较大，表明局部表面方向较为统一；而当邻域内法向量与查询点法向量差异较大时，$\bar{\mathrm{proj}}_i$ 值减小，通常对应于边缘或角点区域。

2.3.3 局部特征描述符数值可视化分析

通过上述计算的局部特征描述符，本文最终选择其中六个组成特征描述向量，并用于后续特征融合和分类任务。最终特征向量如公式 (2.14) 所示。六个特征均为标量，特征向量维度为 6，包含点云的位置分布特性和法向量变化信息，能够有效表征局部几何结构属性。

$$\mathbf{x}_i^{\mathrm{c}} = \left(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma_{\theta,i}^2, \bar{\mathrm{proj}}_i \right) \tag{2.14}$$

图 2.7 对单个物体点云的六个特征进行了空间分布可视化。每个子图分别显示了特征描述符 κ_i（曲率）、$\bar{d}_i$（投影距离均值）、r_i（中心偏离比）、$\mu_{\theta,i}$（法向量角度

差）、$\sigma^2_{\theta,i}$（法向量分布方差）、$\bar{\text{proj}}_i$（法向投影距离均值）在点云空间上的数值分布情况。颜色表示数值大小，采用从蓝色（低值）到红色（高值）的渐变色带。根据上一小节对各特征的定义，可以观察到：除了特征 $\bar{\text{proj}}_i$ 外，其他五个特征在面、边缘和角点区域均表现出从低到高的数值变化趋势（蓝色到红色）。而特征 $\bar{\text{proj}}_i$ 则呈现出相反的趋势，在面区域数值较高（红色），而在边缘和角点区域数值降低（橙黄色）。各个特征在不同的几何结构上有着明显的区别。

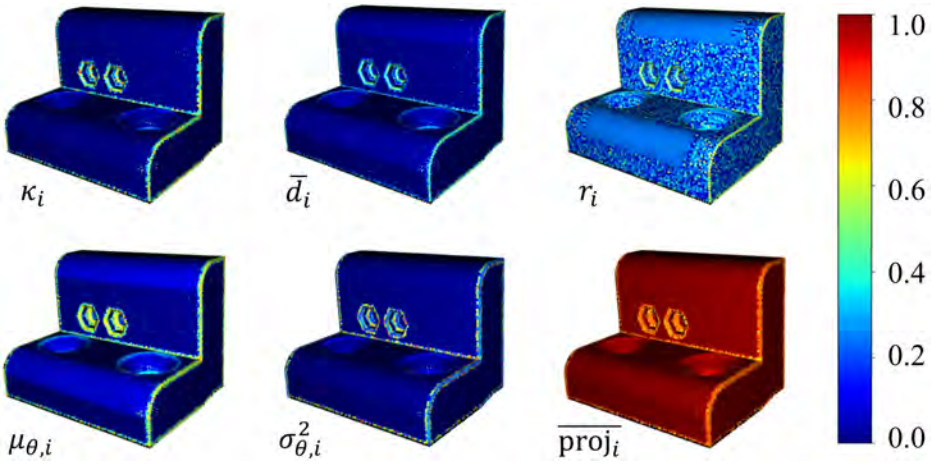


图 2.7 单个物体点云的六个特征描述符在空间上的数值分布情况

Figure 2.7 Spatial distribution of six feature descriptors for a single object point cloud.

图 2.8 给出了构建的数据集 ABC-Corner 中 1000 个点云样本在三类标签下的六个特征数值分布，数据集的描述及构建过程见章节 3.2。纵轴为数据集中的点云 ID，横轴为特征数值（归一化至 [0, 1]），颜色标记类别：蓝色为面、黄色为边缘、红色为角点。统计结果显示，在面、边缘、角点三类之间，所有特征分布具有明显界限。以曲率和法向分布为例，角点主要集中在中高值段，面点则聚集于低值，边缘点分布于中间区域。其他如投影距离、均值中心距离等特征也展现出对类别的良好区分能力。

虽然上述特征描述符在一定程度上已具备几何特征区分能力，但若直接基于阈值进行判别，仍属于传统解析范式，通常依赖人工参数调节，且难以保证在复杂场景中的稳健性。为此，本文引入神经网络对特征矩阵进行学习，以结合解析特征的可解释性与数据驱动方法的自适应能力，实现更稳定、准确的分类。

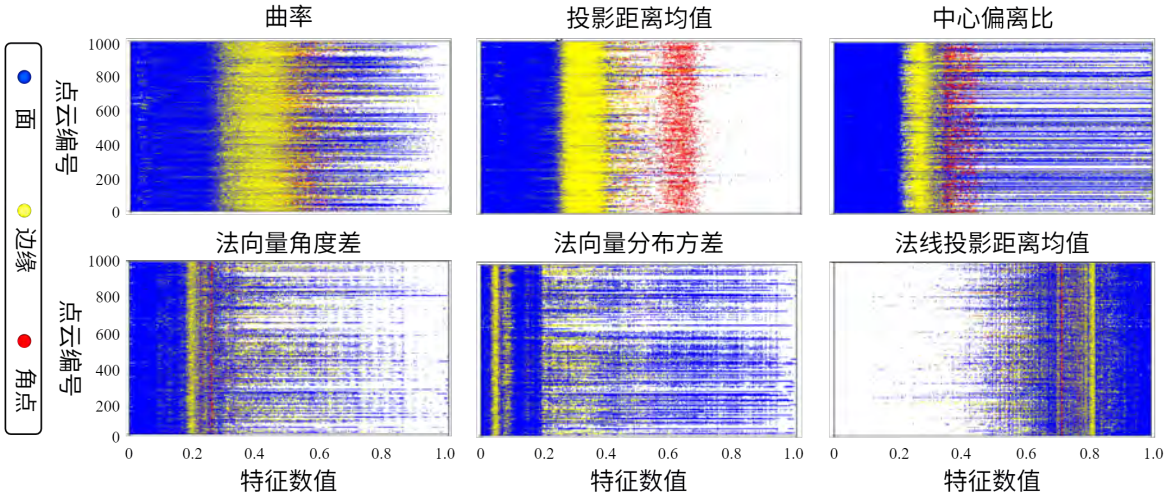


图 2.8　六个特征描述符在三类标签下的数值分布情况

Figure 2.8　Distribution of six feature descriptors under three class labels.

2.4　NECDNet 网络架构设计

NECDNet 网络架构面向输入点的精细分类任务（面点、边缘点和角点），设计了以多层感知机为核心、融合多尺度特征与分阶段判别的高效结构[60]。整体网络流程如图 2.9 所示，主要包括两大模块：首先，多尺度特征融合模块从多个邻域尺度提取并逐级整合局部几何信息，实现输入信息的丰富表达；其次，逐级分类模块采用分层分类思路，将点的最终类别归属过程划分为由简到繁的两个层次，提升分类准确率与模型泛化能力。结合全连接层、Leaky ReLU 激活及 Dropout 策略，网络能够有效增强判别能力并抑制过拟合风险[61-62]。下文将分别对多尺度特征融合与逐级分类策略进行详细阐述。

2.4.1　多尺度特征融合

NECDNet 的输入部分针对每个查询点构建了多尺度邻域下的几何属性特征矩阵。具体地，针对每个点，分别在 $k = 8, 16, 32, 64$ 四种不同邻域尺度内提取点云的几何特征，每个尺度获得一个 6 维特征向量 $\mathbf{x}_{i,k} \in \mathbb{R}^6$，所有尺度拼接形成 4×6 的特征矩阵。

上述多尺度特征首先经过特征提取单元处理。对于第 j 个尺度 ($j \in \{1, 2, 3, 4\}$) 的输入特征 $\mathbf{x}_{i,j}$，通过全连接层（FC）、Leaky ReLU 激活函数进行非线性映射。该过程可表示为：

$$\mathbf{h}_i^{(1)} = \sigma_{\text{LReLU}}(\mathbf{W}_i^{(1)}\mathbf{x}_{i,j} + \mathbf{b}_i^{(1)}) \tag{2.15}$$

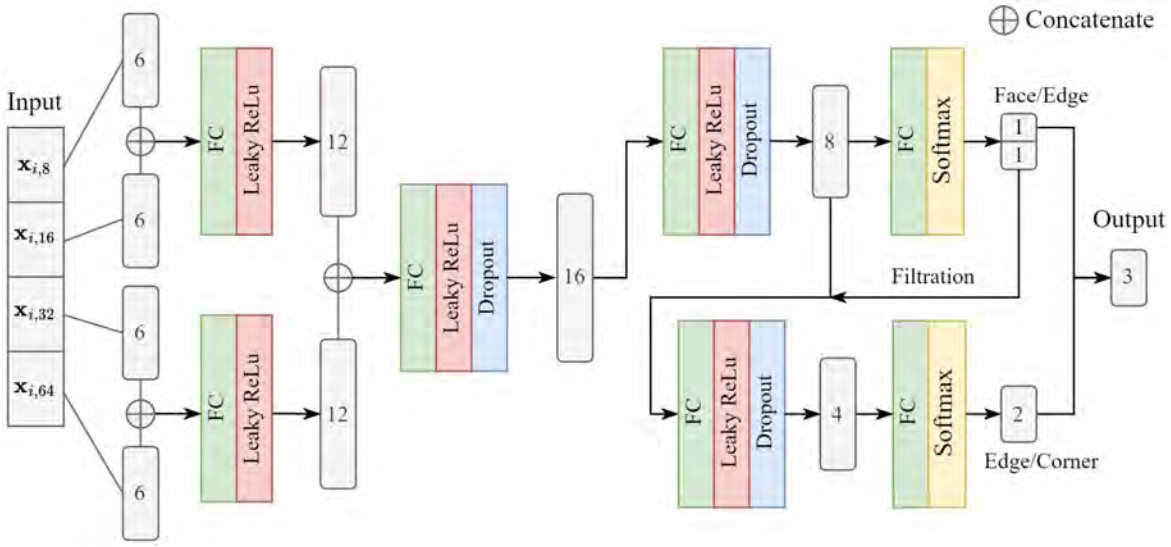


图 2.9　NECDNet 网络架构示意图

Figure 2.9　NECDNet network architecture diagram.

其中，$\mathbf{W}_i^{(1)}$ 和 $\mathbf{b}_i^{(1)}$ 为权重矩阵和偏置项，σ_{LReLU} 表示 Leaky ReLU 激活函数，其定义为 $f(x) = \max(x, \alpha x)$，α 为负半轴斜率（通常取 0.01）[61]。

随后，参考图 2.9 中的结构，模型将相邻两个尺度的特征进行两两拼接（Concatenate）。例如，将 $k = 8$ 和 $k = 16$ 对应的特征 $\mathbf{h}_1^{(1)}$ 和 $\mathbf{h}_2^{(1)}$ 拼接得到 $\mathbf{z}_{12} = [\mathbf{h}_1^{(1)}, \mathbf{h}_2^{(1)}]$。融合后的特征再次通过类似的非线性变换，具体如公式 (2.16) 所示。相较于上一步，这里引入了 Dropout 层以防止过拟合现象的发生[62]。

$$\mathbf{h}_{12}^{(2)} = \text{Dropout}\left(\sigma_{\text{LReLU}}(\mathbf{W}_{12}^{(2)}\mathbf{z}_{12} + \mathbf{b}_{12}^{(2)})\right) \tag{2.16}$$

同理可得 $\mathbf{h}_{34}^{(2)}$。接着，将这两组特征进一步拼接为 24 维大向量 $\mathbf{z}_{\text{final}}$，并通过进一步的 FC 层非线性降维，得到 16 维的综合多尺度特征输出 $\mathbf{F}_{\text{out}}$。

整个多尺度特征融合过程不仅实现了不同邻域尺度下信息的交互、互补和融合，还通过层级式的非线性变换消除了简单拼接可能造成的信息冗余，使网络能够自主学习到最具区分力的综合表达，为后续分类模块奠定坚实基础。

2.4.2　逐级分类器

多尺度特征融合单元输出的 16 维向量 $\mathbf{F}_{\text{out}}$ 随后交由逐级分类器进行细粒度类别判别。该模块采用两级分层判别架构。

1） 第一级分类（面点判别）

首先，$\mathbf{F}_{\text{out}}$ 经过类似公式 (2.16) 的变换降维至 8 维，得到中间特征 $\mathbf{v}_{\text{mid}}$。随后，通过 FC 层输出面点与非面点的逻辑值（Logits）$\mathbf{l}_1 \in \mathbb{R}^2$。最终的初级分类概率分布 $\mathbf{p}_1$ 由 Softmax 函数计算得出[63]：

$$\mathbf{p}_1 = \text{Softmax}(\mathbf{l}_1) = \frac{e^{\mathbf{l}_{1,j}}}{\sum_{k=1}^{2} e^{\mathbf{l}_{1,k}}}, \quad j \in \{1, 2\} \tag{2.17}$$

若判定为面点，则直接据此输出结果；若为非面点，则将中间特征 $\mathbf{v}_{\text{mid}}$ 送入下一级分类子模块。

2） 第二级分类（边缘点与角点判别）

在第二级分类器中，传入的 8 维特征 $\mathbf{v}_{\text{mid}}$ 再次经历 FC、Leaky ReLU 和 Dropout 处理，降维为 4 维特征 $\mathbf{v}_{\text{sub}}$，最后映射为边缘点和角点的二分类逻辑值 $\mathbf{l}_2$。同样利用 Softmax 得到概率分布 $\mathbf{p}_2$，类似公式 (2.17) 所示。最终，对于每个输入点，网络结合两级输出确定“面-边缘-角”三类别的归属。

这种分级判别方法，有效简化了单次多分类的复杂度，提升了点云中特征类别区分的精度和鲁棒性。值得一提的是，每层分类器均结合 Leaky ReLU 增强非线性表达，Dropout 有效应对过拟合风险，整体保证了 NECDNet 在结构复杂、类别分布不均等点云场景下的自适应能力。

2.4.3 损失函数

训练数据中三类几何特征点的分布存在不平衡现象，面点数量远多于边缘点和角点，尤其是角点[64]。为应对类别不平衡问题，本文在训练过程中采用 Focal Loss 作为优化指标[65]。Focal Loss 旨在解决训练中前景与背景类别极度不平衡的单阶段物体检测场景。其在交叉熵损失（Cross Entropy, CE）基础上引入调节因子，降低易分类样本权重，从而使模型更加关注难分类样本。

交叉熵损失是分类任务中常用的损失函数，可度量模型预测概率分布与真实标签分布之间的差异。交叉熵越小，说明两者越相似；越大，说明差异越大。交叉熵损失的定义如公式 (2.18) 所示[66]。其中，p_t 表示模型对真实类别的预测概率。然而，交叉熵损失在类别不平衡情况下容易被大量易分类样本主导，导致模型对少数类别

学习不足。

$$\mathrm{CE}(p_t) = -\log(p_t) \tag{2.18}$$

为解决类别极度不均衡问题，可在交叉熵损失基础上引入类别权重 α，得到加权交叉熵损失（Weighted Cross Entropy, WCE）。其在计算时对不同类别赋予不同权重，增强对少数类别的关注，定义如公式 (2.19) 所示。其中，α_t 为类别 t 的权重，通常根据类别频率设置。

$$\mathrm{WCE}_{\alpha}(p_t) = -\alpha_t \log(p_t) \tag{2.19}$$

Focal Loss 正是在加权交叉熵损失基础上的改进。Focal Loss 在加权交叉熵损失基础上引入调节因子 $(1-p_t)^{\gamma}$，其中 γ 为调节参数，用于控制易分类样本的权重衰减程度。Focal Loss 的定义如公式 (2.20) 所示[65]。相较于加权交叉熵损失，Focal Loss 通过调节因子有效降低易分类样本影响，使模型更加关注难分类样本，从而提升类别不平衡场景下的分类性能。

$$\mathrm{FL}(p_t) = -\alpha_t (1-p_t)^{\gamma} \log(p_t) \tag{2.20}$$

2.5 本章小结

本章围绕 NECDNet 的方法设计与实现过程展开。首先，给出了逐点邻域构建、前处理与法向量估计策略，并分析了法向量估计精度对后续检测性能的潜在影响。其次，构建了多尺度特征矩阵，设计并计算了六类局部几何描述符，结合可视化结果验证了其对物体几何特征（面、边缘、角点）的区分能力。在此基础上，本章进一步介绍了 NECDNet 的网络架构，包括多尺度特征融合、逐级分类器与损失函数设计。总体而言，本章为后续章节的实验评估提供了完整的方法基础与实现依据。

第三章　几何特征检测对比实验及分析

3.1　引言

本章旨在通过系统性的实验验证本文所提出的 NECDNet 在三维点云边缘与角点检测任务中的有效性与鲁棒性。实验主要基于本文构建的 ABC-Corner 数据集展开。首先，本章将详细阐述 ABC-Corner 数据集的构建过程、实验的硬件环境、参数配置以及针对数据不平衡问题所采用的评价指标与训练策略。随后，将 NECDNet 与当前主流的传统几何分析方法及深度学习方法进行多维度的定性与定量对比。此外，为了验证网络结构设计的合理性，本章还对特征维度、多尺度参数选择及数据增强策略进行了消融实验分析。通过全面的实验评估，本章将深入分析 NECDNet 在不同类别（面、边缘、角点）上的检测性能，探讨其在处理复杂几何结构时的优势与局限性，并为后续章节的模型优化与应用提供实证基础。

3.2　ABC-Corner 数据集构建

网络训练和评估离不开高质量的标注数据集。针对点云几何特征检测任务，本文构建了一个专门的数据集：ABC-Corner 数据集。该数据集基于 ABC 数据集[67] 中的 CAD 模型，经过标注和处理，包含丰富的面点、边缘点和角点样本，能够有效支持深度学习模型的训练与评估。下文将详细介绍数据集的选取标准、标注流程及统计特性。

3.2.1　数据集选取

针对点云数据的深度学习任务，目前已有多个公开数据集可供使用，图 3.1 展示了 ShapeNet[68]、ScanNet[69]、RGB-D Object Dataset[70] 数据集中的部分内容。这些数据集的原始数据一般为扫描得到的非结构化点云，或者由 RGB-D 数据估计得到的点云，适用于分类、分割和重建等多种点云处理任务。然而，在本文的几何特征检测任务中，数据集需具备高质量的几何特征标注，特别是边缘点和角点的精确位置标注。通过扫描或重建得到的点云数据往往存在噪声与不完整性，且难以获得精确标注，因此本文选择基于 CAD 模型的数据集进行构建。



图 3.1　常用点云数据集对比示意图

Figure 3.1　Comparison of commonly used point cloud datasets.

在 CAD 模型数据集中，ABC 数据集因其丰富的几何多样性和高精度的模型表示而被广泛应用于几何处理和计算机图形学领域[67]。如图 3.2，ABC 数据集包含了大量由真实工程设计生成的 CAD 模型，涵盖了各种复杂的几何形状和结构，适合用于点云几何特征检测任务。并且，CAD 模型本身具有明确的几何定义，便于从中提取精确的边缘和角点信息，满足本文对数据集标注质量的高要求。因此，本文选择 ABC 数据集作为构建 ABC-Corner 数据集的基础。

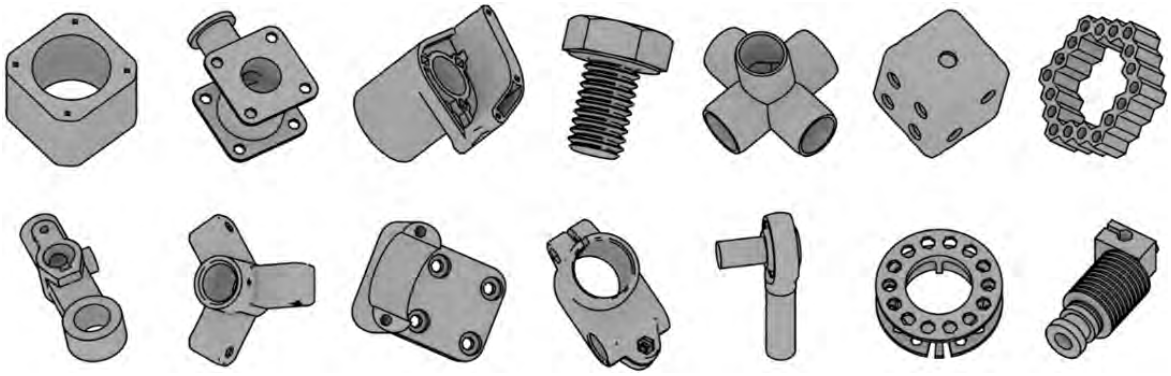


图 3.2　ABC 数据集中的部分 CAD 模型示例

Figure 3.2　Examples of CAD models from the ABC dataset.

3.2.2　数据集标注流程

ABC 数据集中包含大量 CAD 模型，原始数据为模型的几何表示（B-Rep）。该数据集在构建过程中基于模型原始数据生成了网格化表示和几何真值（法向量、曲率、补丁分割、尖锐特征等）。本文构建的 ABC-Corner 主要使用原始数据集中的 OBJ 模型文件及其对应几何真值文件，结合自定义标注流程，生成包含面点、边缘点与角点标签的点云数据集。如图 3.3 所示，标注流程主要包括边缘提取、粗角点检测和人

工精修三个步骤。

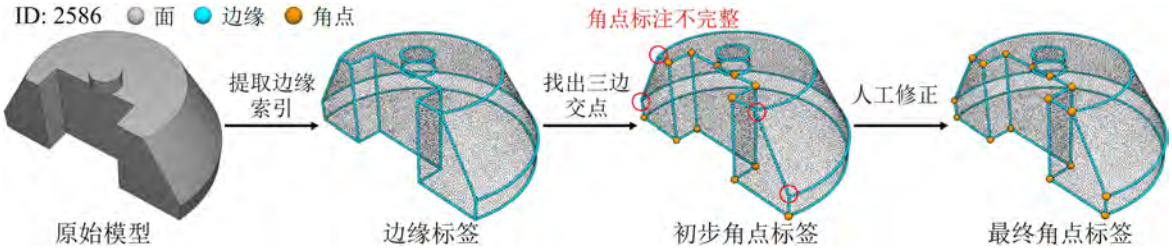


图 3.3　ABC-Corner 数据集标注流程示意图

Figure 3.3　Annotation pipeline for the ABC-Corner dataset.

ABC 数据集的模型文件中包含均匀采样得到的点云数据（顶点），以及每个顶点的法向量和曲率信息。几何真值文件中包含了模型的曲面补丁划分和边缘曲线信息。其中的边缘曲线信息是将模型所有边缘进行参数化表示，包含边缘上各顶点的索引信息，以及曲线的样式。基于该信息可以实现边缘点的自动标注。

ABC 数据集中虽然包含了边缘信息，但并未直接提供角点的标注。为了提取角点，本文设计了一种基于几何规则的粗角点检测方法。具体而言，根据边缘曲线信息，识别出边缘的交叉点作为角点候选集，即某个索引在所有曲线中出现三次或三次以上，则将其视为角点。在实际检测中发现对于样条曲线，交点的提取由于索引定义的问题，按照上述规则会将所有构成点均视为角点，导致误检较多。因此，在角点粗提取中会排除样条曲线，仅针对直线和圆弧进行交点检测。通过该方法，能够初步获得角点的候选集。

观察图 3.3 中的初步角点标注结果，可以发现自动提取的角点存在一定的误差和遗漏。为此，本文引入了人工精修环节，对自动标注的结果进行校正和补充。具体而言，使用点云处理软件 CloudCompare 对点云进行展示，人工检查每个模型的边缘和角点标注，修正错误标注并补充遗漏的特征点。通过该流程，最终生成了高质量的点云几何特征标注数据集 ABC-Corner。

ABC-Corner 数据集在 ABC 数据集基础上补充了模型尖锐角点的准确标注，显著提升了其在点云几何特征检测任务中的适用性。该数据集包含多样化几何形状与复杂结构，能够有效支持深度学习模型的训练与评估。在平衡人工标注成本与训练数据规模需求后，最终的 ABC-Corner 选取了 ABC 数据集 chunk00 子集中的 1000 个模型，重点筛选几何特征较为突出的对象。每个模型均经过上述标注流程处理，生成包含面点、边缘点和角点标签的点云数据。图 3.4 展示了 ABC-Corner 数据集中的

部分样本及其标注结果。

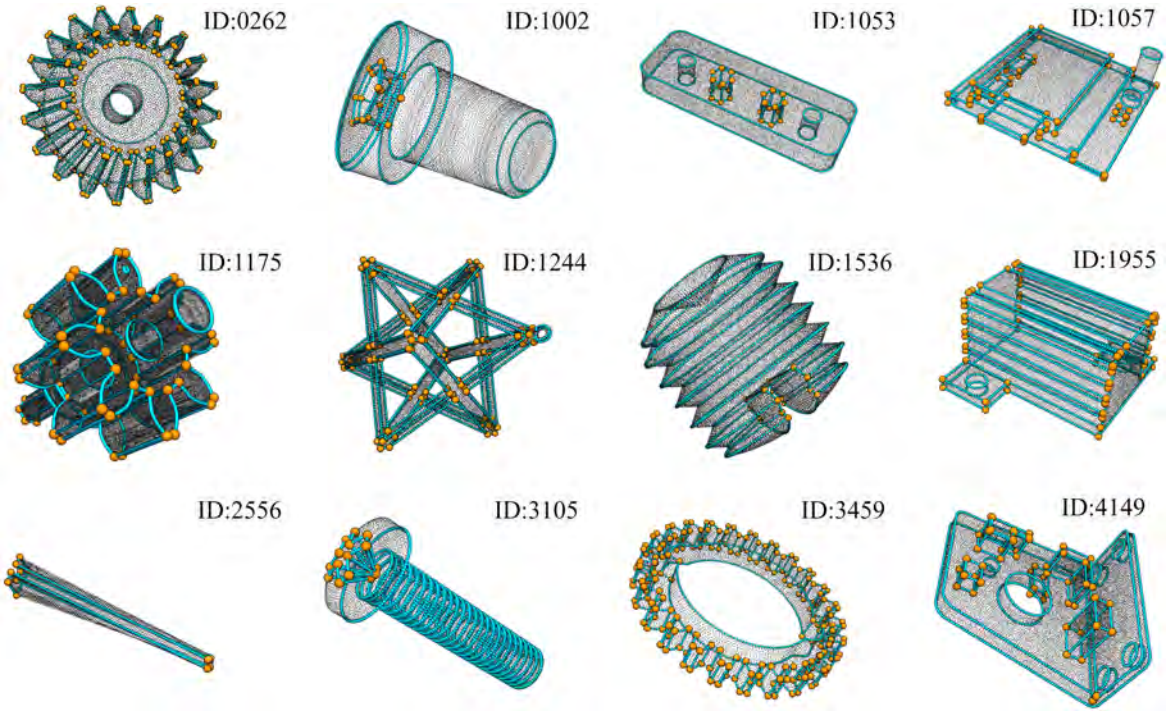


图 3.4　ABC-Corner 数据集中的部分样本及其标注结果

Figure 3.4　Samples from the ABC-Corner dataset and their annotation results.

3.3　实验环境与参数配置

进行实验验证前，需明确实验软硬件环境、数据处理方法、模型训练超参数及评价指标设计，以确保结果具有可复现性、科学性和可比性。本文实验主要基于自建的 ABC-Corner 数据集，涵盖两个关键任务：点云几何特征多分类检测（面点、边缘点与角点联合检测）以及面点与边缘点二分类检测。设立双任务的主要原因在于，部分对比方法仅具备边缘特征检测能力。为全面评估本文方法有效性，除多分类检测外，本文还在 ABC 数据集上针对单独边缘提取任务与这些方法进行对比。本节将系统介绍实验流程，包括数据预处理策略、训练环境与超参数配置、法向量估计方法比较，以及多维度评价指标体系设计。

3.3.1　软硬件环境与开发框架

本文实验的计算硬件采用一台配备 NVIDIA RTX 3090 GPU（显存 24 GB）的工作站，CPU 为 Intel Core i7-10700K，内存 256 GB。软件环境为 Ubuntu 22.04 LTS 操作

系统。算法实现基于 PyTorch 2.10 深度学习框架，使用 Python 3.10 编程语言和 CUDA 13.0 计算平台。此外，采用 scikit-learn 库用于计算各种评价指标，numpy 和 scipy 库用于数值计算和科学计算[71-74]。

3.3.2 数据预处理与划分方案

ABC-Corner 数据集中包含 1000 个点云及其对应几何特征标签，各点云点数不一致。根据章节 2.4 中描述的 NECDNet 网络架构可知，网络输入为逐点多尺度特征矩阵。因此，在数据预处理阶段，首先需从原始点云中计算各点的多尺度特征矩阵。根据章节 2.3 所述方法进行特征计算时，数据归一化已在流程中实现，输入点云无需再进行点数或尺寸归一化。为提升处理效率，特征计算采用并行方式，进程数设为 16。得到逐点特征矩阵后，后续处理以点为单位进行，ABC-Corner 的数据点总量达到千万级。

本文采用分层 k 折交叉验证（Stratified k-Fold Cross-Validation）的方法进行数据集划分。本实验选取 $k = 5$，即采用 5 折分层交叉验证，此时训练集数据占比为 60%，验证集占比为 20%，测试集占比为 20%，能够在保证训练数据充足的同时，提供足够的验证和测试数据用于模型评估。交叉验证方法具体而言，首先将整个数据集按照标签类别比例进行分层，随机划分为 5 个互不重叠的子集。在每一轮实验中，轮流选取其中 1 个子集作为测试集，1 个子集作为验证集，其余 3 个子集作为训练集。通过这种方式，共进行 5 次独立的训练与评估过程，确保每个子集都曾作为测试集被评估过。最终的实验结果取这 5 次实验的平均值，以减小随机划分带来的偶然误差，从而更准确地反映模型的泛化能力。

此外，在各折数据划分时，本文采用了随机分层划分的方式，确保每个子集中各类别的分布比例与整个数据集保持一致。这种分层划分方法能够有效避免由于随机划分导致的模型训练偏差，即将某些类别过多地分配到训练集或测试集中，从而导致模型在某些类别上的性能评估不准确。通过分层划分，能够确保模型在训练和评估过程中都能接触到各个类别的样本，从而更全面地评估模型的性能。

3.3.3 训练超参数配置

网络模型的训练还需要进行超参数配置，本文的设置主要目的是在计算效率与模型性能之间取得最优平衡。部分参数在进行多次训练后的模型评估进行选择，确

保最终模型的稳定性和性能。各项参数的具体配置如下。

1） 批量大小与数据加载

为了充分利用 GPU 显存并提高训练效率，批次大小（Batch Size）设定为 20,000。数据加载器（DataLoader）的并行工作线程数配置为 16，以实现多线程数据读取和预处理，减少 GPU 的空闲时间。为了避免因随机数据顺序导致的模型不稳定，采用了随机 Seed 固定的方法，实现数据加载的可重复性，确保实验的可复现性。

2） 训练轮次与早停策略

训练过程的轮次（Epoch）设置为 64，为了防止过拟合现象的发生，实现了早停机制：在验证集上的 F1 分数连续 10 个 Epoch 不再改善时，训练自动停止。这种策略能够在保证模型性能的同时，避免不必要的计算浪费。

3） 优化器与学习率策略

模型优化采用 Adam 优化器，该优化器结合了动量法和自适应学习率的优点，特别适合处理稀疏梯度和高维优化问题[75]。本文中 Adam 优化器的超参数设置为：一阶矩估计系数 $\beta_1 = 0.9$，二阶矩估计系数 $\beta_2 = 0.999$，数值稳定性参数 $\epsilon = 10^{-8}$。

模型的学习率设置采用余弦退火（Cosine Annealing）学习率衰减策略，其数学表达式如式 (3.1) 所示。其中 $\eta_{\max} = 0.001$ 为最大学习率，$\eta_{\min} = 1e^{-5}$ 为最小学习率，t 为当前 epoch，$T = 64$ 为训练总 epoch 数。这种策略能够确保网络在训练初期快速收敛，在训练后期通过较小的学习率进行精细调优，提高最终模型的性能和稳定性[76]。

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})\left(1 + \cos\left(\pi \frac{t}{T}\right)\right) \tag{3.1}$$

3.3.4 类别不平衡问题处理

由于物体固有几何特征分布差异，ABC-Corner 数据集中三类几何特征呈现明显不平衡，具体统计如表 3.1 所示。面点约占 95.4%，边缘点占 4.4%，角点仅占 0.2%。这种极度不平衡会使网络在训练过程中受大量简单样本（面点）主导，进而导致少数类（尤其是角点）学习不足。例如，模型可能倾向于将多数点预测为面点，以换取较高整体准确率，但这显然无法满足边缘与角点检测需求。为此，本文采用 Focal Loss 损失函数，并结合针对性数据上采样（Oversampling）策略，以共同缓解类别不

平衡影响。

表 3.1　ABC-Corner 数据集中各类几何特征的分布统计

Table 3.1　Distribution statistics of geometric features in the ABC-Corner dataset.

几何特征类别	点数量	占比 (%)
面	36,428,079	95.4%
边缘	1,711,843	4.4%
角点	36,916	0.2%

在损失函数的设计上，本文采用了 Focal Loss[65] 作为主要的训练损失函数，如章节 2.4.3 所述。Focal Loss 通过引入动态加权因子 $(1-p_t)^\gamma$，能够自适应地降低易分类样本（面点）的权重，同时增加难分类样本（边缘点与角点）的权重。本文中聚焦参数 γ 设为 2.5，类别权重均衡因子 α 对三类设置为 $[0.2, 0.3, 0.5]$，即对角点赋予最高的权重。

此外，为了进一步增强训练数据的多样性和模型的鲁棒性，本文对少数类样本进行了上采样处理。通常的数据平衡策略是将所有类别的样本数量上采样至一致，但在本文的任务中，角点的数量级远小于面点和边缘点。在进行面点与边缘点的二分类任务时，通过 Focal Loss 的权重调整已能较好地改善类别不平衡问题。然而，角点样本的极度稀缺仍是制约多分类性能的瓶颈。

因此，本文的策略是仅对角点进行上采样，将其数量补充至与边缘点一致，从而将三类的数量比例调整为，面: 边缘: 角点 = 100:5:5。这种策略旨在重点解决角点学习不足的问题，避免了对面点和边缘点进行不必要的过度采样，还降低了由于过度上采样导致的过拟合风险。为了验证该策略的有效性——即探究是仅对角点上采样更好，还是对边缘点和角点同时上采样至与面点一致更好——本文在后续的消融实验（章节 3.5）中进行了详细的对比分析与指标评估。

3.3.5　法向量估计方法的选择与对比

法向量是 NECDNet 计算特征的重要输入之一，其精度直接影响检测结果。章节 2.2.3 已详细论述了本文所涉及的两种法向量估计方法：基于 PCA 的点云法向量估计与基于 CAD 网格模型的法向量估计。基于 PCA 的方法适用于非结构化点云，而基于 CAD 网格模型的方法能够提供精确的几何真值。

为了验证法向量估计精度对检测网络性能的影响，本文设计了对比实验，分别训练了两个版本的 NECDNet 模型：一个使用基于 PCA 方法估计的法向量作为输入特征（记为 NECDNet），以模拟原始数据为点云；另一个使用从 CAD 网格模型提取的精确法向量作为输入（记为 NECDNet†），作为原始数据为网格模型时的对照组。后续实验对两者在 ABC-Corner 数据集上的检测性能进行定量评估和对比分析，以验证法向量精度对边缘与角点检测结果的显著影响。

3.3.6 评价指标设计

为了全面评估 NECDNet 在点云几何特征检测任务中的性能，本文采用了多种评价指标，包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）、交并比（Intersection over Union, IoU）和马修斯相关系数（The Matthews Correlation Coefficient, MCC）[64,77-78]。这些指标能够从不同角度反映模型的分类效果，特别是在处理类别不平衡问题时，精确率和召回率尤为重要。评价指标主要通过混淆矩阵（Confusion Matrix）进行计算，混淆矩阵记录了模型在各类别上的预测结果与真实标签的对比情况。混淆矩阵的行表示真实类别，列表示预测类别，其中对角线上的值表示正确分类的数量，非对角线上的值表示分类错误的数量。基于混淆矩阵，可以计算出各项评价指标，从而全面评估模型的性能[79]，各项指标的具体计算公式请见附录 B。

本文中分类任务为三分类，类别分别为：f（面点）、e（边缘点）、c（角点）。可以构建对应的混淆矩阵，如表 3.2 所示。表中，TP（True Positive）表示正确预测为正类的数量，TN（True Negative）表示正确预测为负类的数量，FP（False Positive）表示错误预测为正类的数量，FN（False Negative）表示错误预测为负类的数量。

表 3.2 三分类任务的混淆矩阵示例

Table 3.2 Example of confusion matrix for three-class classification task.

	预测类别			
真实类别	f	e	c	总计
f	TP_{f}	FP_{e}	FP_{c}	P_{f}
e	FN_{f}	TP_{e}	FP_{c}	P_{e}
c	FN_{f}	FN_{e}	TP_{c}	P_{c}
总计	N_{f}	N_{e}	N_{c}	N

上述评价指标的标准公式是基于二分类任务进行设计的。对于多分类任务，需要在指标的计算或者混淆矩阵的构建上进行调整。例如 Erbani 等人[80] 提出基于传输的混淆矩阵构建方法，建立在最优传输理论和最大熵原理之上，针对多标签或软标签分类复杂任务提出了一种新的混淆矩阵构建方法。此外，在指标计算上可以采用宏平均（Macro-Averaging）和微平均（Micro-Averaging）两种方式[64,77]。宏平均是对每个类别分别计算指标，然后取平均值，适用于类别分布不均衡的情况；而微平均则是将所有类别的预测结果合并后计算指标，更适用于类别分布均衡的情况。

由于本文的分类任务较为简单，且为了与目前的其余最新方法（state-of-the-art, SOTA）进行对比，本文中主要采用一般的混淆矩阵构建方法加宏平均的方式计算各项评价指标。具体而言，设 C 为类别总数，M_c 为类别 c 的评价指标值，则宏平均的计算公式如 (3.2) 所示。本文中 $C=3$，分别对应面、边缘、角点三类。

$$M_{\text{macro}} = \frac{1}{C}\sum_{c=1}^{C} M_c \tag{3.2}$$

3.4 对比实验结果及分析

为了全面评估 NECDNet 的性能，本节将其与现有的 SOTA 方法进行了对比。对比实验涵盖两个层面：一是针对边缘与角点联合检测的三分类任务，对比方法包括基于协方差分析的 CA 方法[31]、两阶段检测法 TECD[6] 以及深度学习方法 PIE-Net[14]；二是针对纯边缘检测的二分类任务，对比方法包括 PCEDNet[12] 和 BoundED[13]。

3.4.1 边缘与角点联合检测结果分析

在边缘与角点的联合检测任务中，表 3.3 展示了各方法在 ABC-Corner 数据集上的定量评估结果。为了确保结果的统计可靠性，所有方法的报告数据均为 5 折交叉验证的平均值。其中 PIE-Net 的作者仅开源了其网络模型部分，并未提供完整的数据处理过程，难以进行复现，因此本文直接引用其论文中的数据进行大致对比。对于 CA 和 TECD 方法，本文在 ABC-Corner 数据集上进行了重新实现和评估，以确保对比的公平性和准确性。对于 NECDNet，本文分别评估了使用基于 PCA 的法向量输入（NECDNet）和使用从 CAD 网格模型提取的精确法向量输入（NECDNet†）两种版本，以验证法向量精度对检测性能的影响。

表 3.3　ABC-Corner 数据集上各边缘与角点检测方法的宏平均指标评分
Table 3.3　Macro-averaging metrics for edge and corner detection methods on the ABC-Corner dataset.

评估方法	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
CA[31]	0.415	0.616	0.420	0.616	0.346	0.276
TECD[6]	0.472	0.642	0.513	0.642	0.438	0.526
PIE-Net[14]	0.615	0.814	0.686	0.935	0.577	0.718
NECDNet (Ours)	0.646	0.857	0.715	0.983	0.616	0.833
NECDNet† (Ours)	**0.765**	**0.933**	**0.815**	**0.995**	**0.743**	**0.943**

PIE-Net 的数据基于其作者提供的评估结果整理得出。
† 表示使用从 Mesh 模型估计的法向量。

表 3.3 的总体评估结果显示，NECDNet 在各项核心指标上均显著优于现有方法。具体而言，NECDNet 的宏平均 F1 分数达到 0.715，相较于 PIE-Net 提升了约 4.2%；在使用网格法向量（NECDNet†）时，F1 分数更提升至 0.815，展现了卓越的特征提取能力。在反映分类一致性的 MCC 指标上，NECDNet† 达到 0.943，远超 PIE-Net (0.718) 和 TECD (0.526)，证明了模型在处理极度不平衡样本时的鲁棒性。

为了进一步揭示各方法在处理复杂几何结构时的具体表现差异，图 3.5 选取了四个具有代表性的复杂机械零件进行可视化对比，其中绿色、红色和灰色点分别代表边缘、角点和平面点。对应地，表 3.4 详细列出了这四个对象在各方法下的分类别指标（Precision, Recall, F1, Accuracy, IoU, MCC）。本文方法（Ours）取得了最佳的检测效果。CA 和 TECD 缺乏鲁棒性，PIE-Net 检测精度不足，PCEDNet 表现出良好的边缘检测能力但无法检测角点。下文将结合上述整体统计结果与具体案例的细节表现，对传统几何方法和深度学习方法分别展开深入剖析。

1）　与传统几何分析方法的对比

传统的几何分析方法，如 CA（Covariance Analysis）[31] 和 TECD（Two-Stage Edge-Corner Detection）[6]，主要依赖手工设计的几何特征和基于阈值的判决规则。在本文的对比实验中，针对 ABC-Corner 数据集，CA 方法中边缘检测阈值设置为 0.085，角点检测阈值设置为 0.14。TECD 方法的边缘阈值 λ 设为 1.0，同时保留了其原论文中针对角点检测的其他阈值设置[6]。本文为 CA 和 TECD 方法选择的参数均经过了在 ABC-Corner 数据集上的网格搜索优化，以确保其在该数据集上的最佳性能表现。

CA 方法基于协方差矩阵的特征值进行阈值判定，具有计算简单、速度快的优点，但在实际应用中存在显著局限性。首先，CA 方法采用单一固定阈值进行分类判

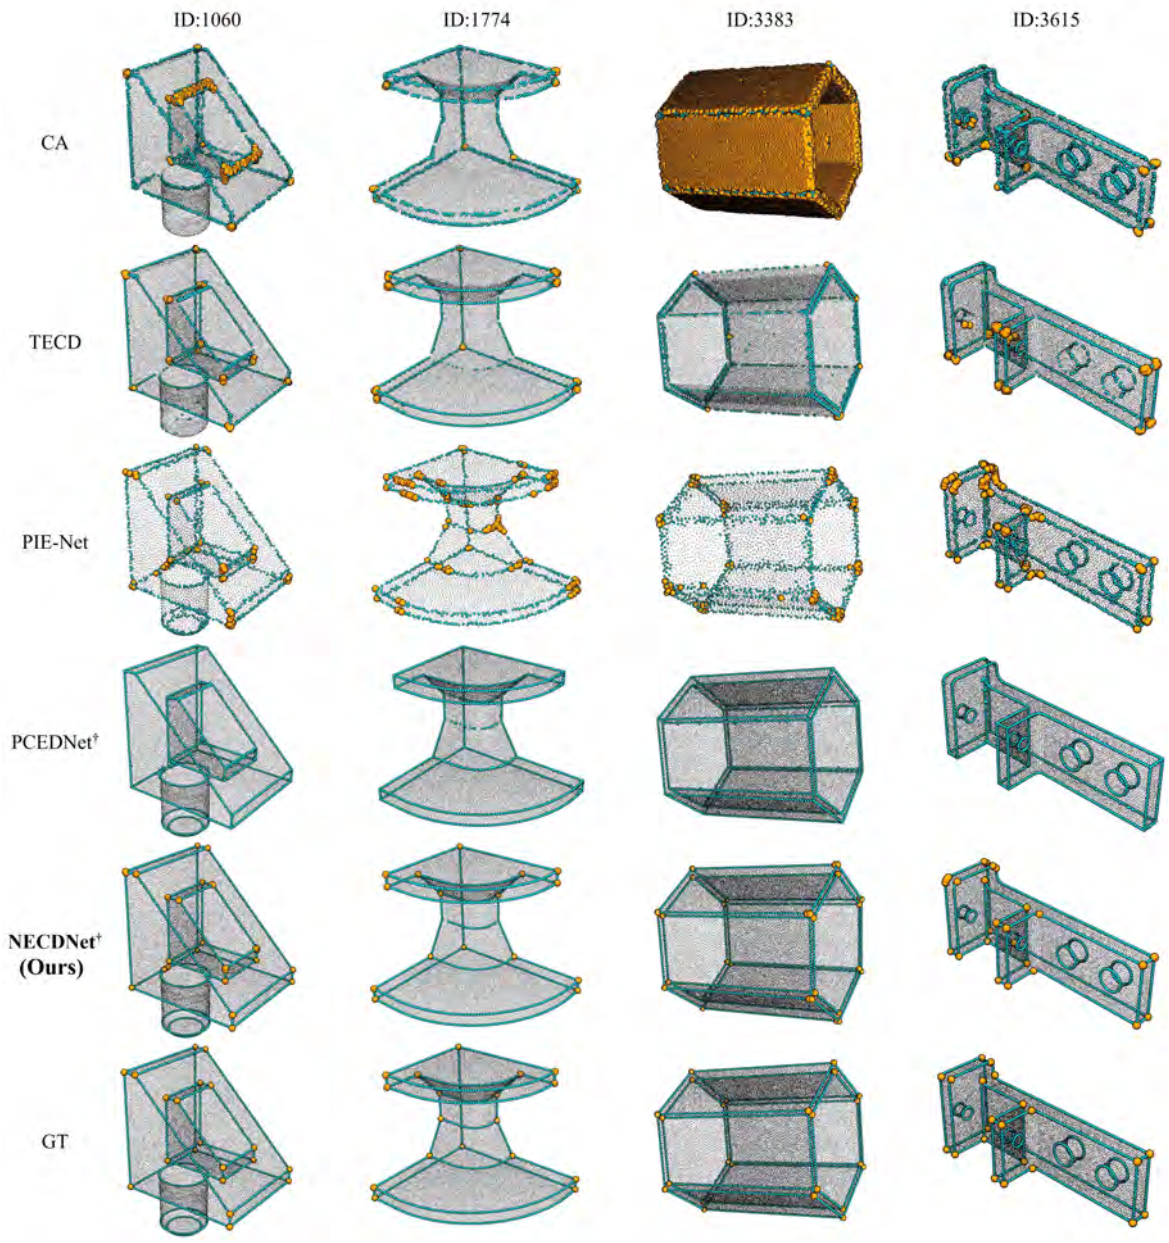


图 3.5　ABC-Corner 数据集上各方法的边缘与角点检测结果可视化对比

Figure 3.5　Comparison of edge and corner detection results on the ABC-Corner dataset.

定，这种设计对阈值的选择极为敏感，而实际物体的几何复杂度差异巨大，薄壳结构和厚重物体的尖锐程度存在数量级的差异，统一的阈值无法有效处理如此多样的场景。如图 3.5 所示的可视化结果，CA 检测出的边缘线条极其不连续且包含大量噪声点（误检），可视化结果对应到表 3.4 中的数据可见：CA 在边缘类别的 F1 分数仅为 0.405，IoU 仅为 0.254。而且由于采用单一尺度的邻域分析，CA 在处理如对象 3383 这样的薄壁结构时，容易同时包含正反两个面的几何信息，导致特征值计算异常。更为重要的是，CA 缺乏专门的角点检测机制，这在表 3.4 数值上体现为其角点

表 3.4 图 3.5 中四个点云对象的分类别指标评分。

Table 3.4 Category-wise metrics for the four point cloud objects in Figure 3.5.

评估方法	Precision(↑)			Recall(↑)			F1(↑)		
	Face	Edge	Corner	Face	Edge	Corner	Face	Edge	Corner
CA[31]	0.975	0.303	0.001	0.582	0.614	0.303	0.729	0.405	0.002
TECD[6]	0.986	0.705	0.062	0.980	0.762	0.158	0.983	0.732	0.089
PIE-Net[14]	0.995	0.673	0.278	0.950	0.898	0.964	0.972	0.770	0.432
NECDNet (Ours)	**0.999**	0.970	0.519	0.998	**0.987**	0.921	**0.999**	0.978	0.664
NECDNet† (Ours)	**0.999**	**0.994**	**0.540**	**1.000**	0.974	**0.987**	**0.999**	**0.984**	**0.698**

评估方法	Accuracy(↑)			IoU(↑)			MCC(↑)
	Face	Edge	Corner	Face	Edge	Corner	
CA[31]	0.582	0.614	0.303	0.573	0.254	0.001	0.184
TECD[6]	0.980	0.762	0.158	0.967	0.578	0.046	0.707
PIE-Net[14]	0.950	0.898	0.964	0.946	0.626	0.275	0.759
NECDNet (Ours)	0.998	**0.987**	0.921	0.997	0.957	0.496	0.972
NECDNet† (Ours)	**1.000**	0.974	**0.987**	**0.999**	**0.968**	**0.536**	**0.983**

PIE-Net 的数据基于其作者提供的评估结果整理得出。

† 表示使用从 Mesh 模型估计的法向量。

检测 Precision 仅为 0.001，F1 分数更是低至 0.002，几乎完全丧失了角点识别能力。其整体 MCC 仅为 0.184，说明预测结果与真实值之间的相关性极低。

TECD 方法试图通过两步策略改进检测效果，即先检测边缘再基于边缘定位角点。相较于 CA，TECD 在边缘检测上取得了一定进步，表 3.4 显示其具体案例的边缘 F1 提升至 0.732。然而，其级联设计的缺陷在角点检测中暴露无遗：角点检测完全依赖于第一步边缘提取的质量，早期错误会被后续步骤放大。从表 3.4 可以看出，尽管 TECD 的边缘召回率尚可，但其角点 Recall 仅为 0.158，F1 分数仅为 0.089，这表明绝大多数角点被漏检。此外，TECD 的整体分类一致性 MCC 为 0.707，虽然优于 CA，但仍远低于 NECDNet 的 0.972。这种性能差距主要源于 TECD 对多个手工阈值的敏感性，难以通过单一参数设置适应图 3.5 中多样化的几何特征。

相比之下，NECDNet 在各个维度上均展现出压倒性优势。在这些典型复杂对象的测试中，NECDNet 在保持极高面部识别精度（Precision $>$ 0.99）的同时，将边缘 F1 分数提升至 0.978，角点 F1 分数提升至 0.664（Mesh 法向版本更达到 0.698）。特别是在 MCC 指标上，NECDNet 达到了 0.972，比 TECD 高出 37.5%。这得益于端到端的特征学习机制，使其能够自适应地处理不同尺度的几何结构，有效克服了传统

方法参数敏感和级联误差积累的问题。

2） 与现有深度学习方法的对比

在深度学习方法中，PIE-Net（Point-wise Implicit Embedding Network）是目前最有代表性的工作。然而，从图 3.5 的可视化对比中可以观察到，PIE-Net 虽然能够检测出大致的轮廓，但在角点区域的识别上存在明显的模糊，且在平滑曲面上容易产生误检点。基于 PIE-Net 作者提供的评估数据，本文结合 ABC-Corner 数据集上的实验结果，对其各项指标进行了重新计算与整合。

结合表 3.4 针对这四个典型复杂对象的定量评估，NECDNet 相比 PIE-Net 展现出了显著的性能提升。具体而言，PIE-Net 在角点检测任务上的 Precision 仅为 0.278，虽然 Recall 高达 0.964，但这极低的精确率说明其高召回率是建立在大量误检（过分割）的基础上的。这直接导致其角点 F1 分数仅为 0.432，意味着其检测的可信度较低。作为对比，NECDNet 在保持高召回率（0.921）的同时，将角点 Precision 提升至 0.519（提升 86.6%），使得 F1 分数达到 0.664（提升 53.7%）；若使用 Mesh 法向量，F1 更达到 0.698。在边缘检测方面，NECDNet 的边缘 F1 (0.978) 也显著优于 PIE-Net 的 0.770。此外，在反映整体分类质量的 MCC 指标上，NECDNet 达到 0.972，远超 PIE-Net 的 0.759。

PIE-Net 性能受限的根本原因在于其采用的双分支架构设计。该方法使用两个独立的分支分别处理边缘和角点检测，这种独立设计割裂了边缘与角点作为相互关联几何特征的内在联系，导致网络难以利用边缘信息来辅助角点定位。由于缺乏对边缘与角点特征差异性的联合鉴别机制，PIE-Net 容易产生较多的误检（False Positives），正如其仅为 0.278 的角点 Precision 所示。相比之下，NECDNet 通过统一的多尺度特征融合架构和分层分类器，能够更有效地捕捉局部几何结构中的细微差异，特别是利用从网格模型估计的精确法向量作为输入时，模型的整体 F1 分数和分类一致性均达到最优水平，展现了极高的鲁棒性。

3.4.2 纯边缘检测结果分析

为了验证模型在通用边缘检测任务上的有效性，表 3.5 展示了在 ABC 数据集上仅关注边缘二分类任务时的对比结果。由于 PCEDNet 和 BoundED 未开源代码，我们引用了其论文中的数据进行对比。本文的模型在该部分实验中进行了调整，将边缘和角点合并为一个类别进行二分类训练，以适应纯边缘检测的评估需求，记作

NECDNet-2c 和 NECDNet-2c†（分别对应使用基于 PCA 的法向量和使用从 CAD 网格模型提取的精确法向量）。

表 3.5 ABC 数据集上各边缘检测方法的指标评分

Table 3.5 Metrics for edge detection methods on the ABC dataset.

评估方法	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
PCEDNet-2c†[12]	0.735	0.984	0.822	0.970	0.597	0.808
BoundED-2c[13]	**0.959**	0.857	0.875	0.987	0.778	0.869
NECDNet-2c (Ours)	0.708	0.988	0.825	0.980	0.702	0.827
NECDNet-2c† (Ours)	0.922	**0.992**	**0.956**	**0.996**	**0.915**	**0.954**

PCEDNet 和 BoundED 的数据分别整理自文献[12] 和[13]。

† 表示使用从 Mesh 模型估计的法向量。

表 3.5 的结果显示，NECDNet 在边缘检测任务上同样表现出色。使用 Mesh 法向量的 NECDNet-2c† 在 Precision、Recall、F1、Accuracy、IoU 和 MCC 等所有指标上均显著优于 PCEDNet 和 BoundED，尤其是在 F1 分数上达到 0.956，远超 PCEDNet 的 0.822 和 BoundED 的 0.875。这表明 NECDNet 不仅能够准确地提取边缘特征，还能有效地减少误检和漏检，提高了整体的检测质量。而利用基于 PCA 的法向量输入的 NECDNet-2c 也表现出较强的竞争力，尤其是在 Recall 上达到 0.988，说明模型能够尽可能多地检出潜在边缘，虽然 Precision 相对较低（0.708），但整体 F1 分数仍然优于 PCEDNet。

除了定量指标对比，图 3.5 的可视化结果也直观展示了各方法在边缘检测上的表现。PCEDNet（图示第四行）作为一个专门的边缘检测网络，能够清晰、连续地提取出物体的几何轮廓，展现了良好的边缘提取效果，但其局限性在于仅能输出二值的边缘预测结果，无法区分边缘与角点。此外，PCEDNet 使用的是基于网格模型的法向量。与此相比，本文提出的 NECDNet 在边缘检测的视觉质量上与其相当，均能提取出锐利且干净的边缘线条，同时还能准确识别出角点特征。对于 BoundED，由于其作者未将模型开源，依据其论文中的描述进行复现时，复现的结果与其论文中的结果存在较大差异，故本文舍弃了该方法的可视化对比，仅在定量指标上进行了对比分析。

整体实验表明，NECDNet 在边缘与角点的联合检测任务中表现出色，并且在纯边缘检测任务中同样具有竞争力。特别是使用从 CAD 网格模型提取的精确法向量作

为输入时，NECDNet 的性能得到了显著提升，进一步验证了法向量估计精度对检测性能的关键影响。

3.4.3 法向量估计精度对检测的影响

在深入分析实验结果后，本文发现法向量的精度是影响检测性能的关键因素。NECDNet 的部分输入特征（法向角差、法向分布及投影法向模长）均直接依赖于法向量的计算。从表 3.3 可以看出，仅通过改变法向量的来源，模型的 F1 分数就从 0.715 提升至 0.815，增幅达 13.9%，这充分体现了法向量对检测性能的决定性影响。

为了量化这一影响，本文详细对比了两种法向量估计方式。基于点云局部表面最小二乘拟合的方法假设邻域点位于一个光滑平面上。然而，在物体的尖锐边缘和角点附近，这一假设被打破：邻域点横跨了两个或多个法向截然不同的平面。此时，拟合算法会产生平滑过渡的” 平均化” 法向，而非真实的表面法向。

为了更深入地理解法向量精度对检测性能的影响，我们进行了详细的数值分析。考虑一个尖锐的角点邻域：邻域点分别来自两个法向为 $\mathbf{n}_1$ 和 $\mathbf{n}_2$ 的平面，两个平面的夹角为 90 度。当使用基于最小二乘拟合的法向估计方法时，得到的平均法向 $\mathbf{n}_{\text{avg}}$ 会被迫介于两个真实法向之间，其与真实法向的夹角为 45 度。这种方向上的偏差虽然看似不大，但会直接影响法向角差、法向分布方差等特征的计算。由于这些特征是分类器的核心输入，45 度的法向偏差会导致角点和边缘点的特征值在特征空间中变得接近，从而显著增加分类的困难。

图 3.6 的对比实验清晰地展示了这种影响。在使用点云估计法向的结果（图 3.6(c)）中，由于邻域法向的平滑化，原本尖锐的边缘特征和角点特征在特征空间中的表现变得模糊和重叠。这种混淆直接导致网络将部分边缘点误判为角点，或将角点误判为边缘点，从而产生 0.715 的 F1 分数。相反，当使用从 Mesh 模型计算出的法向量时（图 3.6(b)），法向量能够精确反映物体的几何拓扑结构。特别是在尖锐特征处，Mesh 法向能够保留法向的突变特征，而不会出现平滑化造成的方向混淆。这使得网络能够准确捕捉到微小的曲率变化，从而实现近乎完美的分类效果，F1 分数达到 0.815。

上述分析表明，虽然 NECDNet 具有强大的多尺度特征提取能力，但其对输入法向量的精度存在较高的依赖性。在实际应用场景中，往往难以获取完美的网格模型，仅能基于含噪点云进行法向估计，这在一定程度上限制了模型的性能上限。因此，如

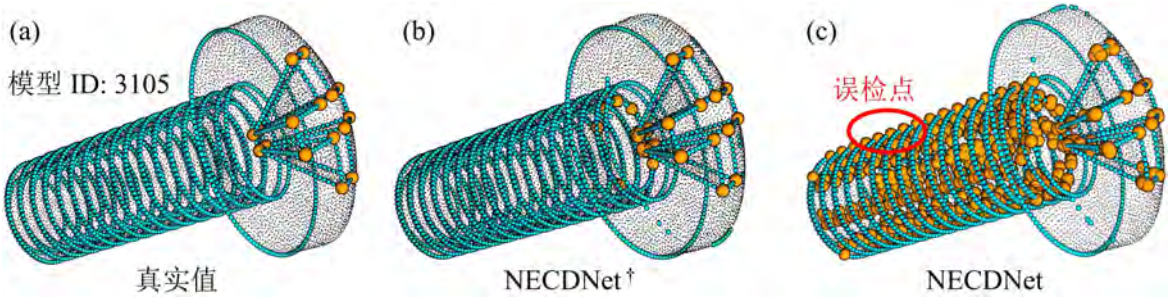


图 3.6　法向量估计方法对检测结果的影响分析：(a) 检测结果真值；(b) 使用从模型估计的法向量；(c) 使用从点云估计的法向量

Figure 3.6　Analysis of the impact of normal vector estimation method on detection results: (a) Ground truth; (b) Using normals estimated from Mesh; (c) Using normals estimated from point cloud.

何在缺乏网格先验的情况下，缩小基于点云与基于网格的检测性能差距，是后续研究值得深入探讨的方向。

3.5　消融实验分析

为了验证 NECDNet 各个模块设计的合理性，本节基于 ABC-Corner 数据集开展了多维度的消融实验。实验设定随机抽取 100 个模型对应的点云数据用于训练，另取 100 个用于测试，控制变量以确保结论的可靠性。主要包括对网络学习的输入特征维度、多尺度参数选择、数据处理策略等方面的参数分析。通过对比不同配置下训练得到的模型定性评价指标，探讨各设计选择对模型性能的具体影响。

3.5.1　特征维度

特征描述子的选择直接决定了网络输入信息的丰富程度与有效性。在构建特征向量时，除了最终选用的 6 个标量特征（$\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i$）外，实验还尝试引入了 3 维 PCA 特征值向量 σ_i 和 3 维法向量差均值向量 $\Delta\bar{\mathbf{n}}_i$。表 3.6 展示了不同特征维度组合的性能差异。各组合从上至下依次代表：仅使用基于位置的特征、仅使用基于法向的特征、使用所有标量特征、使用所有标量特征加上法向差均值向量、使用所有标量特征加上 PCA 特征值向量、使用所有特征。

实验结果显示，当模型仅使用 6 个标量特征时，各项评价指标反而达到了最高值。只使用部分特征时，模型性能明显下降，尤其是当仅使用基于位置的特征时，F1 分数仅为 0.654；而仅使用基于法向的特征时，F1 分数提升至 0.719，但仍不如使用标量特征的组合。而引入向量特征后，性能未升反降。分析其原因，$\hat{\boldsymbol{\sigma}}_i$ 和 $\Delta\bar{\mathbf{n}}_i$ 特征

表 3.6　特征维度选择消融实验结果

Table 3.6　Ablation study results for feature dimension selection.

特征组合	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i)$	0.647	0.847	0.654	0.977	0.601	0.790
$(\bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.680	0.922	0.719	0.986	0.656	0.886
$(\kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	**0.754**	**0.946**	**0.805**	**0.996**	**0.735**	**0.946**
$(\kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.714	0.935	0.758	0.994	0.693	0.929
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.739	0.946	0.793	0.995	0.720	0.934
$(\hat{\boldsymbol{\sigma}}_i, \kappa_i, \bar{d}_i, r_i, \bar{\Delta\mathbf{n}}_i, \mu_{\theta,i}, \sigma^2_{\theta,i}, \bar{\text{proj}}_i)$	0.743	0.940	0.797	0.994	0.722	0.929

特征计算的具体方法详见章节 2.3.2 所述。

维度与其他标量特征相比显著增加，导致特征空间维度过高，训练数据不足以覆盖整个特征空间，进而引发过拟合问题。此外，这些向量特征在尖锐边缘和角点处的分布较为复杂，可能引入了更多的噪声和不稳定性，反而削弱了模型的判别能力。

因此，尽管引入更多维度的特征理论上可以提供更丰富的信息，但在实际训练过程中，过多的特征维度反而可能导致模型性能的下降。最终，使用所有标量特征的组合在保持信息丰富性的同时，避免了过拟合和噪声引入的问题，从而实现了最佳的检测性能。

3.5.2　多尺度参数

多尺度特征融合是解决点云密度不均和特征尺度变化问题的关键。本节对尺度数量和尺度范围（邻域大小 k）进行了探索，有关尺度的定义请见章节 2.2.1。实验设定 k 的取值范围覆盖 8 到 128，尺度数量从 2 增加至 8。表 3.7 表明，随着尺度数量的增加，模型性能呈现先上升后下降的趋势。

表 3.7　多尺度参数选择消融实验结果

Table 3.7　Ablation study results for multi-scale parameter selection.

尺度选择 (k)	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
(8, 16)	0.704	0.913	0.751	0.993	0.680	0.910
(8, 16, 32, 64)	**0.743**	**0.940**	**0.797**	0.994	**0.722**	0.929
(8, 16, 32, 48, 80, 128)	0.723	0.927	0.770	**0.995**	0.702	**0.932**
(8, 16, 24, 32, 48, 64, 96, 128)	0.740	0.935	0.795	0.994	0.718	0.930

尺度的定义对应于 k-NN 邻域大小 k。

当选择 4 个尺度（$k = 8, 16, 32, 64$）时，模型取得了最佳的 F1 分数和 IoU。当尺

度数量过少（如 2 个）时，网络的感受野受限，难以提取宏观的几何结构信息；而当尺度数量过多（如 6 个或 8 个）时，不仅计算开销显著增加，而且大尺度的邻域（如 $k = 128$）引入了过多的无关背景噪声，平滑了局部的尖锐特征，从而抑制了网络的判别能力。因此，4 个尺度的设置在特征丰富度与噪声控制之间取得了最佳平衡。

3.5.3 训练策略

针对类别不平衡问题，本节对数据处理和样本标注策略进行了系统的对比研究。其中，数据处理主要涉及对各类样本的重采样操作，旨在平衡不同类别点的数量；而标注策略则关注是否对尖锐特征（边缘、角点）进行平滑处理，即是否将其附近一定范围内的邻域点也视为该特征点。

1） 数据重采样策略

在数据重采样方面，实验对比了两种策略。第一种策略是” 边缘与角点重采样”，即对边缘点和角点进行重采样，使其数量与面点数量保持一致，达到 1:1:1 的比例。第二种策略是” 仅角点重采样”，仅对数量最稀少的角点进行适度重采样。

实验结果如表 3.8 所示。两种策略的性能差异极小，F1 分数分别为 0.795 和 0.797，仅相差 0.2%。然而，第一种 1:1:1 的完全平衡策略会使训练数据集规模显著增长，导致训练时长大幅增加。在效率优先的考量下，最终选择了” 仅重采样角点” 的策略。这种选择充分平衡了检测性能与计算成本，既能缓解类别不平衡问题，又避免了过度的数据冗余。

表 3.8 数据重采样策略的消融实验结果

Table 3.8 Ablation study results for data resampling strategy.

重采样策略	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
边缘与角点	0.741	**0.941**	0.795	**0.994**	0.721	0.923
仅角点 (Baseline)	**0.743**	0.940	**0.797**	**0.994**	**0.722**	**0.929**

2） 标注平滑策略

在样本标注方面，本文探索了” 平滑尖锐特征” 策略的可行性，这一策略受到边缘检测方法 PCEDNet 中” 平滑边缘” 方法的启发[12]。具体做法是将尖锐特征（边缘、角点）附近一定范围内的邻域点也标记为该特征参与模型训练，在增加少数类数据的同时降低尖锐特征与平滑特征之间的差异。

实验结果如表 3.9 所示。引入平滑策略后，性能反而出现明显下降，F1 分数从 0.797 降至 0.736。这主要是因为边缘点和角点在几何拓扑上具有本质差异。边缘特征具有连续性，温和平滑有助于强化连通性；而角点属于奇异点，具有极高的局部化特征。当人为地扩展角点标签范围到邻域内时，会使原本属于面点或边缘点的邻域点被强制标记为角点，破坏了样本标签的一致性，导致分类器决策边界模糊。因此，最终方案坚持对尖锐特征进行精确的单点监督，不使用平滑策略。

表 3.9　标注平滑策略的消融实验结果

Table 3.9　Ablation study results for smoothing strategy.

标注策略	Precision(↑)	Recall(↑)	F1(↑)	Accuracy(↑)	IoU(↑)	MCC(↑)
使用平滑	0.706	0.874	0.736	0.989	0.670	0.868
不使用平滑 (Baseline)	**0.743**	**0.940**	**0.797**	**0.994**	**0.722**	**0.929**

3.6　本章小结

本章系统地评估了 NECDNet 在点云几何特征检测任务中的性能。首先，详细介绍了 ABC-Corner 数据集的构建流程及实验参数配置。对比实验结果表明，NECDNet 在边缘与角点联合检测及纯边缘检测任务中均优于现有的传统方法及深度学习模型，且法向量精度的分析进一步证实了高质量几何先验对尖锐特征检测的重要性。在消融实验中，验证了特征选择与多尺度架构的合理性。特别是针对训练策略的深入探讨，明确了” 仅角点重采样” 在兼顾性能与效率上的优势，并通过对比标注策略，揭示了保持角点拓扑奇异性对于分类决策边界的重要性，否定了平滑标注在角点检测中的适用性。本章工作确立了 NECDNet 的最佳配置，证明了其从复杂点云中提取高质量几何特征的能力，为下游机器人感知任务提供了可靠支持。

第四章　适应复杂几何特征接触的机器人抓取规划

4.1　引言

机器人抓取规划是机器人操作中不可或缺的步骤，其目标是确定机械手与目标物体之间的接触点，以实现稳定且可靠的抓取。抓取规划的方法多种多样，涵盖了从基于模型的方法到基于学习的方法。其中基于模型的方法通常依赖于物体的几何信息，通过分析物体表面的形状特征来选择合适的接触点。基于学习的方法则利用大量的抓取数据，通过训练神经网络等机器学习模型来预测最佳的抓取位置。在已知物体几何模型的情况下，例如工业场景下的零件分拣、码垛任务，基于模型的抓取规划方法因其解释性强、计算效率高和精确性而被广泛应用[15-16]。

在基于模型的抓取规划方法中，传统的规划方法通常侧重于面接触，忽略了边缘和角点等几何特征的潜在优势[21,51]。然而，在实际应用中，边缘和角点接触往往能够提供更高的抓取适应性和灵活性，特别是在处理复杂形状，或物体所处环境不适用面接触时。因此，本文针对物体的几何特征，提出了一种接触点采样与配对方法，结合软接触模型对抓取稳定性进行评估，并引入抓取增强策略以提升整体抓取性能。

基于模型的抓取规划方法，输入的物体模型通常以三角网格的形式表示，最后输出一系列的手爪相对物体的六自由度（6-DOF）位姿以及对应的手爪宽度、抓取稳定评分等参数。本文的方法采用基于采样点进行抓取规划，如图 4.1，规划流程包含几何特征检测、抓取构型检测及稳定性评估等关键步骤。图中的物体为本文单独进行构建的，命名为箭头，目的是展示三种不同几何特征（面、边、角）能实现的六种接触方式（面-面，面-边，面-角，边-边，边-角，角-角），后续的相关方法具体介绍也将以该物体为示例。

本文的抓取规划算法具体而言，首先通过类别感知的体素采样方法，均衡地从物体表面的面、边、角区域采样潜在接触点。其次，本文设计了特征化的接触检测器，分别针对面接触、边接触和角接触进行检测，得到各种查询点对应的潜在接触点对。随后，基于法向量约束和几何位置的筛选规则，实现对偶接触点的配对。之后通过抓取增强策略提升抓取数量并进行手爪与被抓物体的碰撞检测。最后，采用软

接触模型对生成的抓取构型进行稳定性评估，得到最终的稳定抓取构型。

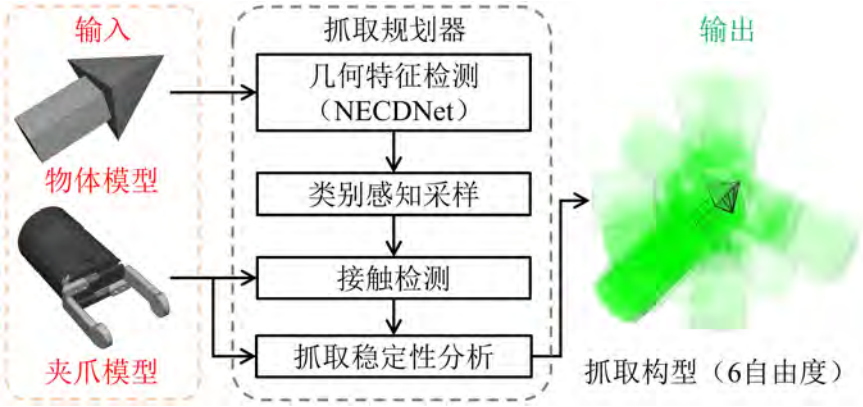


图 4.1　适应复杂几何特征接触的机器人抓取规划框架

Figure 4.1　Robotic grasp planning framework based on geometric features.

4.2　类别感知的接触点采样

基于采样点进行抓取规划的方法，首先需要从物体表面获取潜在的接触点。然而，若直接采用全局采样方法，物体的面（Face）、边（Edge）和角（Corner）区域的采样分布将呈现严重的“长尾”特征：即由于面区域占据了绝大部分表面积，接触候选点将主要集中在面上，而极少落在边或角上。这种分布不均将导致抓取规划难以充分利用物体的几何边缘特性，有悖于本文的研究目标。

为此，本文提出了一种类别感知的体素采样方法。该方法首先对物体表面的点云进行几何特征标记，随后在每个类别内独立进行采样。这不仅确保了不同几何区域（面、边、角）能获得数量近似的接触样本，避免了长尾问题，还有效提升了接触样本的多样性。本文将最终的采样点集记为 $\mathcal{S} = \{\mathbf{s}_i\}_{i=1}^{m}$，其中 m 为采样点总数，$\mathbf{s}_i$ 对应的几何特征标签记为 f_i，其取值范围为 $\{\mathtt{f}, \mathtt{e}, \mathtt{c}\}$，分别代表面、边和角。

4.2.1　几何特征检测

进行接触点采样前，首先利用第二章介绍的 NECDNet 算法架构对物体的几何特征进行检测与分类。由于 NECDNet 的输入为点云信息，需先通过均匀采样将物体的三角网格模型转换为点云表示，随后将其输入预训练网络。NECDNet 输出每个点的类别标签 f_i，将点云划分为面、边、角三类。由于基于模型的方法已知物体的真实法向量，上述网络选用了基于真实法向量训练的模型版本。

考虑到角点在物体表面通常呈稀疏且孤立的分布，直接使用原始检测点可能造成冗余。为了使结果更适用于抓取规划，本文在 NECDNet 检测后引入 DBSCAN（Density-Based Spatial Clustering of Applications with Noise）聚类算法对角点进行聚类处理[81]。DBSCAN 聚类过程如公式 (4.1) 所示，其中 P 表示待聚类的点集，ϵ 为邻域半径，$MinPts$ 为最小邻域点数。其核心思想是通过考察数据点的邻域密度，将密度较高的数据区域识别为簇，并能有效识别噪声点。算法首先随机选择一个未被访问的数据点，若其 ϵ 邻域内的点数不少于 $MinPts$，则以该点为核心，扩展形成一个新簇；否则，该点被标记为噪声。该过程不断重复，直到所有数据点均被处理，从而实现对数据点的聚类。

$$\text{DBSCAN}(P, \epsilon, MinPts) \tag{4.1}$$

聚类得到的每个簇对应一个角点区域。为简化表示并便于后续算法处理，首先计算各簇中点的质心，将其作为该区域的代表点。随后，为保持点云数据的一致性，利用原始点云的 KD-树检索距离质心最近的实际点，并将其标记为该区域的角点 c。这样不仅确保后续规划算法使用的仍为原始点云中的有效点，同时使角点的表达更加紧凑，有利于进一步的采样和配对操作。

4.2.2 基于类别的体素采样

在获得带有几何特征标签的点云后，本文采用基于体素的均衡采样方法。具体而言，首先将点云按几何类别划分为三个子集，随后分别对每个子集进行体素化处理：将空间划分为体素网格，并在每个非空体素内随机选择一个点作为采样点 $\mathbf{s}_i$。这种方法确保了采样点在空间上的均匀分布，并强制保证了数量较少的边缘和角点类别也能被充分采样，从而为后续的抓取规划提供均衡的候选集。

在本文方法中，体素网格的尺寸是影响采样效果的关键参数。由于抓取规划过程中模型尺寸需与实际物体尺寸保持一致，不能对物体进行归一化处理，因此体素采样参数 v 的定义参考了归一化物体的尺寸。具体而言，物体的实际尺寸通过其包围盒对角线长度进行度量。将实际尺寸与归一化参考尺寸的比值乘以设定的 v，即可获得用于点云采样的体素网格尺度。这种方式能够适应不同物体的尺寸变化，确保采样点数量处于合理区间。体素尺寸 v 可根据需求进行调节：较小的 v 生成更密集的采样点 $\mathcal{S}$，可拓展抓取规划的搜索空间但增加计算负担；较大的 v 则减少采样点，

可能遗漏部分关键几何信息。图 4.2 展示了同一物体在不同采样策略下的对比结果。图中结果表明，相较于全局采样，基于类别的体素采样能够在不同几何区域实现更均匀的分布。

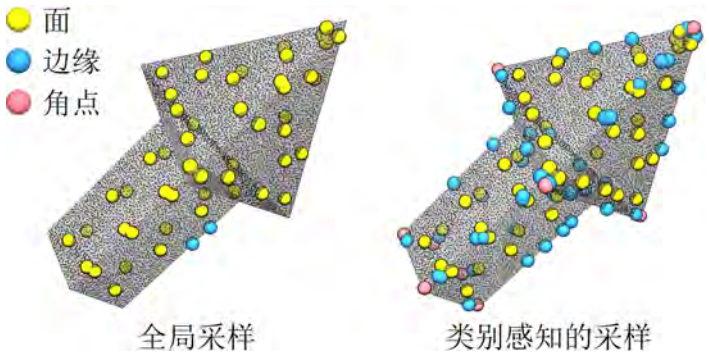


图 4.2 不同体素采样策略下的采样结果

Figure 4.2 Sampling results under different sampling strategies.

4.2.3 凸性检测

此外，为确保接触点具备物理可行性，本文引入了凸性检测（Convexity Check）机制，以剔除位于凹陷区域的点。具体方法为：对于每个下采样点 $\mathbf{s}_i \in \mathcal{S}$，首先定义其在采样前点云中 k 个最近邻点组成的局部邻域 $\mathcal{Q}_i^{\mathrm{s}}$，并计算邻域点的质心 $\mathbf{c}_i^{\mathrm{s}}$。然后，构造指向质心的向量 $\mathbf{v}_i^{\mathrm{s}} = \mathbf{c}_i^{\mathrm{s}} - \mathbf{s}_i$。通过计算该点法向量 $\mathbf{n}_i^{\mathrm{s}}$ 与 $\mathbf{v}_i^{\mathrm{s}}$ 之间的夹角 θ_i^{s}，用于判断其几何属性，如公式 (4.2) 所示：

$$\theta_i^{\mathrm{s}} = \arccos\left(\frac{\mathbf{n}_i^{\mathrm{s}} \cdot \mathbf{v}_i^{\mathrm{s}}}{\|\mathbf{n}_i^{\mathrm{s}}\|\|\mathbf{v}_i^{\mathrm{s}}\|}\right) \tag{4.2}$$

如图 4.3 所示，位于凹陷区域的点，其 θ_i^{s} 通常较小，而位于凸起区域的点则具有较大的夹角。选取阈值 θ_{th}，当 $\theta_i^{\mathrm{s}} < \theta_{th}$ 时，将该点判定为凹陷点并从采样集合 $\mathcal{S}$ 中剔除。由于平坦的指腹难以在凹陷位置实现稳定有效的接触，经过凸性筛选后得到的采样点集 $\mathcal{S}$ 既具备几何均衡性，又满足基本的物理接触约束，有效提升了抓取灵活性与成功率。

4.3 基于几何特征的接触对检测

在通过体素均衡采样获得具有类别标签的点集 $\mathcal{S}$ 后，抓取规划的下一阶段任务是搜索能够形成稳定力封闭（Force Closure）的对偶接触点对（Antipodal Contact

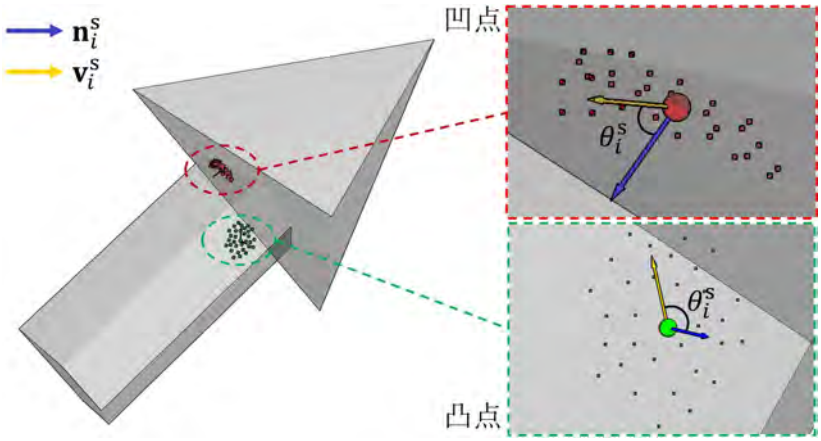


图 4.3 凸性检测中凹凸查询点对应 θ_i^s 对比

Figure 4.3 Comparison of θ_i^s for concave and convex query points in convexity check.

Pairs）。传统的接触检测方法，如基于射线投射（Ray-shooting）的采样策略，通常假设接触表面为理想平面，这极大地限制了机械手在复杂几何物体表面的抓取灵活性[21]。然而，在实际操作中，物体的边缘和角点往往提供了关键的几何特征，允许手指绕接触点或接触轴进行一定程度的旋转，从而在受限空间内实现有效抓取。

为了突破传统平面假设的局限，本文提出了一种基于几何特征的自适应接触对检测方法。该方法不再单一地依赖法向射线，而是针对面（f）、边（e）、角（c）三种不同的几何特征，分别构建了与之拓扑结构相适应的空间检测器：圆柱体、扇形柱和圆锥体。这一过程本质上是将接触点对的寻找转化为一个带几何约束的空间搜索问题。对于每一个作为查询点的采样点，算法利用其对应的检测器在物体空间中搜索潜在的对偶点。随后，结合法向量共线性约束和几何投影规则，对候选点集进行严格的筛选与配对，以确保生成的抓取构型在物理上满足指腹接触的稳定性要求。

图 4.4 展示了基于几何特征的接触对具体检测流程。首先，从采样集 $\mathcal{S}$ 中选取一个查询点 $\mathbf{s}_i$，根据其特征 f_i 生成对应的检测器 $\mathcal{D}_i$（圆柱、扇形柱、圆锥体）。计算 $\mathcal{D}_i$ 与点集 $\mathcal{S}$ 的空间交集，得到潜在的候选接触点集 $\mathcal{M}_i = \mathcal{S} \cap \mathcal{D}_i$，图 4.4(b) 中红色点。之后对 $\mathcal{M}_i$ 中的每个候选点 $\mathbf{m}_j^s$，根据其特征 f_j 以及与查询点 $\mathbf{s}_i$ 的几何关系，应用相应的配对策略进行筛选，最终得到符合稳定性要求的对偶接触点对 $\mathcal{C}_i$，图 4.4(c) 中黑色线段表示的单个查询点抓取对组合。遍历所有查询点，组合所有单个查询点的结果 $\mathcal{C}_i$ 为最终对偶接触点对规划结果 $\mathcal{P}$。

检测流程中的关键步骤包含：针对不同几何特征设计适配的空间检测器，以捕捉潜在的接触机会；利用几何约束对候选点进行筛选，确保生成的抓取构型满足物

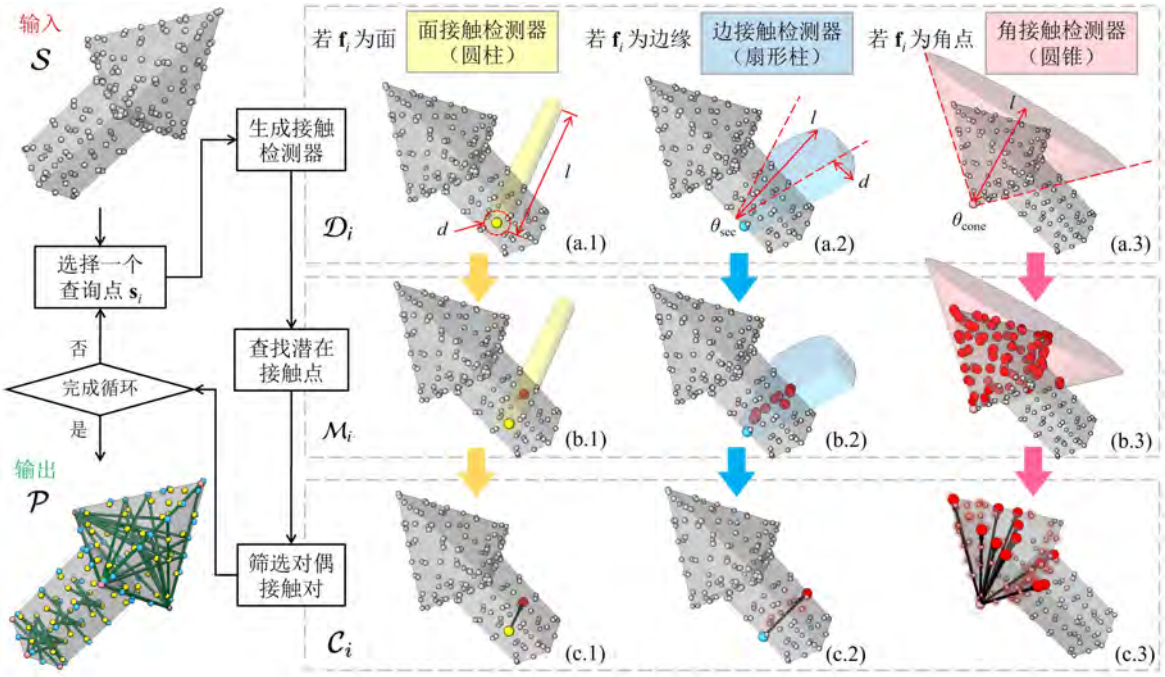


图 4.4　基于几何特征的接触对检测流程

Figure 4.4　Contact pair detection process based on geometric features.

理稳定性要求。通过上述方法，本文能够有效地从复杂的物体几何中提取出高质量的抓取构型。下文将详细介绍特征化接触检测器的设计以及对偶接触点的配对策略。

4.3.1　特征化接触检测器设计

为了捕捉不同几何自由度下的潜在接触机会，本文定义了一组参数化的几何约束检测器 $\mathcal{D}$。检测器的几何形态与尺寸严格依赖于查询点的几何特征类别 $f_i \in \{\mathtt{f}, \mathtt{e}, \mathtt{c}\}$，其构建方向始终沿查询点法向量的负方向 $-\mathbf{n}_i^s$ 延伸，旨在搜索位于物体“对侧”的表面区域。三种检测器的几何定义及示意如图 4.4(a.1-3) 所示。

1）　面接触检测器

面接触受限于半空间几何约束，要求手指指腹平面尽可能与物体表面平行。因此，面特征点的对偶搜索主要沿法线反方向进行。考虑到机械手并不能总是完美垂直于表面，且指腹具有一定的物理面积，本文将传统的射线模型扩展为圆柱体检测器，如图 4.4(a.1) 所示。圆柱体的直径 d 对应指腹的有效接触直径（对于平行夹爪，取 d 为指腹最大内切圆直径），代表了允许的横向接触容差。圆柱体的长度 l 决定了搜索的深度范围，为了确保能够覆盖物体的整体几何结构，本文将 l 设定为物体点云包围盒（Bounding Box）的最大对角线长度 d_{bb}。此时，检测器 $\mathcal{D}$ 定义为一个半径为

$d/2$、高为 l 的圆柱空间，凡是落入该区域的点均被视为潜在的对偶面接触点。

2） 边接触检测器

与面接触不同，边接触属于线接触模型。当手指与物体边缘接触时，机械手具备绕边缘轴线旋转的一个自由度。为了适应这种额外的旋转灵活性并捕捉边缘走向，检测器 $\mathcal{D}$ 被设计为扇形柱（Cylindrical Sector），如图 4.4(a.2) 所示。该检测器在法向截面上呈扇形，半径为 l，厚度为指腹直径 d。扇形的张角 θ_{sec} 决定了允许的旋转搜索范围，考虑到抓取稳定性，防止过大的倾角导致滑脱，本文限制实际使用时 $\theta_{\text{sec}} < 90°$。

在构建扇形柱检测器时，确定扇形的展开方向（即边缘切线方向）是关键步骤。由于原始点云具有较强的离散性，传统差分法推算法向量的鲁棒性较差，难以获得准确的切向信息。针对这一问题，本文采用随机采样一致性（Random Sample Consensus, RANSAC）算法对边缘点进行局部直线拟合，以获取高精度的切向量[82]。

具体而言，以当前查询边缘特征点 $\mathbf{s}_i$ 为中心，在仅包含边缘点的点云（采样前）中检索其半径 r 范围内的邻域点，形成局部点集。在局部点集中，通过 RANSAC 算法迭代执行直线拟合：每次随机选取两点确定一条直线模型，计算其他点到该直线的欧氏距离，并将距离小于一定阈值的点标记为局内点（inliers）。重复上述迭代过程一定次数，最终选取局内点数量最多的直线作为最优拟合结果。该直线的方向向量即作为边缘点 $\mathbf{s}_i$ 局部范围内的切向量。据此，可调整扇形柱检测器的姿态，使其厚度方向与该切向量保持平行，从而保证检测器能够沿着边缘的法平面准确展开，实现对边缘方向的鲁棒感知与拟合。

3） 角接触检测器

角接触近似为点接触模型，理论上允许手指绕接触点在三维空间内进行球面旋转。为了最大化搜索范围，检测器 $\mathcal{D}$ 被设计为圆锥体，如图 4.4(a.3) 所示。圆锥的高为 l，顶角 θ_{cone} 为可调参数。较大的 θ_{cone} 能够覆盖更广阔的对偶区域，但也可能引入几何上不稳定或发生干涉的抓取构型。与边检测器类似，θ_{cone} 的取值需在覆盖率与稳定性之间进行权衡。

上述检测器的设计充分考虑了不同几何特征下的接触自由度与机械手的物理限制，其尺寸参数主要包括 d、l、θ_{sec} 和 θ_{cone}。其中，d 和 l 直接关联机械手的指腹尺寸与物体的整体尺度，在手爪与物体确定的情况下无需进行参数调节。而 θ_{sec} 和 θ_{cone} 则反映了接触点的几何灵活性，可以进行调节以适应不同的抓取任务需求。章节 5.2.3 中

将探讨这些参数对抓取规划结果的影响。

4.3.2 对偶接触点配对策略

设计完成上述特征化接触检测器后，即可开展对偶接触点对的检测工作。具体可以分为两个步骤：首先，利用检测器在物体空间中搜索潜在的接触点对；其次，对潜在的接触点对进行对偶筛选，以确保生成的抓取构型在物理上满足稳定性要求。针对潜在接触点对的筛选工作，本文设计了一套基于几何特征的分类配对策略，对不同的接触点组合制定了相应的筛选规则，以确保生成的抓取构型在物理上满足稳定性要求。

如图 4.4 所示，对于 $\mathcal{M}_i$ 中的任意候选点 $\mathbf{m}_j^s$，虽然其空间位置满足检测器的几何约束，但仍需进一步验证其法向量和局部几何特征是否能与 $\mathbf{s}_i$ 构成稳定的力封闭抓取。为此，本文根据接触点对 $(\mathbf{s}_i, \mathbf{m}_j^s)$ 的特征组合，制定了不同的分类配对策略。后续配对特征描述中，点对特征表示为 (f_i-f_j)，其中 f_i 和 f_j 分别为查询点 $\mathbf{s}_i$ 和候选点 $\mathbf{m}_j^s$ 的几何特征类别。根据三种基本特征（面 `f`、边 `e`、角 `c`）的组合，存在六种可能的接触对类型：`f-f`、`f-e`、`f-c`、`e-e`、`e-c`、`c-c`。针对每种类型，本文设计了相应的配对规则，以确保生成的抓取构型在物理上满足稳定性要求。

1） 角-角接触配对（`c-c`）

当两个接触点均为角点时，由于角接触提供了最大的旋转自由度，且角点处的法向量通常具有较大的不确定性，过于严格的法向约束会导致可行解丢失。因此，对于 `c-c` 组合，只要点 $\mathbf{m}_j^s$ 落入圆锥检测器内，本文即认为该配对在几何上是可行的。

2） 角-边/面接触配对（`c-e`, `c-f`）

在此类组合中，一个接触点为角点（$\mathbf{s}_i$），另一个为边或面点（$\mathbf{m}_j^s$）。由于边和面对手指的姿态有较强的几何约束，且指腹尺寸有限，我们需要确保角点 $\mathbf{s}_i$ 能够稳定地落在对侧手指的有效接触区域内。为此，本文引入了指标 d_{proj}。该指标计算从 $\mathbf{s}_i$ 出发的射线在对侧点 $\mathbf{m}_j^s$ 的约束平面（对于面）或约束直线（对于边）上的投影偏离程度。具体计算如公式 (4.3) 所示：

$$d_{\text{proj}} = \begin{cases} \|\mathbf{d}_j^{\text{s}} - (\mathbf{d}_j^{\text{s}} \cdot \mathbf{n}_j^{\text{s}})\mathbf{n}_j^{\text{s}}\| & \text{若} f_j^{\text{s}} = \texttt{f} \\ \|\mathbf{d}_j^{\text{s}} \cdot \mathbf{t}_j^{\text{s}}\| & \text{若} f_j^{\text{s}} = \texttt{e} \end{cases} \tag{4.3}$$

其中，$\mathbf{d}_j^{\mathrm{s}} = \mathbf{m}_j^{\mathrm{s}} - \mathbf{s}_i$ 为接触连线向量，$\mathbf{n}_j^{\mathrm{s}}$ 为面点的单位法向量，$\mathbf{t}_j^{\mathrm{s}}$ 为边点的单位切向量。若 $d_{\mathrm{proj}} < d$（指腹直径），说明角点处于对侧指腹的有效覆盖范围内，判定该配对有效。

3） 面/边-面/边接触配对（`f-f`, `e-f`, `e-e`）

当接触对中不包含角点时，两个接触点均具有相对准确的法向量估计，且受到较强的几何约束。为了保证抓取的对指性质（Antipodal property），两点的法向量应近似相反，以抵消抓取力。定义法向夹角 θ_j^{s} 如公式 (4.4)：

$$\theta_j^{\mathrm{s}} = \arccos\left(\frac{\mathbf{n}_i^{\mathrm{s}} \cdot \mathbf{n}_j^{\mathrm{s}}}{\|\mathbf{n}_i^{\mathrm{s}}\|\|\mathbf{n}_j^{\mathrm{s}}\|}\right) \tag{4.4}$$

设定阈值 θ_{th}，若 $\theta_j^{\mathrm{s}} > \theta_{\mathrm{th}}$，则认为两点法向足够对立，配对有效。$\theta_{\mathrm{th}}$ 直接影响生成抓取的数量与质量：阈值越大，约束越严格，生成的配置越少但对指度越高。后续实验章节 5.2.3 展示了不同 θ_{th} 下的实验对比结果。

4.3.3 初步抓取构型生成

在完成接触点对的筛选与配对后，最后一步是根据确认有效的接触对 $(\mathbf{s}_i, \mathbf{m}_j^{\mathrm{s}})$ 计算机械手的 6-DOF 抓取位姿。一个完整的抓取构型通常由抓取中心位置 $\mathbf{j}_i$ 和抓取方向（即接触向量 $\mathbf{v}_i$）决定。

抓取中心 $\mathbf{j}_i$ 定义为两个接触点的几何中心，代表了机械手闭合时的理想中心位置，如公式 (4.5) 所示：

$$\mathbf{j}_i = \frac{\mathbf{m}_j^{\mathrm{s}} + \mathbf{s}_i}{2} \tag{4.5}$$

对于接触向量 $\mathbf{v}_i$，它决定了机械手接近物体的方向。由于面特征（`f`）对法向有严格的平行约束，即机械手必须沿着面法线的反方向接近以确保指腹贴合。而边和角特征允许一定的旋转自由度，手爪指腹可以绕接触点进行旋转以适应边缘或角点的几何特性。因此，针对不同的接触对类型，本文设计了不同的接触向量计算策略。

若接触对中包含面接触点（$f_j^{\mathrm{s}} = \mathtt{f}$），则优先采用面点的法向量 $\mathbf{n}_j^{\mathrm{s}}$ 作为接触方向，以确保指腹与平面贴合。若接触对仅由边或角点组成（$f_j^{\mathrm{s}} \in \{\mathtt{e}, \mathtt{c}\}$），则缺乏明确的表面法向约束，此时采用两接触点的连线方向作为接触向量，以最大化抓取力

的传递效率。计算方式归纳为公式 (4.6)：

$$\mathbf{v}_i = \begin{cases} \mathbf{n}_j^{\mathrm{s}} & \text{若} f_j^{\mathrm{s}} = \mathtt{f} \\ \mathbf{m}_j^{\mathrm{s}} - \mathbf{s}_i & \text{若} f_j^{\mathrm{s}} \in \{\mathtt{e}, \mathtt{c}\} \end{cases} \tag{4.6}$$

通过上述策略，本文能够从复杂的几何特征中高效地提取出满足物理约束的高质量抓取构型，为后续的运动规划奠定基础。

4.4 抓取构型增强及碰撞检测

在得到初步的抓取构型后，下一阶段的任务是对这些构型进行增强和筛选，以确保其在实际操作中的可行性与稳定性。具体而言，在上文得出的包含抓取中心和接触向量的抓取构型上进行旋转增强，以增加规划出的抓取数量，防止在运动规划阶段因环境避障或运动学奇异点而导致无解的情况。同时，由于初步抓取构型的生成过程并未显式考虑机械手与物体之间的空间干涉，因此需要引入碰撞检测机制，以剔除那些在几何上不可行的抓取构型，提升整体规划的成功率。该步骤在抓取规划流程中起到了关键的过滤作用，确保后续的稳定性评估和运动规划仅针对物理上可行的抓取构型进行，从而提升整体效率与成功率。

4.4.1 抓取构型增强策略

经过稳定性筛选的接触对仅确定了机械手的空间接触位置 $\mathbf{j}_i$ 和轴向接触矢量 $\mathbf{v}_i$。为了构建完整的 6-DOF 抓取构型，需进一步确定机械手绕接触轴（即夹爪坐标系 x 轴）的旋转角度 β，以定义机械手的姿态。不同的 β 角对应机械手在接触点周围的不同旋转位置，能够显著增加抓取构型的数量。

如图 4.5(a) 所示，机械手坐标系原点定位于抓取中心 $\mathbf{j}_i$，其 x 轴与接触向量 $\mathbf{v}_i$ 重合。此时，机械手仍保留一个绕 $\mathbf{v}_i$ 旋转的自由度。通过在 $[0, 2\pi)$ 范围内对旋转角 β 进行离散化采样，可基于单一几何接触对生成一系列具备不同末端姿态的抓取构型，如图 4.5(b) 所示。该策略显著扩充了候选抓取集，赋予了机器人在运动规划阶段应对环境避障及运动学奇异点时更大的解空间。

值得注意的是，尽管不同的 β 角对应不同的机械手末端位姿，其本质上基于同一组几何接触特征。因此，在后续章节（详见章节 5.2.3）对抓取分布多样性进行评估时，为避免统计数据的冗余与偏差，评估指标将主要聚焦于接触向量 $\mathbf{v}_i$ 的空间分

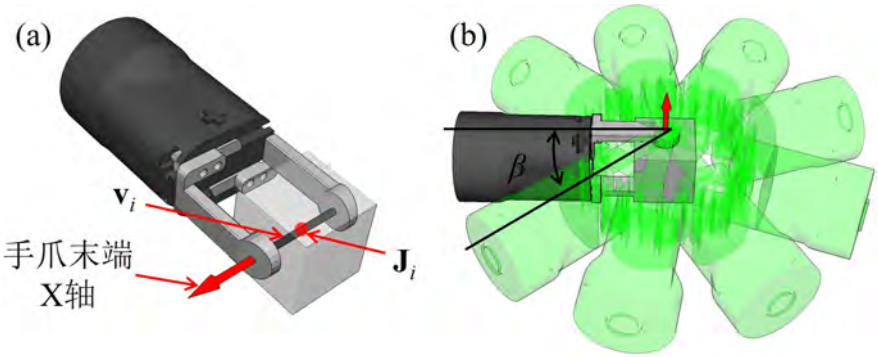


图 4.5　抓取构型增强示意图

Figure 4.5　Schematic of grasp configuration augmentation.

布（表征 3D 旋转多样性）以及抓取中心的位置分布（表征 3D 空间覆盖率），而非单纯统计增强后的配置总数。同理，在结果的可视化呈现中，为保持图像的清晰度，对于每个接触对仅随机选取一个 β 角生成代表性构型进行渲染，省略了密集的旋转增强结果。

4.4.2　碰撞检测策略

完成抓取构型增强后，每个候选抓取构型均对应一个确定的夹爪 6-DOF 位姿，由上文中的抓取中心 $\mathbf{j}_i$ 和接触向量 $\mathbf{v}_i$ 以及旋转角 β 共同定义。由于抓取对规划及增强过程并未显式考虑夹爪实体几何与目标物体的空间干涉，部分抓取构型可能会与物体发生几何干涉，无法作为合理的抓取规划结果。因此需要执行碰撞检测以剔除几何上不可行的候选构型，降低后续稳定性求解的计算负担并提升整体规划成功率。

碰撞检测的目标是在给定两组刚体几何模型及其空间位姿的情况下，判断二者是否发生几何干涉（interference）。对任意一对几何体 $\mathcal{A}$ 与 $\mathcal{B}$，碰撞检测通常可表述为：若存在至少一对点 $(\mathbf{x} \in \mathcal{A}, \mathbf{y} \in \mathcal{B})$ 使得两者在空间中相交或产生穿透，则判定为碰撞；反之则为无碰撞。本文在几何层面采用三角网格对场景物体进行建模，目标物体直接使用精细 CAD 网格以准确表征表面细节与局部凹凸结构。对于夹爪模型，为兼顾检测精度与批量筛选效率，本文将夹爪掌部、指体与指尖等刚体部件用多个有向包围盒（Oriented Bounding Box, OBB）进行组合近似。该组合式 OBB 表示能够在保留姿态相关外形特征的同时显著降低碰撞测试复杂度，适合对大量增强构型进行快速判定。

在碰撞求解器层面，本文采用 Open Dynamics Engine (ODE) 提供的碰撞检测机制，并将参与检测的几何体分别表示为 ODE 的碰撞几何对象：夹爪端执行器由若干

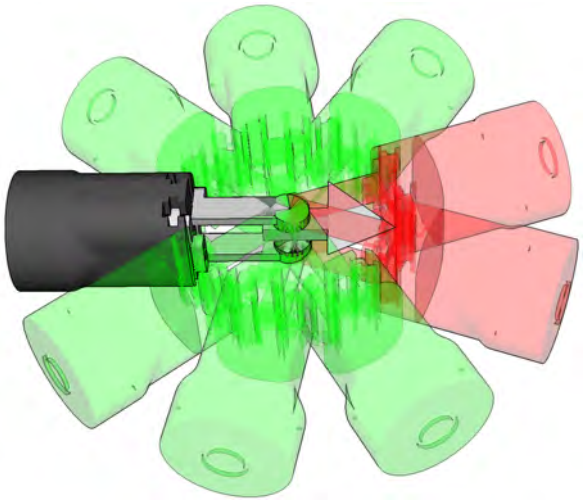


图 4.6　碰撞检测结果展示：红色表示发生碰撞的构型，绿色表示无碰撞的构型
Figure 4.6　Comparison of collision detection results: red indicate colliding configurations, green indicate non-colliding configurations.

OBB 碰撞体组合构成，目标物体则由其 CAD 三角网格构建为 TriMesh 碰撞体。在给定候选构型的 6-DOF 位姿后，首先对夹爪各 OBB 碰撞体施加相应的刚体变换，使其与当前抓取姿态一致；随后调用 ODE 的碰撞查询在夹爪与目标物体之间生成接触信息（contact manifold）。若碰撞查询返回的接触点集合非空，则说明夹爪碰撞体与目标物体 TriMesh 在该构型下发生几何接触或穿透，该候选构型被判定为不可行并从候选集中剔除；反之，若无接触点生成，则认为该构型在几何上无干涉并被保留，用于后续的稳定性评估与规划求解。

通过上述基于 ODE 的碰撞检测策略，本文能够在抓取构型增强产生的大规模候选集合中高效滤除与目标物体发生几何干涉的构型，确保后续计算仅针对空间上可执行的抓取构型进行，从而提升整体抓取规划流程的效率与鲁棒性，部分检测结果如图 4.6 所示。

4.5　基于软接触模型的稳定性评估

在初步获取潜在接触点对后，需对其进行物理层面的力学稳定性评估。实际应用中，机械手末端通常配备柔性指腹（Soft Finger Pad），其在接触物体时发生的弹性形变能够有效拟合目标表面的边、角等不规则几何特征。这种形变不仅显著增加了有效接触面积，还能通过接触面间的微观互锁提供额外的摩擦力矩，从而大幅提升抓取的鲁棒性。然而，柔性材料与复杂几何特征（特别是锐边与尖角）之间的接触力学呈现出高度的非线性，对其进行精确的有限元建模将带来巨大的计算开销，难以

满足抓取规划的实时性要求。

为此，本文提出一种基于离散化近似的软接触模型。该模型在保留指腹物理厚度与压缩特性的基础上，将复杂的连续软接触简化为一组分布式的硬点接触集合，进而利用经典的力封闭（Force Closure）理论进行高效的稳定性判别。

4.5.1 接触区域的离散化建模

指腹的变形能力在模型中被量化为沿法向的有效压缩深度。如图 4.7 所示，对于任意给定的接触对 $(\mathbf{s}_i, \mathbf{m}_j^s)$，以其接触向量 $\mathbf{v}_i$ 为轴向、接触点位置为中心，构建指腹的几何包围体（图中绿色圆柱所示）。设 t_{pad} 为指腹的物理厚度，引入无量纲参数 $\eta \in [0,1]$ 作为有效压缩系数，用于表征指腹在特定抓取力作用下的最大形变率。在此模型下，凡是落入指腹投影区域内且与指腹表面的距离小于有效变形阈值 $d_{\text{eff}} = \eta t_{\text{pad}}$ 的物体表面点，均被判定为有效接触点。

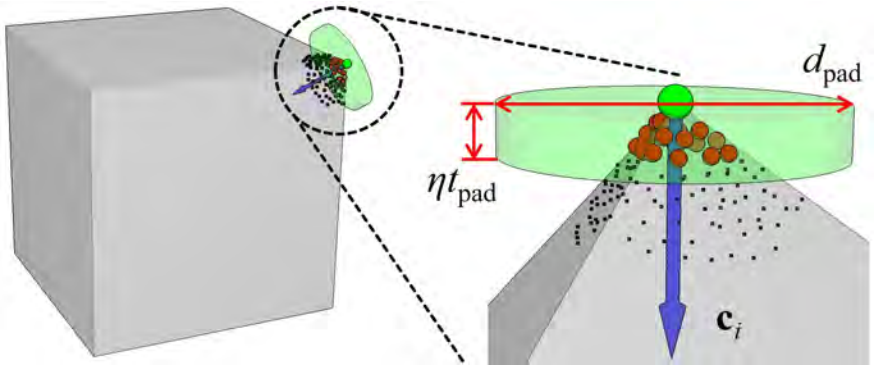


图 4.7　基于软接触变形的接触点集获取示意图

Figure 4.7　Obtaining contact points for stability estimation considering soft contact.

由于依赖于许多耦合因素，准确建模参数 η 数值较为困难。在物理场景中，柔性指腹材料的特性、施加的握力、物体材料以及接触区域的几何形状都会影响有效压缩，其中许多效应是非线性的。为此，本文选择采用实际实验进行参数标定。通过实验标定（以配备 3 mm 橡胶指腹的 DH-ROBOTICS PGC 夹爪为例，施加 100 N 抓取力），对于角接触与边接触，η 的经验值分别取约为 0.7 与 0.4。

基于上述定义，原本的单一接触点被扩展为一个离散的接触点簇 $\mathbf{C}_i = \{\mathbf{x}_{i,1}, \mathbf{x}_{i,2}, \ldots, \mathbf{x}_{i,|\mathbf{C}_i|}\}$（如图中红色点集所示）。对于簇中任意一点 $\mathbf{x}_{i,j}$，其局部接触法向量近似统一为指腹的进近方向 $\mathbf{n}_{\text{fp}}$。尽管物体表面的局部法向可能存在微小扰动，但在指腹包裹变形的假设下，该近似能够有效反映接触力的主传递方向。

4.5.2 力学平衡与稳定性判据

抓取稳定性的评估核心在于验证接触力空间中是否存在满足物理约束的可行解，以平衡重力及潜在的外力扰动。假设接触面摩擦系数 μ 均匀分布，对于点簇 $\mathbf{C}_i$ 中的任意离散点 $\mathbf{x}_{i,j}$，其接触力 $\mathbf{f}_{i,j}$ 需满足库仑摩擦定律（Coulomb Friction Law）约束：

$$\begin{cases} \mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}} \leq 0 & \text{(单向压力约束)} \\ \|\mathbf{f}_{i,j} - (\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}})\mathbf{n}_{\text{fp}}\| \leq \mu |\mathbf{f}_{i,j} \cdot \mathbf{n}_{\text{fp}}| & \text{(摩擦锥约束)} \end{cases} \tag{4.7}$$

上述约束保证了接触作用力仅表现为压力，且切向分量受限于最大静摩擦力。

系统的力矩平衡方程定义为：

$$\sum_{i=1}^{2} \sum_{j=1}^{|\mathbf{C}_i|} \begin{bmatrix} \mathbf{f}_{i,j} \\ \mathbf{r}_{i,j} \times \mathbf{f}_{i,j} \end{bmatrix} + \mathbf{w}_{\text{g}} + \mathbf{w}_{\text{ext}} = \mathbf{0} \tag{4.8}$$

其中，$\mathbf{r}_{i,j}$ 表示接触点 $\mathbf{x}_{i,j}$ 相对于物体质心的位置矢量；$\mathbf{w}_{\text{g}} \in \mathbb{R}^6$ 为重力旋量（Wrench），包含重力及其产生的力矩；$\mathbf{w}_{\text{ext}} \in \mathbb{R}^6$ 代表外部扰动旋量（本研究中设为零向量，但模型保留其通用性）。

若线性规划求解器能在约束范围内找到一组可行力解 $\{\mathbf{f}_{i,j}\}$，则判定该抓取构型具备力封闭稳定性。需特别指出，与经典软指模型将接触简化为单点并附加显式扭转摩擦约束不同[83]，本文采用的分布式多点接触模型通过积分离散点集产生的力矩（即 $\sum \mathbf{r}_{i,j} \times \mathbf{f}_{i,j}$ 项），能够隐式且更真实地捕捉软指腹抵抗旋转扭矩的物理特性，避免了对扭转摩擦系数的显式约束。

4.6 本章小结

本章针对机器人操作中复杂几何物体的抓取难题，面向传统方法在处理非平面特征时的局限性，提出了一种融合面、边、角多维几何特征的系统化抓取规划方法。首先，针对物体表面几何特征分布不均导致的采样“长尾”问题，本文提出类别感知的体素均衡采样策略，并结合 NECDNet 特征推理与 DBSCAN 聚类实现面、边、角区域的独立体素化采样，确保稀疏特征（如角点）在候选集中的有效覆盖。其次，依据不同几何特征的自由度约束特性，设计圆柱体、扇形柱和圆锥体等特征化空间接触检测器，构建相应的对偶接触点配对策略，并通过投影距离与法向夹角联合筛选

提升候选抓取的几何合理性。最后，为准确评估柔性指腹在边缘与角点处的接触稳定性，本文建立基于离散化近似的软接触力学模型，将连续非线性软接触转化为分布式硬点接触簇，实现基于力封闭理论的高效判别，并结合沿接触轴旋转采样的抓取构型增强策略扩展可行解空间。综上，所提方法有效突破了传统平面接触假设的束缚，显著提升了抓取规划算法对复杂几何外形的适应性，为后续实验验证与实际应用提供了理论与算法支撑。

第五章　面向复杂接触的机器人抓取规划对比实验

5.1　引言

本章旨在通过系统性的实验研究，全面评估本文提出的考虑边缘与角点接触特征的机器人抓取规划方法的性能。为了验证算法在处理复杂几何形状物体时的有效性、鲁棒性及计算效率，本章构建了包含仿真分析与物理样机验证在内的多层次测评体系。首先，详细介绍了实验系统的软硬件环境搭建方案，以及涵盖多种典型几何特征的测试对象集选取依据。随后，通过参数敏感性分析确定了算法的最优配置，并以此为基础，将本文方法与多种主流抓取规划算法进行了对比实验。实验重点从抓取构型的空间分布多样性与真实物理环境下的抓取成功率两个核心维度展开，深入分析了引入边缘与角点接触对提升抓取性能的具体贡献。最后，本章还统计了算法的运行耗时，以验证其在实际工程部署中的实时性与可行性。

5.2　实验环境及参数配置

进行实验验证前，需要搭建一个能够支持算法测试的完整实验环境，并合理配置关键参数以确保实验结果的有效性与可比性。首先需要搭建物理实验平台和软件仿真平台，支持后续的对比实验。此外，根据后续抓取实验的需求，本文还对算法中的关键参数进行了系统性的分析与调优，确保参数配置的合理性。最后，针对实验中的物体模型，本文构建并从多个数据集中选取了具有代表性的测试对象，以全面评估算法在不同几何特征上的表现。

5.2.1　实验平台搭建

实验平台主要由物理实验平台和软件仿真平台两部分组成，分别用于验证算法在真实环境中的抓取性能以及在仿真环境中的抓取构型分布特性。其中软件平台的可视化部分搭建基于物理实验平台的配置，以确保两者之间的一致性和可比性。图 5.1 展示了软硬件平台的整体架构与组成部分。

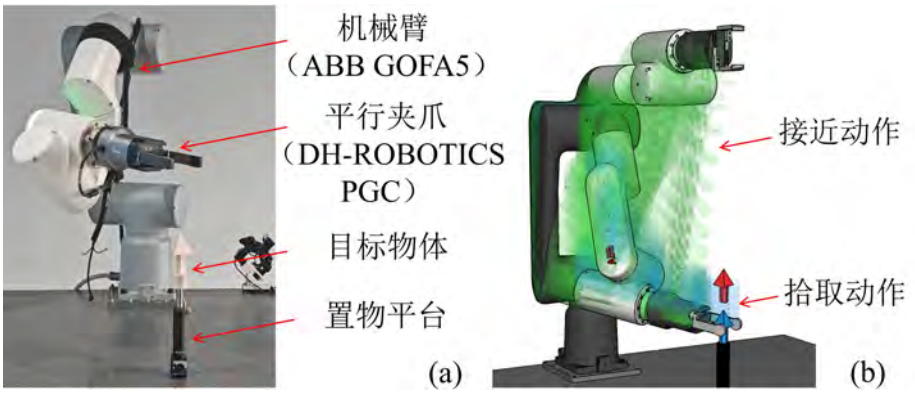


图 5.1　实验平台架构示意图：(a) 物理实验平台整体布局；(b) 软件仿真平台界面展示
Figure 5.1　The architecture of the experimental platform: (a) The physical experimental setup; (b) The software simulation platform interface.

1）　物理实验平台

针对物理实验平台的搭建，为了在真实世界中验证所生成的抓取候选的有效性，本文搭建了一套完整的机器人智能抓取系统实验平台。如图 5.1 所示，物理实验平台下位执行机构采用具备高精度力控与轨迹跟随能力的 ABB GOFA-5 六轴协作机械臂。系统末端执行器配备 DH-ROBOTICS 研发的 PGC 系列平行电动夹爪。该夹爪具备可多段调节的力控特性与灵活的行程适配能力。由于涉及多种不同尺寸的测试物体，通过手动预调整，该夹爪支持在 0-76 mm 与 30-106 mm 的双域张开宽度范围内切换，有效适配了多尺度的操控需求。被抓物体放置于一个固定的工作台上，工作台与机械臂基座之间的相对位置通过精确测量并在软件中进行标定，以确保仿真与物理实验环境的一致性。

此外，考虑到本文所提边缘与角点抓取方法对指腹变形特征的高敏感性，实物夹爪选用了带一定厚度的圆形柔性橡胶指腹。其设计直径为 28 mm，厚度为 3 mm，表面材质的摩擦系数通过预先测定约为 0.25。该构型能够为线接触与点接触提供足够的法向压缩空间，从而在此类局部曲率极大的特征上形成具备一定面积的类平面接触区域，有效支持了章节 4.5 中设计的基于软接触模型的稳定性评估算法。

2）　软件平台

在软件模拟与规划层面，本实验基于 World Robot System (WRS) 机器人操作系统进行开发与测试。WRS 是一个由日本学者万伟伟开发的开源综合机器人软件平台，集成了物理仿真、运动规划及可视化功能[21]。如图 5.1 右侧所示，本研究利用 WRS 提供的精确碰撞检测引擎与运动学解算器，对抓取规划算法生成的候选抓取位姿进

行验证，并生成无碰撞的机械臂运动轨迹。后续所有对比仿真实验与算法性能评估均在该软件框架下统一进行，以确保对比测试环境的一致性。

5.2.2 评估对象集选取

抓取实验的评估对象集选取是验证算法性能的关键环节。为了全面评估本文方法在处理不同几何特征物体上的表现，以及实现与其余算法的有效对比，本文从多个公开数据集中选取了具有代表性的物体模型，并结合人工构造的模型，以及日常生活中的常见物体，构建了一个包含十种不同几何特征的测试对象集。该对象集涵盖了从规则几何体到复杂曲面，从平面到锐边的多样化形状特征，能够充分考察算法在不同接触类型上的适应性与性能表现。选择的物体模型如图 5.2 所示，各物体的来源及选取依据如下：

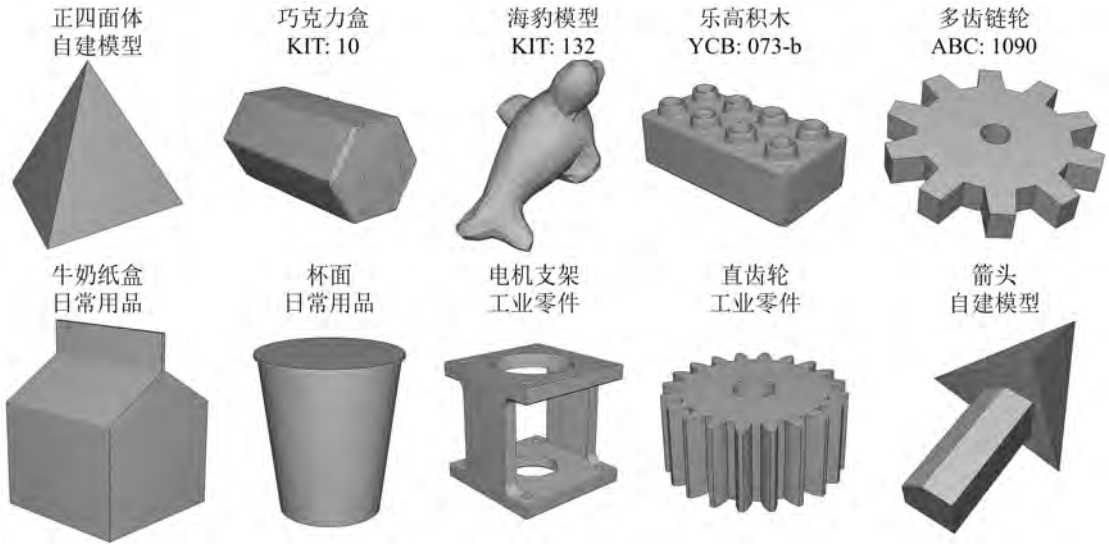


图 5.2　评估对象集的三维模型示例

Figure 5.2　The mesh models of the evaluation object set.

1. 正四面体：标准几何体，表面之间不包含任何平行的面对平面，是验证算法能否在无平行面场景中基于边、角特征稳定工作的重要参考基准。
2. 巧克力盒 (Amicelli)：来源于 KIT 数据集 (ID: 10)，一种典型的正六棱柱包装盒，主要用于考察规划器在扫描模型上基于棱边获取多样性配置的能力。
3. 海豹模型 (Seal)：来源于 KIT 数据集 (ID: 132)，整体无任何锐利直边，呈现出完全连续的平滑曲面结构，用以检测模型对于自由曲界面的适应性。
4. 乐高积木 (LEGO brick)：选自 YCB 数据集 (ID: 073-b)，是长方体与多个圆柱凸

起的组合，用于测算应对局部复杂凹凸拓扑特征的规划表现。

5. 多齿链轮 (Sprocket)：取自 ABC 数据集 (ID: 1090)，表面具备极其复杂且细密的几何分布，包含大量的倒角、凹槽与轮缘，挑战算法对于多尺度几何细节的鲁棒性。
6. 牛奶纸盒：典型日化包装物品，中部呈现平行面，顶部受折叠封口影响为倾斜表面及不同角度角的合集，评估算法在典型包装几何体上的表现。
7. 杯面：圆台形日用品，侧面为特定角度的斜圆锥面，同时顶部具带有凸起的薄壁边缘结构，对传统仅依赖面面接触的方法构成挑战。
8. 电机支架：典型车间用工业部件，具有各类镂孔结构机壁、折弯薄板及不规则表面组合，反映算法在制造零件上的性能。
9. 直齿轮：典型机械传动零件，包含阵列排列的齿状结构特征，从而向模型导入巨量的边缘及角点区域，挑战算法处理非平行接触类型的能力。
10. 箭头：手工构建的由正四面体和正五棱柱结合而成的异形物体。该设计用于展示所有 6 种两指接触种类（角-角、角-边、边-边、角-面、边-面、面-面）的特定目标情况。

上述物体中，自主构建及选自公开数据集的模型均有精准的网格模型，因此利用 3D 打印技术制作了实物。而实际物体则直接从市场上购买，经过精确测量后进行建模与标定，以确保仿真与物理实验环境的一致性。最终各物体的物理重量及体积相关测量信息详细统计于表 5.1 中。这些物体在质量分布与尺度空间上体现了多维度的差异，具备作为测试标准集的多样性特征要求。

表 5.1 实验测试验证对象集的质量及体积测量结果

Table 5.1 The mass and volume measurements of the evaluation object set.

物理属性	四面体	巧克力盒	海豹模型	乐高积木	多齿链轮
重量 (g)	59.27	52.68	29.63	49.72	33.58
体积 (cm^3)	155.16	505.06	226.29	627.66	404.21
物理属性	牛奶纸盒	杯面	电机支架	直齿轮	箭头
重量 (g)	213.91	106.50	152.71	19.90	69.81
体积 (cm^3)	3124.80	5134.24	569.90	226.98	258.56

5.2.3 实验参数分析及配置

确定实验平台及评估对象集后，还需对算法中的关键参数进行分析与配置，以确保实验结果的有效性与可比性。如第四章所述，本文的抓取规划算法涉及到部分需要进行人工调节的参数，这些参数的取值直接影响到特征提取的质量、接触点检测的数量以及最终抓取构型的生成。参数具体包括体素尺寸 v（章节 4.2.2）、接触检测器尺寸参数 $d, \theta_{\text{sec}}, \theta_{\text{cone}}$（章节 4.3.1）、接触对验证阈值 θ_{th}（章节 4.3.2）以及抓取增强旋转角 β（章节 4.4.1）。在正式进行对比实验前，本文对这些关键参数进行了系统性的敏感性分析与调优，以确定最优的参数配置。

1） 体素尺寸 v

体素尺寸 v 决定了点云采样的密度，直接影响可用于抓取规划的候选点数量。如图 5.3 所示，本文对比了 v 在 0.02, 0.025 及 0.03 时的采样效果。观察发现，随着 v 的增加，采样密度降低，导致点云稀疏且候选点减少。反之，较小的 v 值能产生更密集的表示，提供更多的潜在接触位置，但计算成本也随之增加。经过实验分析，选择 $v = 0.025$ 作为后续实验的默认参数，以在采样密度与计算效率之间取得平衡。此时采样点数约为 100 个，与其余类似方法的采样点数相差较小，利于后续对比实验的开展。

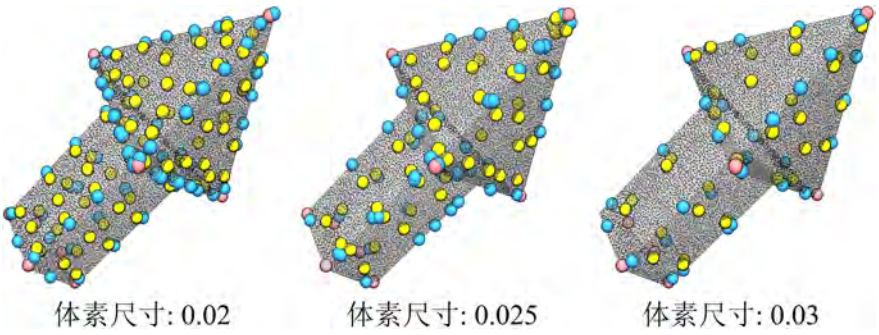


图 5.3 体素尺寸 v 对采样结果的影响分析

Figure 5.3 The influence of voxel size v on the sampling results.

2） 接触检测器尺寸 $d, \theta_{\text{sec}}, \theta_{\text{cone}}$

接触检测器的尺寸参数决定了潜在对跖接触点的搜索区域。其中可调参数 d 用于确定圆柱检测器（用于面接触）的直径大小，θ_{sec} 定义了扇形检测器（用于边接触）的张角范围，而 θ_{cone} 则控制了圆锥检测器（用于角接触）的顶角大小。本文在一定

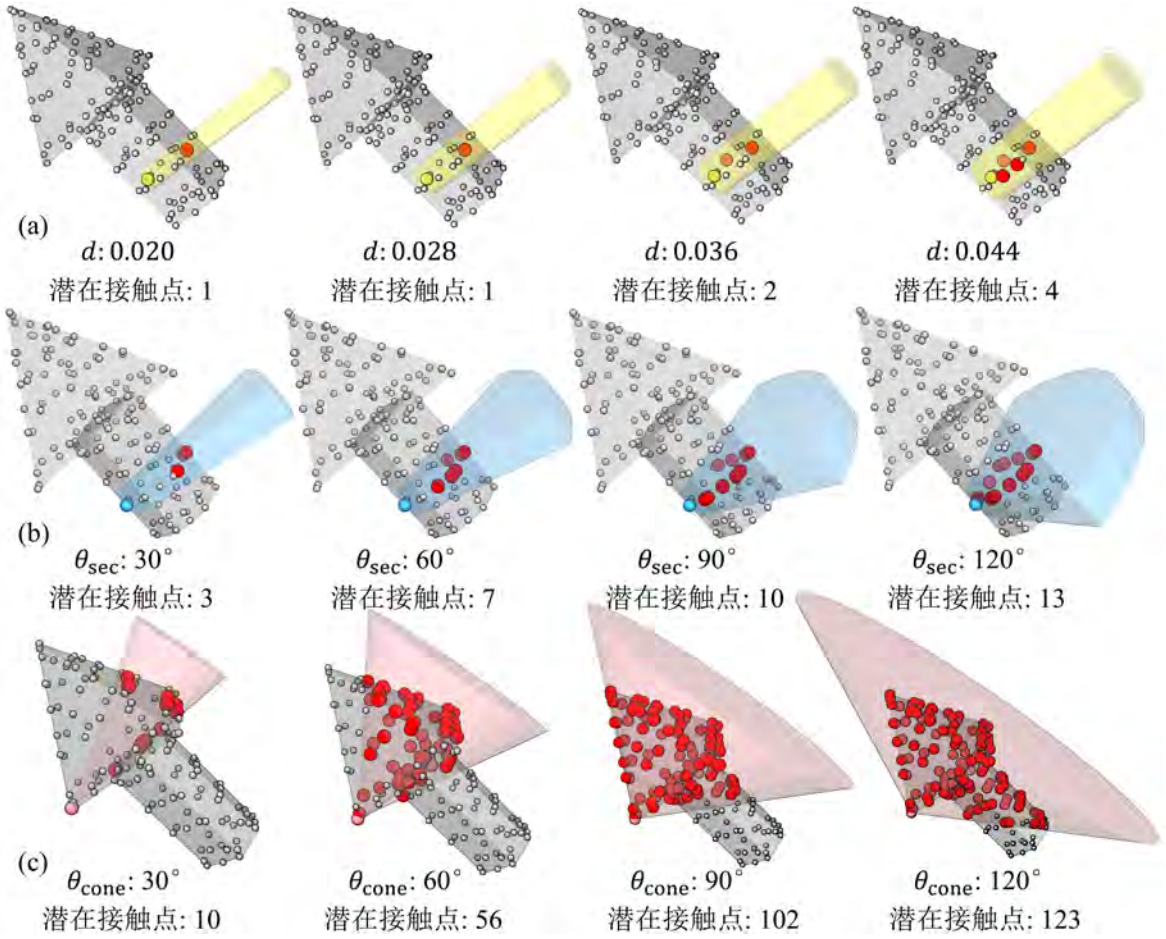


图 5.4　接触检测器尺寸参数 d、θ_{sec} 和 θ_{cone} 对潜在对跖接触点数量的影响分析

Figure 5.4　The influence of contact detector size parameters d, θ_{sec}, and θ_{cone} on the number of potential antipodal contact points.

范围内对这些参数进行了调节，以分析它们对潜在对跖接触点数量的影响，结果如图 5.4 所示。各参数的调整对潜在对跖接触点数量的影响如下所示：

- **参数** d：如图 5.4(a) 所示，将 d 从 0.020 增加到 0.044 会扩大圆柱的搜索区域，导致检测到的内部点数量增加（从 1 增加到 4）。
- **参数** θ_{sec}：如图 5.4(b) 所示，将 θ_{sec} 从 30° 放宽到 120° 会显著扩大边缘周围的覆盖面积，导致检测到的内部点数量从 3 上升到 13。
- **参数** θ_{cone}：如图 5.4(c) 所示，将 θ_{cone} 从 30° 增加到 120° 会大幅增加搜索区域，导致内部点数量急剧增加（从 10 增加到 123）。

总体而言，较大的检测器尺寸能够覆盖更广的搜索区域，从而增加潜在对跖接触点的数量，但过大的尺寸可能会引入无效接触点，降低抓取质量。通过对比，本文选择了 $d = 0.028$、$\theta_{\text{sec}} = 90°$ 和 $\theta_{\text{cone}} = 90°$ 作为后续实验的默认参数配置，以在捕获足够的边缘与角点特征的同时，控制潜在接触点的数量，确保后续抓取规划的效率

与质量。

3） 接触对验证阈值 θ_{th}

阈值 θ_{th} 作为接触对对齐质量的过滤器，用于强制执行对跖约束。图 5.5 展示了将 θ_{th} 从 150° 变化到 180° 的影响。为了取消抓取增强对该部分评估的影响，图中只对接触对进行可视化与统计，而非最终的抓取构型。观察发现，θ_{th} 与有效对的数量成反比。当 θ_{th} 较低（150°）时，约束较宽松，允许不太完美的对跖接触对，从而产生较多数量的有效接触对（82 对）。随着 θ_{th} 向 180° 增加，标准变得更严格，要求表面法线几乎完全共线。因此，经过验证的接触对数量减少（在 180° 时降至 40 对），这虽然保证了更高的抓取稳定性，但也减少了可用抓取候选的总数。本文选择 $\theta_{\text{th}} = 170°$ 作为后续实验的默认参数，以在抓取稳定性与候选数量之间取得平衡。

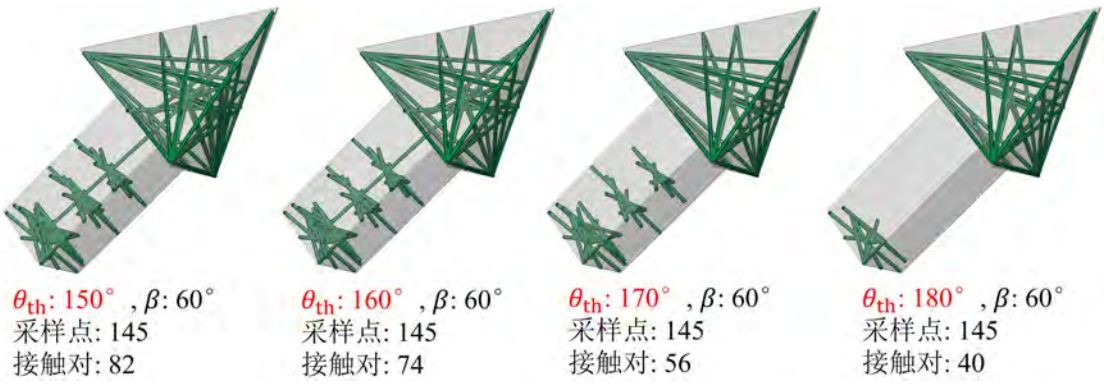


图 5.5 接触对验证阈值 θ_{th} 对接触对数量的影响分析

Figure 5.5 The influence of threshold θ_{th} on the number of generated contact pairs.

4） 抓取增强旋转角 β

参数 β 定义了沿接触向量旋转夹爪的角度步长，用于针对单个接触对生成多个抓取方向。图 5.6 展示了在固定 θ_{th} 的情况下，将 β 从 30° 变化到 180° 的影响。由于 β 是在配对后应用的，因此有效接触对的数量保持不变（56 对）。然而，生成的抓取总数对 β 高度敏感。较小的 β（例如 30°）意味着更精细的采样分辨率，能生成覆盖 360° 范围的密集抓取构型集合（595 个抓取）。随着 β 增加到 180°，采样变得粗糙，显著将总抓取数量减少至 106 个。因此，较小的 β 通过为机器人提供更多的方向选项，增强了抓取的多样性和灵巧性。本文选择 $\beta = 30°$ 作为后续实验的默认参数，以提高后续机械臂规划成功率。

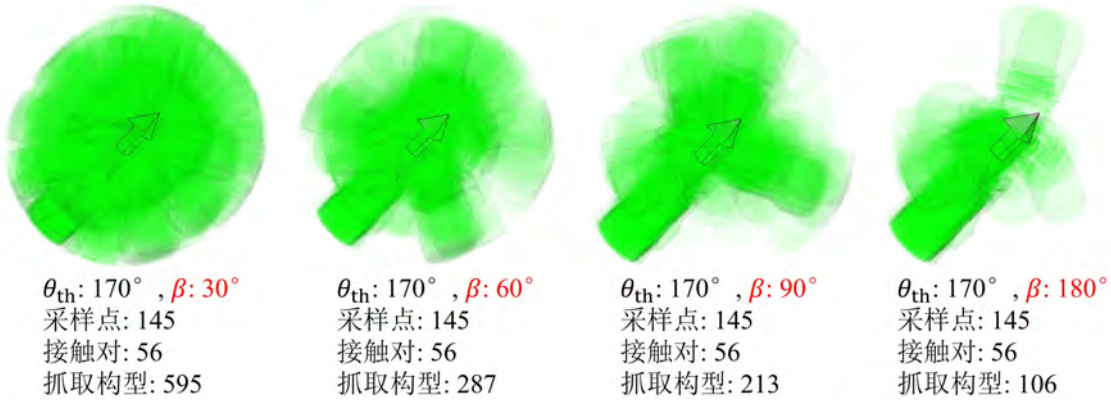


图 5.6　抓取增强旋转角 β 对抓取构型数量的影响分析

Figure 5.6　The influence of grasp enhancement rotation angle β on the number of generated grasps.

5.3　对比实验及分析

针对本文提出的基于边缘与角点特征的抓取规划方法，本文设计了两个阶段的系统性对比实验。第一阶段主要在仿真环境中进行，分析不同算法生成的抓取构型在空间分布上的多样性，以验证本文方法在探索复杂物体抓取解空间方面的优势。第二阶段则在构建的物理实验平台上开展，通过真机实验评估各算法在真实环境中的抓取成功率，从而验证引入边缘与角点接触特征对实际抓取性能的提升效果。

5.3.1　对比实验设置

为了全面评估本文提出的抓取规划方法的性能，实验选取了三种具有代表性的基准算法作为对比对象，涵盖了基于物理模型、几何分析以及数据驱动的主流技术路线。首先是 GraspIt![45]，这是一款经典的机器人抓取规划仿真工具。该方法依赖于刚体接触模型，利用模拟退火算法在物体表面搜索接触点，通过最小化能量函数来寻找满足力封闭约束的稳定抓取构型。其次是 Wan 等人[21] 提出的一种基于表面分割的规划算法（记为 Wan's），该方法侧重于提取物体表面的平行平面特征以计算抓取位姿，具有计算效率高、适合处理规则几何形状物体的特点。最后是 GPD[51]，该方法利用点云采样生成候选抓取，并基于预训练的卷积神经网络对候选进行评分。

为确保对比实验的公平性，所有算法均统一在相同的输入物体模型及手爪参数下运行。针对各算法的关键参数，均遵循其官方推荐的默认设置或经过验证的优化配置。具体而言，对于 GraspIt!，设定最大规划步数为 10,000，并启用“Energy”评价指标；对于 Wan's 算法，设置模型采样点数为 100，接触对法向量角度差阈值为 170°，其余参数保持默认；对于 GPD，采用在两指夹爪数据集上预训练的权重模型，点云

采样点数设为 100，并设定较高的抓取评分阈值以筛选高置信度结果。

鉴于不同算法生成的最终抓取构型数量存在差异，为了便于横向比较，本文统一选取每个算法生成的 Top-20 抓取构型（按质量排序）进行后续分析。特别地，对于 Wan's 方法，由于其完全基于平行面构建抓取，可能在部分非规则物体上无法生成足量的抓取构型，在此情况下将使用其生成的全部有效抓取构型参与评估。

5.3.2 抓取构型多样性分析

在机器人抓取领域，传统的评价指标（如力封闭或形状封闭）主要关注单个抓取位姿的稳定性，却往往忽视了抓取解集在三维空间中的分布特性。然而，在非结构化环境中，一个空间分布广泛且均匀的抓取构型集合对于任务的成功至关重要。多样化的抓取构型意味着机器人拥有更丰富的接近方向选择，能够更灵活地适应环境中的避障需求及机械臂自身的运动学约束（如关节极限、奇异位形）。因此，验证规划算法生成的抓取构型在空间覆盖上的广度与均匀性，是评估其鲁棒性的重要维度。

为了量化评估各算法生成的抓取构型（以接触向量 $\mathbf{v}_i$ 表征）的空间分布特性，本文引入了三个统计学指标：标准差 (Standard Deviation, STD)、极差 (Range, R) 以及平均绝对偏差 (Mean Absolute Deviation, MAD)。其中，标准差反映抓取方向相对于中心均值的离散程度，数值越大表明分布越发散，不易陷入局部最优；极差记录分布边界之间的最大跨度，能够直观体现算法覆盖的工作空间广度；平均绝对偏差则描述样本点相对于均值的偏差均值，相比标准差具有更好的抗干扰性。基于这三个指标，本文选取正四面体、巧克力盒及海豹模型作为代表性物体，分别对应无平行面几何体、规则棱柱及自由曲面物体，并据此对各算法生成的抓取集合进行统计分析。图 5.7 的可视化对象与表 5.2 保持一致，均为上述三类代表性物体。

表 5.2 不同抓取规划方法在三种代表性外形物体上的分布统计指标比较

Table 5.2 Comparison of distribution metrics on three selected objects.

评估方法	正四面体			巧克力盒			海豹模型		
	STD (↑)	R (↑)	MAD (↑)	STD (↑)	R (↑)	MAD (↑)	STD (↑)	R (↑)	MAD (↑)
GraspIt![45]	0.2516	0.8676	0.1998	0.1669	0.6687	0.1177	0.2718	0.9063	0.2154
GPD[51]	0.2878	0.9375	0.2389	0.2742	0.9454	0.2162	0.2667	0.8409	0.2284
Wan's[21]	/	/	/	0.2639	0.9365	0.2002	0.2427	0.8690	0.2014
Ours	**0.2995**	**0.9498**	**0.2450**	**0.2835**	**0.9922**	**0.2193**	**0.2857**	**0.9154**	**0.2429**

表 5.2 详细列出了不同算法在上述物体上的统计结果。数据表明，本文提出的方法在所有测试对象的 STD、R 及 MAD 三项指标上均取得了最高值，这有力地论证了引入边缘及角点接触特征能够有效打破传统方法对平面接触的依赖，显著拓宽抓取解的空间分布。

图 5.7(a) 从定性角度进一步展示了本文方法的优势。对于完全不具备平行面的正四面体（图 5.7(a.1)），依赖平行面约束的 Wan's 方法完全失效（未找到可行解），而 GraspIt! 与 GPD 仅产生少量且空间聚集的候选解。相比之下，本文方法充分利用棱边与角点特征，实现了对正四面体表面的更充分覆盖。在六棱柱巧克力盒（图 5.7(a.2)）中，Wan's 与 GraspIt! 的结果主要集中于侧面区域，而本文方法能够有效补充棱角过渡区域，形成更连续的抓取分布。对于平滑曲面的海豹模型（图 5.7(a.3)），本文方法同样保持了优于基准方法的均匀性。图 5.7(b) 的接触向量三维散点投影进一步印证了上述结论，其中代表本文方法的红色点集呈现出更广泛且更均匀的空间覆盖。

5.3.3 抓取成功率分析

为了进一步验证本文方法在真实物理环境中的有效性与鲁棒性，本节开展了机器人实物抓取实验。相较于仿真分析，物理实验能够真实反映传感器噪声、系统标定误差及接触动力学不确定性对抓取性能的综合影响。实验覆盖了评估对象集中的 10 种典型物体，涵盖了从规则几何体到复杂异形件的多种特征。实验具体流程如下：针对每种测试物体，利用各对比算法生成并筛选出质量评分最高的 Top-20 抓取构型。随后，控制机械臂依次执行“接近-抓取-提升”的完整作业流程。在操作过程中，若物体能够被稳定提起并在移动过程中保持不发生滑落、掉落或超过阈值的相对位移，则判定为该次抓取成功；反之则记为失败。

表 5.3 汇总了各算法在物理平台上的抓取成功率统计结果。从总体数据来看，本文方法在所有测试对象上均展现出了卓越的稳定性，平均成功率达到 97.5%，显著优于 GraspIt! (77.5%)、Wan's (78.0%) 及 GPD (70.5%)。

进一步分析各算法在不同场景下的性能差异可见：Wan's 算法作为基于几何平面的典型代表，在处理巧克力盒、乐高积木等具有规则平行面的物体时可达到 100% 成功率；然而在正四面体、杯面等缺乏平行特征或包含复杂曲面的物体上，由于难以提取有效平行面特征，其规划能力显著下降，甚至无法给出可行解。

GPD 虽然具备较好的数据驱动泛化能力，但在抓取构型生成阶段仍依赖基于点

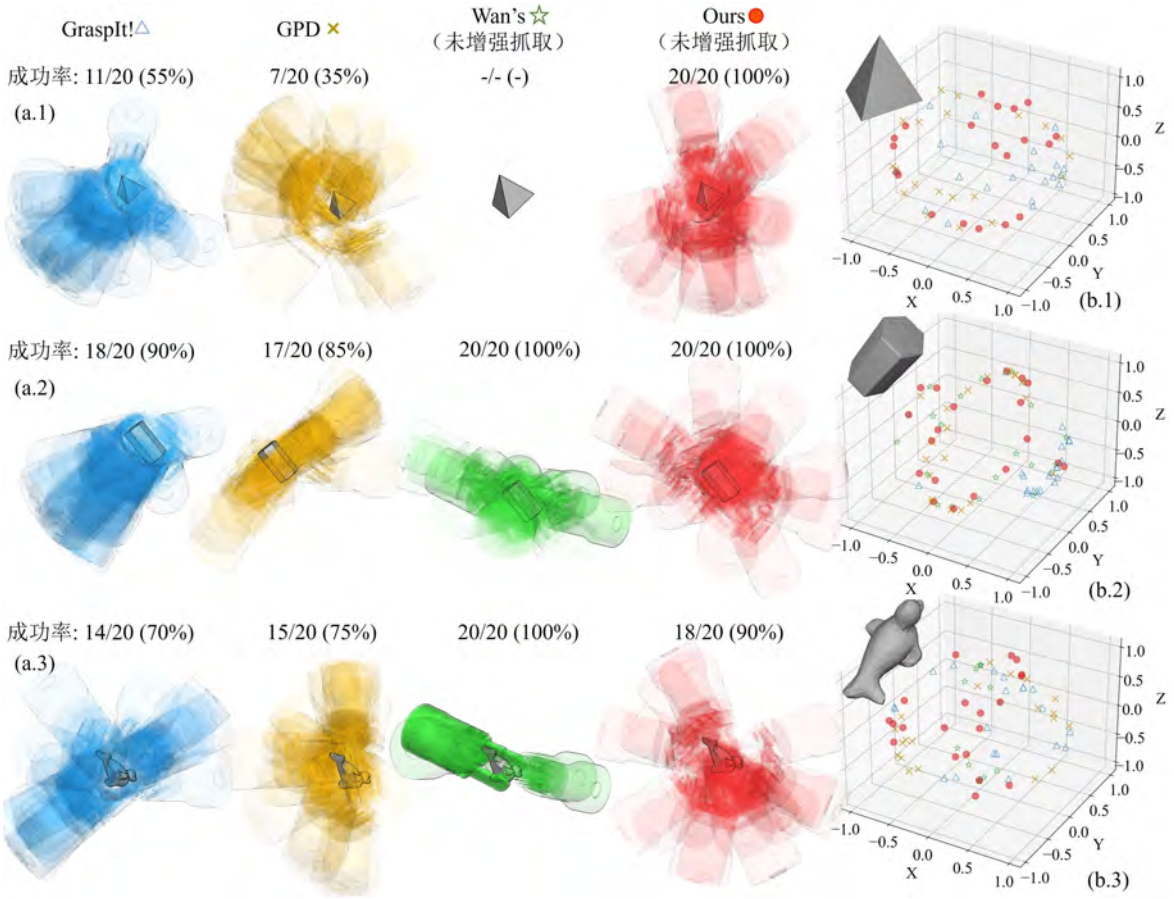


图 5.7 抓取构型空间分布分析：(a) 不同算法在三种代表性物体上的抓取构型分布示例；(b) 各算法生成的抓取接触向量的三维散点投影图

Figure 5.7 Analysis of grasp configuration spatial distribution: (a) Examples of grasp configuration distribution for different algorithms on three representative objects; (b) 3D scatter plot of grasp contact vectors generated by each algorithm.

云采样接触点并遍历可行解的流程。对于几何结构复杂的物体，该流程生成的抓取构型质量波动较大，导致物理抓取成功率受限（约在 35%–85% 区间）。GraspIt! 采用迭代遍历空间中夹爪可行位姿的策略，以寻找能与物体形成力封闭的解。但由于其未对手指与物体的具体接触形式进行深入分析，导致生成的多个抓取构型在实际作业中容易发生滑移，最终导致抓取失败。

相比之下，本文方法得益于软指腹接触变形模型的引入以及对边缘、角点接触特征的针对性规划，不仅在规则物体上保持了高可靠性，更在曲面物体（如杯面、海豹模型）、复杂齿状结构（如多齿链轮、直齿轮）等传统难点物体上取得了接近满分的成绩，充分验证了融合多类型接触特征对于提升复杂环境下机器人抓取成功率的关键作用。

表 5.3　物理实验抓取成功率统计结果

Table 5.3　The results of grasp success rate statistics in physical experiments.

评估方法	正四面体	巧克力盒	海豹模型	乐高积木	多齿链轮
GraspIt![45]	55%	90%	70%	90%	80%
GPD[51]	35%	85%	75%	85%	85%
Wan's[21]	0%	100%	100%	100%	95%
Ours	100%	100%	90%	100%	100%

评估方法	牛奶纸盒	杯面	电机支架	直齿轮	箭头	平均率
GraspIt![45]	80%	90%	75%	70%	75%	77.5%
GPD[51]	70%	75%	70%	55%	70%	70.5%
Wan's[21]	95%	0%	100%	100%	90%	78.0%
Ours	95%	95%	100%	100%	95%	**97.5%**

5.3.4　实物抓取演示

为了直观展示本文方法在实际环境中的执行效果，图 5.8 记录了机械臂对 10 种待测物体进行抓取的物理实验过程。通过抓取演示，可以观察到规划器生成了多样化的接触模式，包括角-角点接触（如正四面体、巧克力盒）、边-边线接触（如乐高积木、直齿轮）以及指腹面接触（如电机支架）等多种组合形式。这些实物抓取试验不仅涵盖了从简单几何体到复杂异形件的广泛对象，也展示了机械臂在不同手爪构型下的稳定抓取能力。实验结果表明，本文方法能够有效适应物体的几何特性，生成物理可行的抓取策略，并在真实世界的各种非结构化接触场景中表现出良好的鲁棒性与适应性。

5.4　算法耗时

除了抓取质量，规划效率也是衡量算法实用性的关键指标。本节统计了算法在配置为 Intel Core Ultra 9 处理器的计算平台上处理所有测试对象时的平均计算耗时。

如表 5.4 所示，单次抓取规划全流程的平均耗时约为 1.583 s。深入分析各阶段的时间开销分布可知，特征提取阶段占据了主要的计算时间，平均耗时约为 1.059 s。该阶段主要依赖预训练的 NECDNet 模型对点云局部几何特征进行编码与学习。虽然网络模型本身的推理速度较快，但作为网络输入的特征矩阵计算过程（涵盖全场点云的法线估计、曲率计算以及邻域特征聚合等预处理步骤）涉及大量的数据运算，因此成为主要的耗时来源。相比之下，接触检测阶段的平均耗时极短，仅为 0.076 s 左

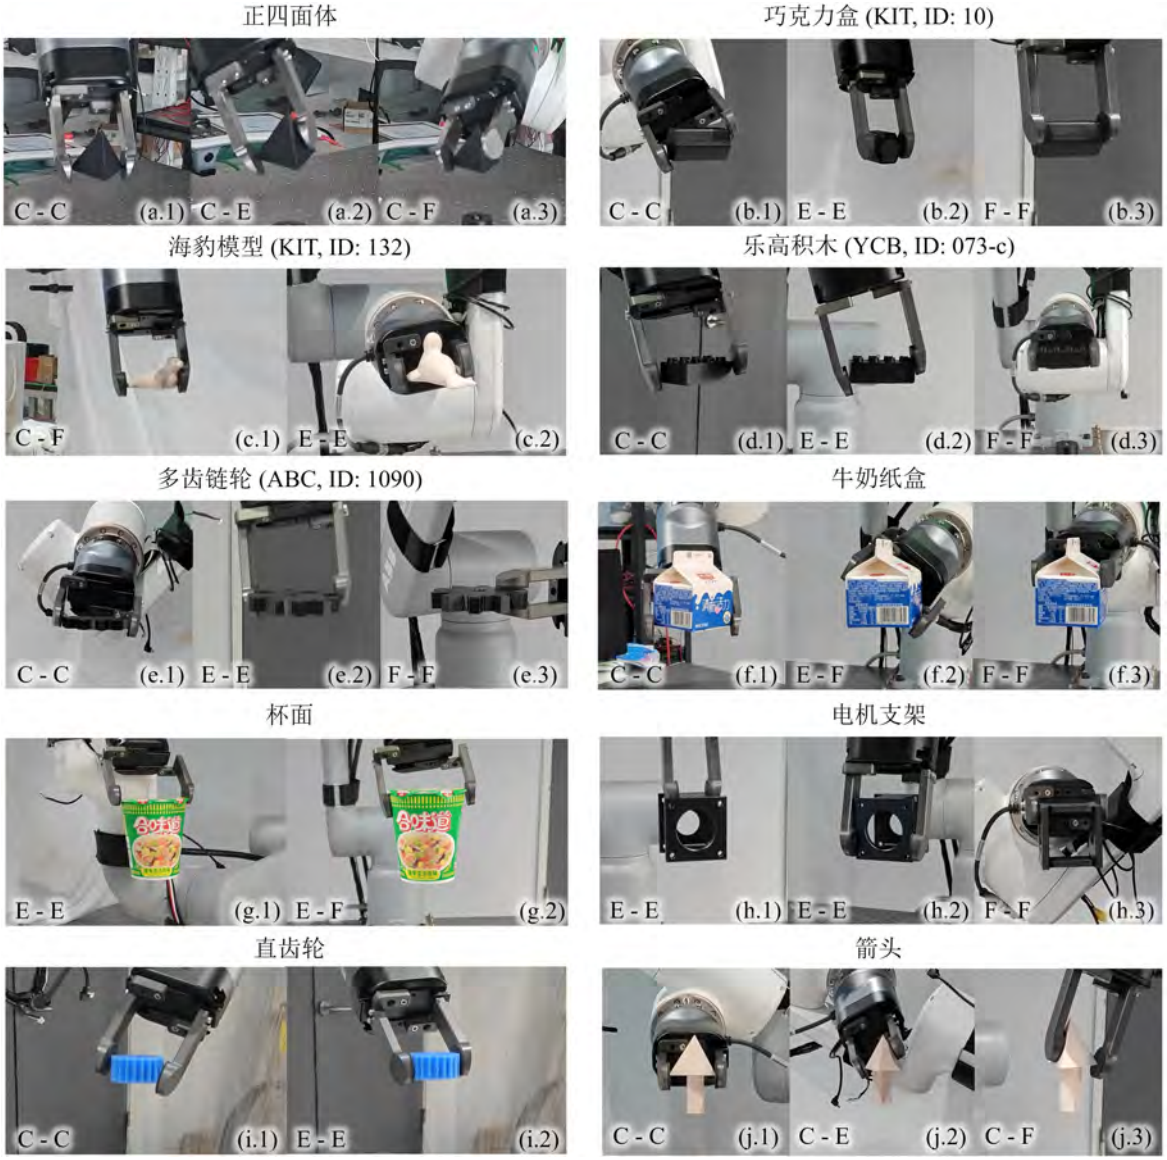


图 5.8　实物抓取实验演示

Figure 5.8　Demonstration of physical grasping experiments.

右，这主要得益于本文设计的几何探测器能够高效地筛选出潜在的接触位置。此外，稳定性分析阶段的平均耗时约为 0.449 s，该过程主要用于对生成的候选抓取构型进行力封闭验证与质量评分排序。

总体而言，各测试物体的计算时间方差较小，表明算法面对不同几何复杂度的物体时具有稳定的时间性能。1.5 秒左右的规划耗时对于静态抓取场景或离线数据库构建任务而言完全能够满足需求，且该算法架构仍具备进一步的代码优化与并行加速潜力以适应更实时的应用场景。

表 5.4　各物体规划阶段耗时统计 (单位: 秒)

Table 5.4　Computation time statistics for each planning stage (unit: seconds).

计算阶段	正四面体	巧克力盒	海豹模型	乐高积木	多齿链轮
几何特征提取	1.102	0.985	1.214	1.056	0.998
接触对检测	0.078	0.032	0.082	0.051	0.071
稳定性分析	0.626	0.591	0.724	0.092	0.601
总耗时	1.806	1.608	2.020	1.199	1.670

计算阶段	牛奶纸盒	杯面	电机支架	直齿轮	箭头	平均耗时
几何特征提取	1.045	1.132	1.087	0.954	1.012	1.059
接触对检测	0.129	0.141	0.059	0.038	0.075	0.076
稳定性分析	0.523	0.301	0.091	0.475	0.461	0.449
总耗时	1.697	1.574	1.237	1.467	1.548	1.583

5.5　总结

本章通过构建包含仿真分析与物理样机验证的多层次实验体系，系统评估了考虑边缘与角点接触特征的抓取规划方法的综合性能。实验结果表明，该方法通过摆脱对平面接触特征的单一依赖，显著拓展了抓取构型在三维空间中的分布广度与均匀性，有效增强了机器人对非结构化复杂环境的适应能力。在抓取成功率方面，得益于软指腹接触模型对锐边、尖角等复杂几何特征的有效利用，本文方法在涵盖各类异形物体的测试集上展现出卓越的稳定性，平均成功率达到 97.5%，有效缓解了传统几何方法在非平行表面上的规划失效问题。此外，算法维持了秒级的规划响应速度，验证了其在实际工程部署中的实时性与应用价值。综上所述，本文提出的方法不仅在理论层面丰富了机器人抓取的接触类型，更在实际应用中证明了其鲁棒性与通用性。

第六章　总结与展望

6.1　全文总结

本文围绕三维点云几何感知与机器人抓取规划领域长期存在的感知精度受限与接触模式相对单一两类关键问题，构建并验证了一条由几何特征检测通向复杂接触抓取生成的完整技术路径。全文首先在问题层面阐明了边缘与角点信息在三维结构表达和抓取决策中的核心作用，继而在方法层面提出兼具学习能力、可解释性与工程可实施性的解决方案，最终依托数据集评测、仿真评估与真机实验形成系统化证据链，对方法有效性进行了全面检验。

在几何特征检测方面，本文提出了 NECDNet 框架，通过多尺度邻域建模与显式解析特征融合，实现了面点、边缘点与角点的统一检测。该方法并未单纯依赖黑箱式端到端表示学习，而是在局部几何建模阶段引入曲率、投影距离均值、中心偏离比、法向角度差、法向分布方差与法向投影距离均值等具有明确物理意义的统计量，并在 $k \in \{8, 16, 32, 64\}$ 的多尺度空间上组织为结构化输入特征矩阵，从而兼顾了模型判别能力与结果可解释性。网络结构采用分层分类思想，先区分面点与非面点，再细分边缘点与角点，配合 Focal Loss 与针对角点稀缺性的重采样策略，有效缓解了类别极不均衡场景下的训练偏置问题。基于 ABC-Corner 数据集的对比实验表明，NECDNet 在多项核心指标上均取得领先结果，其中使用网格法向量输入时宏平均 F1 达到 0.815、MCC 达到 0.943；在二分类边缘检测设置下，NECDNet-2c† 的 F1 达到 0.956。上述结果说明，本文方法不仅提升了边缘检测精度，更在传统方法普遍薄弱的角点检测任务上取得了显著收益。

在数据基础设施方面，本文围绕高质量角点标注稀缺这一制约学习方法性能上限的关键问题，构建了 ABC-Corner 数据集。该数据集以 ABC 的 CAD 模型为基础，形成了规则驱动自动粗标注与人工精修校正相结合的双阶段标注流程，并在样本筛选与质量控制中强调几何特征代表性和标注一致性。通过补充角点精标注，数据集将原有以面和边为主的标注体系扩展为覆盖面、边、角三类特征的完整监督体系，不仅支撑了 NECDNet 的训练与评估，也为后续研究提供了可复现、可比较的实验基准。

在抓取规划方面，本文进一步将几何检测结果转化为抓取决策约束，提出了考

虑边缘与角点接触的六自由度抓取规划方法。针对传统规划器主要依赖平面接触且难以覆盖复杂几何外形的问题，本文通过类别感知体素采样缓解候选接触点在面区域的长尾聚集现象，并为面、边、角分别设计圆柱、扇形柱与圆锥检测器，实现与接触自由度一致的搜索空间建模。随后，方法按照六类接触组合构建差异化配对规则，在对跖约束、投影约束与几何一致性约束的联合作用下生成高质量候选接触对，并结合绕接触轴旋转增强、碰撞检测与软接触稳定性评估形成完整流程。相较于将软指接触简化为单点摩擦模型的经典处理，本文采用离散接触簇近似连续变形接触，能够在可接受计算代价下更准确地表征边缘与角点区域的受力特性。

在实验验证方面，本文通过第五章建立了覆盖仿真与真机场景的系统评估框架。抓取分布多样性分析显示，本文方法在代表性物体上的 STD、R 与 MAD 指标均达到最优，表明其生成的抓取解集在空间覆盖性与方向分散性方面显著优于对比方法。物理抓取实验覆盖十类不同几何特征物体，本文方法平均成功率达到 97.5%，明显高于 GraspIt!、GPD 与 Wan's，且在无平行面或局部曲率变化剧烈的对象上仍保持稳定性能。效率评估结果进一步表明，单次规划平均耗时约 1.583 s，具备工程应用所需的时效性。综合而言，本文完成了由几何感知能力提升到抓取行为质量提升的因果闭环验证，证明了边缘与角点接触建模在复杂对象抓取中的实际价值。

6.2 创新点

本文的创新性主要体现在方法链条的完整性、关键环节的机制设计以及跨任务验证的一致性。首先，在点云几何特征检测任务中，本文提出了将显式几何统计与轻量级学习架构深度耦合的 NECDNet，将多尺度局部几何信息组织为结构化特征输入，并通过分层分类机制提升边缘与角点的可分性。该设计避免了单纯依赖大规模参数学习带来的解释性不足问题，也突破了传统阈值法在复杂场景中的泛化瓶颈，特别是在角点这一高稀疏、高混淆类别上的性能改进具有明显方法学意义。

其次，本文构建了覆盖面、边、角三类标签的 ABC-Corner 数据集，形成了可复现的数据生成与校核流程。该数据集并非仅作为训练样本集合存在，而是在研究中承担了方法开发、性能对比与消融分析的统一评测基座作用，使算法性能提升能够建立在稳定、可追溯的标注标准之上。通过这一数据层创新，本文为相关研究由经验性比较走向规范化比较提供了重要支撑。

再次，本文在抓取规划中显式引入边缘与角点接触，提出与几何特征自由度相匹配的检测器建模和配对策略，并结合软接触离散化稳定性评估，实现了从候选生成到力学可行性判定的统一建模框架。与强调面接触保守性的传统规划路线相比，本文方法在保证稳定性的同时显著扩展了抓取解空间覆盖范围，使规划器在非平行面、曲面与复杂齿状结构对象上的可用性得到实质性提升。该创新不局限于某一独立模块性能的提高，而是体现为感知、几何推理与接触力学三者协同优化后的系统级性能跃迁。

6.3 研究不足与展望

本文工作在取得较高检测精度与抓取成功率的同时，也暴露出若干值得继续深入的问题。首先，NECDNet 对法向量质量仍具有一定敏感性。实验已表明，精确网格法向量可显著提升检测上限，而在实际扫描点云中，局部最小二乘估计在尖锐区域的平滑化偏差会压缩边缘与角点间的特征间隔。这意味着后续研究需要进一步降低模型对高质量外部法向先验的依赖，可通过引入更鲁棒的法向估计模型、构建面向尖锐结构的可微法向优化模块，或直接将法向估计与特征分类联合训练，在同一目标函数下实现误差反向传播与协同收敛。

其次，本文抓取规划框架仍建立在已知完整模型的前提之上，更适用于离线规划与相对受控场景。面对遮挡严重、对象未知或仅有部分可见点云的在线作业环境，现有流程的前提条件将被削弱。后续可将本研究与增量式三维重建、点云补全和不确定性建模结合，在局部几何可观测信息不足时进行风险感知规划，并通过闭环视觉反馈动态修正候选抓取集合，从而推动方法由“完整模型驱动”向“部分观测驱动”迁移。

再次，当前方法主要面向双指平行夹爪，尽管在复杂几何对象上已展现出明显优势，但尚未充分覆盖多指灵巧手场景。多指协同接触不仅涉及更高维的接触组合空间，也涉及手内重构、接触序列切换与力分配协调等问题。未来可在本文面、边、角接触建模思想基础上，研究面向多指系统的接触图优化与协同约束求解，以支持更复杂的操作任务。

最后，本文的优化目标主要聚焦几何稳定性与执行可行性，对任务语义与功能可供性约束的考虑仍显不足。在实际工业与服务场景中，抓取行为通常受后续任务

链条制约，例如工具类物体需优先保留功能端，装配类任务需满足特定姿态约束。后续研究可进一步将语义理解、任务规划与接触几何统一于同一决策框架，使抓取策略由几何可抓提升至任务可用、过程可执行且结果可交付的更高层次智能操作能力。

参考文献

[1] MIRZAEI K, ARASHPOUR M, ASADI E, et al. 3d point cloud data processing with machine learning for construction and infrastructure applications: A comprehensive review[J]. ADVANCED ENGINEERING INFORMATICS, 2022, 51: 101501.

[2] LI Y, LIU S, YANG X, et al. Surface and edge detection for primitive fitting of point clouds[C]//SIGGRAPH '23: ACM SIGGRAPH 2023 Conference Proceedings. New York, NY, USA: Association for Computing Machinery, 2023: 1-10.

[3] Lavín-Delgado J E, Gómez-Aguilar J F, Urueta-Hinojosa D E, et al. An efficient technique for object recognition using fractional harris–stephens corner detection algorithm[J]. Multimedia Tools and Applications, 2024, 83(8): 23173-23199.

[4] 高俊杰, 王瑞安, 王子雄, 等. 基于边缘感知的点云配准算法[J]. 计算机辅助设计与图形学学报, 2024, 36(7).

[5] 张志佳, 魏信, 周自强, 等. 基于深度图像和点云边缘特征的典型零部件识别[J]. 信息与控制, 2017, 46(3).

[6] AHMED S M, TAN Y Z, CHEW C M, et al. Edge and corner detection for unorganized 3d point clouds with application to robotic welding[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2018: 7350-7355.

[7] GUMHOLD S, WANG X. Feature extraction from point clouds[J]. Proceedings of 10th international meshing roundtable, 2001, 2001.

[8] DEMARSIN K, VANDERSTRAETEN D, VOLODINE T, et al. Detection of closed sharp edges in point clouds using normal estimation and graph theory[J]. Computer-Aided Design, 2007, 39(4): 276-283.

[9] NGUYEN K W L, APRILIA A, KHAIRYANTO A, et al. Edge detection from point cloud of worn parts[C]//2018.

[10] CHARLES R Q, SU H, KAICHUN M, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 77-85.

[11] BAZAZIAN D, PARÉS M E. Edc-net: Edge detection capsule network for 3d point clouds[J]. Applied Sciences, 2021, 11(4): 1833.

[12] HIMEUR C E, LEJEMBLE T, PELLEGRINI T, et al. Pcednet : A lightweight neural network for fast and interactive edge detection in 3d point clouds[J]. ACM Transactions on Graphics, 2022, 41(1): 1-21.

[13] BODE L, WEINMANN M, KLEIN R. Bounded: Neural boundary and edge detection in 3d point clouds via local neighborhood statistics[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 205: 334-351.

[14] WANG X, XU Y, XU K, et al. Pie-net: Parametric inference of point cloud edges [C]//NIPS '20: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020: 20167-20178.

[15] LI R, QIAO H. A survey of methods and strategies for high-precision robotic grasping and assembly tasks—some new trends[J]. IEEE/ASME Transactions on Mechatronics, 2019, 24(6): 2718-2732.

[16] NEWBURY R, GU M, CHUMBLEY L, et al. Deep learning approaches to grasp synthesis: A review[J]. Trans. Rob., 2023, 39(5): 3994-4015.

[17] ASADA H. Studies on prehension and handling by robot hands with elastic fingers [D]. Kyoto University, 1979.

[18] MILLER A, KNOOP S, CHRISTENSEN H, et al. Automatic grasp planning using shape primitives[C]//2003 IEEE International Conference on Robotics and Automation (Cat. No.03CH37422): Vol. 2. 2003: 1824-1829 vol.2.

[19] GOLDFEDER C, ALLEN P K, LACKNER C, et al. Grasp planning via decomposition trees[C]//Proceedings 2007 IEEE International Conference on Robotics and Automation. 2007: 4679-4684.

[20] HARADA K, TSUJI T, NAGATA K, et al. Grasp planning for parallel grippers with flexibility on its grasping surface[C]//2011 IEEE International Conference on Robotics and Biomimetics. 2011: 1540-1546.

[21] WAN W, HARADA K, KANEHIRO F. Planning grasps with suction cups and parallel grippers using superimposed segmentation of object meshes[J]. IEEE Transactions on Robotics, 2021, 37(1): 166-184.

[22] CHEN H, KIYOKAWA T, WAN W, et al. Category-association based similarity matching for novel object pick-and-place task[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 2961-2968.

[23] MAHLER J, LIANG J, NIYAZ S, et al. Dex-net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics: arXiv:1703.09312[M]. arXiv, 2017.

[24] LENZ I, LEE H, SAXENA A. Deep learning for detecting robotic grasps[J]. The International Journal of Robotics Research, 2015, 34(4-5): 705-724.

[25] SONG H, WANG M Y, HANG K. Fingertip surface optimization for robust grasping on contact primitives[J]. IEEE Robotics and Automation Letters, 2018, 3(2): 742-749.

[26] RINGWALD J, SCHNEIDER S, CHEN L, et al. Towards task-specific modular gripper fingers: Automatic production of fingertip mechanics[J]. IEEE Robotics and Automation Letters, 2023, 8(3): 1866-1873.

[27] GRADY P, TANG C, TWIGG C D, et al. Contactopt: Optimizing contact to improve grasps[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 1471-1481.

[28] BICCHI A, KUMAR V. Robotic grasping and contact: A review[C]//Proceedings 2000 ICRA. Millennium conference. IEEE international conference on robotics and automation. Symposia proceedings: Vol. 1. IEEE, 2000: 348-353.

[29] XIA S, WANG R. A fast edge extraction method for mobile lidar point clouds[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(8): 1288-1292.

[30] PAULY M, KEISER R, GROSS M. Multi-scale feature extraction on point-sampled surfaces[J]. Computer Graphics Forum, 2003, 22(3): 281-289.

[31] BAZAZIAN D, CASAS J R, Ruiz-Hidalgo J. Fast and robust edge extraction in unorganized point clouds[C]//2015 International Conference on Digital Image Computing: Techniques and Applications (DICTA). 2015: 1-8.

[32] 王丽辉, 袁保宗. 三维散乱点云模型的特征点检测[J]. 信号处理, 2011, 27(6).

[33] CHE E, OLSEN M J. Multi-scan segmentation of terrestrial laser scanning data based on normal variation analysis[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2018, 143: 233-248.

[34] DANIELS J I, HA L K, OCHOTTA T, et al. Robust smooth feature extraction from point clouds[C]//SMI '07: Proceedings of the IEEE International Conference on Shape Modeling and Applications 2007. USA: IEEE Computer Society, 2007: 123-136.

[35] ZHANG J, CAO J, LIU X, et al. Multi-normal estimation via pair consistency voting [J]. IEEE Transactions on Visualization and Computer Graphics, 2019, 25(4): 1693-1706.

[36] LIN Y, WANG C, CHENG J, et al. Line segment extraction for large scale unorganized point clouds[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 102: 172-183.

[37] SCHMIDT J, VOLLAND V, IWASZCZUK D, et al. Detection of hidden edges and corners in slam-based indoor point clouds[J]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2023, XLVIII-1-W1-2023: 443-449.

[38] QI C R, YI L, SU H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[C]//NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2017: 5105-5114.

[39] GUERRERO P, KLEIMAN Y, OVSJANIKOV M, et al. Pcpnet learning local shape properties from raw point clouds[J]. Computer Graphics Forum, 2018, 37(2): 75-85.

[40] JIAO X, LV C, YI R, et al. Msl-net: Sharp feature detection network for 3d point clouds[J]. IEEE Transactions on Visualization and Computer Graphics, 2024, 30(9): 6433-6446.

[41] YU L, LI X, FU C W, et al. Ec-net: An edge-aware point set consolidation network [C]//FERRARI V, HEBERT M, SMINCHISESCU C, et al. Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 398-414.

[42] MATVEEV A, RAKHIMOV R, ARTEMOV A, et al. Def: Deep estimation of sharp geometric features in 3d shapes[J]. ACM Trans. Graph., 2022, 41(4): 108:1-108:22.

[43] ZHU X, DU D, CHEN W, et al. Nerve: Neural volumetric edges for parametric curve extraction from point cloud[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 13601-13610.

[44] HU Z, ZHEN M, BAI X, et al. Jsenet: Joint semantic segmentation and edge detection network for 3d point clouds[M]//VEDALDI A, BISCHOF H, BROX T, et al. Computer Vision – ECCV 2020: Vol. 12365. Cham: Springer International Publishing, 2020: 222-239.

[45] MILLER A T, ALLEN P K. Graspit!: A versatile simulator for grasp analysis[C]// ASME 2000 International Mechanical Engineering Congress and Exposition. American Society of Mechanical Engineers Digital Collection, 2021: 1251-1258.

[46] MAHLER J, MATL M, SATISH V, et al. Learning ambidextrous robot grasping policies[J]. Science Robotics, 2019, 4(26): eaau4984.

[47] MOUSAVIAN A, EPPNER C, FOX D. 6-dof graspnet: Variational grasp generation for object manipulation[C]//International Conference on Computer Vision (ICCV). 2019.

[48] FANG H S, WANG C, GOU M, et al. Graspnet-1billion: A large-scale benchmark for general object grasping[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11441-11450.

[49] CAO H, CHEN G, LI Z, et al. Efficient grasp detection network with gaussian-based grasp representation for robotic manipulation[J]. IEEE/ASME Transactions on Mechatronics, 2023, 28(3): 1384-1394.

[50] FERRARI C, CANNY J. Planning optimal grasps[C]//Proceedings 1992 IEEE International Conference on Robotics and Automation. 1992: 2290-2295 vol.3.

[51] TEN PAS A, GUALTIERI M, SAENKO K, et al. Grasp pose detection in point clouds [J/OL]. The International Journal of Robotics Research, 2017, 36(13-14): 1455-1473. DOI: 10.1177/0278364917735594.

[52] LIANG H, MA X, LI S, et al. Pointnetgpd: Detecting grasp configurations from point sets[J]. 2019 International Conference on Robotics and Automation (ICRA), 2019: 3629-3635.

[53] YU S, ZHAI D H, XIA Y. Mtgrasp: Multiscale 6-dof robotic grasp detection[J]. IEEE/ASME Transactions on Mechatronics, 2025, 30(1): 156-167.

[54] KOPICKI M, DETRY R, SCHMIDT F, et al. Learning dexterous grasps that generalise to novel objects by combining hand and contact models[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). 2014: 5358-5365.

[55] COVER T, HART P. Nearest neighbor pattern classification[J/OL]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27. DOI: 10.1109/TIT.1967.1053964.

[56] BROWN R A. Review of three algorithms that build k-d trees: arXiv:2506.20687 [M/OL]. arXiv, 2025. DOI: 10.48550/arXiv.2506.20687.

[57] SHLENS J. A tutorial on principal component analysis: arXiv:1404.1100[M/OL]. arXiv, 2014. DOI: 10.48550/arXiv.1404.1100.

[58] HOPPE H, DEROSE T, DUCHAMP T, et al. Surface reconstruction from unorganized points[J/OL]. SIGGRAPH Comput. Graph., 1992, 26(2): 71-78. DOI: 10.1145/142920.134011.

[59] CIGNONI P, CALLIERI M, CORSINI M, et al. MeshLab: an Open-Source Mesh Processing Tool[C/OL]//SCARANO V, CHIARA R D, ERRA U. Eurographics Italian Chapter Conference. The Eurographics Association, 2008. DOI: 10.2312/LocalChapterEvents/ItalChap/ItalianChapConf2008/129-136.

[60] TOLSTIKHIN I O, HOULSBY N, KOLESNIKOV A, et al. Mlp-mixer: An all-mlp architecture for vision[C/OL]//RANZATO M, BEYGELZIMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems: Vol. 34. Curran Associates, Inc., 2021: 24261-24272. https://proceedings.neurips.cc/paper_files/paper/2021/file/cba0a4ee5ccd02fda0fe3f9a3e7b89fe-Paper.pdf.

[61] XU B, WANG N, CHEN T, et al. Empirical evaluation of rectified activations in convolutional network: arXiv:1505.00853[M/OL]. arXiv, 2015. DOI: 10.48550/arXiv.1505.00853.

[62] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(56): 1929-1958.

[63] BISHOP C M. Pattern recognition and machine learning[M]. New York: Springer, 2006.

[64] JAPKOWICZ N, STEPHEN S. The class imbalance problem: A systematic study[J]. Intell. Data Anal., 2002, 6(5): 429-449.

[65] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[J/OL]. IEEE transactions on pattern analysis and machine intelligence, 2020, 42(2): 318-327. DOI: 10.1109/TPAMI.2018.2858826.

[66] MAO A, MOHRI M, ZHONG Y. Cross-entropy loss functions: Theoretical analysis and applications[C]//ICML'23: Vol. 202 Proceedings of the 40th International Conference on Machine Learning. Honolulu, Hawaii, USA: JMLR.org, 2023: 23803-23828.

[67] KOCH S, MATVEEV A, JIANG Z, et al. Abc: A big cad model dataset for geometric deep learning[C/OL]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 9593-9603. DOI: 10.1109/CVPR.2019.00983.

[68] CHANG A X, FUNKHOUSER T, GUIBAS L, et al. Shapenet: An information-rich 3d model repository: arXiv:1512.03012[M/OL]. arXiv, 2015. DOI: 10.48550/arXiv.1512.03012.

[69] DAI A, CHANG A X, SAVVA M, et al. Scannet: Richly-annotated 3d reconstructions of indoor scenes[C]//Proc. Computer Vision and Pattern Recognition (CVPR), IEEE. 2017.

[70] LAI K, BO L, REN X, et al. A large-scale hierarchical multi-view rgb-d object dataset [C/OL]//2011 IEEE International Conference on Robotics and Automation. 2011: 1817-1824. DOI: 10.1109/ICRA.2011.5980382.

[71] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in python[J]. Journal of Machine Learning Research, 2011, 12(85): 2825-2830.

[72] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library[A]. 2019.

[73] HARRIS C R, MILLMAN K J, van der Walt S J, et al. Array programming with numpy[J]. Nature, 2020, 585(7825): 357-362.

[74] VIRTANEN P, GOMMERS R, OLIPHANT T E, et al. Scipy 1.0: Fundamental algorithms for scientific computing in python[J]. Nature Methods, 2020, 17(3): 261-272.

[75] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. CoRR, 2014.

[76] LOSHCHILOV I, HUTTER F. Sgdr: Stochastic gradient descent with warm restarts: arXiv:1608.03983[M]. arXiv, 2017.

[77] KRSTINIĆ D, BRAOVIĆ M, ŠERIĆ L, et al. Multi-label classifier performance evaluation with confusion matrix[J/OL]. Computer Science & Information Technology (CS & IT), 2020, 10(8): 1. DOI: 10.5121/csit.2020.100801.

[78] CHICCO D, JURMAN G. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation[J/OL]. BMC Genomics, 2020, 21: 6. DOI: 10.1186/s12864-019-6413-7.

[79] DÜNTSCH I, GEDIGA G. Confusion matrices and rough set data analysis[J/OL]. Journal of Physics: Conference Series, 2019, 1229(1): 012055. DOI: 10.1088/1742-6596/1229/1/012055.

[80] ERBANI J, PORTIER P É, Egyed-Zsigmond E, et al. Confusion matrices: A unified theory[J/OL]. IEEE Access, 2024, 12: 181372-181419. DOI: 10.1109/ACCESS.2024.3507199.

[81] ESTER M, KRIEGEL H P, SANDER J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//KDD'96: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. Portland, Oregon: AAAI Press, 1996: 226-231.

[82] FISCHLER M A, BOLLES R C. Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography[J/OL]. Commun. ACM, 1981, 24(6): 381-395. DOI: 10.1145/358669.358692.

[83] MURRAY R M, SASTRY S S, ZEXIANG L. A mathematical introduction to robotic manipulation[M]. 1st ed. USA: CRC Press, Inc., 1994.

攻读专业硕士学位期间取得的研究成果

一、论文

[1] QIU M, HU Z, CHEN H, DU L, BAO S, YUAN J. Robotic grasp planning considering local concavity of contact[C]//2025 IEEE International Conference on Robotics and Biomimetics (ROBIO). 2025: 948-953.

二、专利

[1] 袁建军, 邱模聪, 杜亮, 鲍晟, 胡正涛, 马书根. 一种欠驱动全向轮: 202410498640.3 [P]. 2024-04-24.

[2] 袁建军, 邱模聪, 胡正涛, 鲍晟, 杜亮, 杨强. 一种基于点云信息的管片拼装定位视觉算法: 202410540772.8 [P]. 2024-04-30.

[3] 胡正涛, 贾永杰, 邱模聪, 袁建军, 鲍晟, 杜亮. 一种小尺寸紧固件机器人视觉抓取方法: 202511588471.3 [P]. 2025-11-03.

三、项目

1. 国家自然科学基金青年基金项目《双臂机器人重抓取降低操作不确定性的规划方法研究》，项目编号：62403297。

致　谢

时光荏苒，研究生阶段的学习与科研工作即将画上句号。在论文完成之际，谨向所有关心、帮助和支持过我的老师、同学、亲友致以最诚挚的感谢。

首先，衷心感谢我的导师袁建军老师。袁老师为本课题提供了宝贵的实验资源与研究平台，并在课题方向把握、研究思路凝练以及学术规范养成等方面给予了我持续而细致的指导，使我受益匪浅。

同时，感谢实验室各位指导老师的悉心帮助，感谢胡正涛老师、杜亮老师、鲍晟老师在科研训练和日常学习中给予我的指导与支持，让我在科研道路上不断成长。特别感谢胡正涛老师，在论文撰写、实验分析和细节打磨过程中给予了我大量耐心、专业且富有启发性的指导，使论文得以不断完善。此外，衷心感谢南京大学张振宇老师、福建农林大学陈昊老师对本论文部分内容提出的指导与建议，为论文内容的完善和研究深度的提升提供了重要帮助。

感谢实验室的师兄师姐、师弟师妹们在科研与生活中的支持与帮助。与你们共同学习、讨论和合作的经历，让我在面对困难时始终能够获得力量，也让我度过了充实而难忘的研究生时光。

最后，感谢我的家人和朋友长期以来的理解、包容与鼓励。正是你们无条件的支持，让我能够心无旁骛地投入学习和研究，并坚持走到今天。

谨以此文，向所有给予我帮助的人致以诚挚谢意！

作者署名：邱模聪

完成地点：上海大学

2026 年 4 月 13 日

附录 A　经典函数公式

论文中用到的经典函数公式如下。

(Sigmoid Function) Sigmoid 函数定义为

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}}.$$

(ReLU Function) ReLU 函数定义为

$$\text{ReLU}(x) = \max(0, x).$$

(Leaky ReLU Function) Leaky ReLU 函数定义为

$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ \alpha x, & x < 0 \end{cases}$$

其中 α 是一个较小的常数，通常取值为 0.01。

附录 B　用于定量比较的指标公式

章节 (3.3.6) 中提到的用于定量比较的指标公式如下。其中 TP、TN、FP 和 FN 分别表示真正例、真反例、假正例和假反例的数量。

(Precision) 精确率定义为

$$\text{Precision} = \frac{TP}{TP + FP}$$

(Recall) 召回率定义为

$$\text{Recall} = \frac{TP}{TP + FN}$$

(F1 Score) F1 分数定义为

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

(Matthews Correlation Coefficient) 马修斯相关系数定义为

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

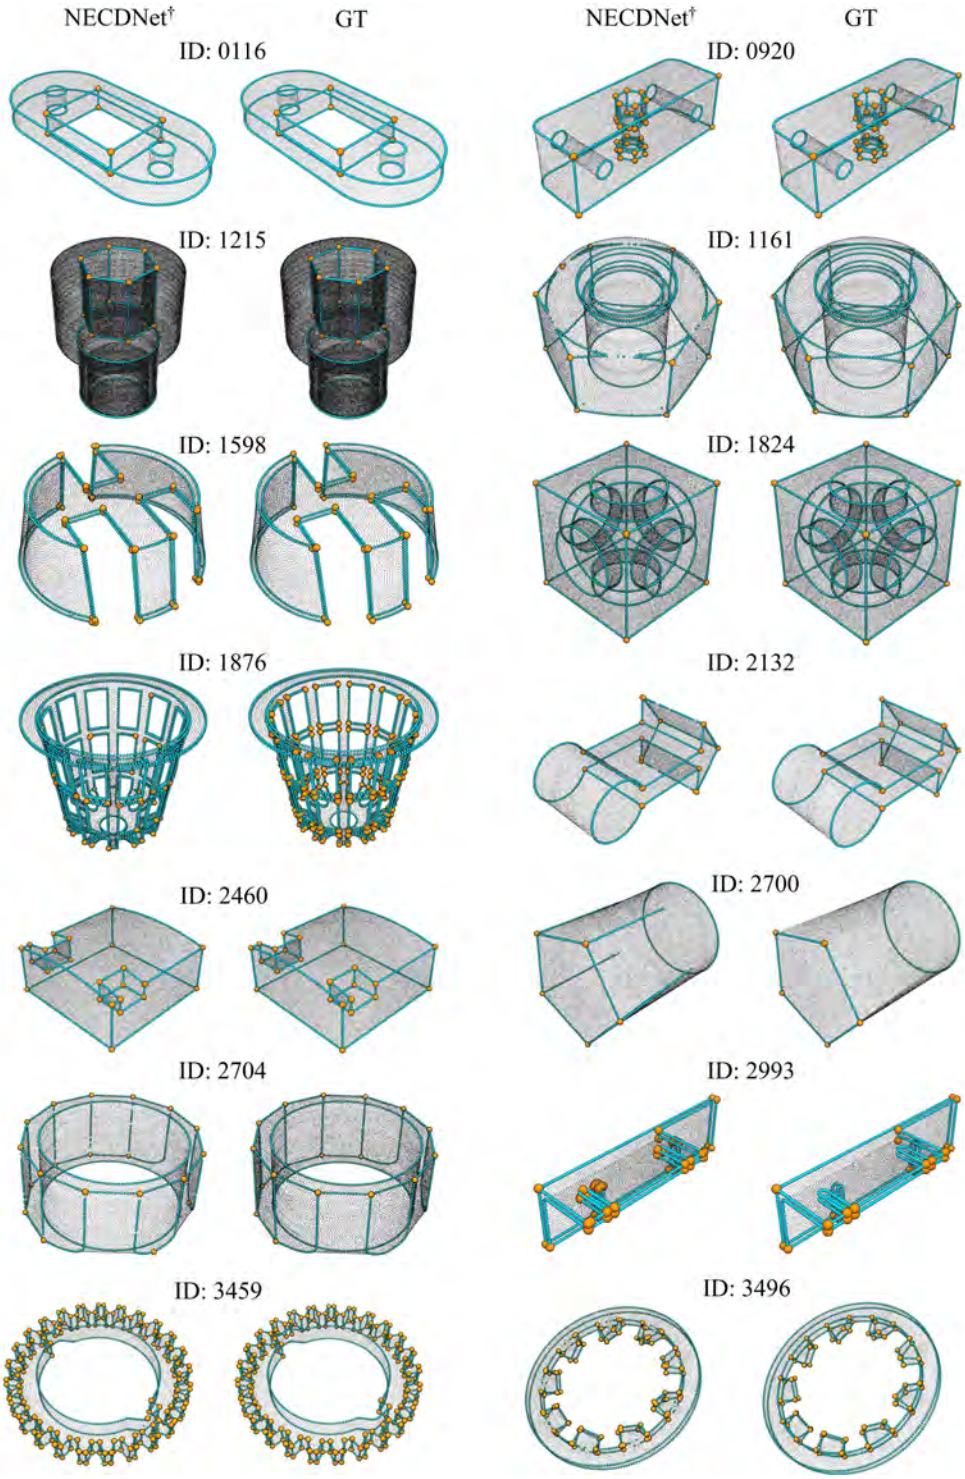
(Intersection over Union) 交并比定义为

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

(Accuracy) 准确率定义为

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

附录 C　NECDNet 额外检测结果



附录 D　额外测试物体上的抓取构型分布图

